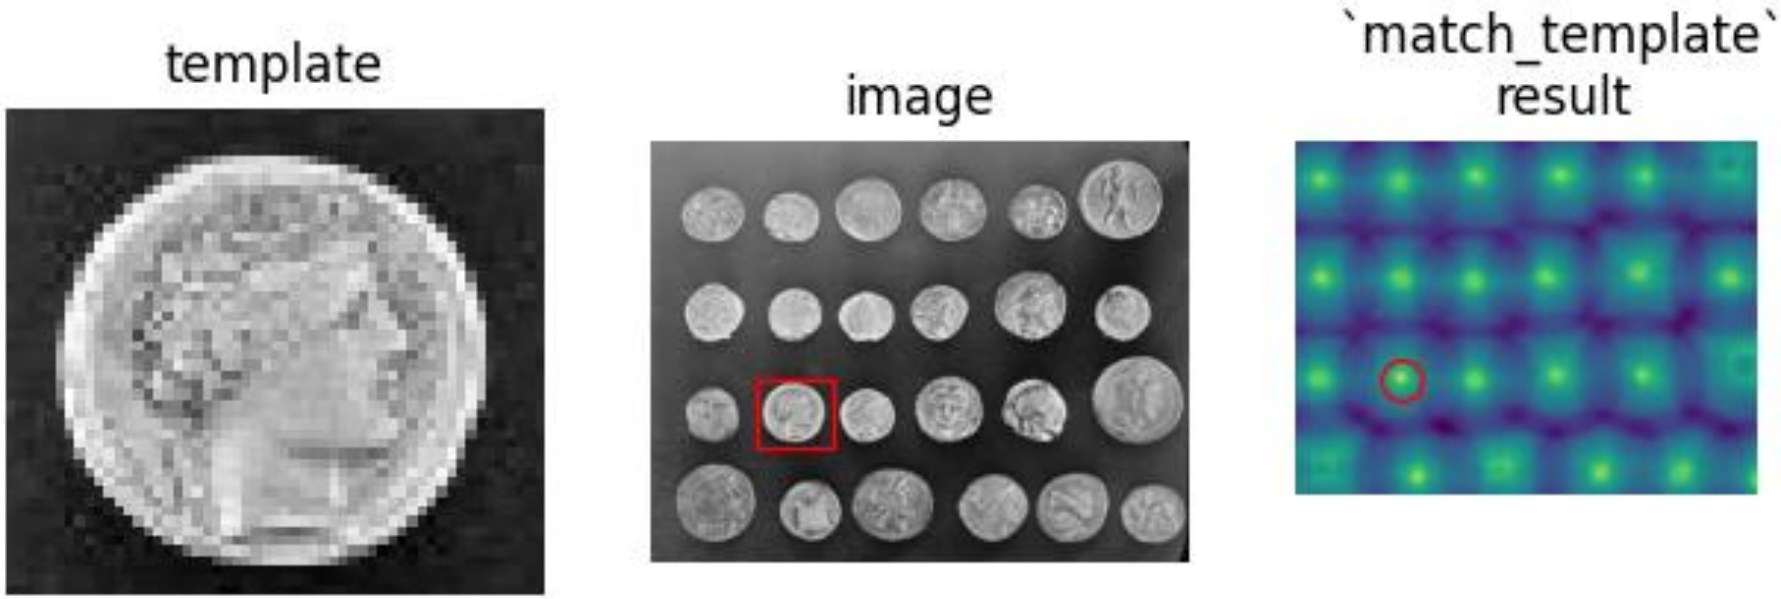
Počítačové vidění

Detekce lokálních zájmových oblastí

Hledání vzorů např. křížovou korelací




```
for y in range(0, výška_obr):
    for x in range(0, šířka_obr):
        okno = image[y-vel:y+vel, x-vel:x+vel]
        match_template_result[y, x] = korelace(okno, template)
```

zdroj: https://scikit-image.org/docs/stable/auto_examples/features_detection/plot_template.html

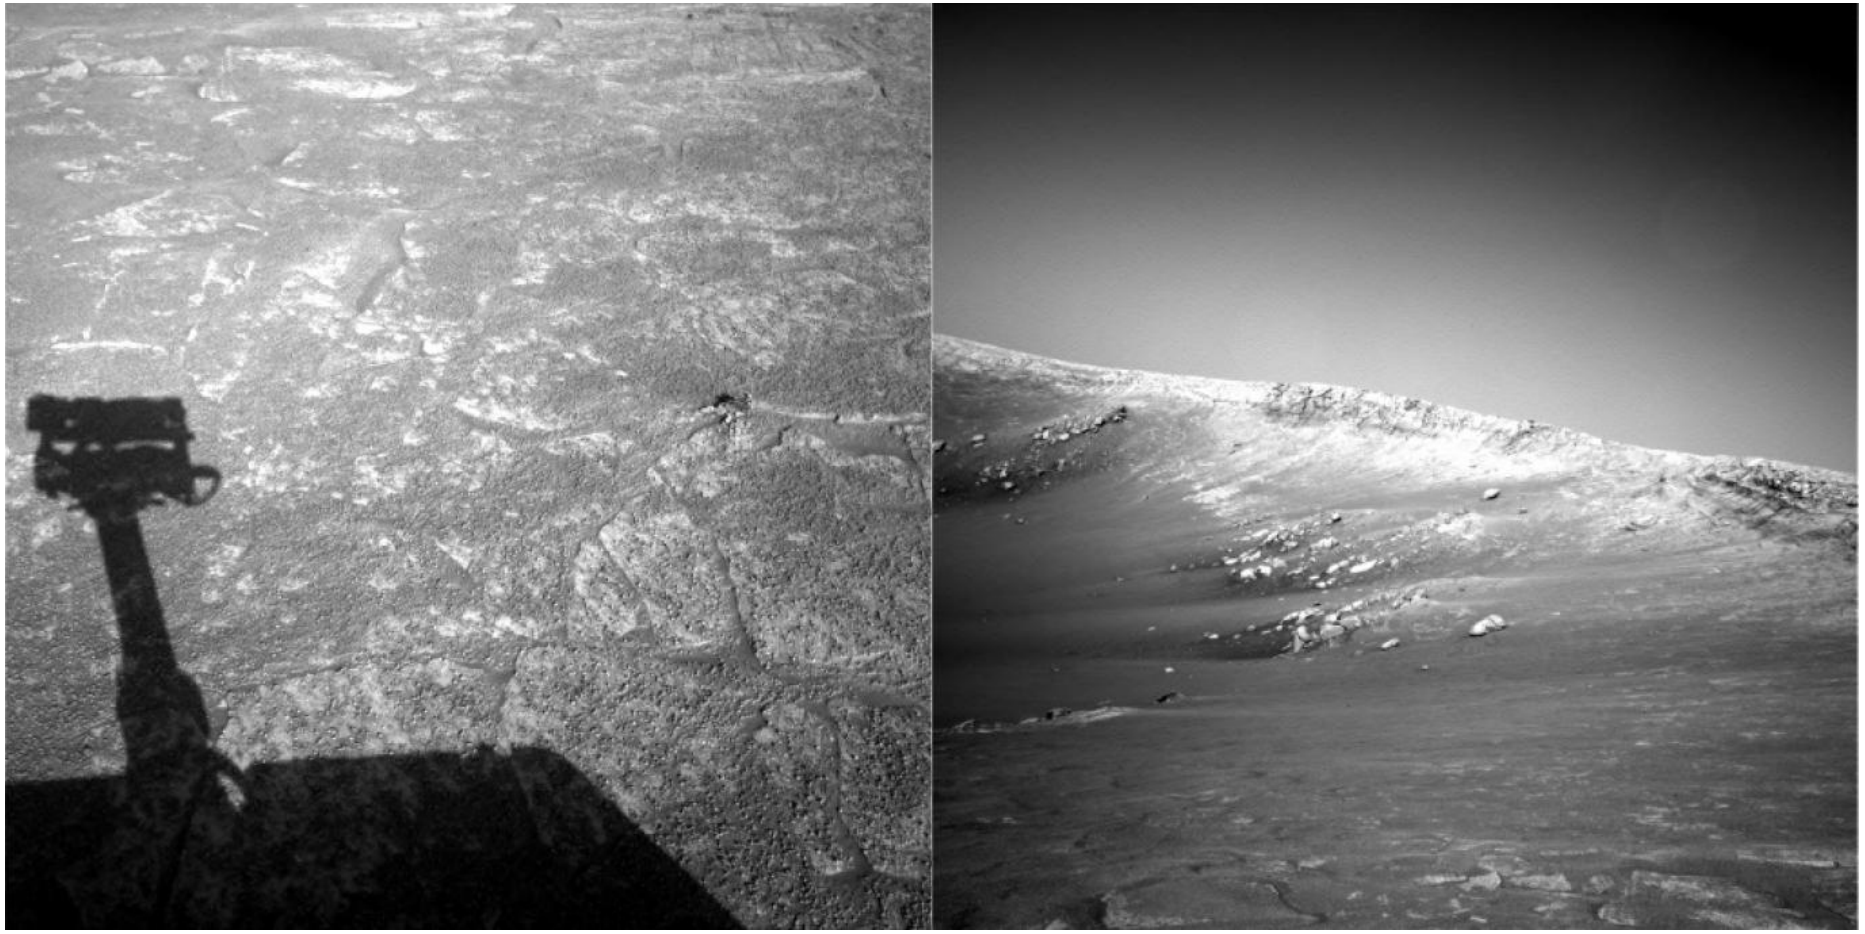
Složitější případ





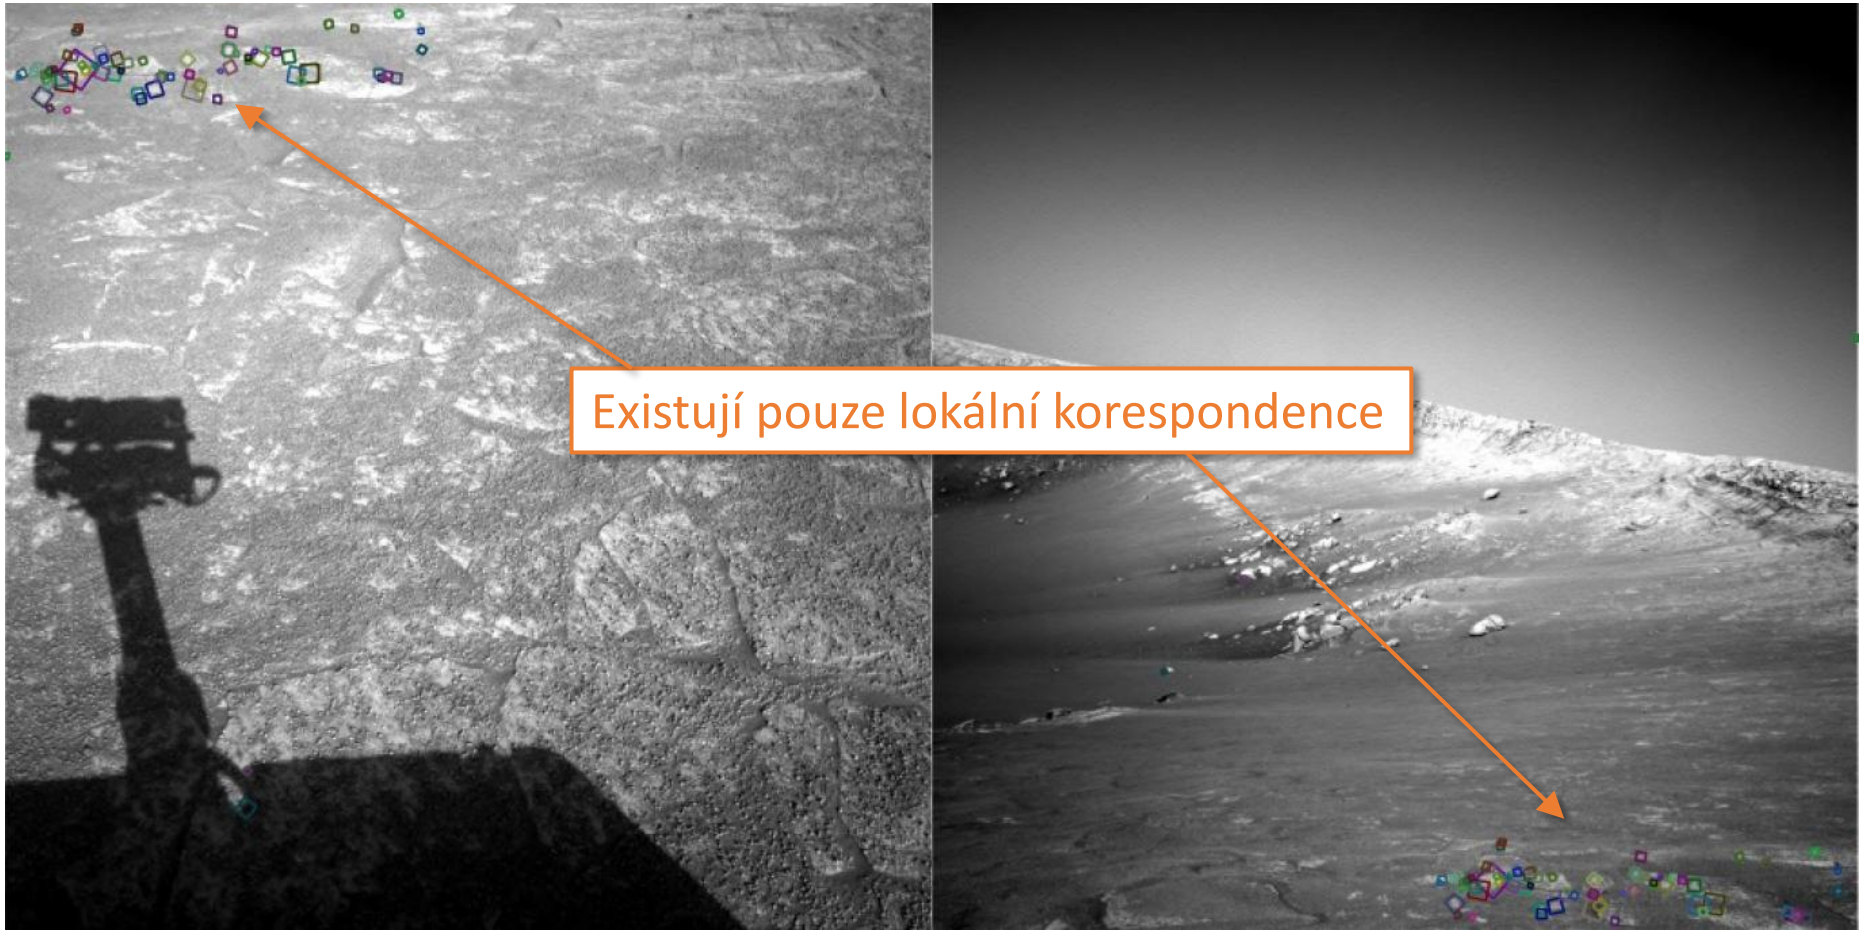
```
for vel in mozne_velikosti:
    for rot in mozne_rotace:
        vzor_upraveny = transformuj(template, vel, rot)
        for y in range(0, výška_obr):
            for x in range(0, šířka_obr):
                okno = image[y-vel:y+vel, x-vel:x+vel]
                match_template_result[vel, rot, y, x] = korelace(okno, vzor_upraveny)
```

Ještě složitější případ: slepování obrazů



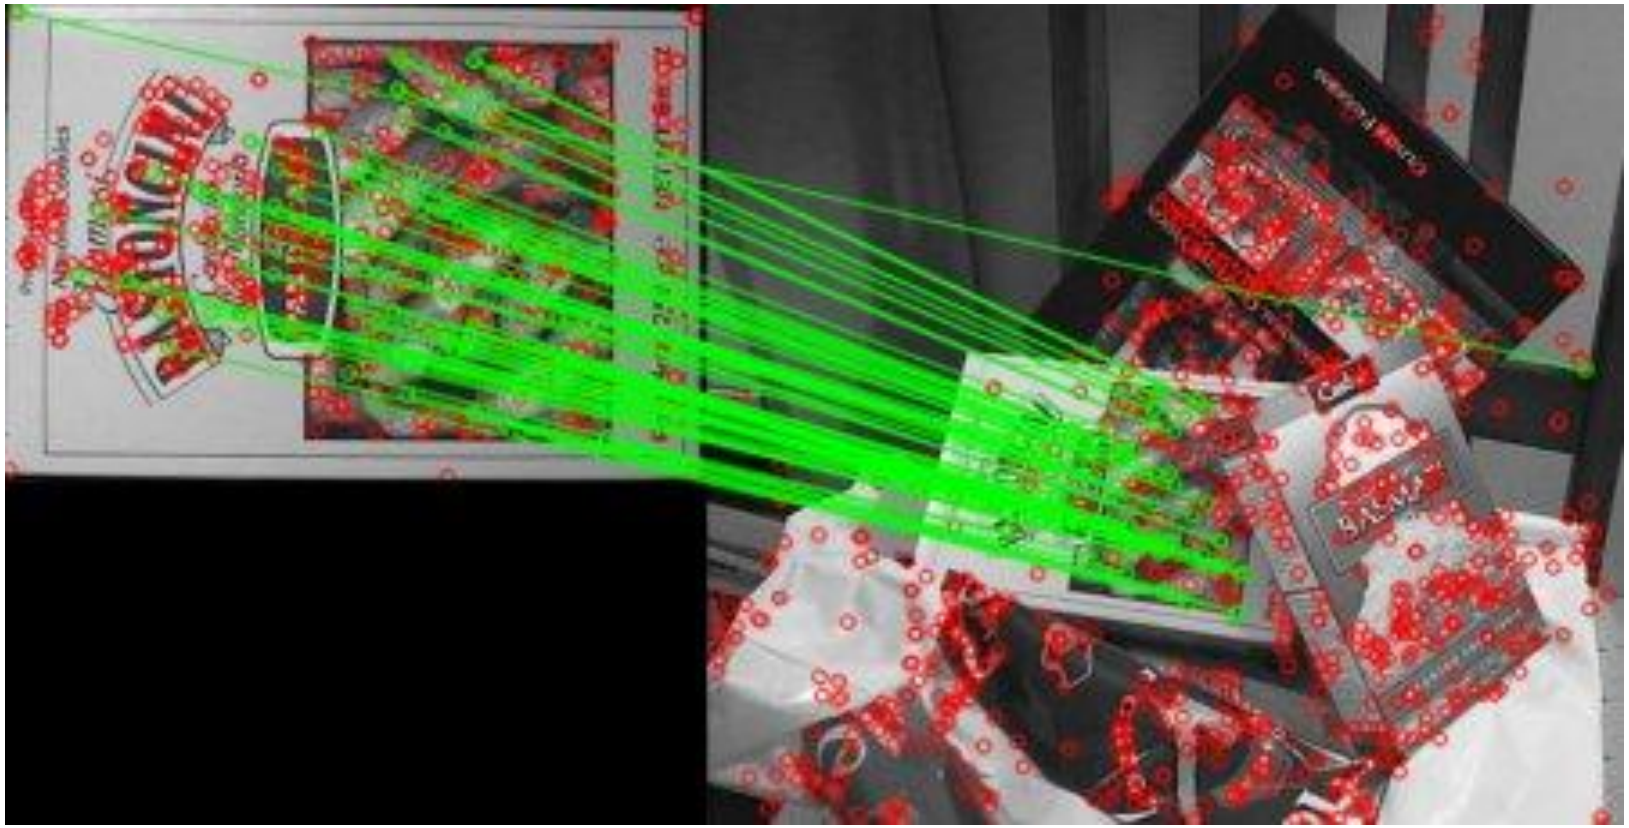
zdroj: https://www.cs.cornell.edu/courses/cs6670/2023fa/

Ještě složitější případ: slepování obrazů



zdroj: https://www.cs.cornell.edu/courses/cs6670/2023fa/

Vyhledávání a rozpoznávání objektů



zdroj: https://docs.opencv.org/3.4/dc/dc3/tutorial_py_matcher.html

Vyhledávání a rozpoznávání objektů



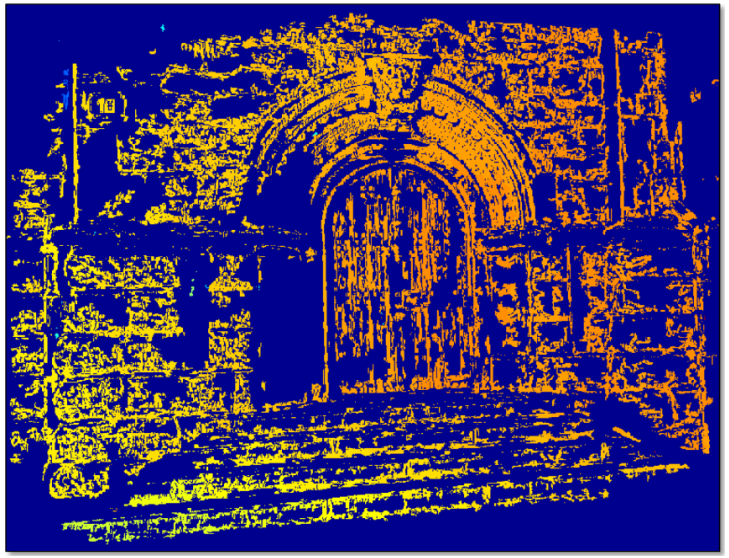


Rektifikace stereo párů a 3D rekonstrukce

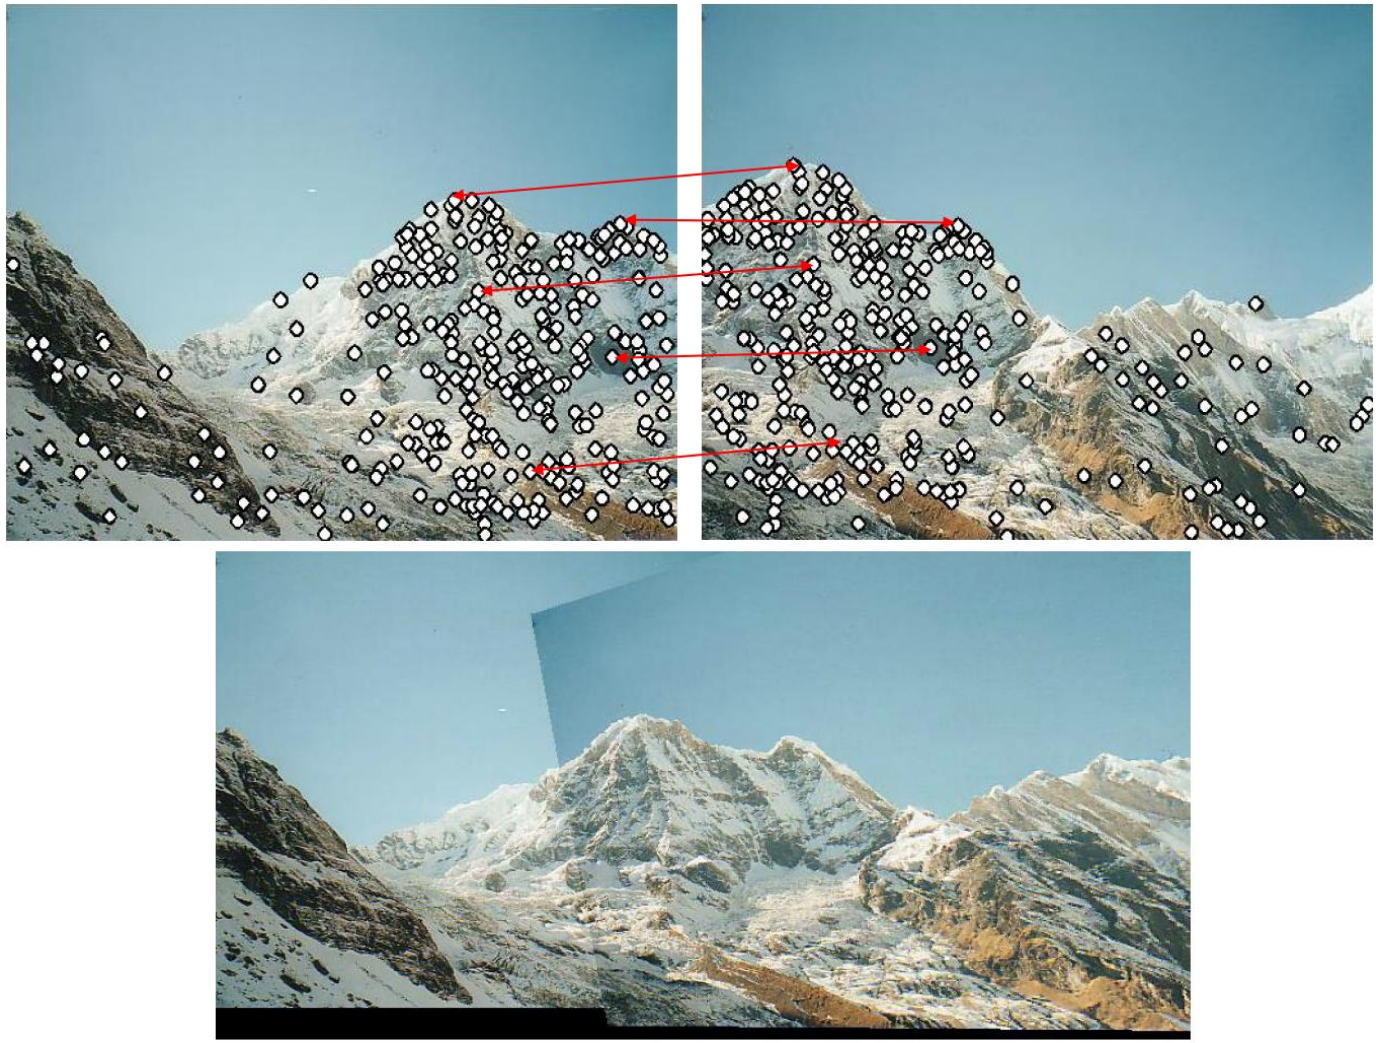








Slepování panoramat



zdroj: http://www.cs.ubc.ca/~mbrown/papers/iccv2003.pdf

Lokalizace zájmových oblastí

Která ze tří oblastí bude nejspolehlivěji lokalizována?









zdroj: https://szeliski.org/Book/

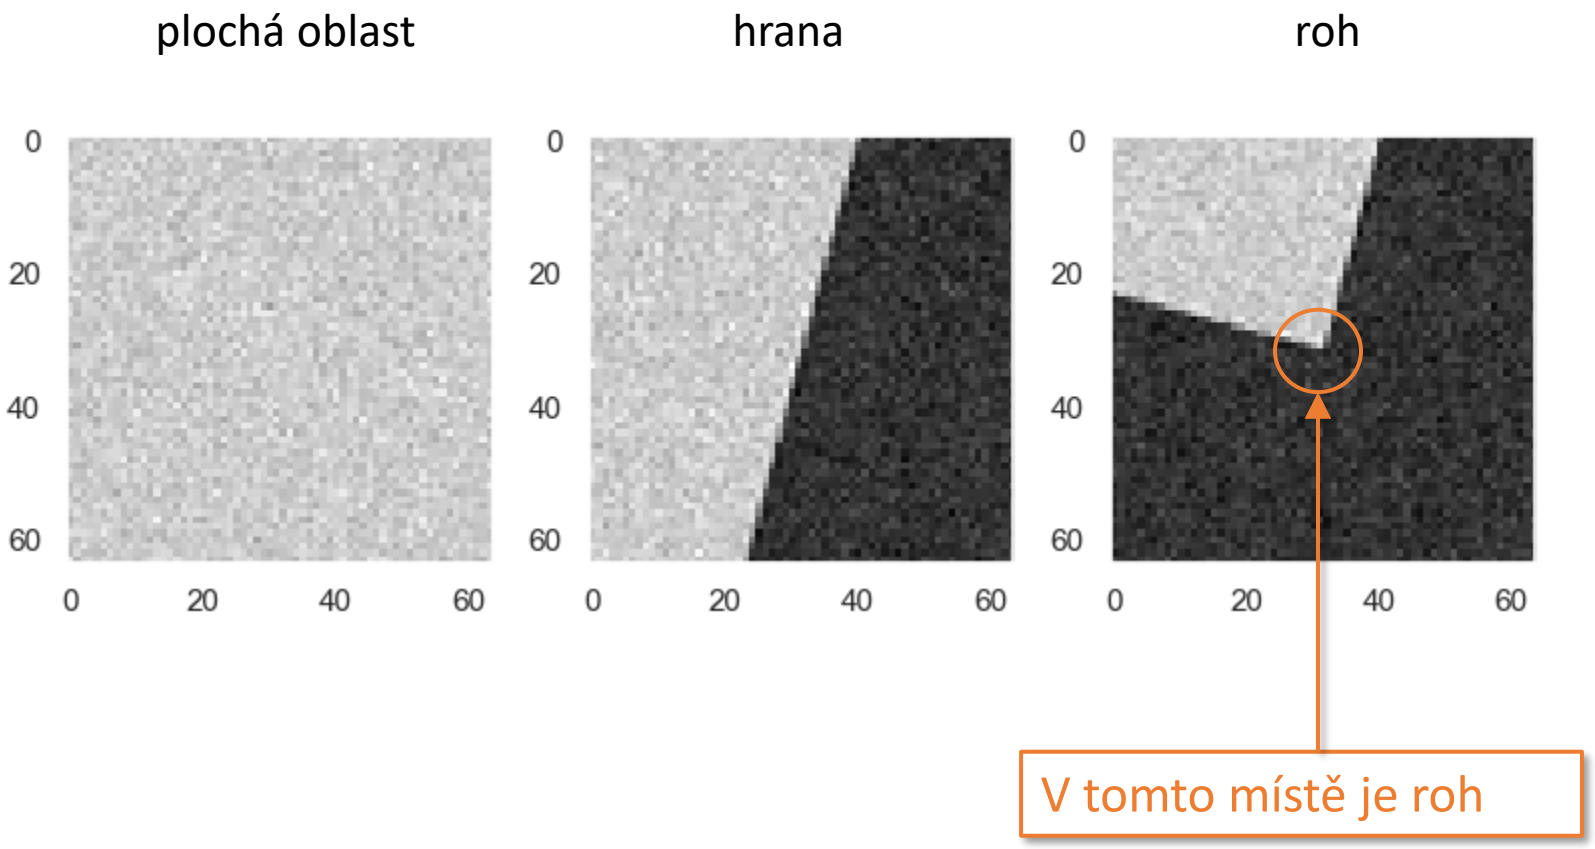
Požadavky na zájmové oblasti

- **Opakovatelnost:** na různých obrazech by měly nalezeny shodné zájmové oblasti, a to i za přítomnosti geometrických zkreslení
- **Rozlišitelnost:** oblasti by od sebe měly být jednoduše rozlišitelné
- **Kompaktnost:** jednolitvé oblasti by neměly porkývat velkou část obrazu

Vyhledávání rohů

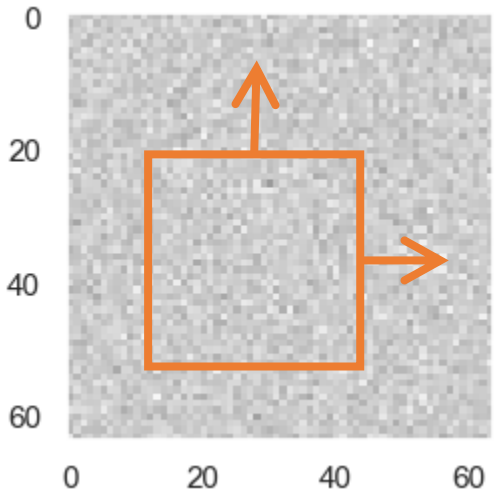
Roh

- Roh = místo, kde se potkávají dvě hrany



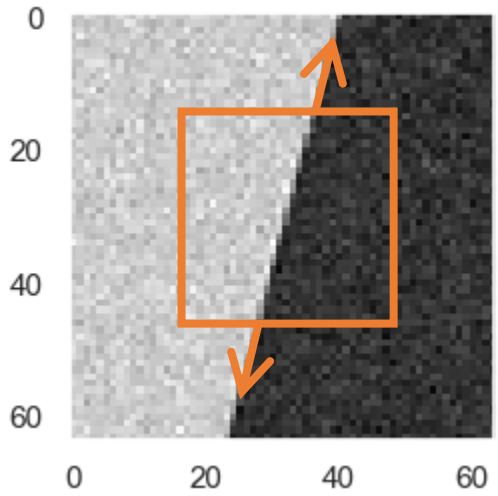
Jak poznáme roh?

plochá oblast



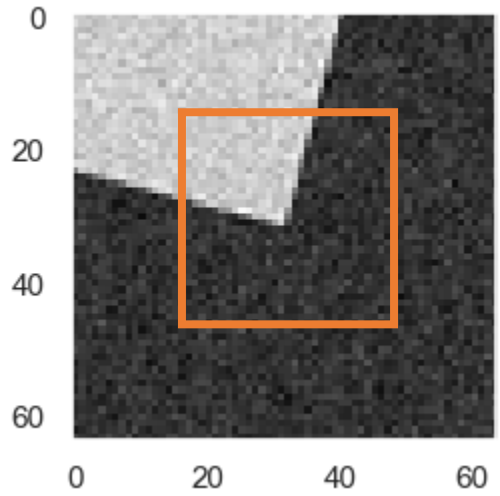
plochá oblast:
textura okna se s jeho pohybem nemění

hrana



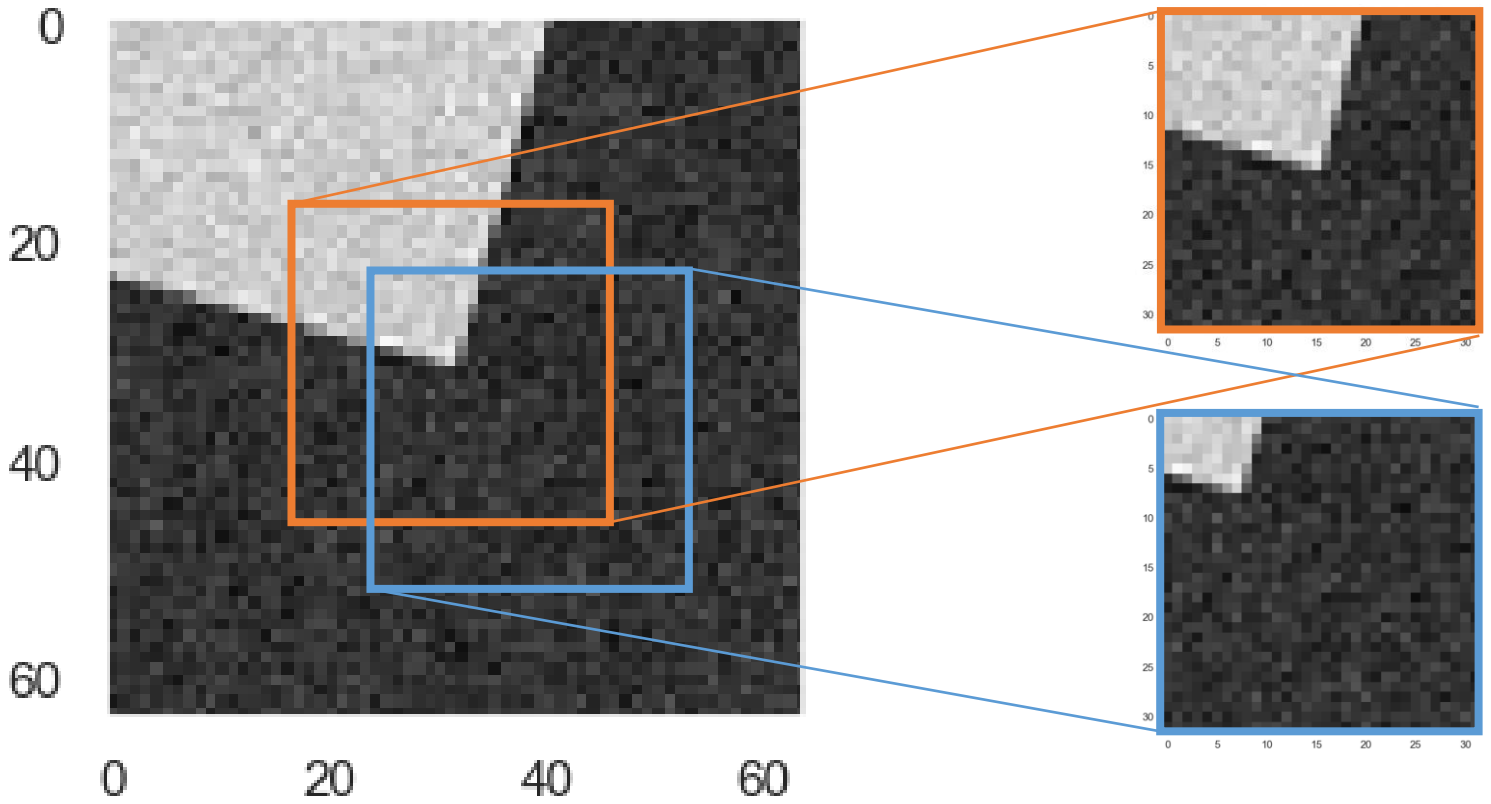
hrana:
textura okna se s pohybem podél hrany nemění

roh



roh:
textura okna se změní při jakémkoliv pohybu

Podobnost oken



$I(x, y)$

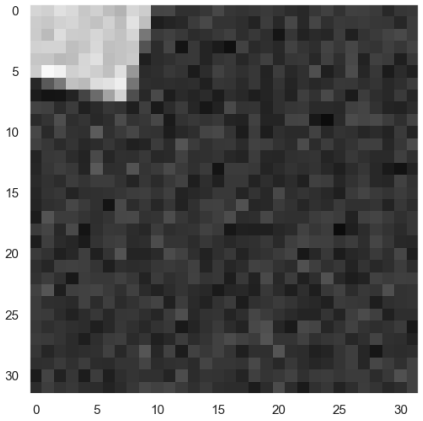
$I(x + \Delta x, y + \Delta y)$

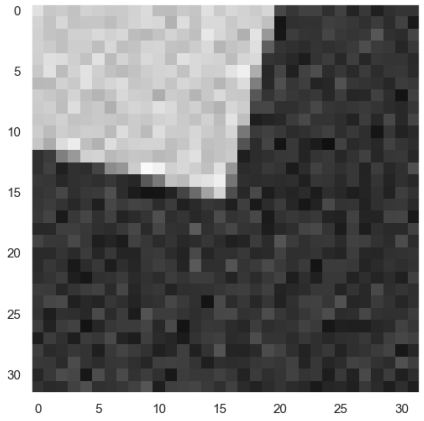
Podobnost oken: suma čtverců

Vyhodnotíme pro různé offsety $(\Delta x, \Delta y)$

$$E(\Delta x, \Delta y) = \sum_{x,y} \big(I(x + \Delta x, y + \Delta y) - I(x, y)\big)^2$$

$$\sum_{x,y} \Big(\quad - \quad \Big)^2$$





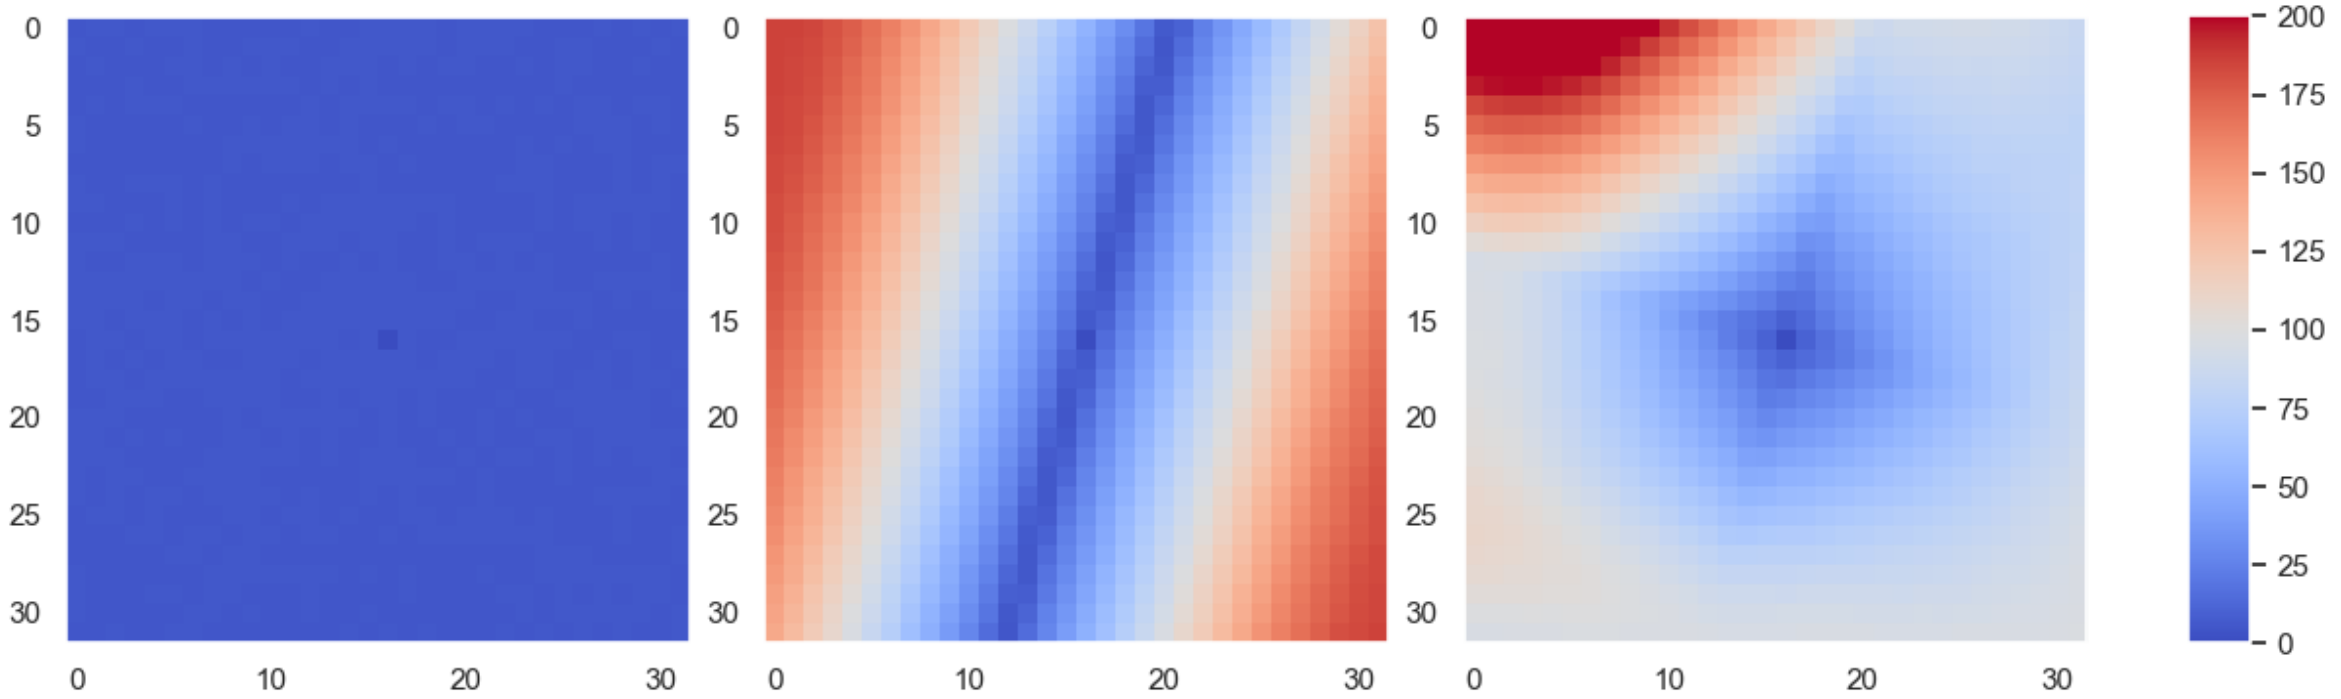
Změna textury v závislosti na pohybu okna

obrázky jsou mapy rozdílů $E(u, v)$

plochá oblast

hrana

roh



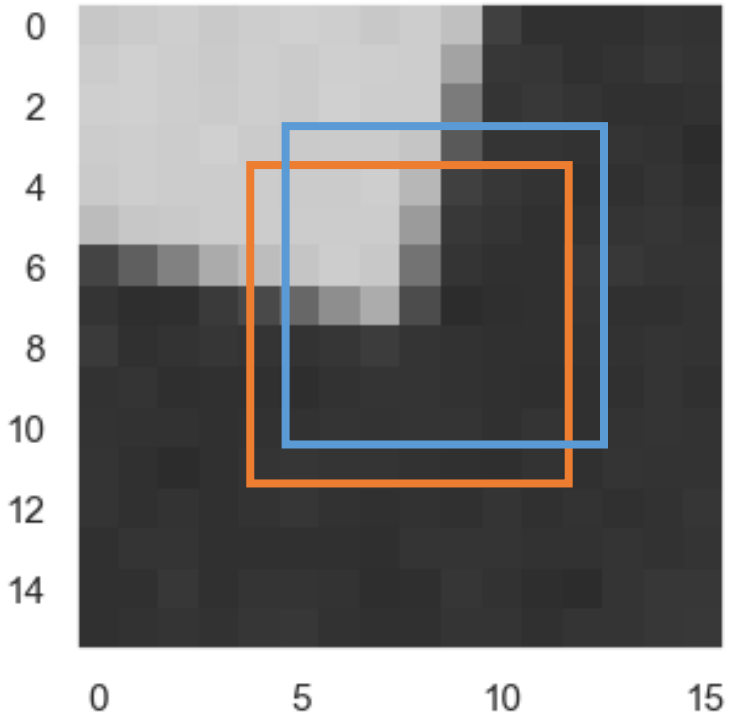
plochá oblast:
textura okna se s jeho pohybem nemění

hrana:
textura se mění pouze při pohybu "proti" hraně

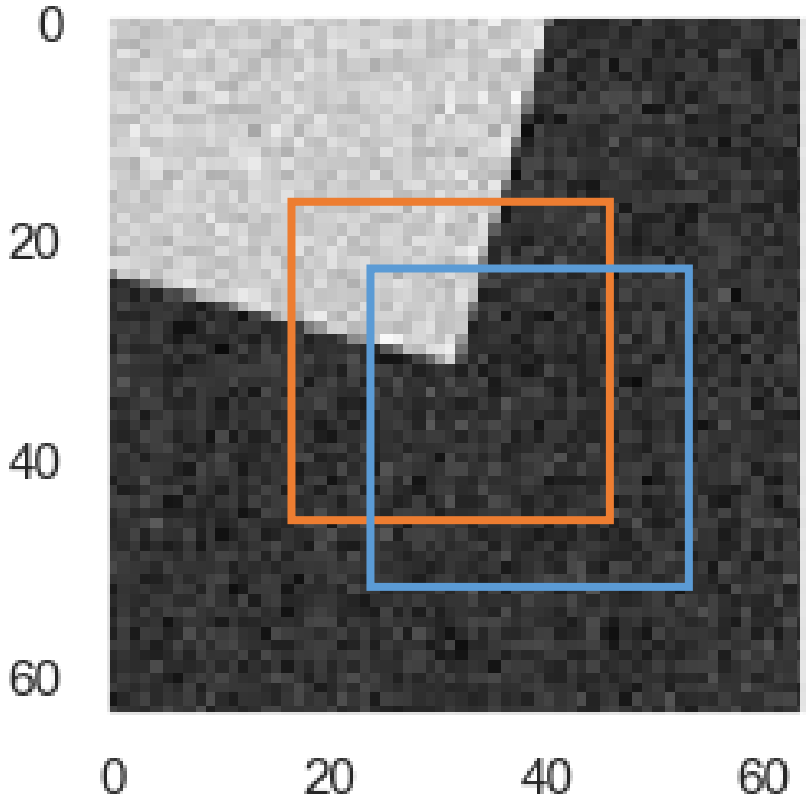
roh:
textura okna se změní při jakémkoliv pohybu

Moravcův detektor rohů (1980)

- Pouze 4 offsety $(\Delta x, \Delta y)$:
  1. $e_1 = \sum_{x,y} \big(I(x+1,y) - I(x,y)\big)^2$
  2. $e_2 = \sum_{x,y} \big(I(x+1,y+1) - I(x,y)\big)^2$
  3. $e_3 = \sum_{x,y} \big(I(x,y+1) - I(x,y)\big)^2$
  4. $e_4 = \sum_{x,y} \big(I(x-1,y+1) - I(x,y)\big)^2$
- Roh je nalezen, pokud
$$\min(e_1, e_2, e_3, e_4) \geq T$$
- Nedostatky:
  - Citlivost na šum
  - Pouze 4 směry
  - Není izotropický → při “nesprávném” natočení hrany detekuje jako roh



Aproximace okolí Taylorovým polynomem



$$E(\Delta x, \Delta y) = \sum_{x,y} \left(I(x + \Delta x, y + \Delta y) - I(x, y) \right)^2$$

vyhodnocení pro více $(\Delta x, \Delta y)$ by bylo příliš pomalé

→ aproximujeme okolí Taylorovým polynomem

$$I(x + \Delta x, y + \Delta y) \approx I(x, y) + I_x \cdot \Delta x + I_y \cdot \Delta y$$

$$I_x = \frac{\partial I(x, y)}{\partial x} \qquad I_y = \frac{\partial I(x, y)}{\partial y}$$

lokální derivace vyhodnocené v okolí bodu (x, y)

Aproximace okolí Taylorovým polynomem

$$E(\Delta x, \Delta y) = \sum_{x,y} \big(I(x+\Delta x, y+\Delta y) - I(x,y)\big)^2$$

$$\approx \sum_{x,y} \Big(I(x,y) - I_x \cdot \Delta x + I_y \cdot \Delta y - I(x,y)\Big)^2$$

$$= \sum_{x,y} \big(I_x \cdot \Delta x + I_y \cdot \Delta y\big)^2$$

$$= \sum_{x,y} I_x^2 \cdot \Delta x^2 + 2 \cdot I_x \cdot I_y \cdot \Delta x \cdot \Delta y + I_y^2 \cdot \Delta y^2$$

Maticový zápis

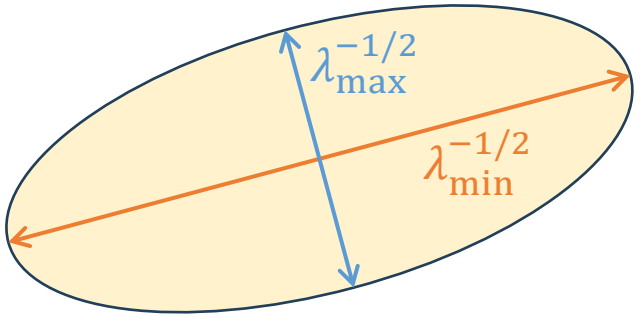
$$E(\Delta x, \Delta y) \approx [\Delta x \quad \Delta y] \cdot \boldsymbol{M} \cdot \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix}$$

$$\boldsymbol{M} = \begin{bmatrix} \sum_{x,y} I_x^2 & \sum_{x,y} I_x \cdot I_y \\ \sum_{x,y} I_x \cdot I_y & \sum_{x,y} I_y^2 \end{bmatrix}$$

Matice druhých momentů
Vyhodnocena v každém bodě obrazu

“Autokorelační” matice $\boldsymbol{M}$

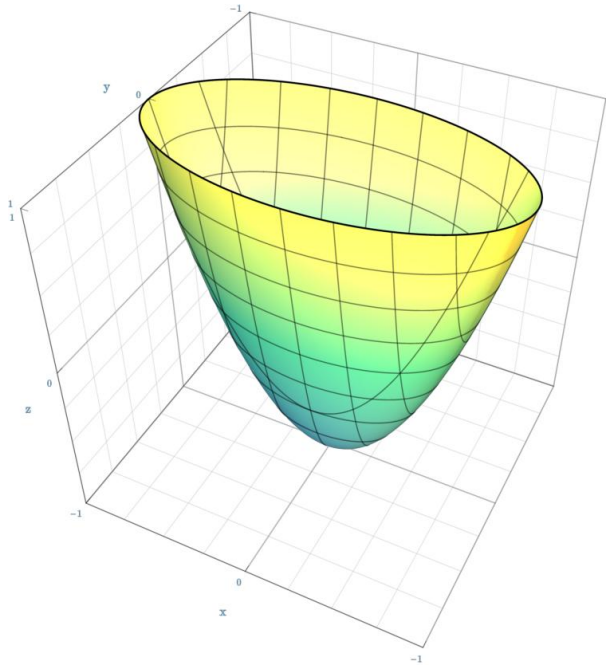
Vrstevnice paraboloidu jsou elipsy, jejichž hlavní osy odpovídají vlastním číslům matice $\boldsymbol{M}$



$\lambda_{\max}^{-1/2}$ … větší ze dvou vlastních čísel $\boldsymbol{M}$

$\lambda_{\min}^{-1/2}$ … menší ze dvou vlastních čísel $\boldsymbol{M}$

Aproximace změny podoby v závislosti na offsetu pomocí paraboloidu



Tzv. kvadratická forma

$$E(\Delta x, \Delta y) \approx [\Delta x \quad \Delta y] \cdot \boldsymbol{M} \cdot \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix}$$

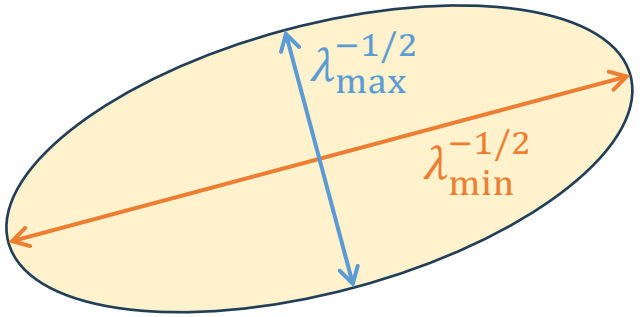
$$\boldsymbol{M} = \begin{bmatrix} \sum_{x,y} I_x^2 & \sum_{x,y} I_x \cdot I_y \\ \sum_{x,y} I_x \cdot I_y & \sum_{x,y} I_y^2 \end{bmatrix}$$

Matice druhých momentů
Vyhodnocena v každém bodě obrazu

Vektory hlavní a vedlejší osy elipsy udávají směr nejmenší, resp. největší změny okolí aktuálního bodu v obraze

Vlastní čísla a vektory matice $\boldsymbol{M}$

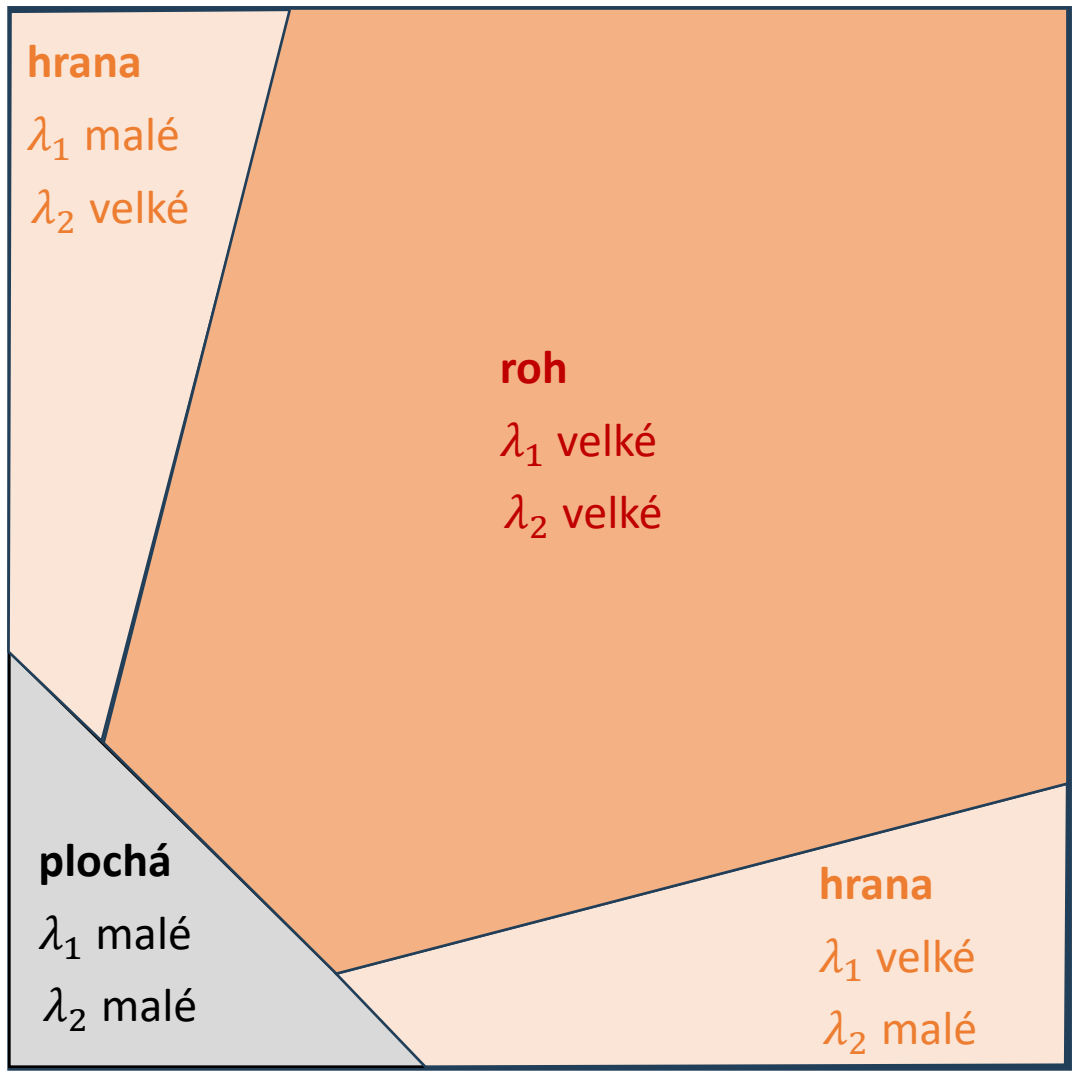
Vrstevnice paraboloidu jsou elipsy, jejichž hlavní osy odpovídají vlastním číslům matice $\boldsymbol{M}$



$\lambda_{\max}^{-1/2}$ … větší ze dvou vlastních čísel $\boldsymbol{M}$

$\lambda_{\min}^{-1/2}$ … menší ze dvou vlastních čísel $\boldsymbol{M}$

Vektory hlavní a vedlejší osy elipsy udávají směr nejmenší, resp. největší změny okolí aktuálního bodu v obraze

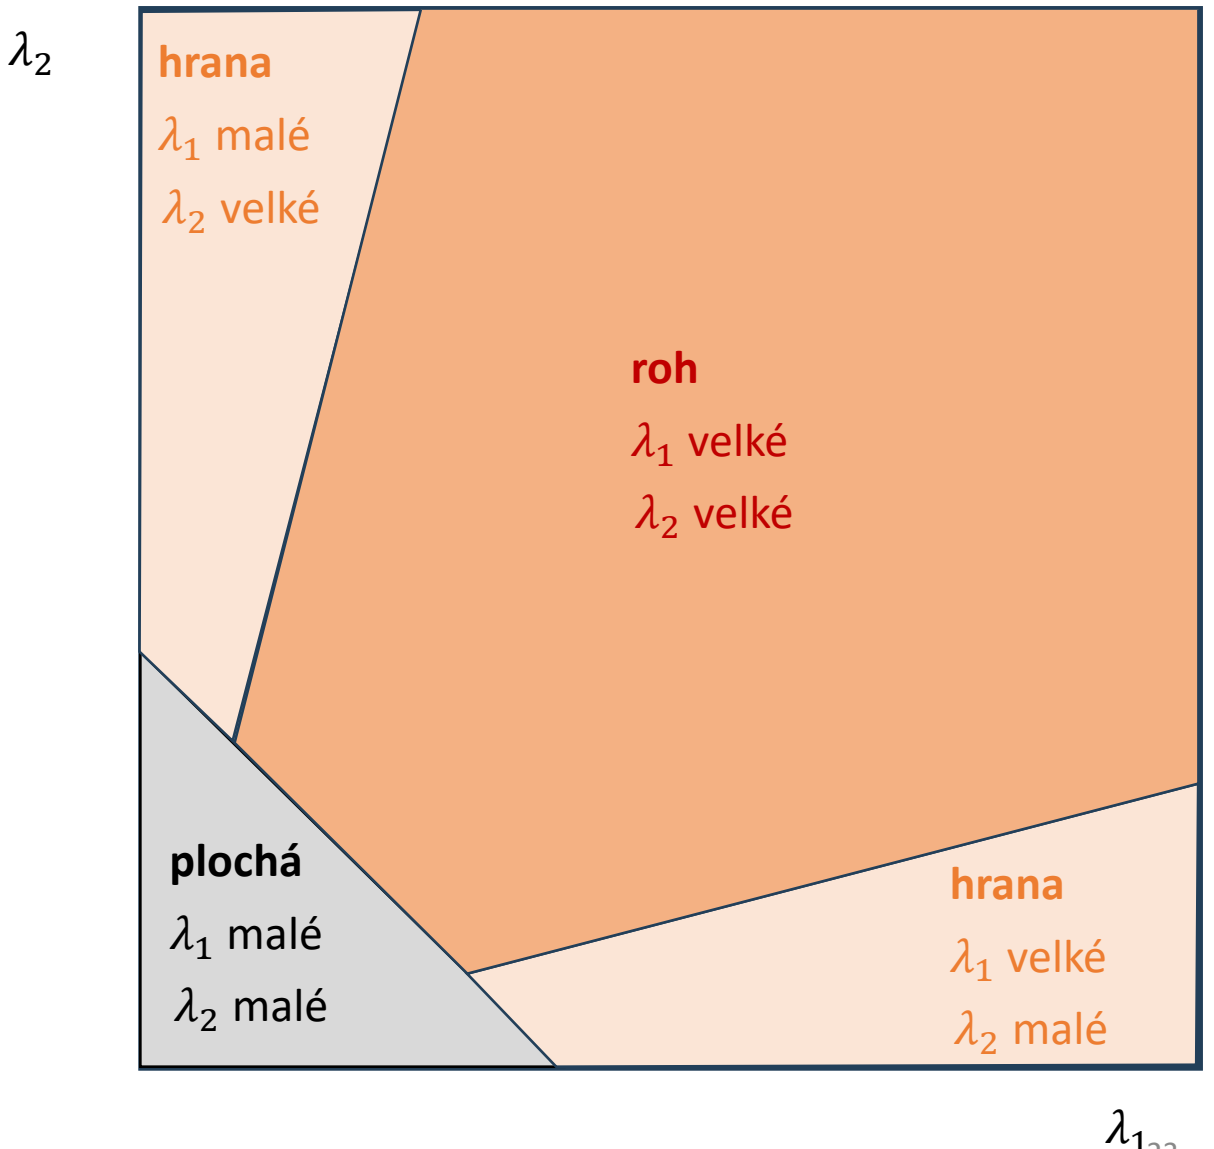


Harrisovo kritérium “rohovosti”

- Jedno číslo R vyjadřující, nakolik každý pixel vypadá jako roh
- Velká hodnota R = nejspíše roh
- Malá hodnota R = něco jiného
- Harrisovo kritérium:

$$R = \lambda_1 \cdot \lambda_2 - \alpha \cdot (\lambda_1 + \lambda_2)^2 = \det(\boldsymbol{M}) - \alpha \cdot \mathrm{trace}(\boldsymbol{M})$$

- α je parametr, nejčastěji $\alpha = 0.04$

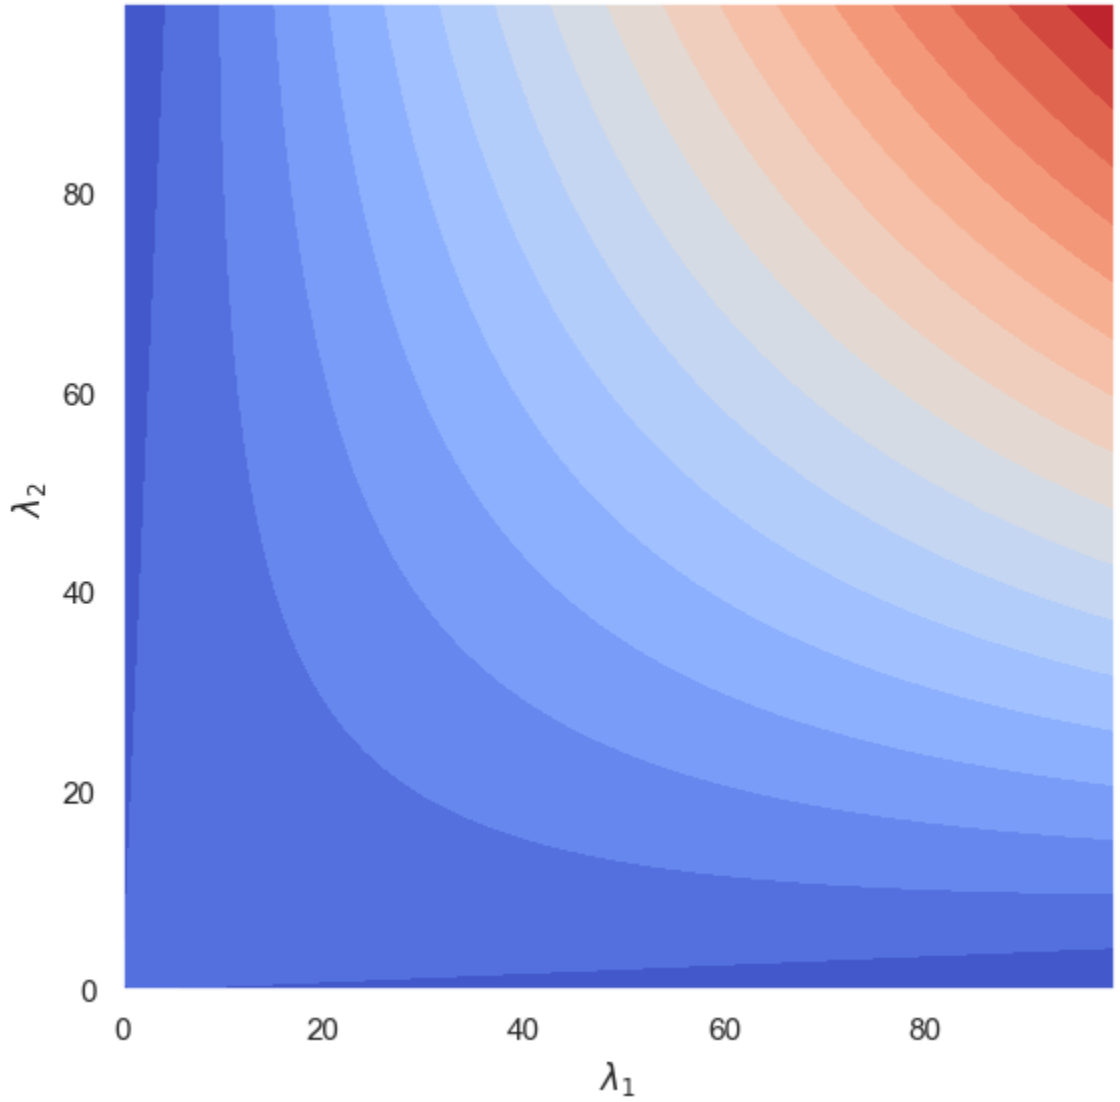


Harrisovo kritérium “rohovosti”

- Jedno číslo R vyjadřující, nakolik každý pixel vypadá jako roh
- Velká hodnota R = nejspíše roh
- Malá hodnota R = něco jiného
- Harrisovo kritérium:

$$R = \lambda_1 \cdot \lambda_2 - \alpha \cdot (\lambda_1 + \lambda_2)^2$$
$$= \det(\boldsymbol{M}) - \alpha \cdot \mathrm{trace}(\boldsymbol{M})$$

- α je parametr, nejčastěji $\alpha = 0.04$

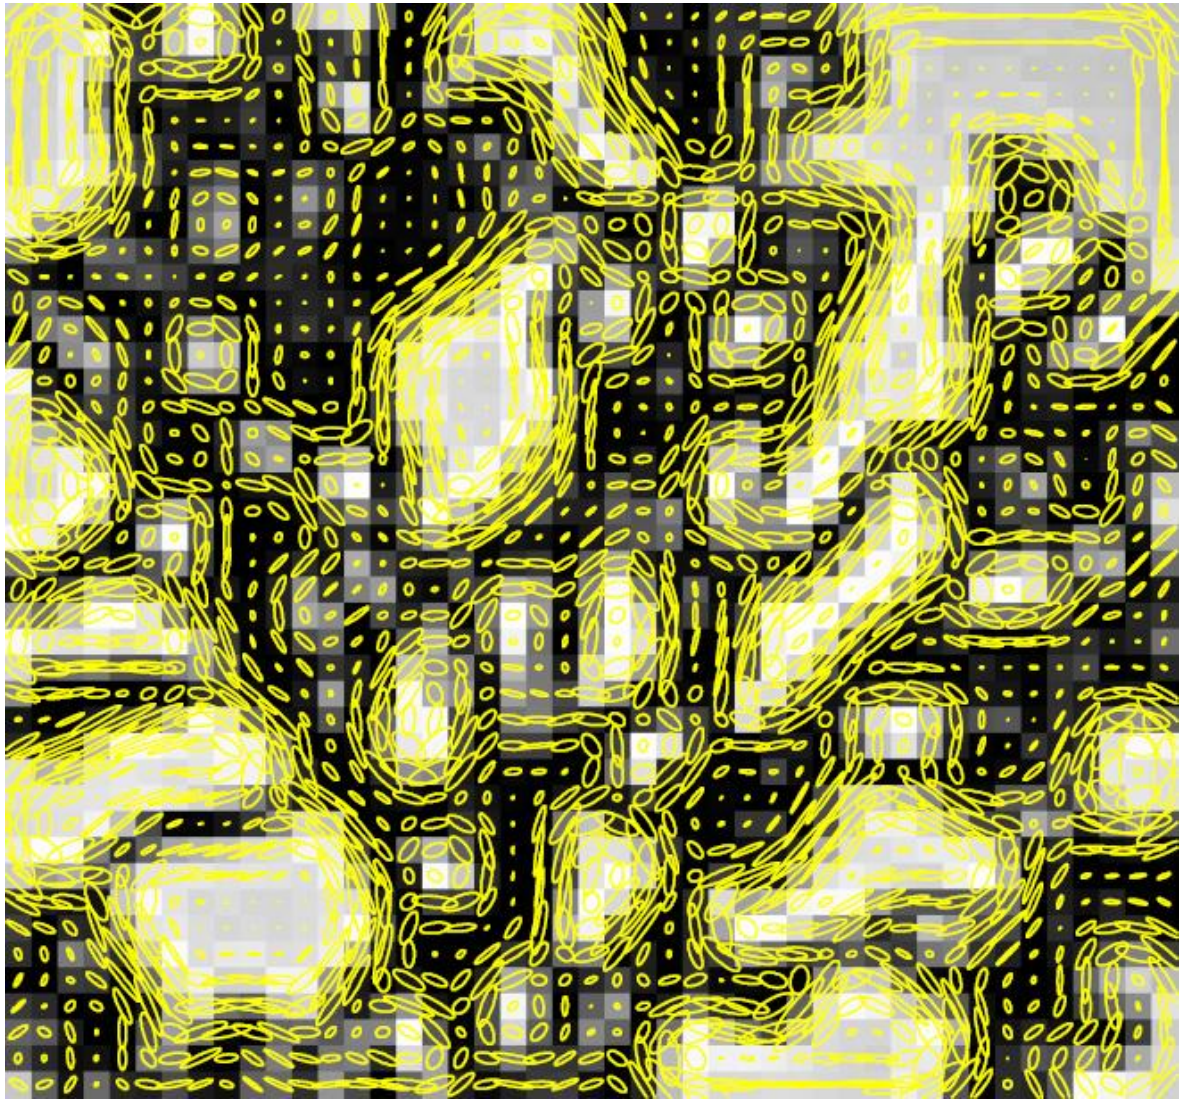


Vizualizace matice $\boldsymbol{M}$



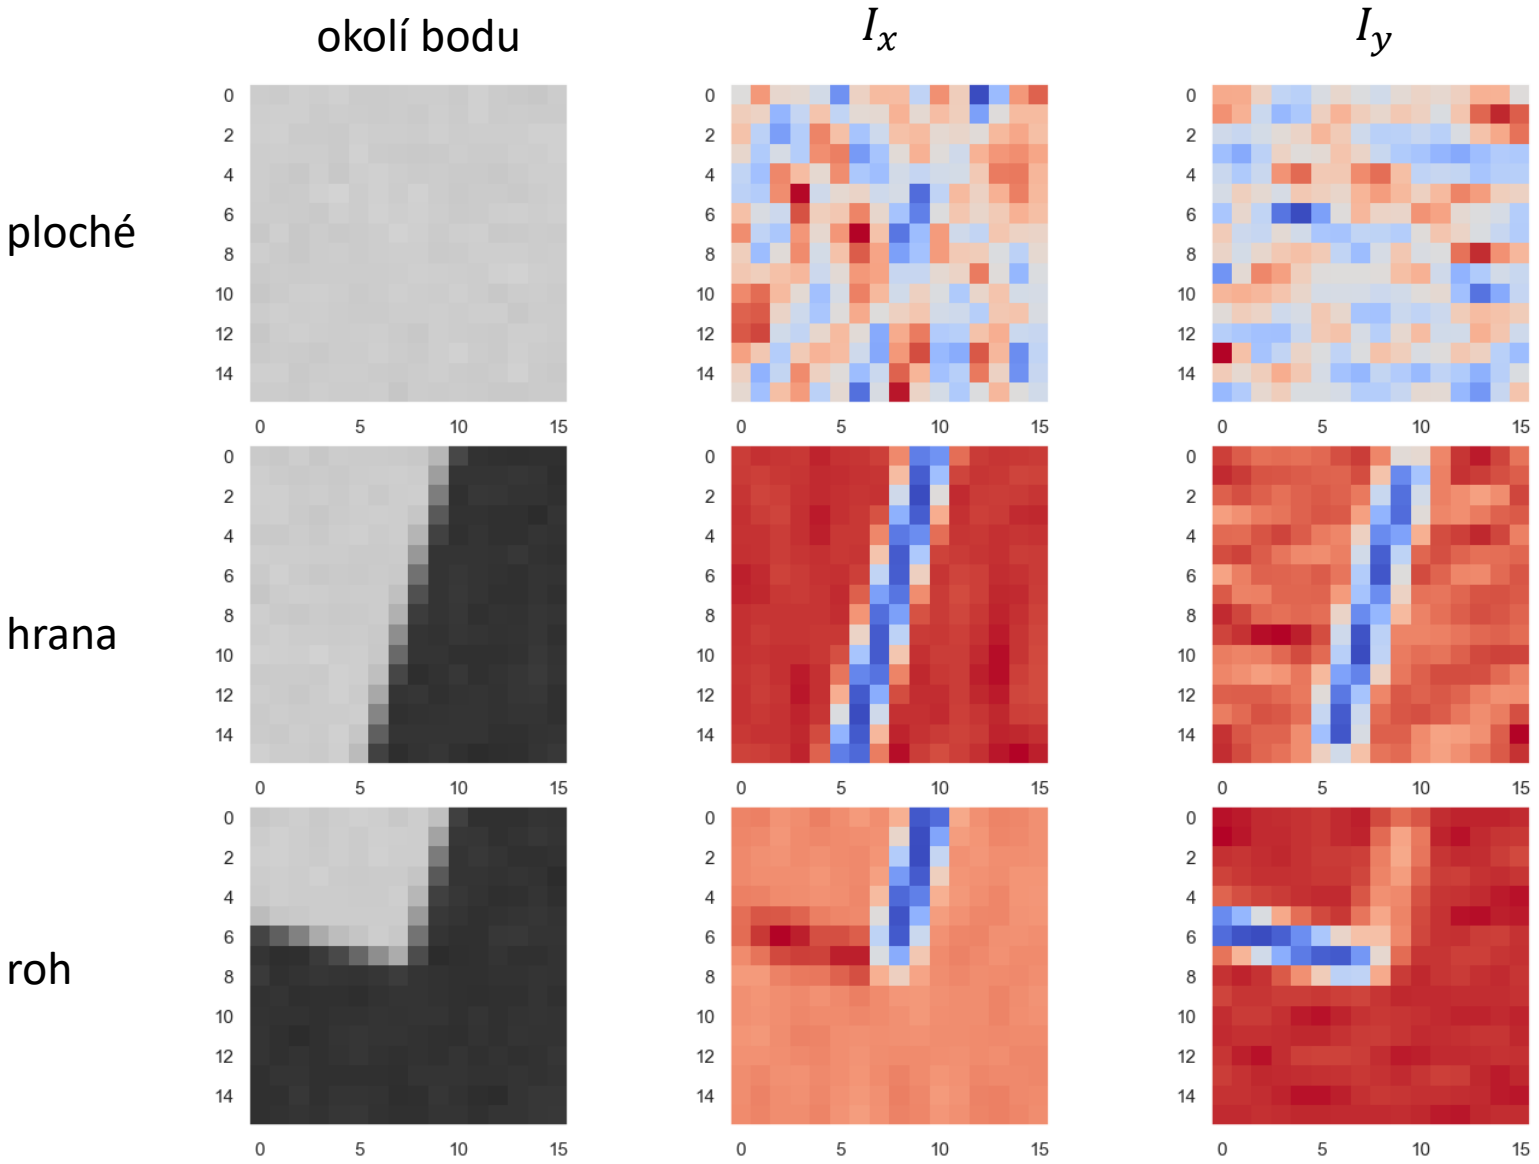
zdroj: https://slazebni.cs.illinois.edu/fall22/

Vizualizace matice $\boldsymbol{M}$



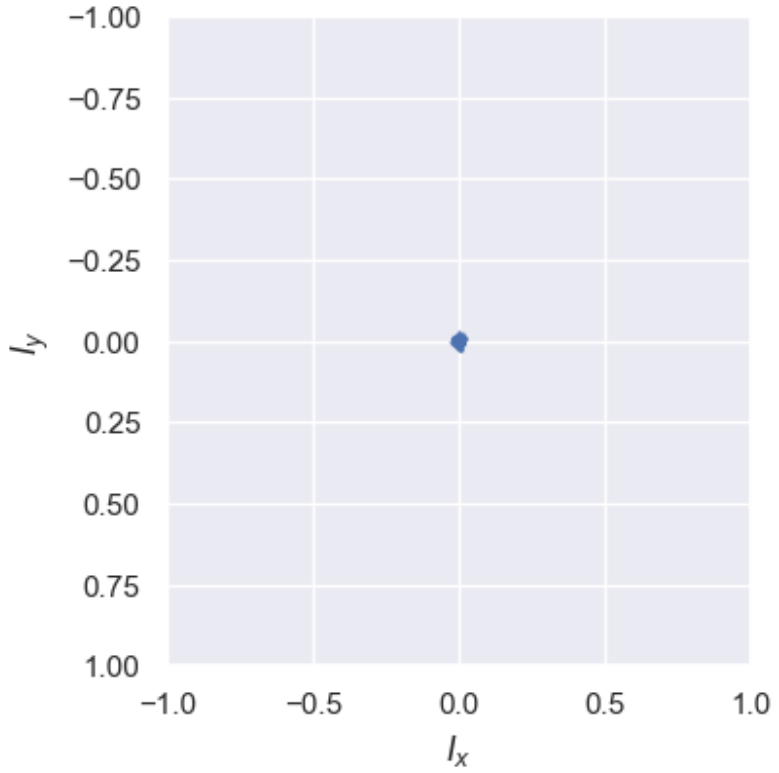
zdroj: https://slazebni.cs.illinois.edu/fall22/

Interpretace matice $\boldsymbol{M}$ z pohledu rozložení lokáních gradientů



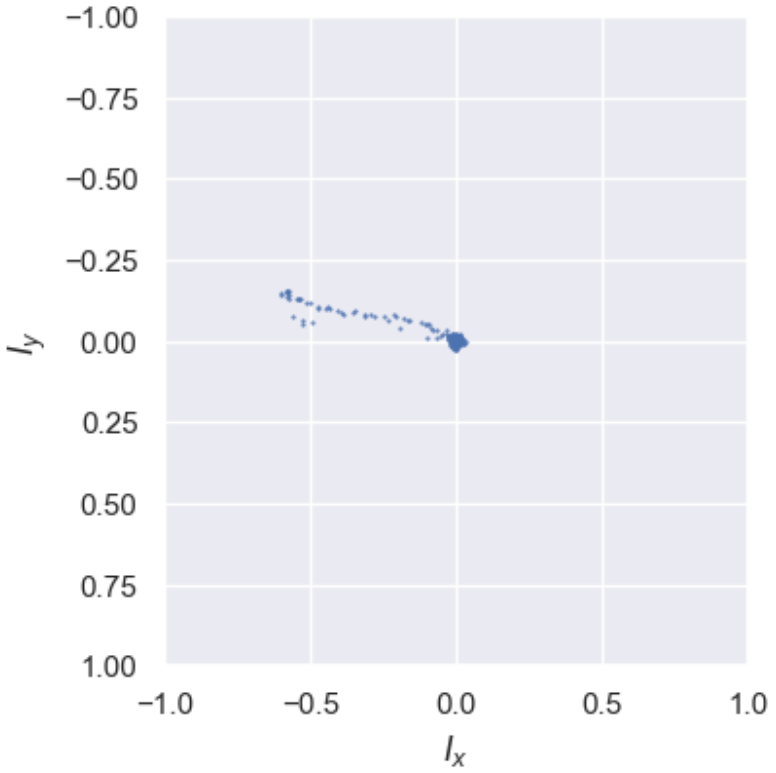
Interpretace matice $\boldsymbol{M}$ z pohledu rozložení lokáních gradientů

plochá oblast



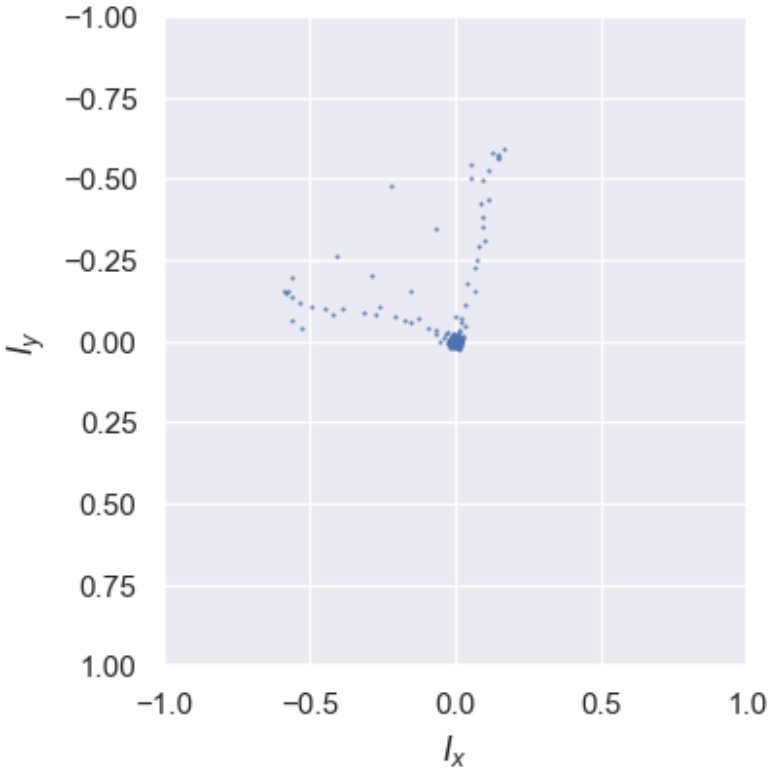
gradienty jsou slabé

hrana



gradienty jsou v jednom směru

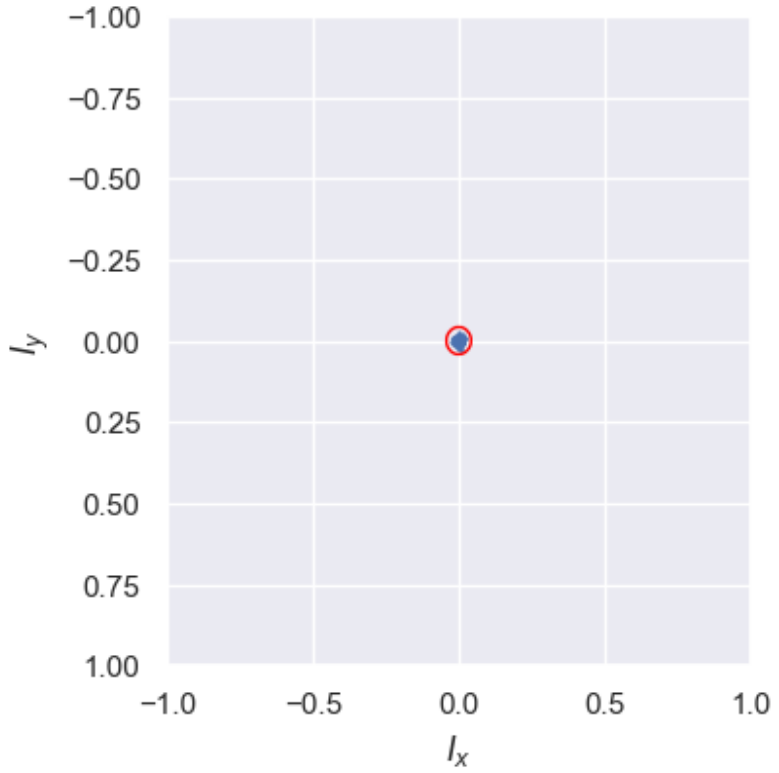
roh



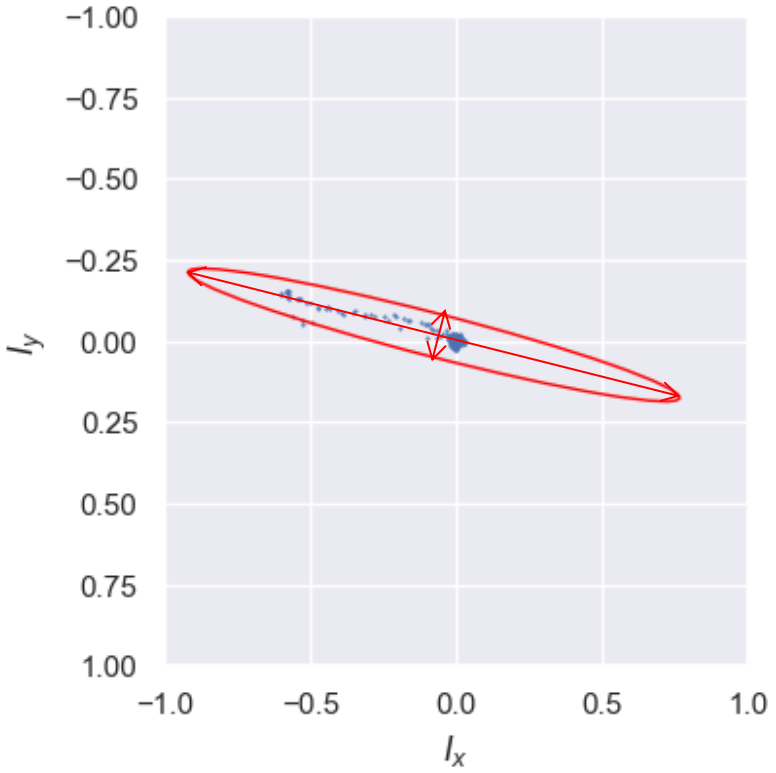
gradienty ve více směrech

Interpretace matice $\boldsymbol{M}$ z pohledu rozložení lokáních gradientů

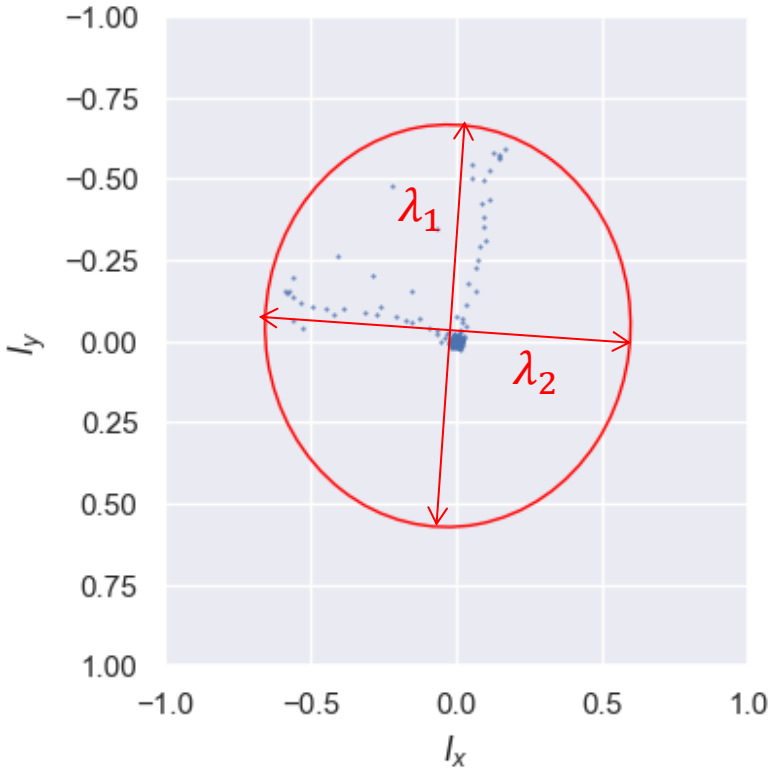
plochá oblast



hrana



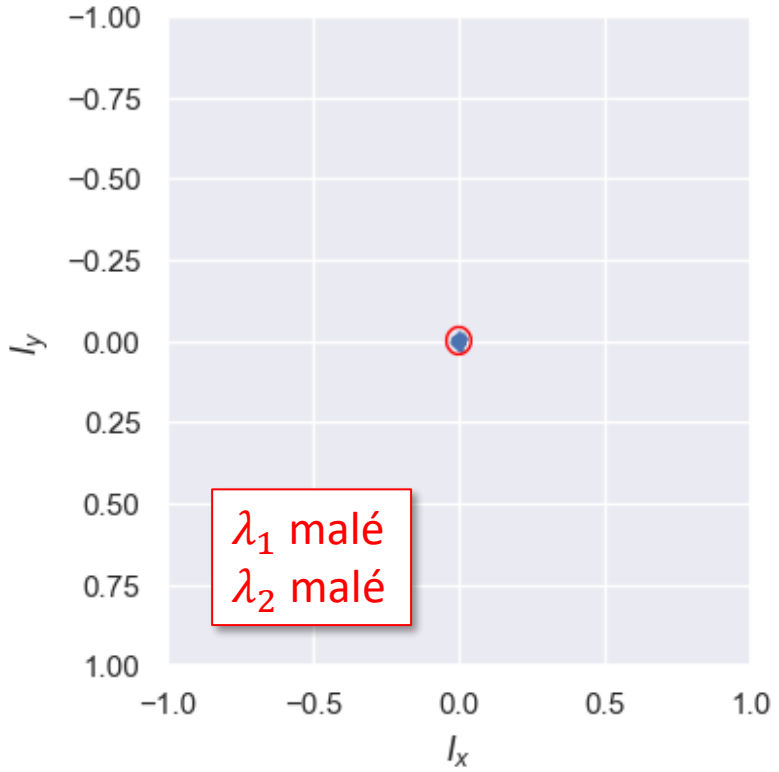
roh



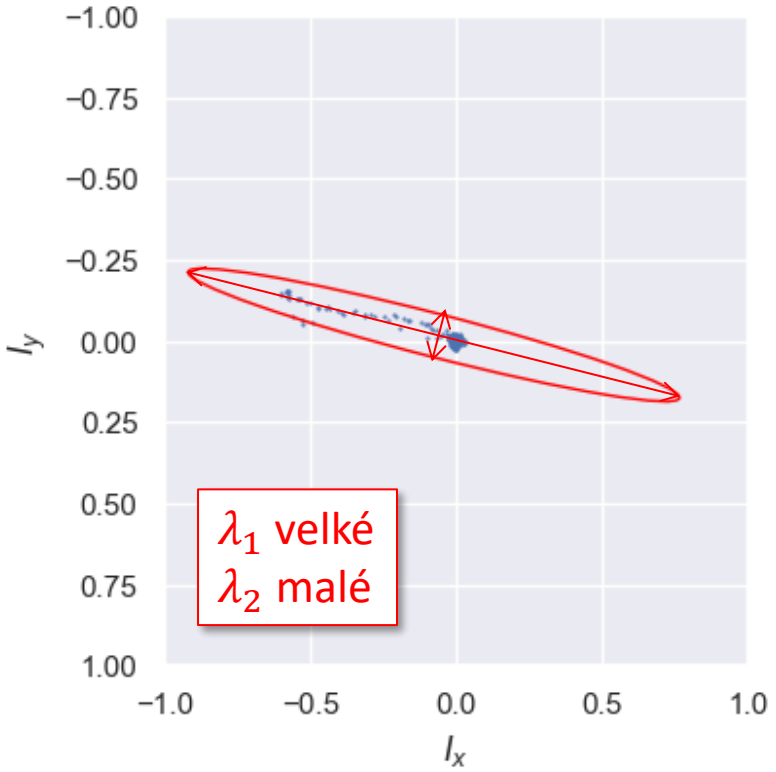
$$\boldsymbol{M} = \begin{bmatrix} \sum_{x,y} I_x^2 & \sum_{x,y} I_x \cdot I_y \\ \sum_{x,y} I_x \cdot I_y & \sum_{x,y} I_y^2 \end{bmatrix}$$ … kovarianční matice, jejíž vlastní čísla λ_1, λ_2 a vektory popisují elipsu

Interpretace matice $\boldsymbol{M}$ z pohledu rozložení lokáních gradientů

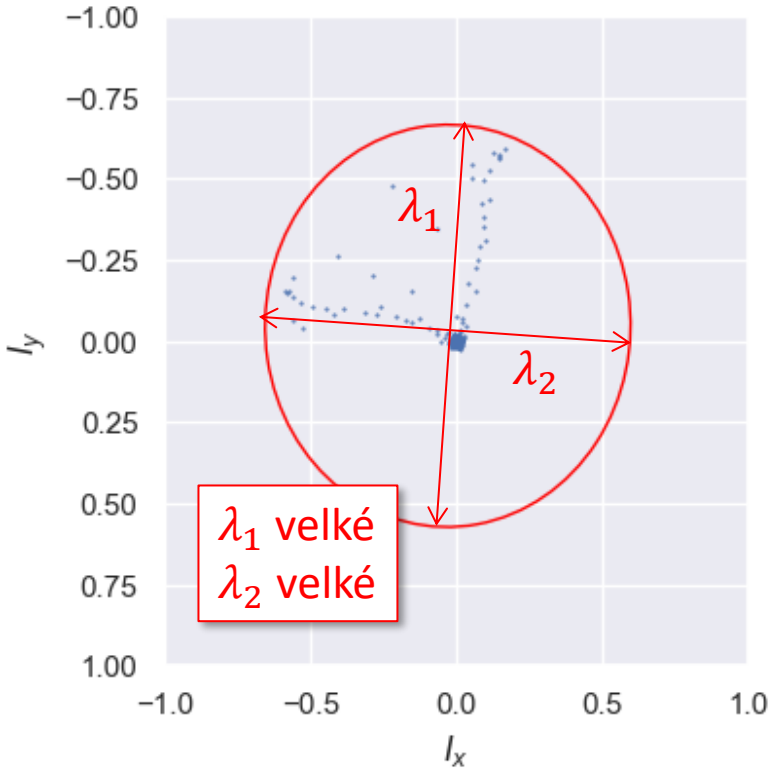
plochá oblast



hrana



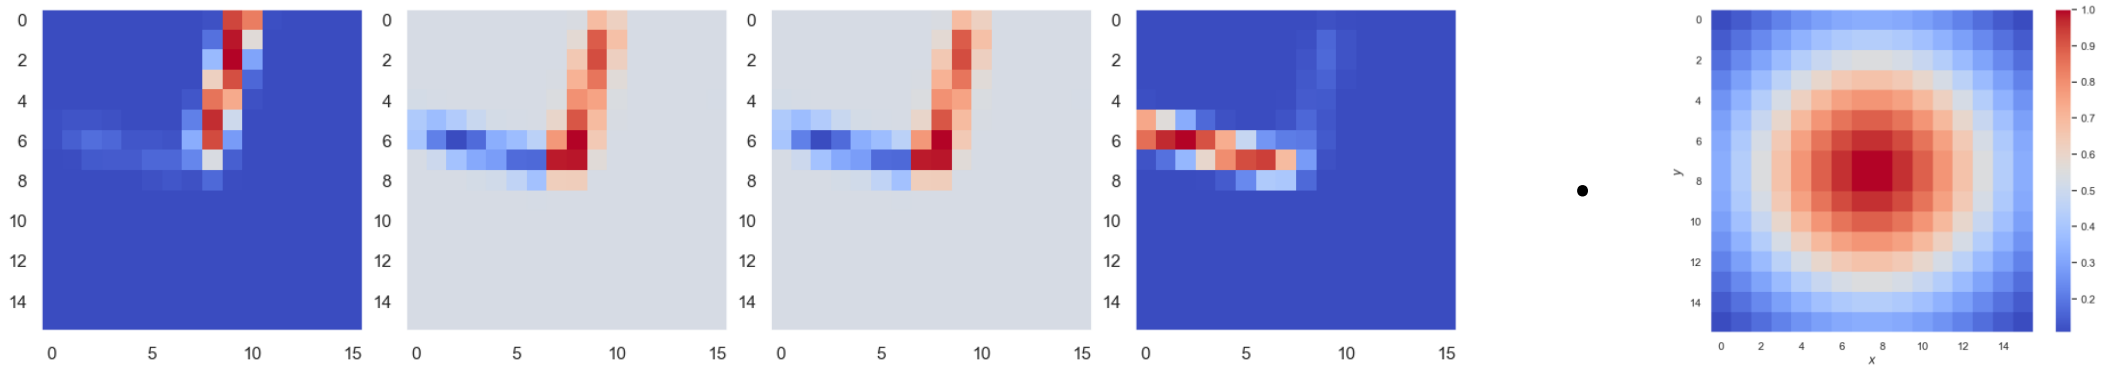
roh



$$\boldsymbol{M} = \begin{bmatrix} \sum_{x,y} I_x^2 & \sum_{x,y} I_x \cdot I_y \\ \sum_{x,y} I_x \cdot I_y & \sum_{x,y} I_y^2 \end{bmatrix}$$ … kovarianční matice, jejíž vlastní čísla λ_1, λ_2 a vektory popisují elipsu

Vyhlazení gaussovskou funkcí

I_x^2 $I_x \cdot I_y$ $I_y \cdot I_x$ I_y^2 w_g



$$\boldsymbol{M} = \begin{bmatrix} \sum_{x,y} w_g(x,y) \cdot I_x^2(x,y) & \sum_{x,y} w_g(x,y) \cdot I_x(x,y) \cdot I_y(x,y) \\ \sum_{x,y} w_g(x,y) \cdot I_x(x,y) \cdot I_y(x,y) & \sum_{x,y} w_g(x,y) \cdot I_y^2(x,y) \end{bmatrix}$$

Harrisův detektor rohů

1. Vypočteme derivace I_x a I_y v každém bodě obrazu $I \in \mathbb{R}^{M \times N}$
   - Derivace se aproximuje typicky centrální diferencí, tj. např. $I_x(x, y) \approx I(x+1, y) - I(x-1, y)$
2. Vypočteme I_x^2, $I_x \cdot I_y$ a I_y^2 (mají rozměry shodné s $I \in \mathbb{R}^{M \times N}$)
3. Vyhladíme konvolucí s gaussovským oknem w_g

$$\boldsymbol{M} = \begin{bmatrix} I_x^2 * w_\mathrm{g} & \left(I_x \cdot I_y\right) * w_\mathrm{g} \\ \left(I_x \cdot I_y\right) * w_\mathrm{g} & I_y^2 * w_\mathrm{g} \end{bmatrix}, \qquad \boldsymbol{M} \in \mathbb{R}^{M \times N \times 2 \times 2}$$

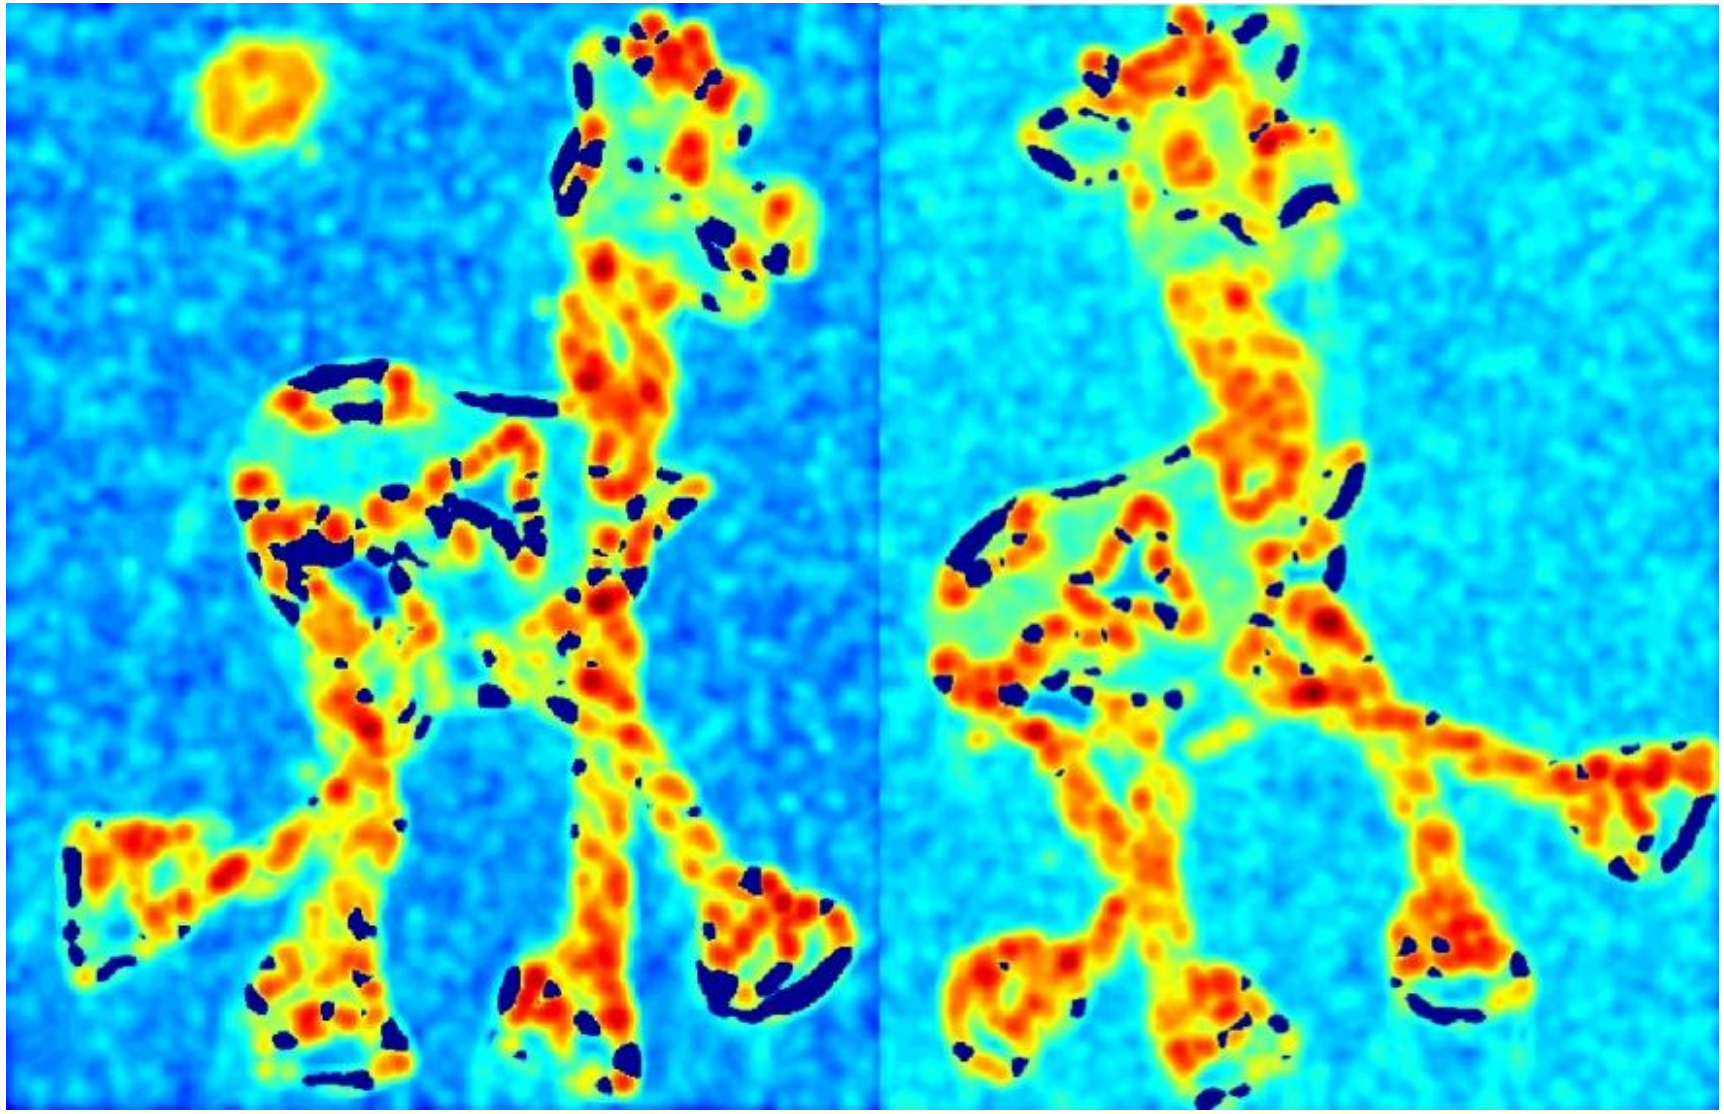
4. V každém pixelu vypočteme "rohovost" $R = \det(\boldsymbol{M}) - \alpha \cdot \mathrm{trace}(\boldsymbol{M})$
5. Najdeme lokální maxima R a prahujeme

Příklad: vstupní obrázek



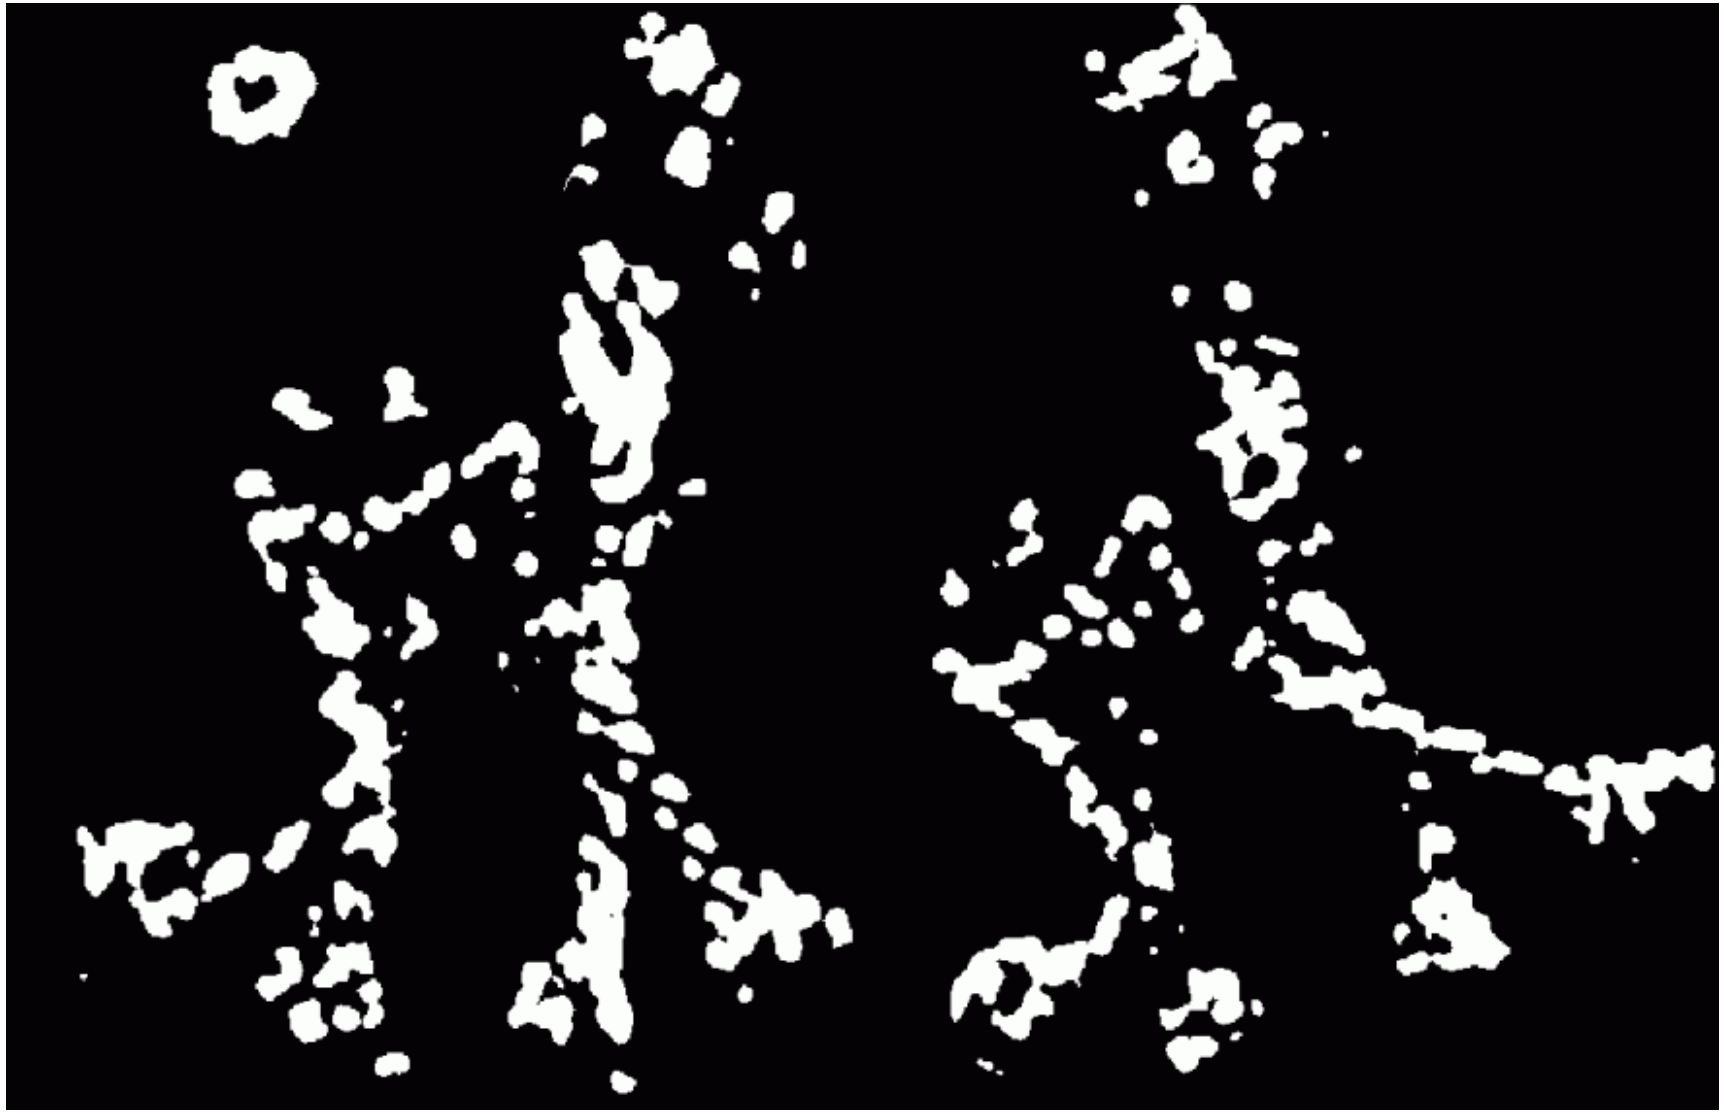
zdroj: https://slazebni.cs.illinois.edu/fall22/

Příklad: “rohovost” R



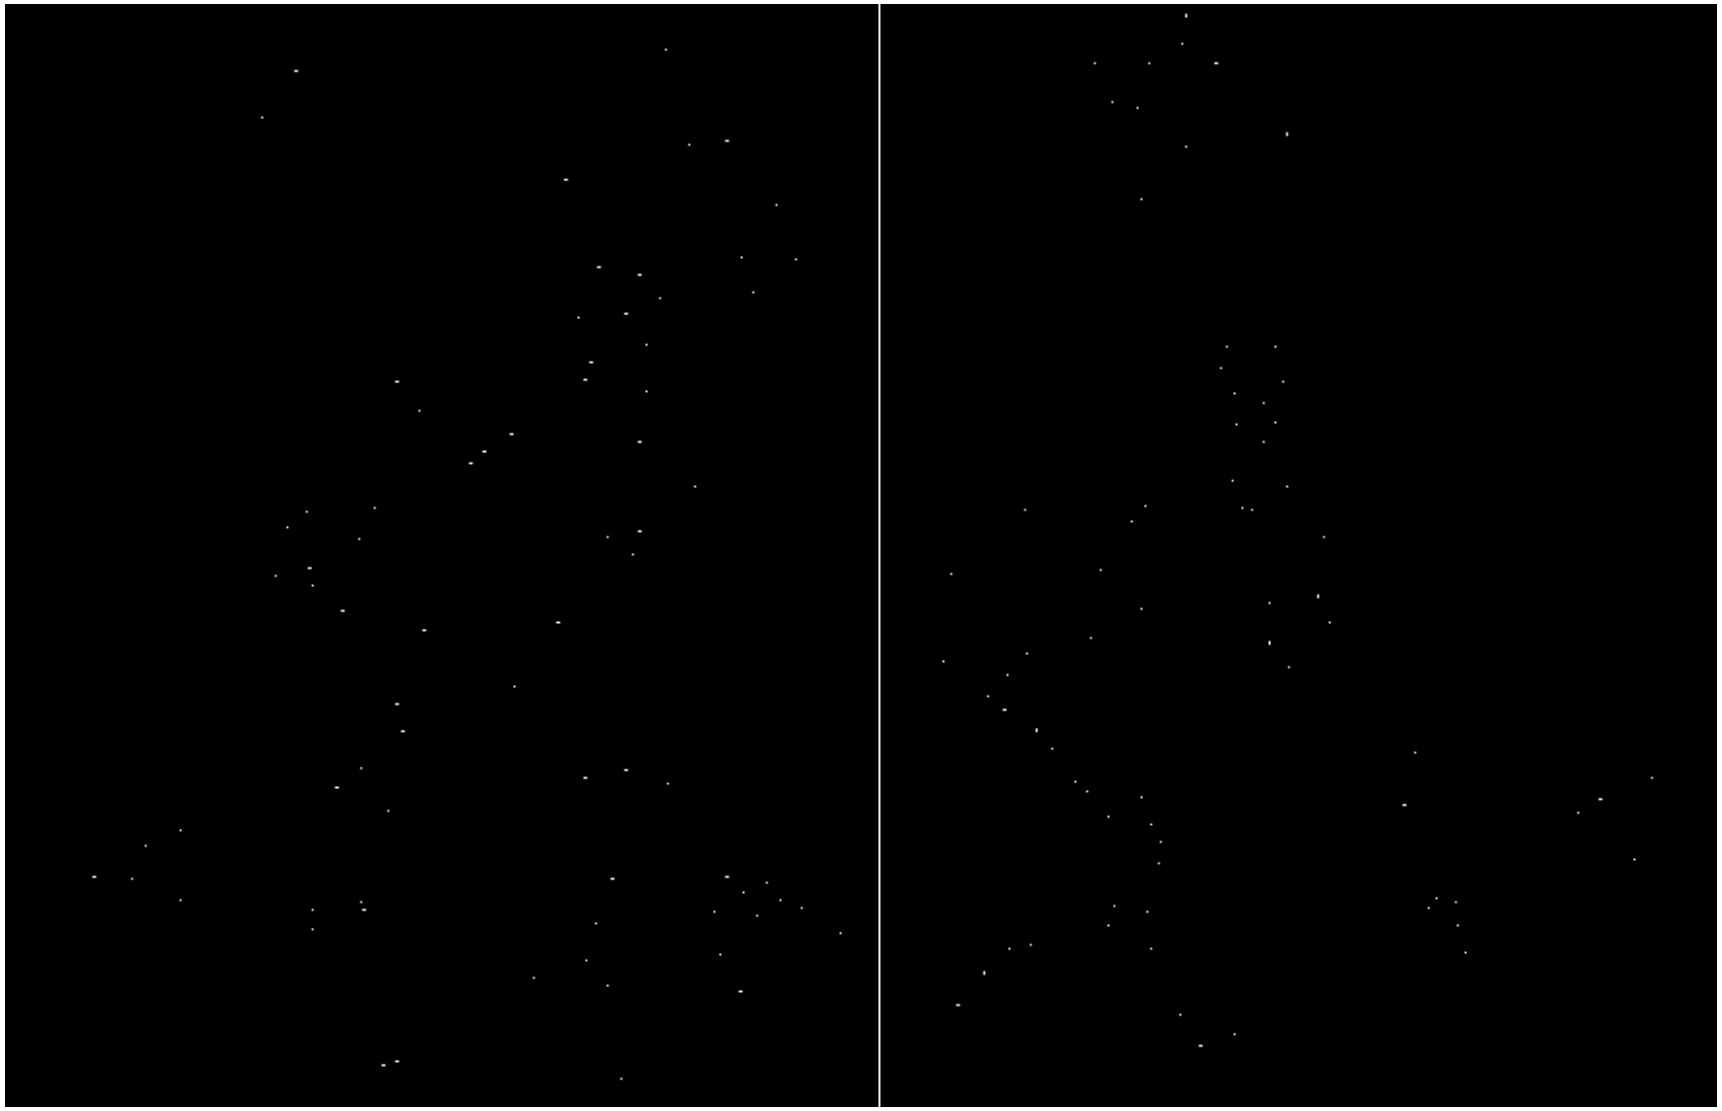
zdroj: https://slazebni.cs.illinois.edu/fall22/

Příklad: prahování



zdroj: https://slazebni.cs.illinois.edu/fall22/

Příklad: pouze lokální maxima



zdroj: https://slazebni.cs.illinois.edu/fall22/

Příklad: vykreslení nalezených rohů

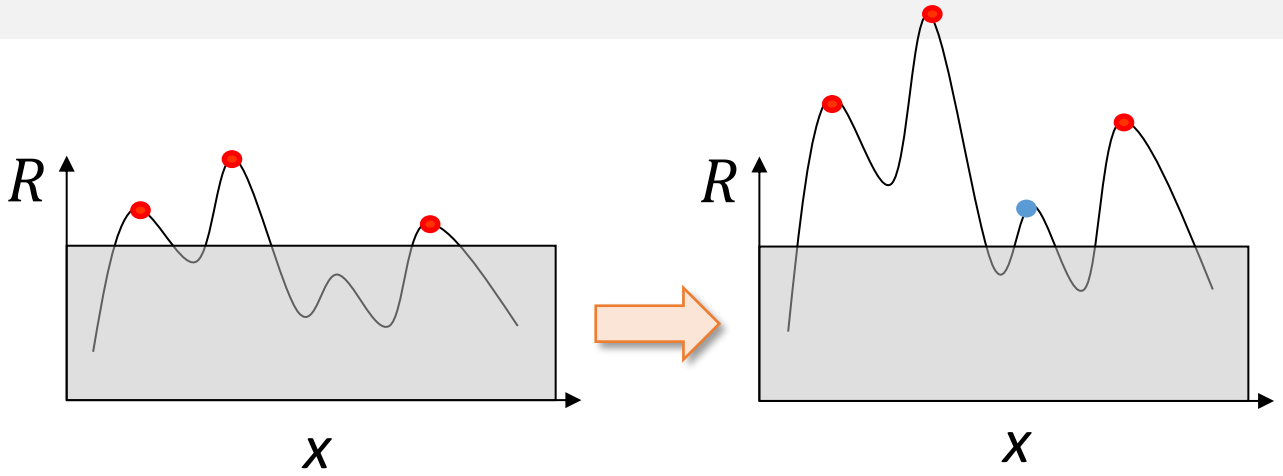


zdroj: https://slazebni.cs.illinois.edu/fall22/

Invariance/kovariance Harrisova detektoru rohů

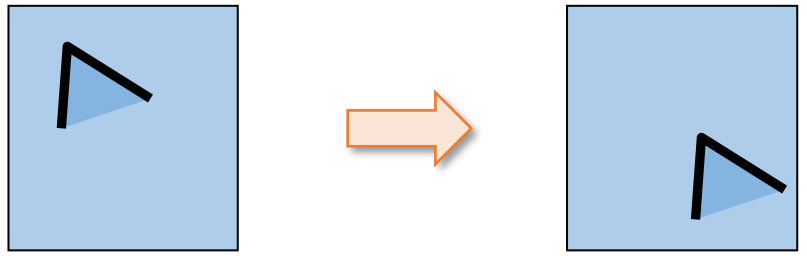
Jas & kontrast

- Matice M založena na derivacích → odečítá průměr → Invariantní vůči posunu jasu $I' = I + a$
- Není invariantní vůči změně kontrastu $I' = b \cdot I$



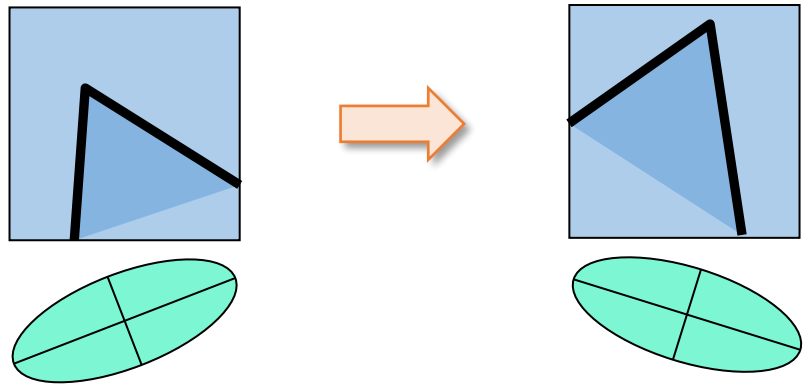
Posun

- "Rohovost" invariantní
- Pozice lokálních maxim rohovosti (rohů) kovariantní



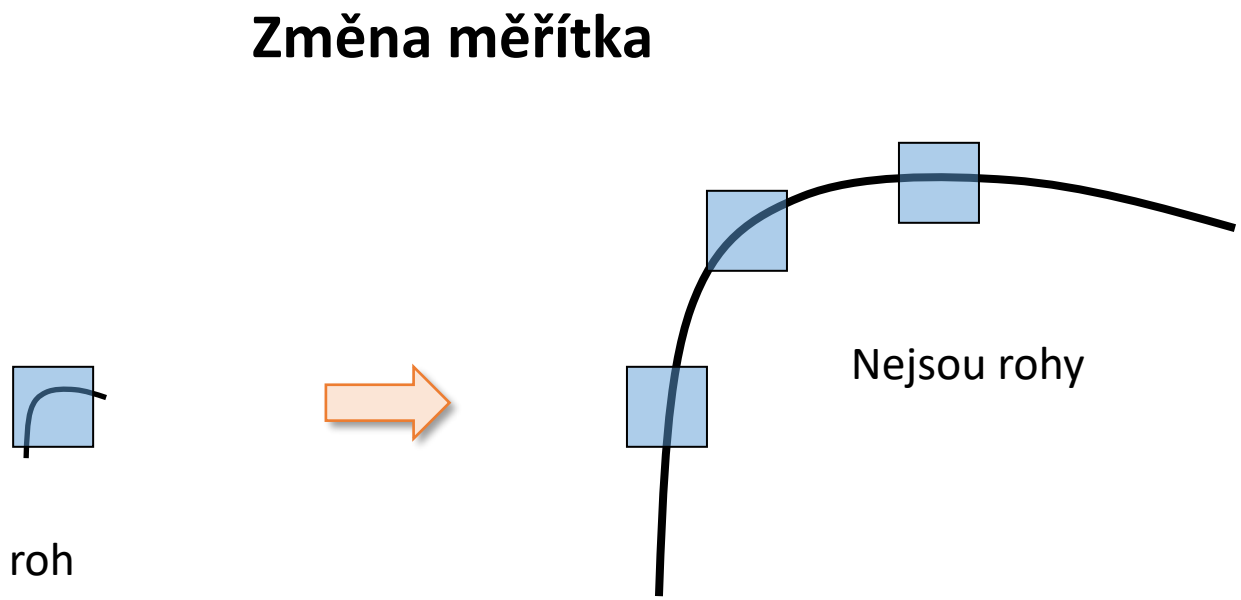
Rotace

- "Rohovost" invariantní
- Pozice lokálních maxim rohovosti (rohů) kovariantní



zdroj: https://slazebni.cs.illinois.edu/fall22/

Invariance/kovariance Harrisova detektoru rohů



(Základní) Harrisův detektor rohů není invariantní vůči změně měřítka

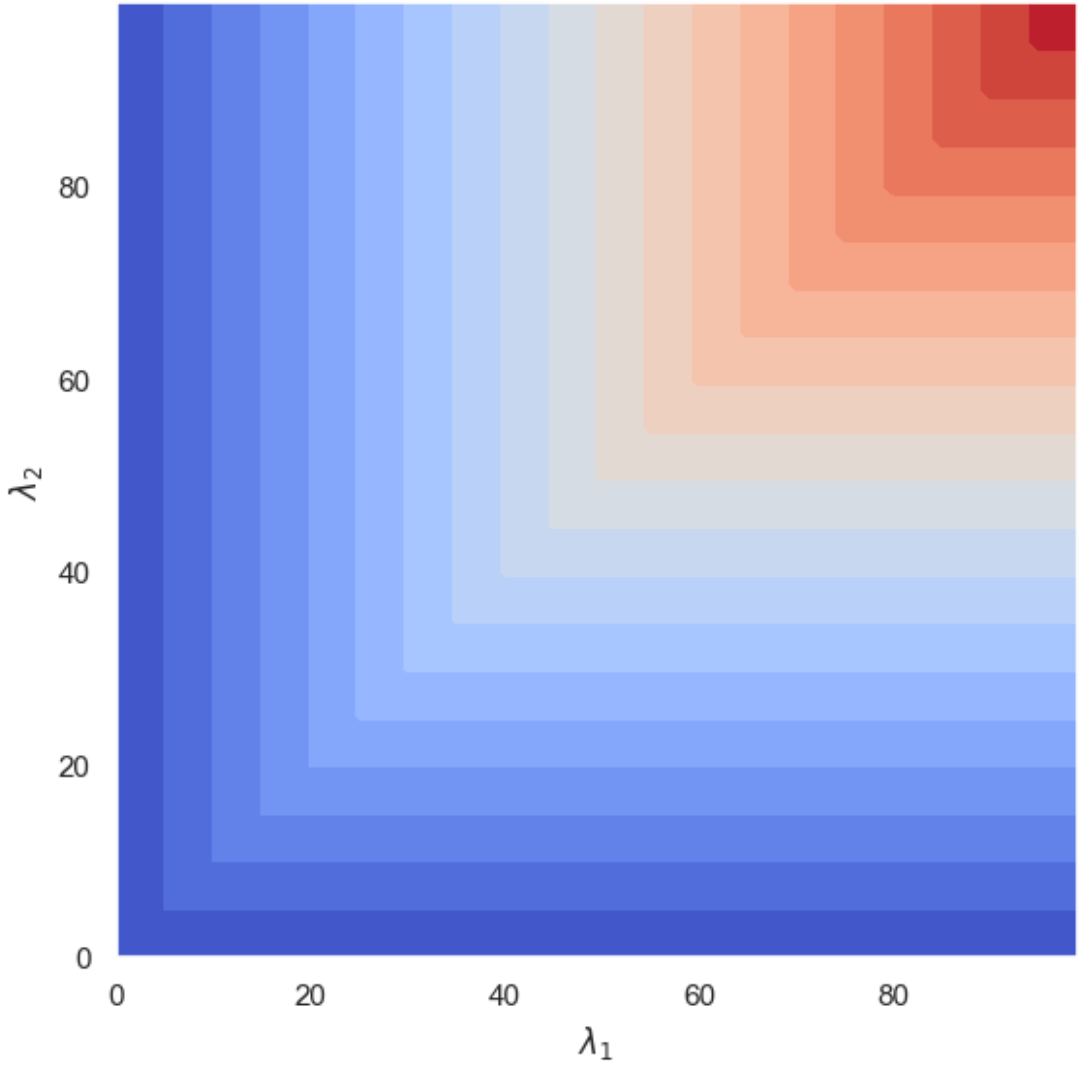
zdroj: https://slazebni.cs.illinois.edu/fall22/

Shi-Tomasi rohový detektor

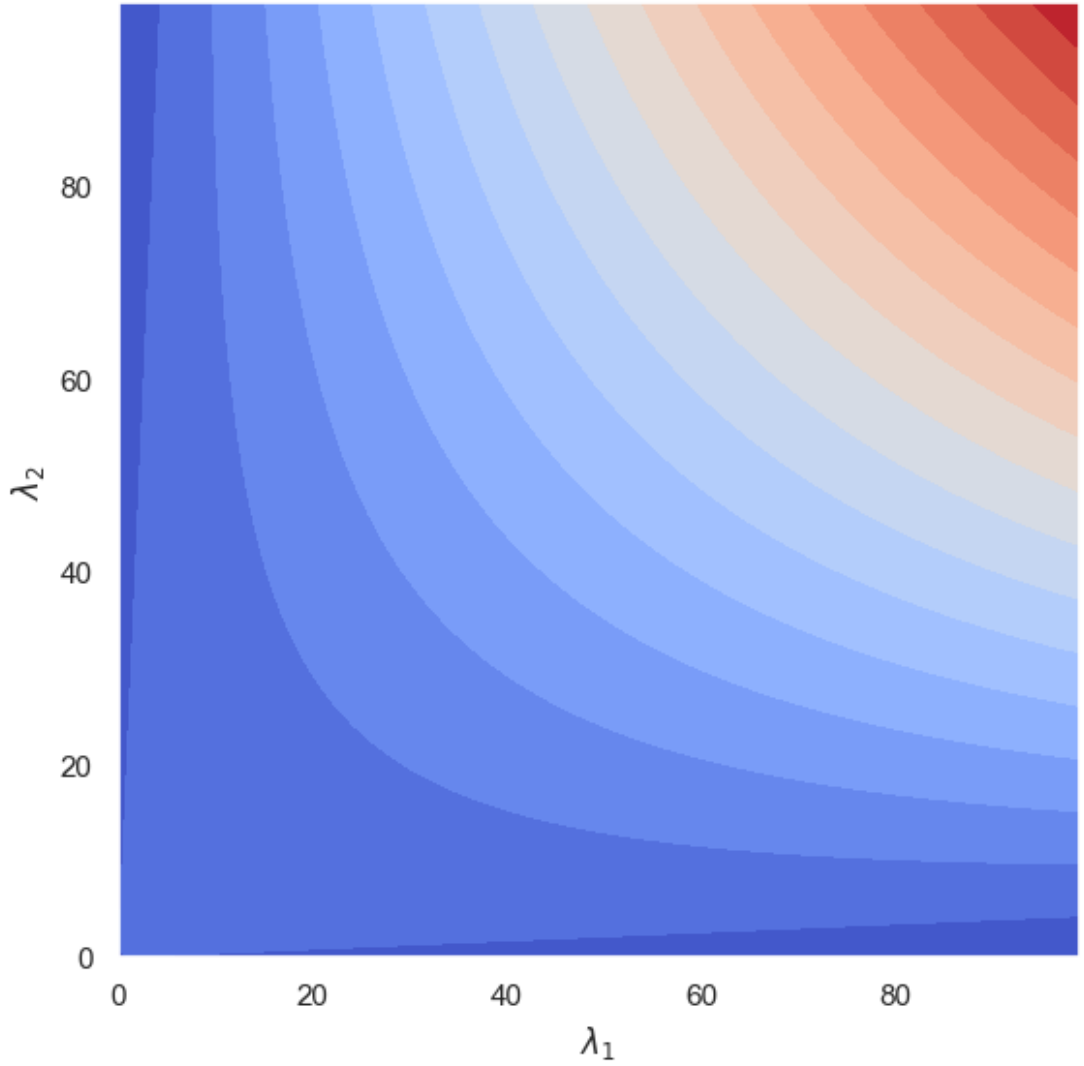
- Rohovost definována jako

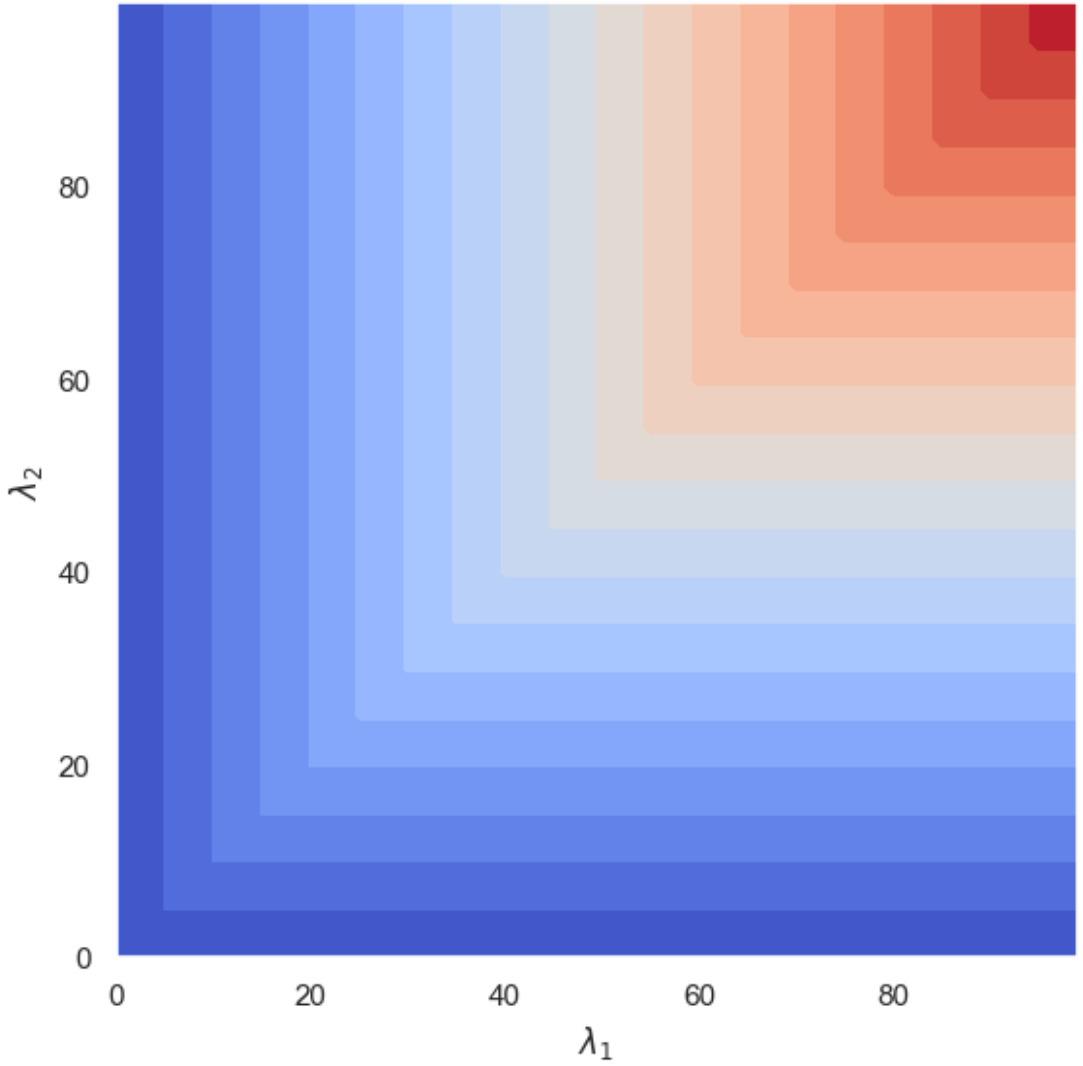
$$R_{\mathrm{ST}} = \min(\lambda_1, \lambda_2)$$

- Pokud je menší z vlastních čísel dostatečně velké, musí být dostatečně velké i větší z nich
- Good features to Track
  - optimalizace Shi-tomasi detektoru pro sledování oblastí (např. ve videu)
  - Z obrazu se vybírá pouze N nejsilnějších rohů, které od sebe navíc musí být dostatečně vzdálené



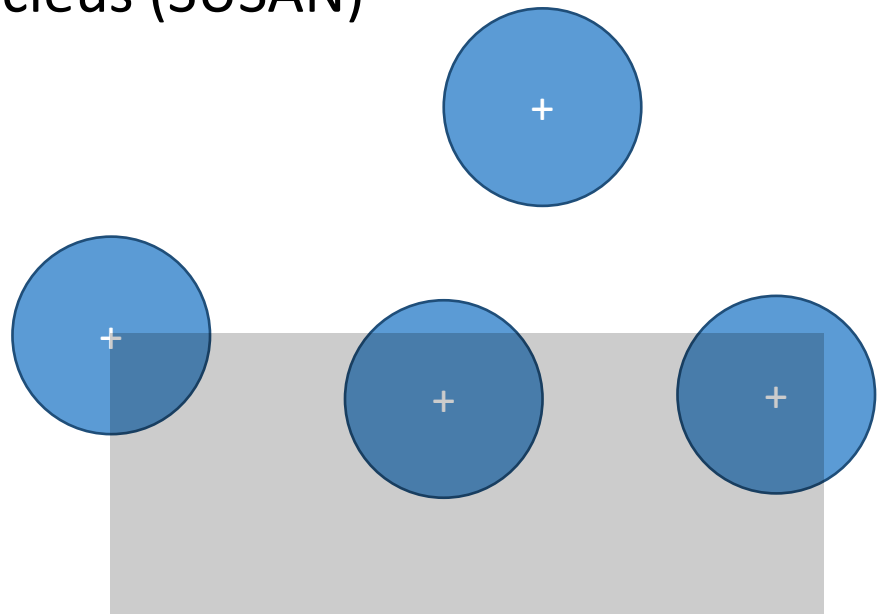
Shi-Tomasi rohový detektor



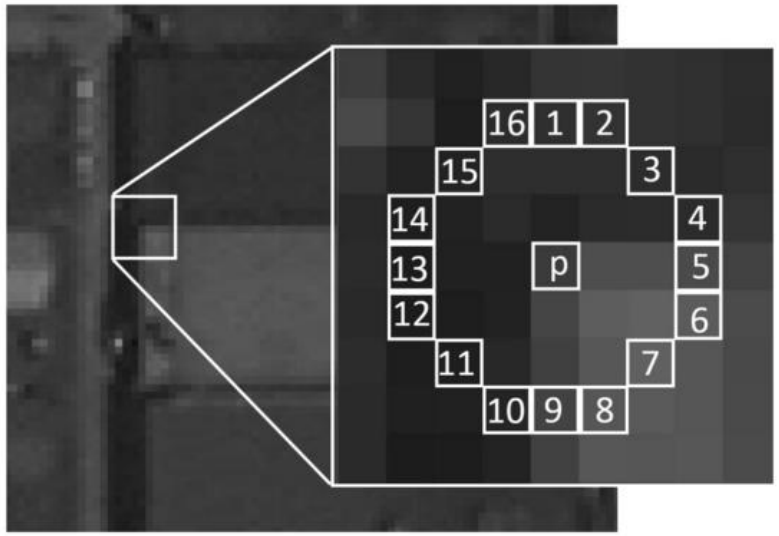


Další detektory rohů

- Smallest Univalue Segment Assimilating Nucleus (SUSAN)



- Features from Accelerated Segment Test (FAST) – základ pro ORB



- Rohy jsou takové pixely, pro které je zastoupení pixelů s podobnou hodnotou jasu v nějakém blízkém okolí malé

- Roh = souvislá posloupnost pixelů dlouhá alespoň N ma vyšší nebo nižší hodnotu než p

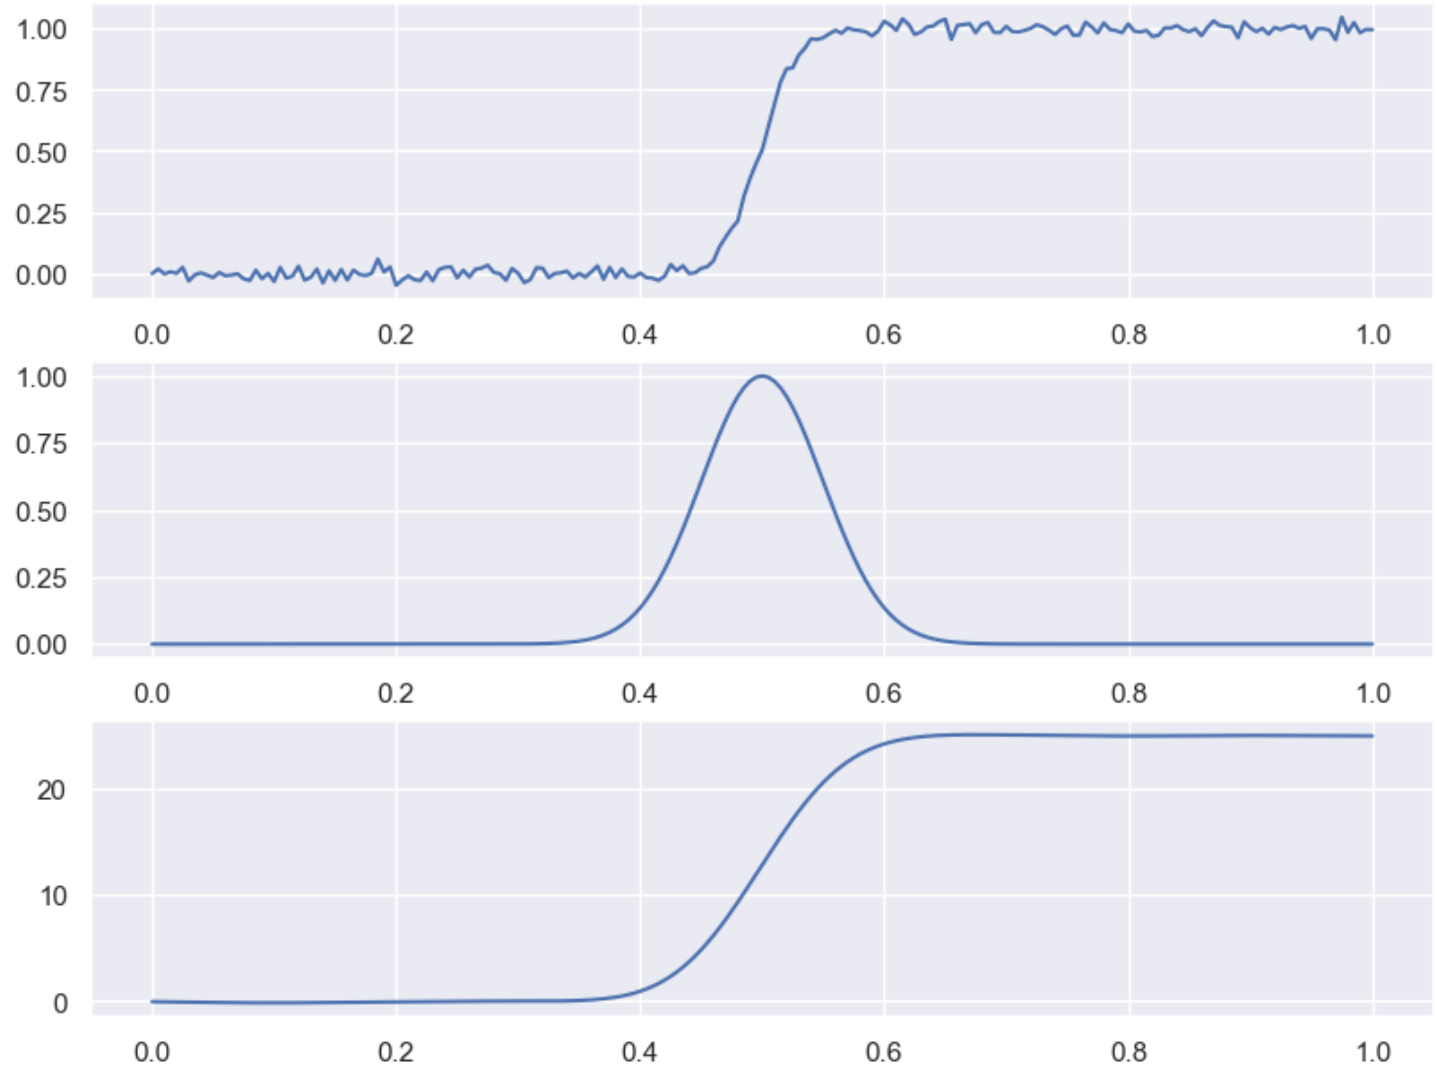
Detekce blobů

Gaussovský filtr

f

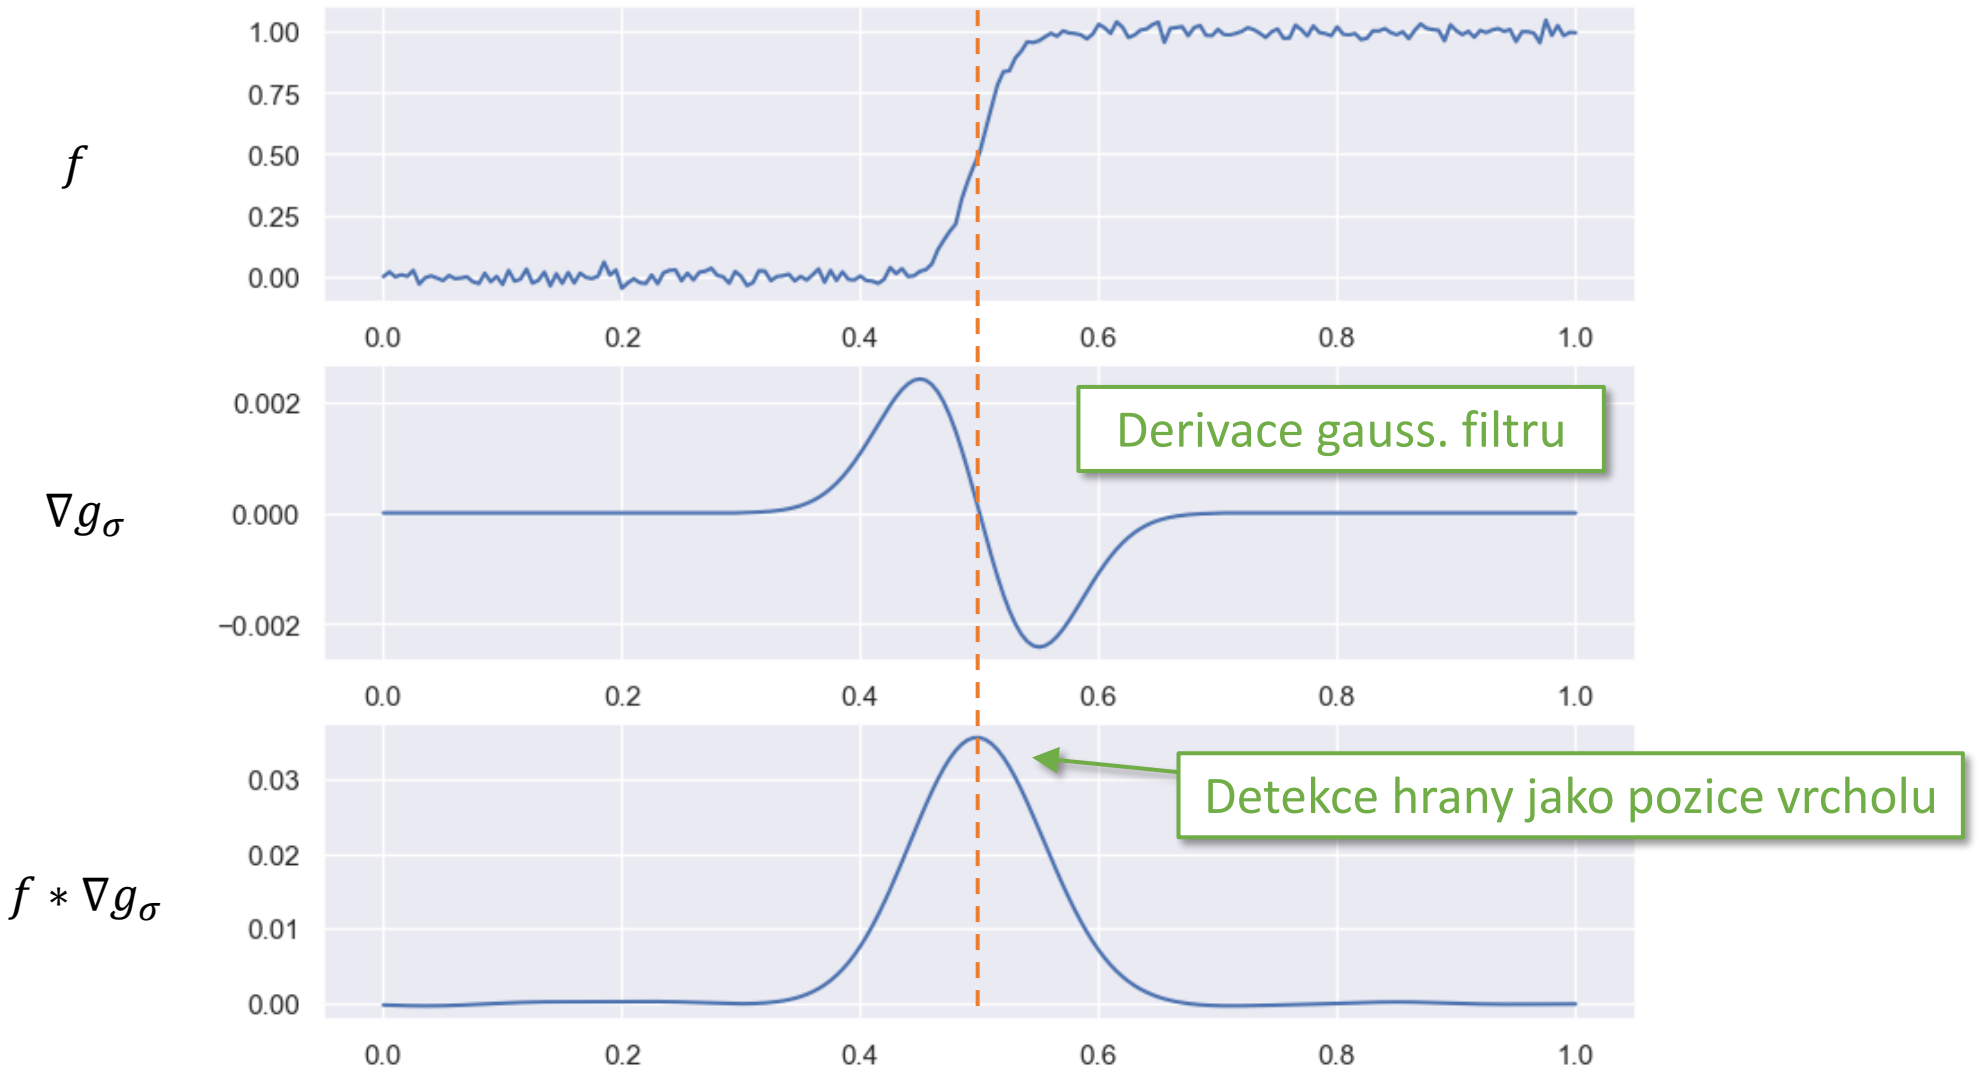
g_σ

$f * g_\sigma$



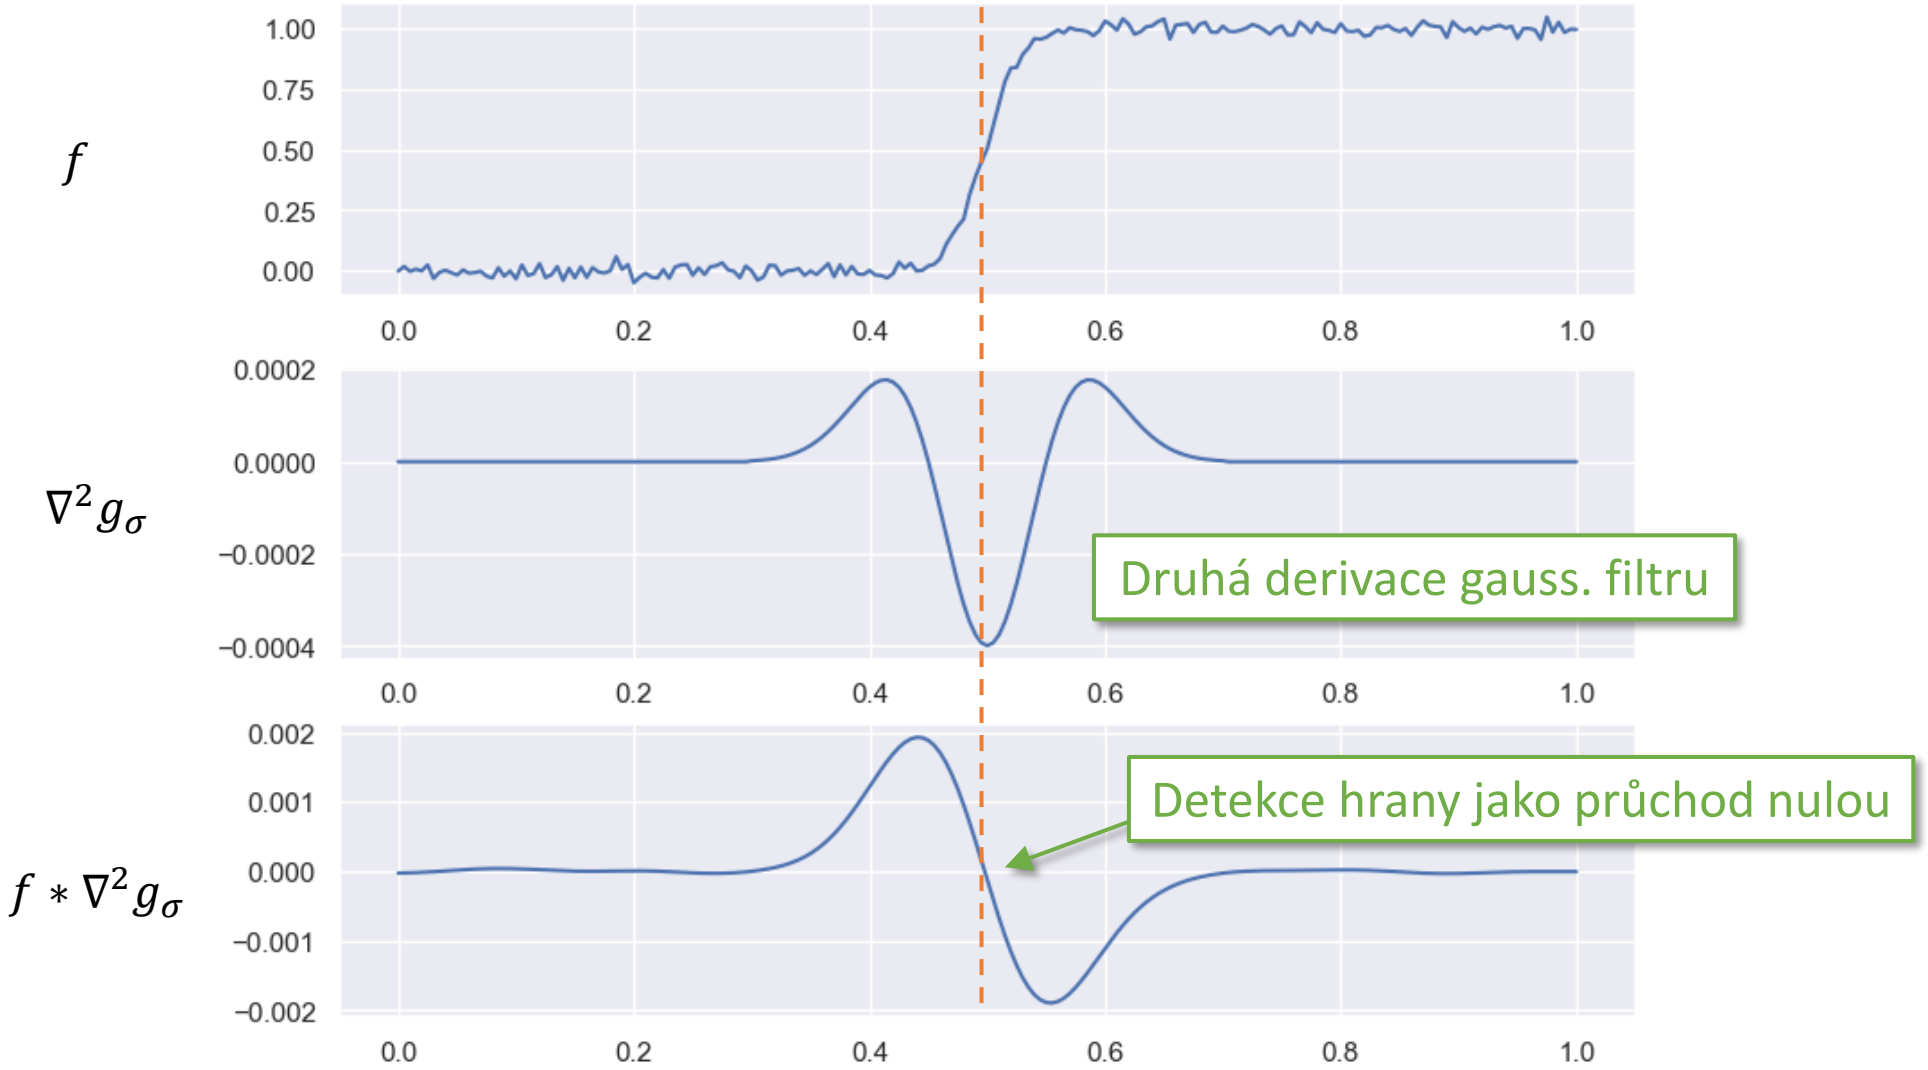
zdroj: https://fpcv.cs.columbia.edu/

Derivace gaussovského filtru



zdroj: https://fpcv.cs.columbia.edu/

Druhá derivace gaussovského filtru



zdroj: https://fpcv.cs.columbia.edu/

1D blob a druhá derivace gaussiánu

$\sigma = 5$

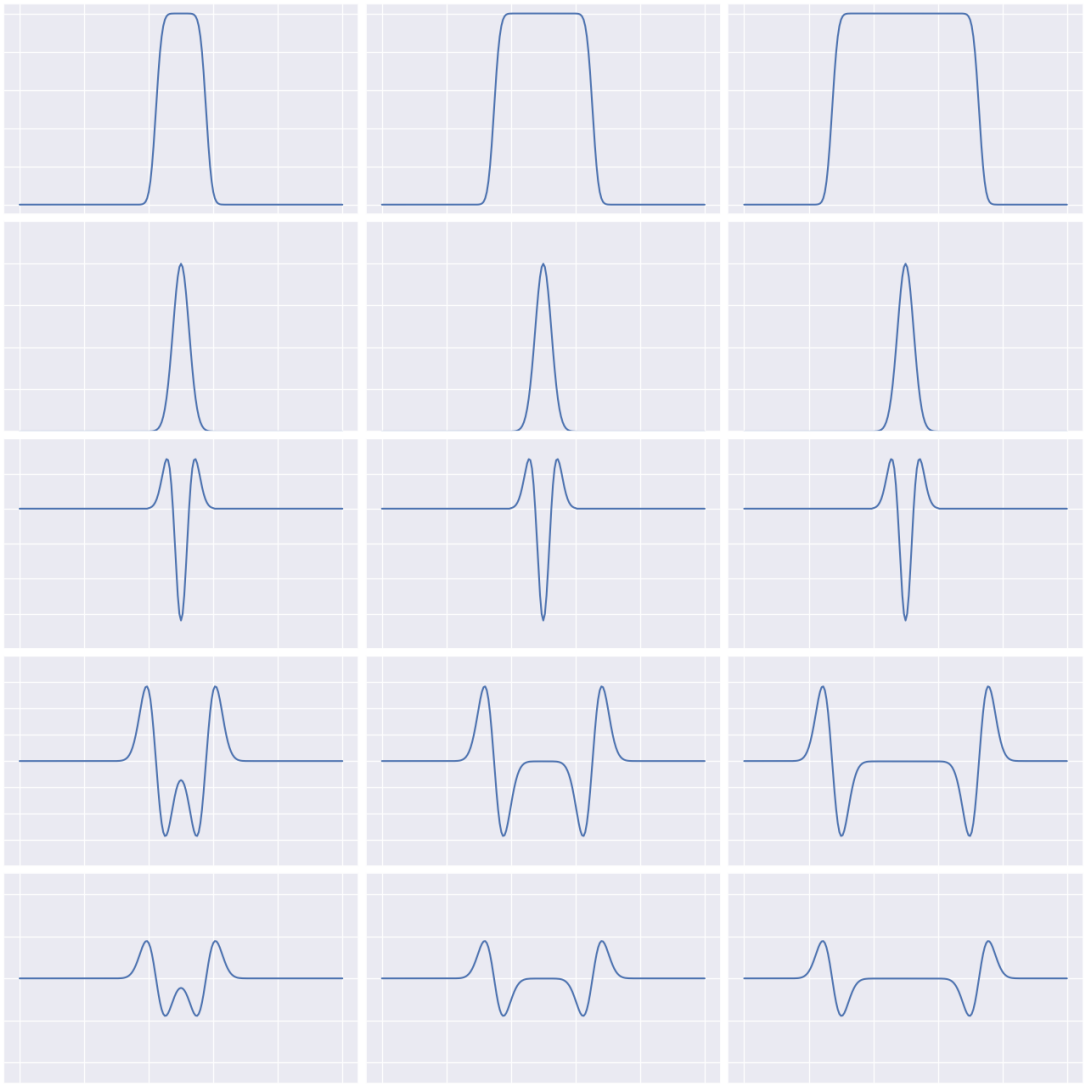
f

g_σ

$\nabla^2 g_\sigma$

$f * \nabla^2 g_\sigma$

$\sigma^2 \cdot f * \nabla^2 g_\sigma$



Tři různé bloby

Gaussovský filtr

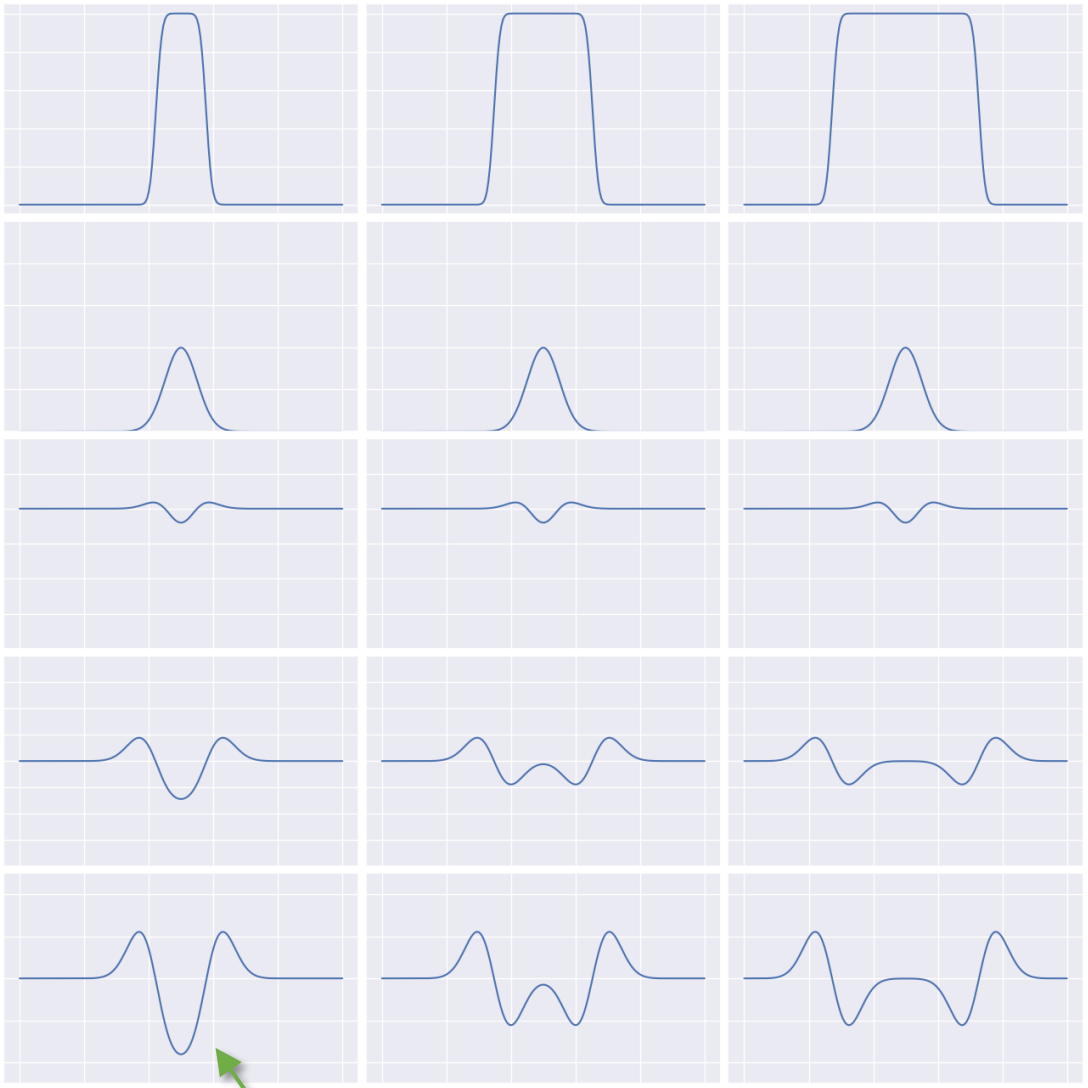
Druhá der. gauss. filtru

Odezva na $\nabla^2 g_\sigma$

Měřítkem normalizovaná odezva

zdroj: https://fpcv.cs.columbia.edu/

1D blob a druhá derivace gaussiánu



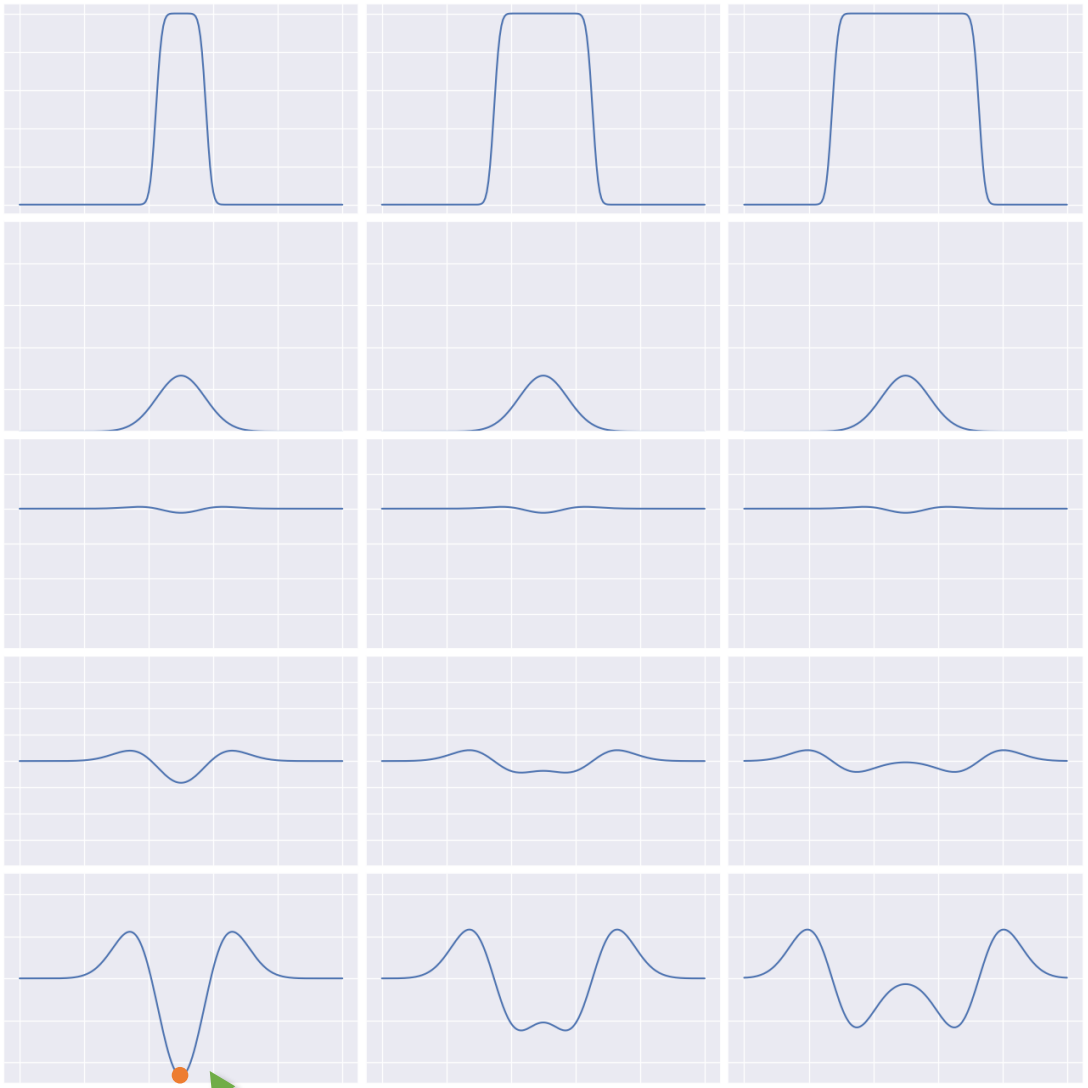
$\sigma = 10$

Zvýšíme σ

Normalizovaná odezva se zvýší pro první blob

zdroj: https://fpcv.cs.columbia.edu/

1D blob a druhá derivace gaussiánu



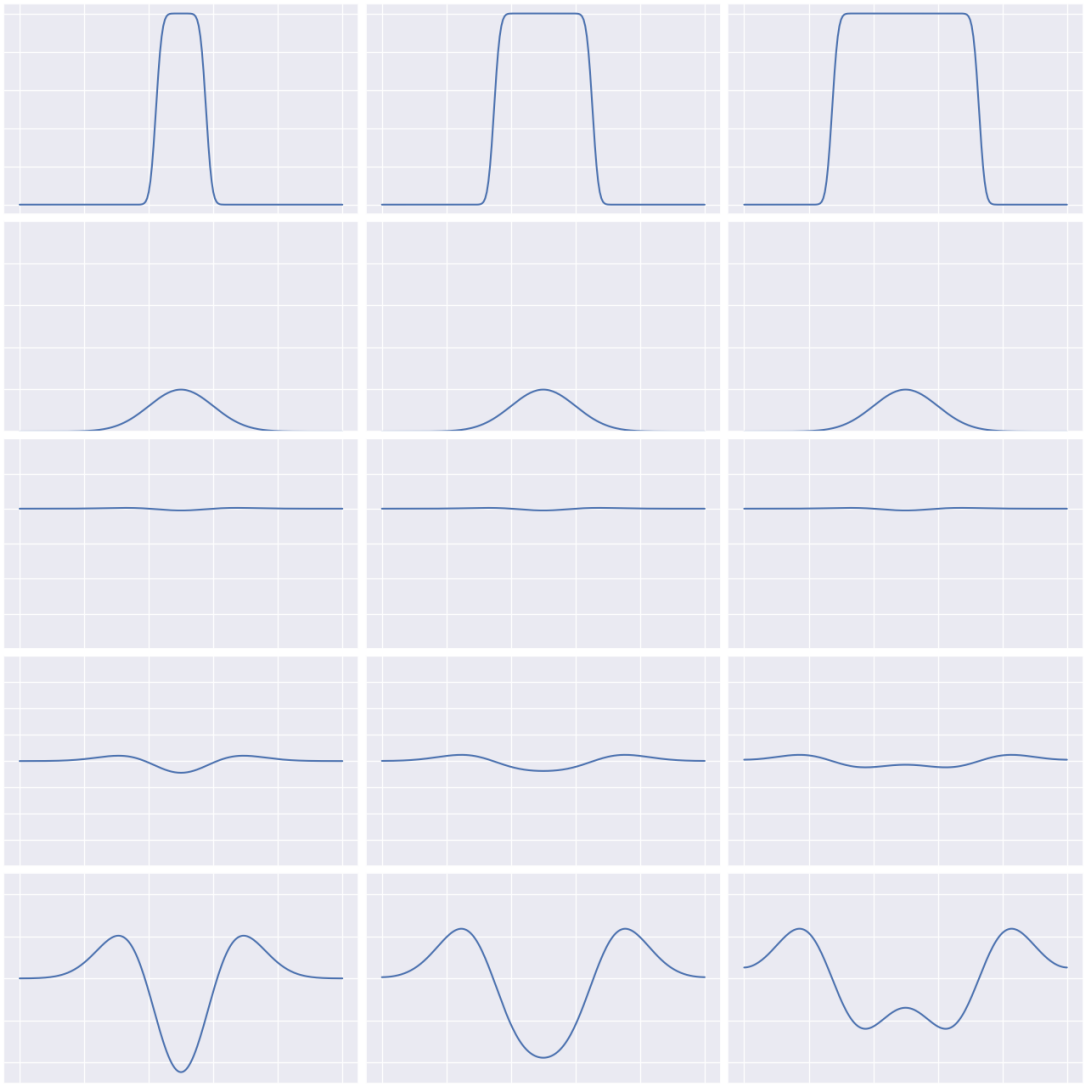
$\sigma = 15$

Zvýšíme σ

Pro $\sigma_A = 15$ je odezva max., dále se zvyšovat nebude

zdroj: https://fpcv.cs.columbia.edu/

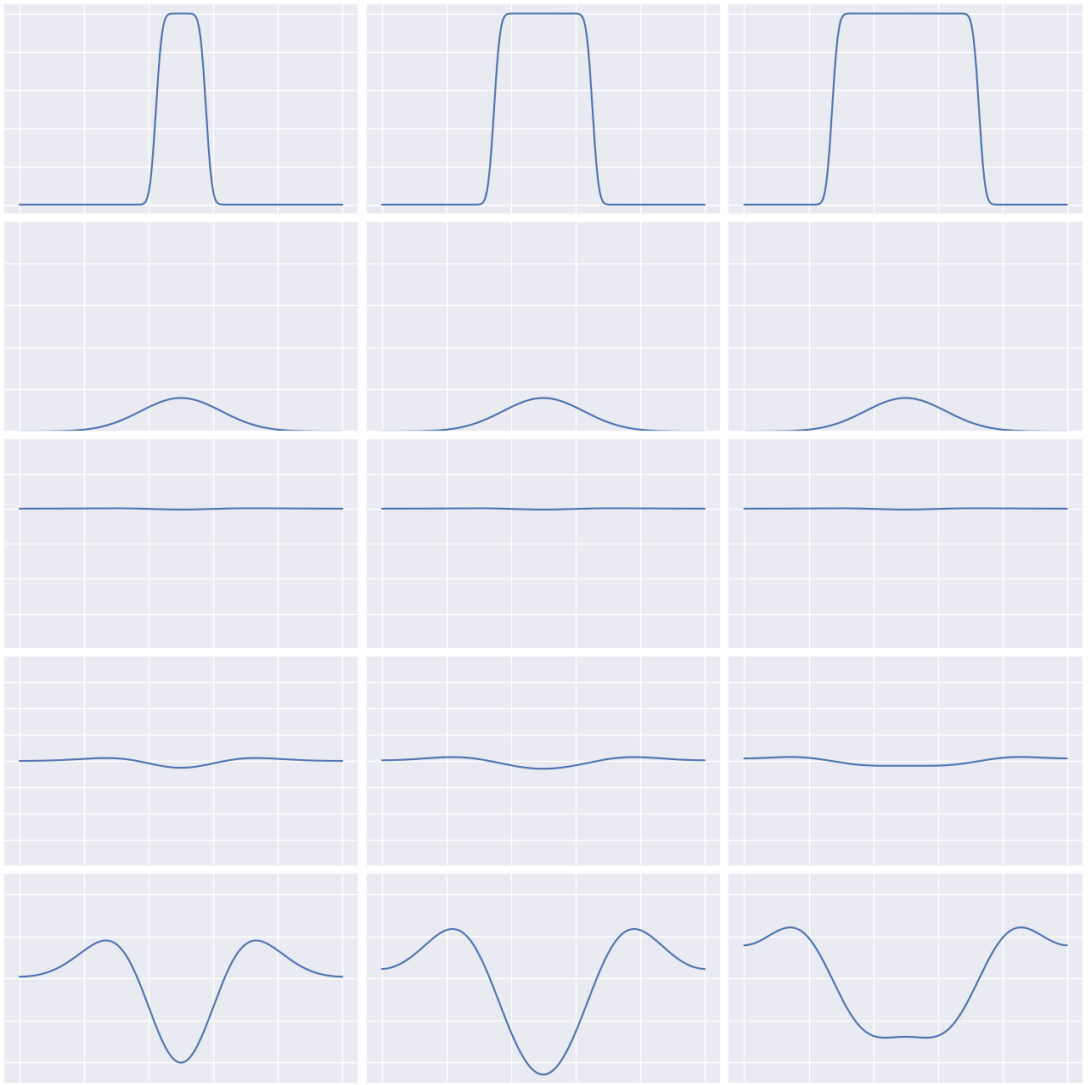
1D blob a druhá derivace gaussiánu



Zvýšíme σ

zdroj: https://fpcv.cs.columbia.edu/

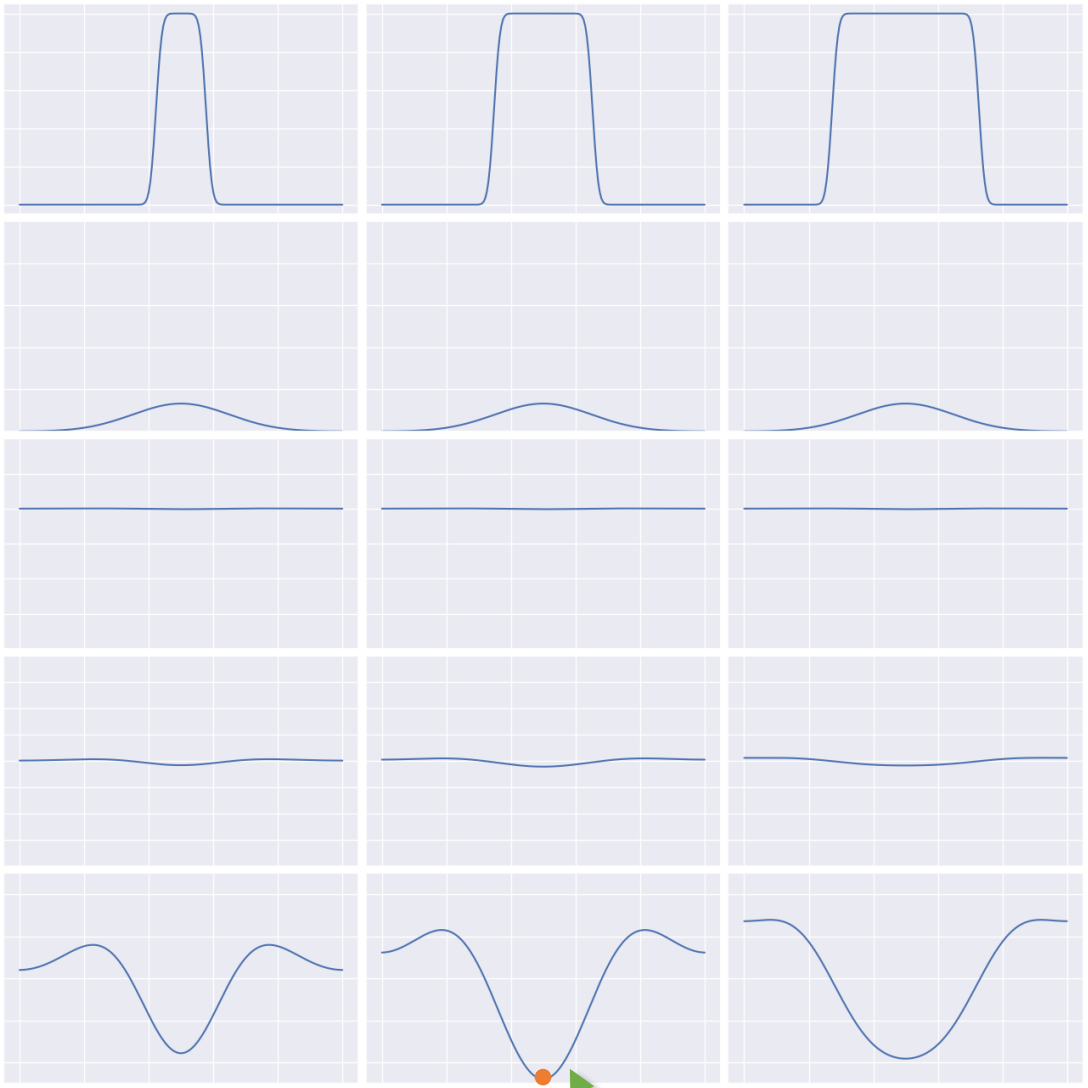
1D blob a druhá derivace gaussiánu



Zvýšíme σ

zdroj: https://fpcv.cs.columbia.edu/

1D blob a druhá derivace gaussiánu



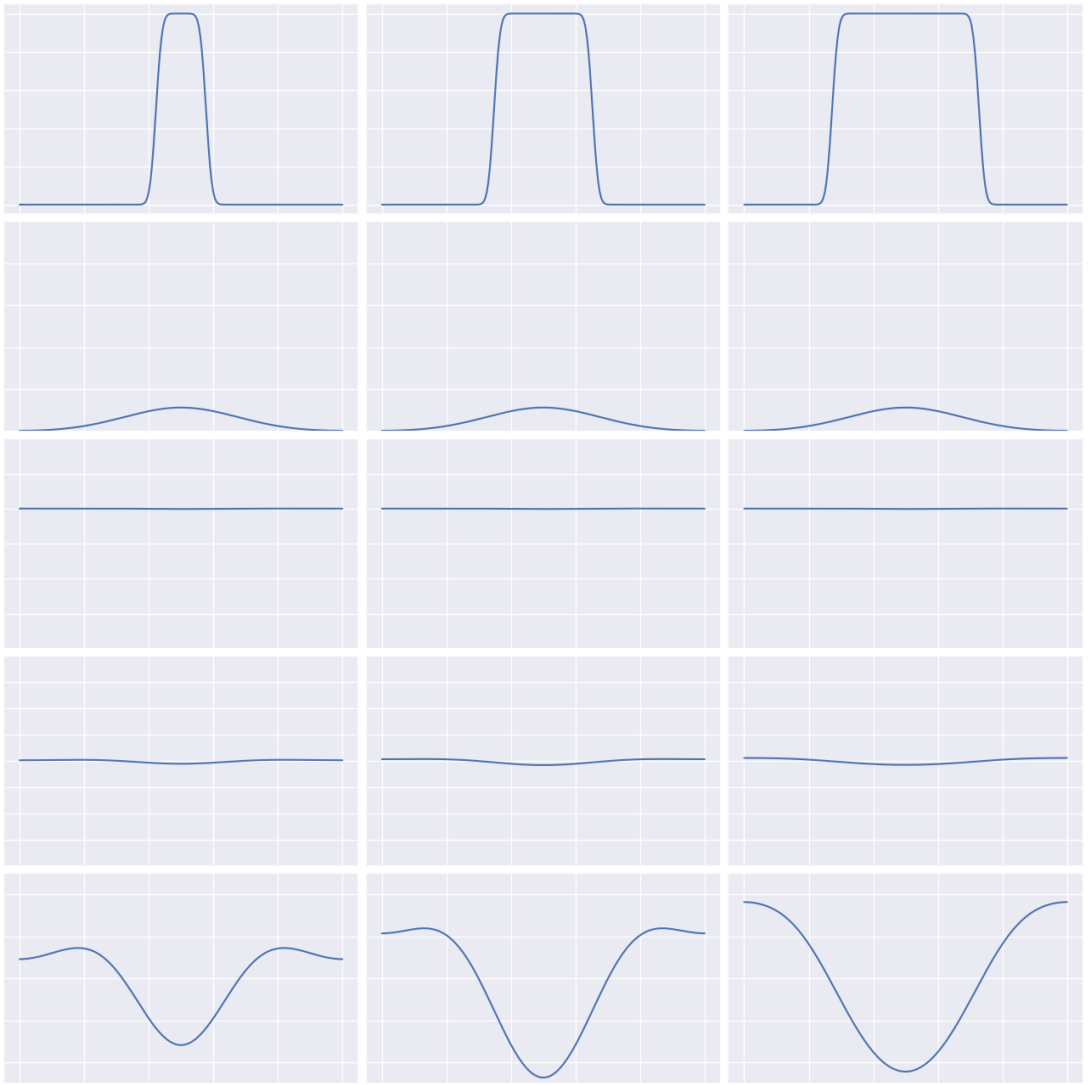
$\sigma = 30$

Zvýšíme σ

Druhý blob má maximum pro $\sigma_B = 30$

zdroj: https://fpcv.cs.columbia.edu/

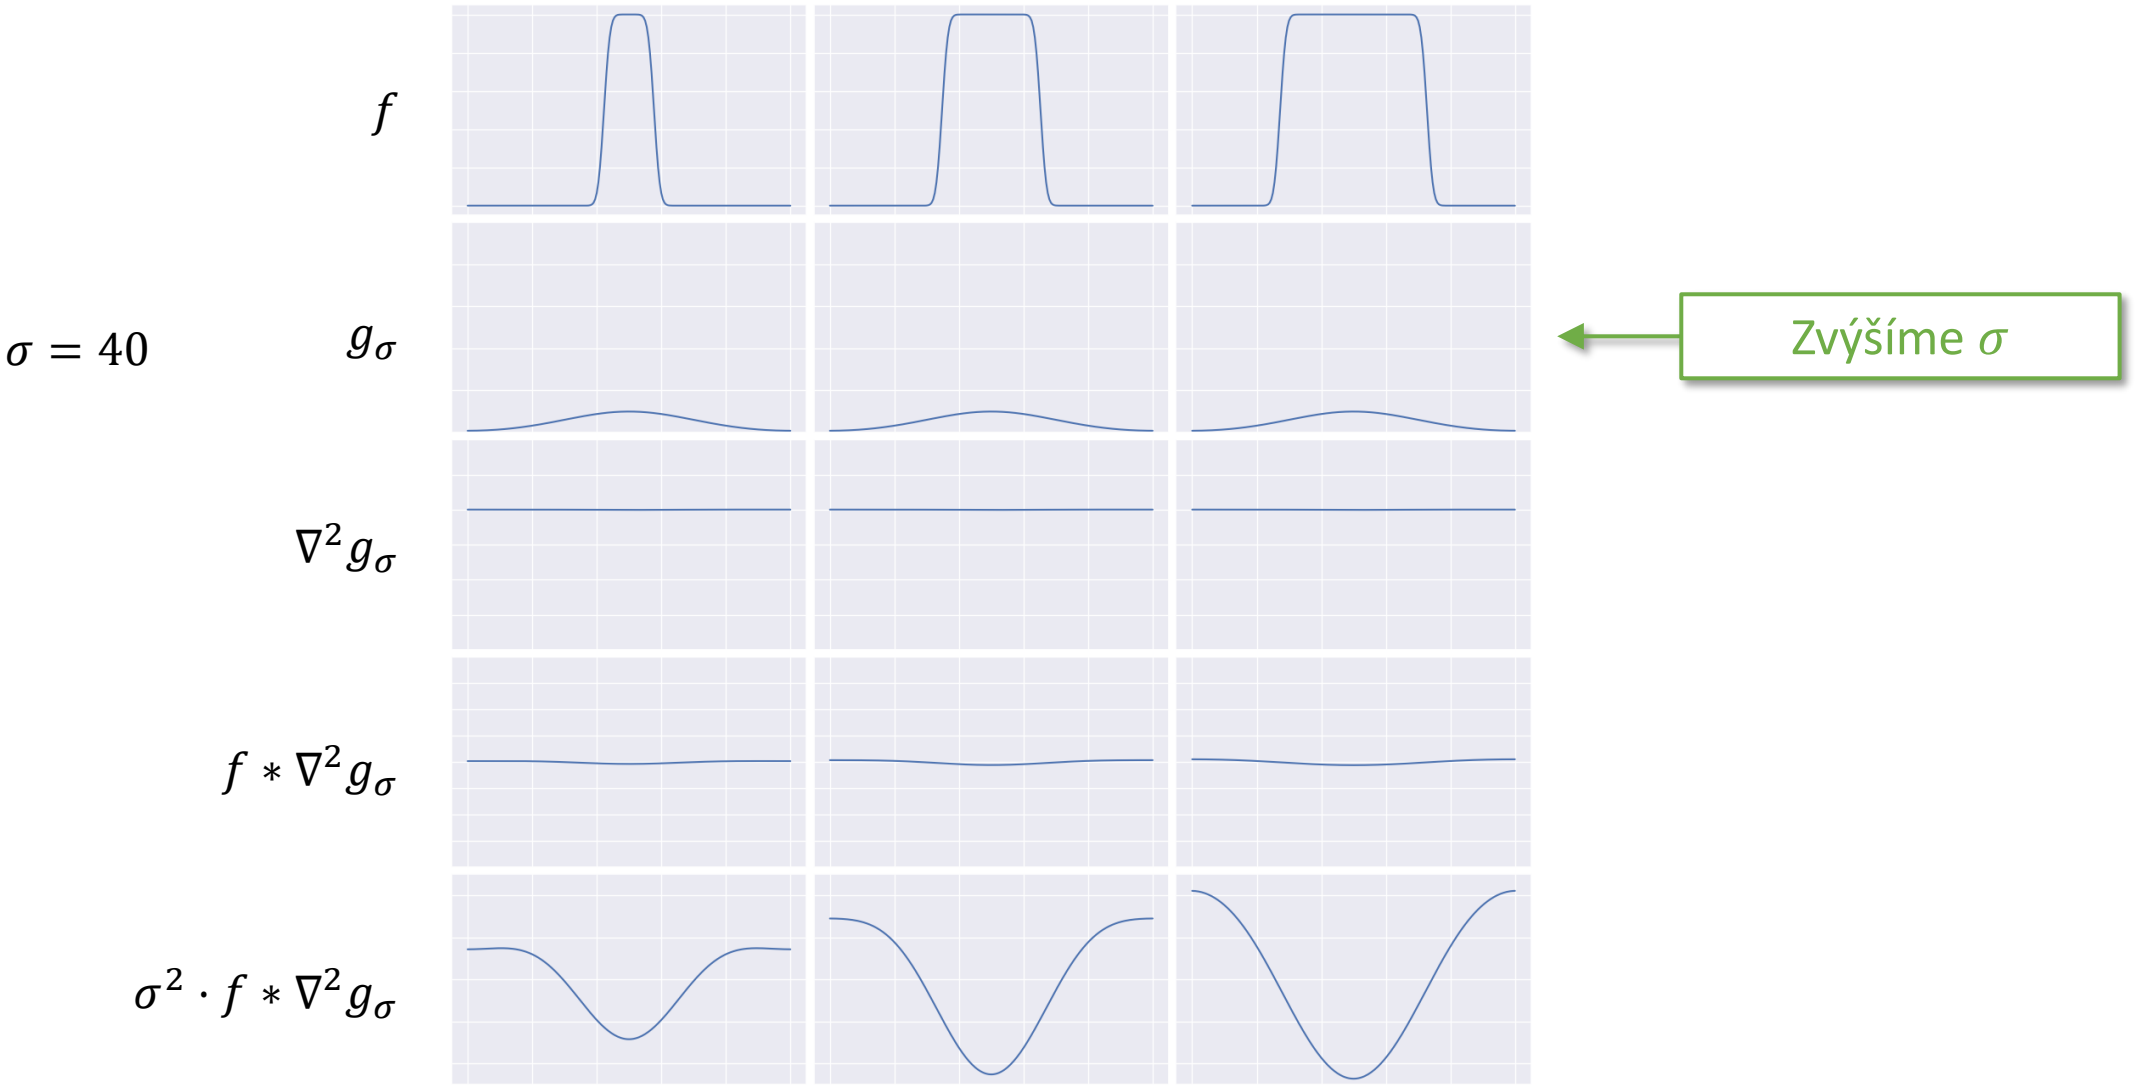
1D blob a druhá derivace gaussiánu



Zvýšíme σ

zdroj: https://fpcv.cs.columbia.edu/

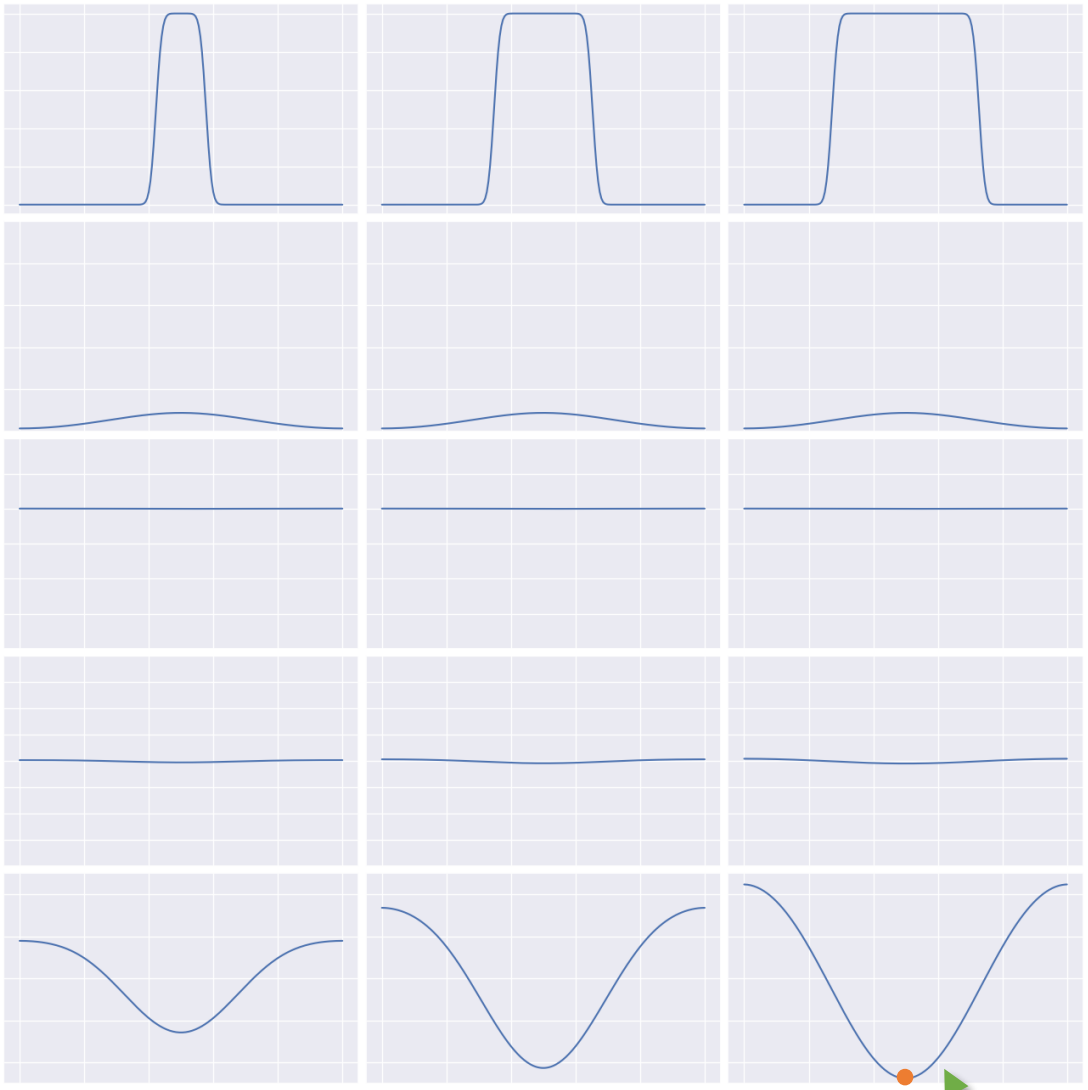
1D blob a druhá derivace gaussiánu



zdroj: https://fpcv.cs.columbia.edu/

1D blob a druhá derivace gaussiánu

$\sigma = 45$

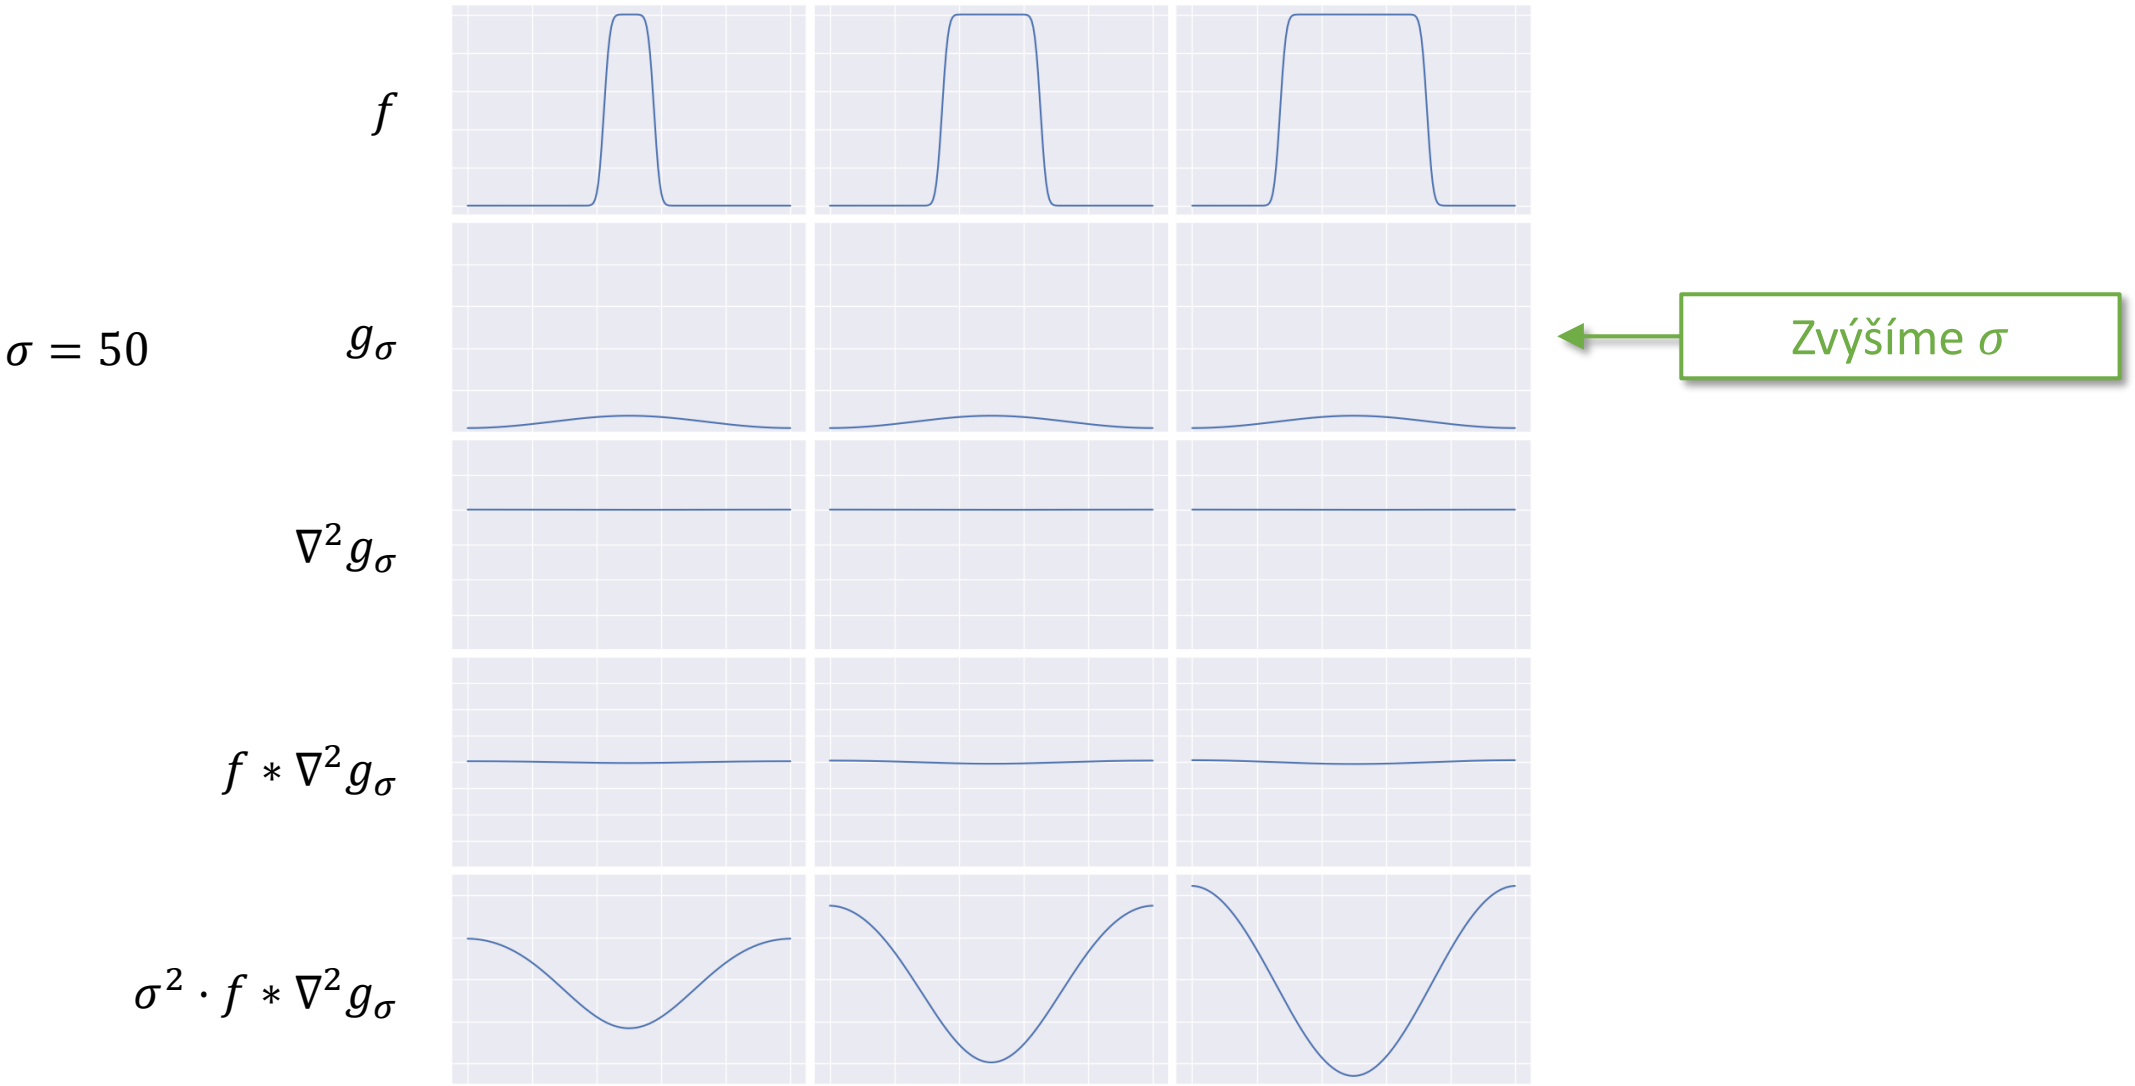


Zvýšíme σ

Třetí blob má maximum pro $\sigma_C = 45$

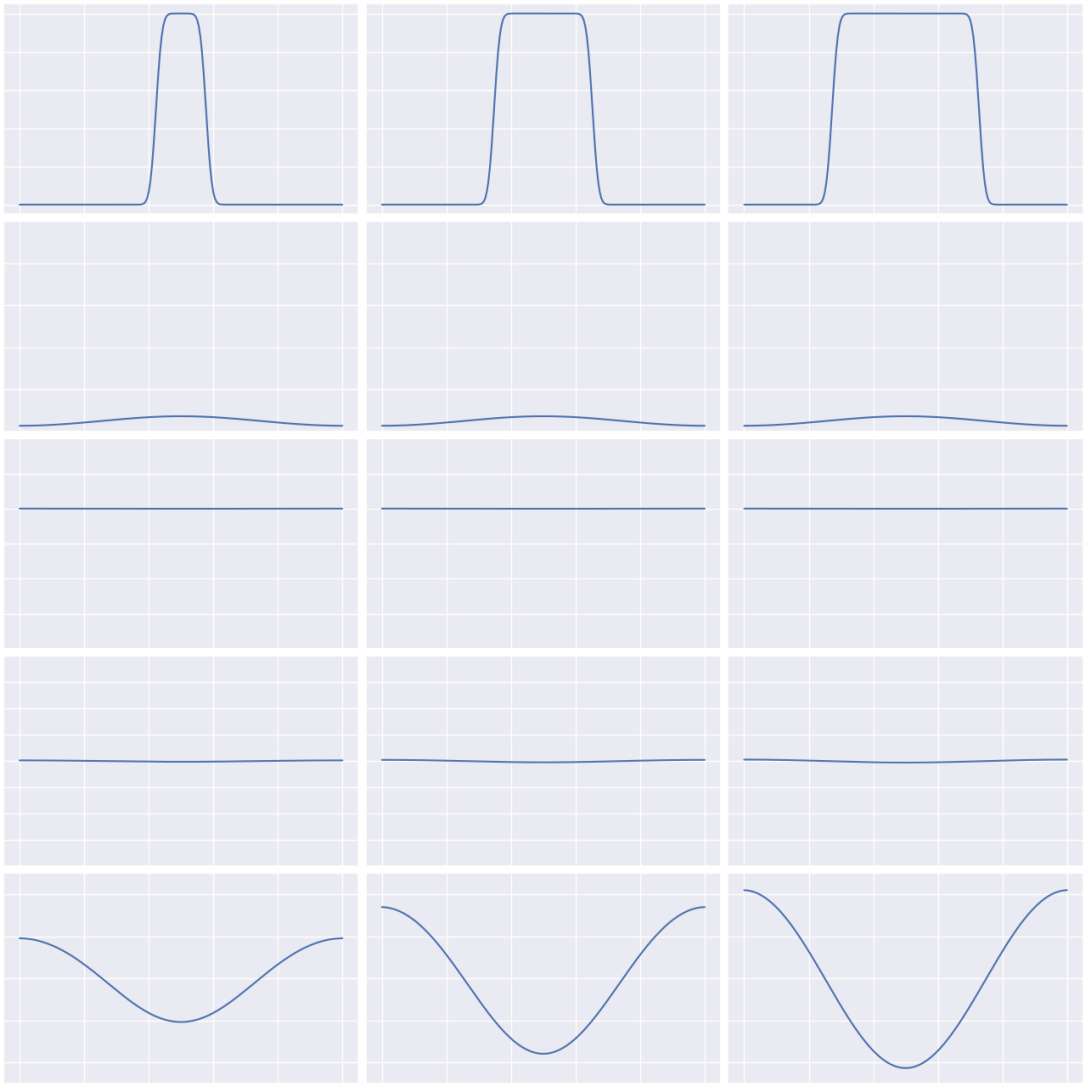
zdroj: https://fpcv.cs.columbia.edu/

1D blob a druhá derivace gaussiánu



zdroj: https://fpcv.cs.columbia.edu/

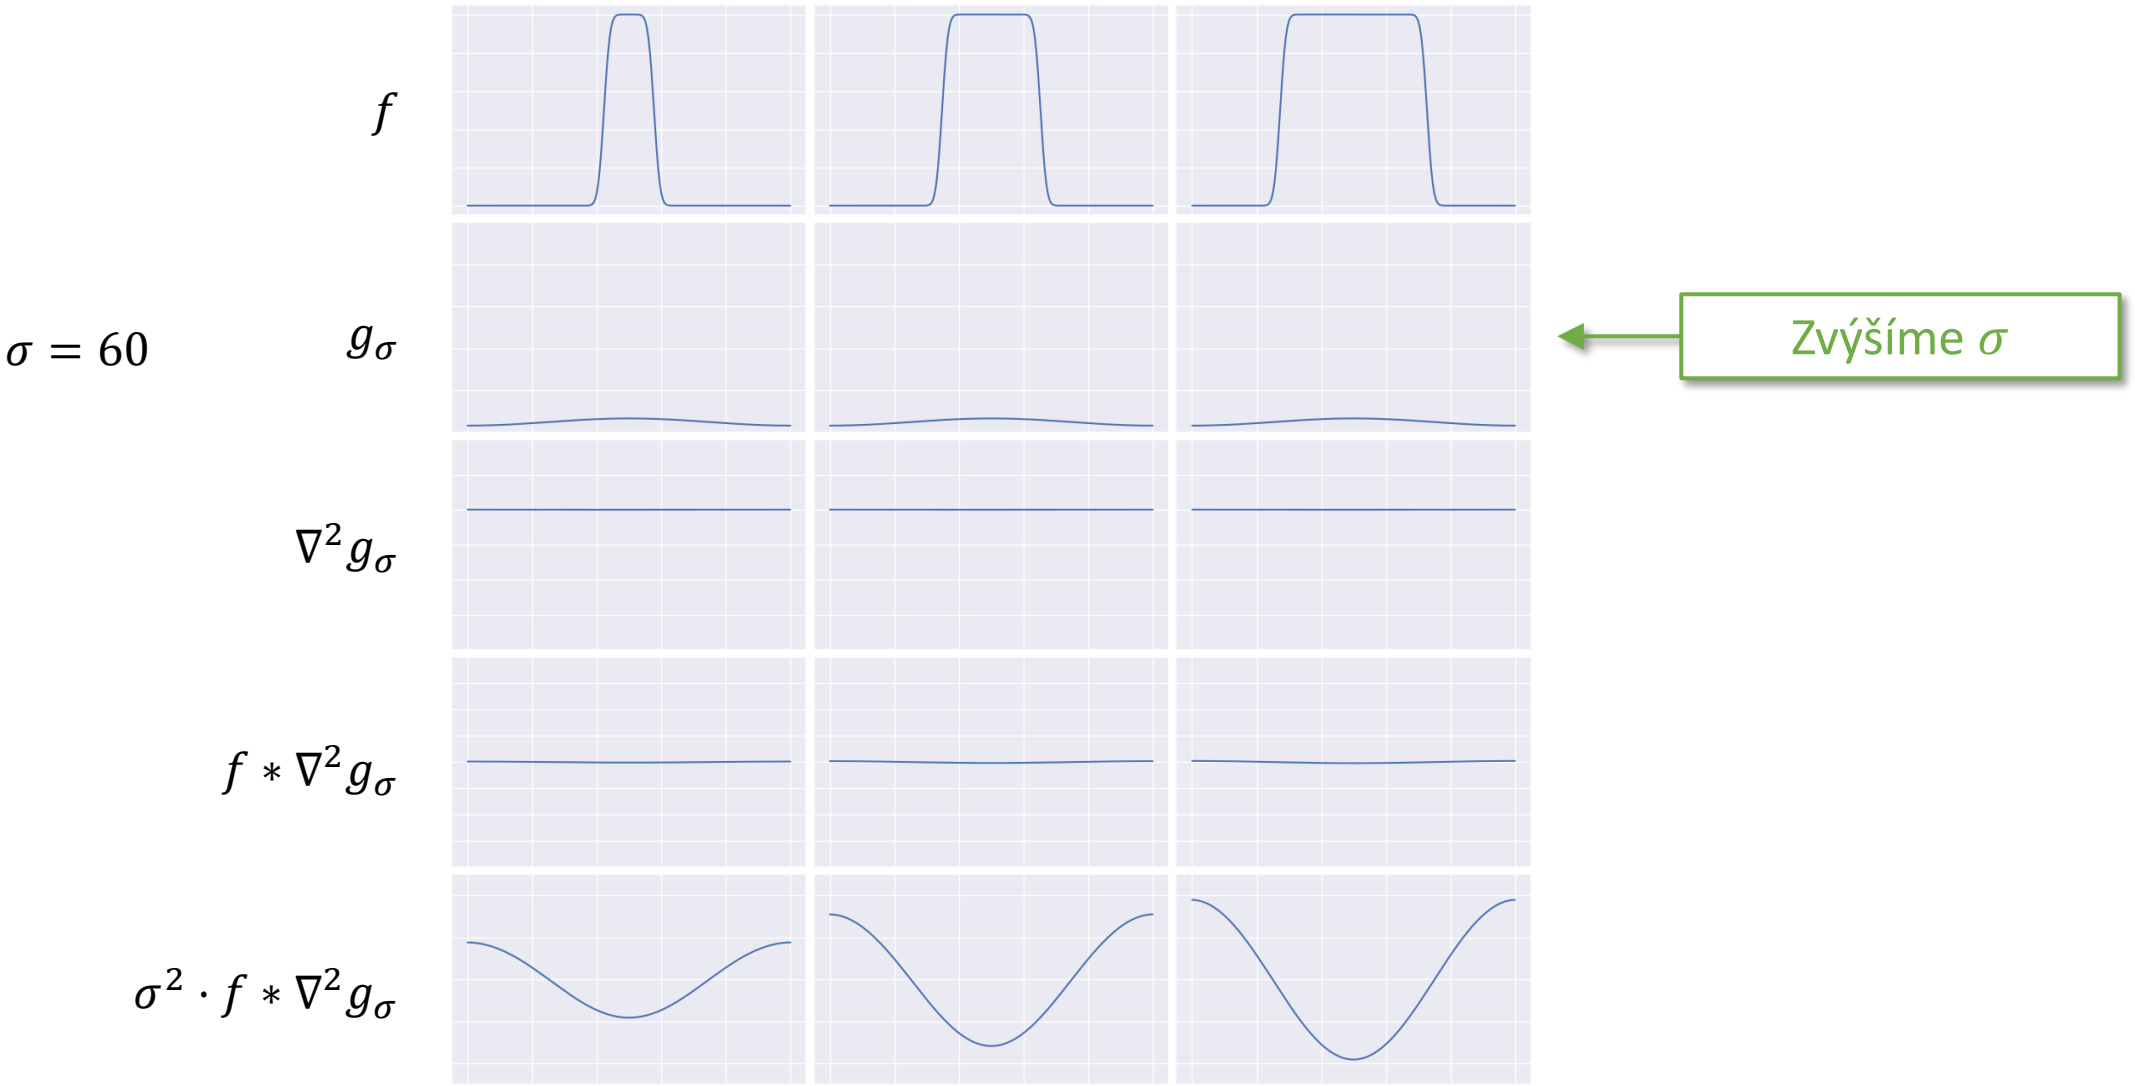
1D blob a druhá derivace gaussiánu



Zvýšíme σ

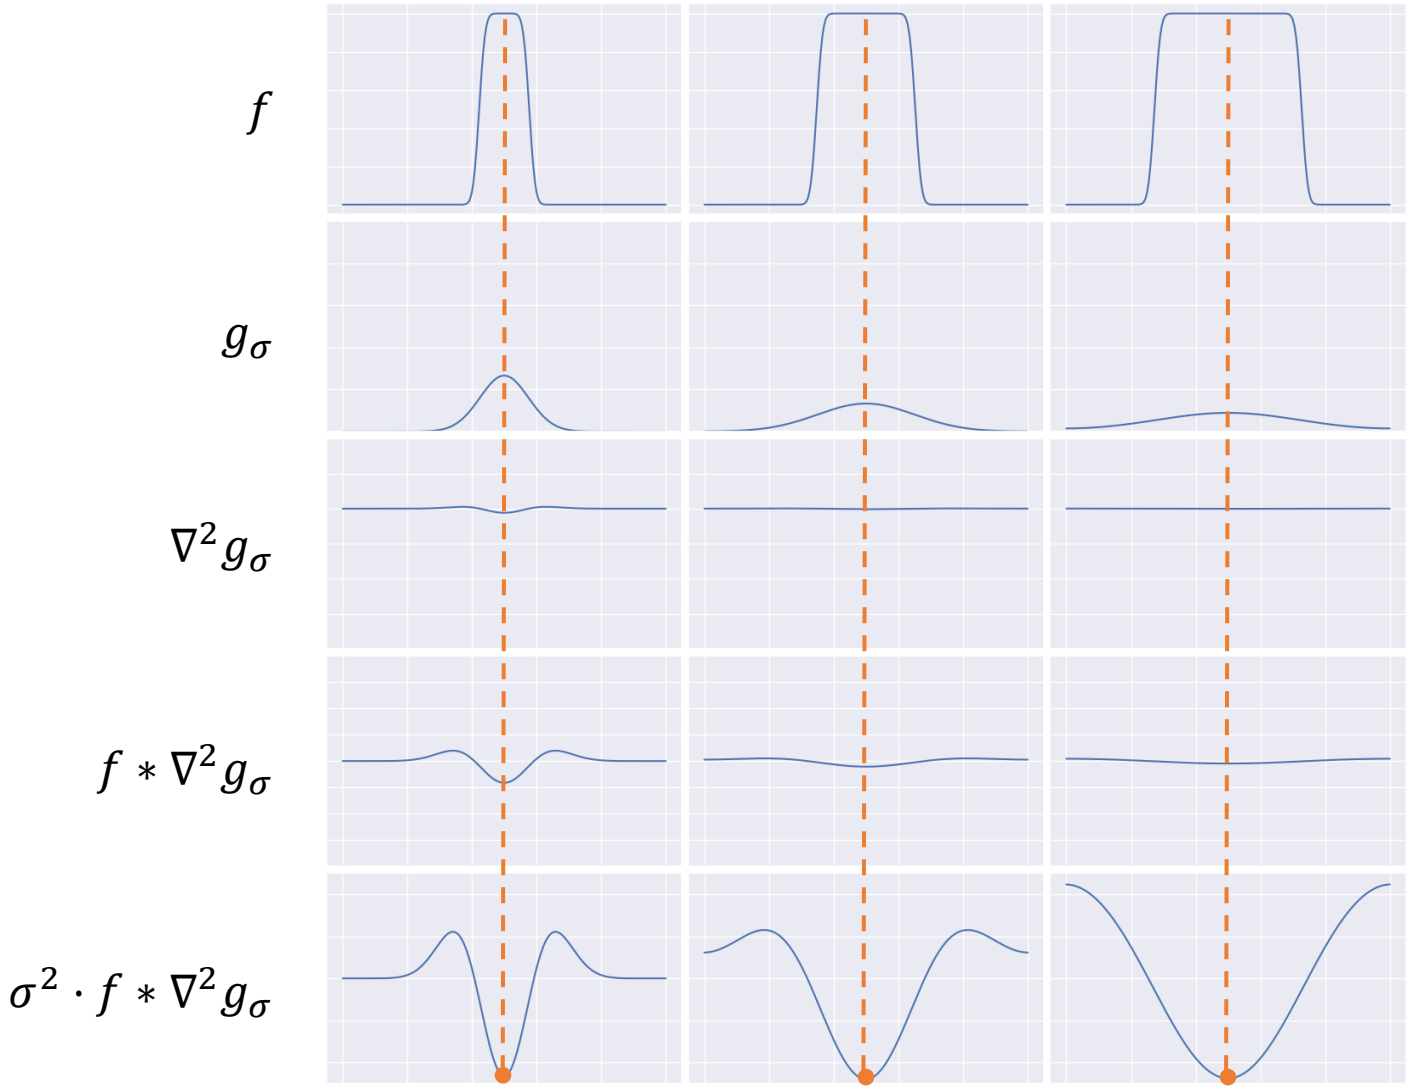
zdroj: https://fpcv.cs.columbia.edu/

1D blob a druhá derivace gaussiánu



zdroj: https://fpcv.cs.columbia.edu/

1D blob a druhá derivace gaussiánu

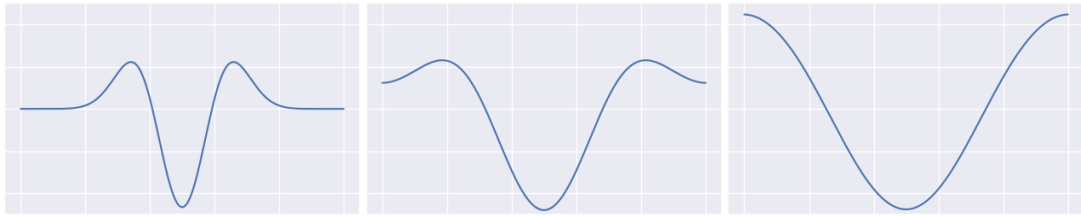


Zvýšíme σ

Bloby jsou lokalizovány pozicí a měřítkem = tzv. prostor měřítek (scale space)

zdroj: https://fpcv.cs.columbia.edu/

1D blob a druhá derivace gaussiánu



(x_A, σ_A) (x_B, σ_B) (x_C, σ_C)

$x_{\{A,B,C\}}$ … **Pozice blobu** v prostoru (v obraze pokud 2D)

$\sigma_{\{A,B,C\}}$ … **Charakteristické měřítko** blobu, tj. σ, pro kterou měřítkem normalizovaná odezva je maximální

Charakteristické měřítko ∝ velikost blobu

zdroj: https://fpcv.cs.columbia.edu/

Detekce blobů v 1D

1. Máme jednorozměrnou funkci $f(x)$
2. Vytvoříme norm. odezvu přes prostor měřítek $\nabla^2_{\text{norm}} L(x, \sigma) = \sigma^2 \cdot f(x) * \nabla^2 g_\sigma(x)$
   - pro $\sigma \in (\sigma_0, \sigma_1, \sigma_2, \dots, \sigma_S)$
   - $\nabla^2_{\text{norm}} L(x, \sigma)$ je dvourozměrný "obraz"
3. Nalezneme lokální maxima (x_i^*, σ_i^*) v $|L(x, \sigma)|$
   - x_i^* je pozice i-tého blobu
   - σ_i^* je charakteristické měřítko blobu (velikost)

Detekce blobů ve 2D

- Ve 2D je operátor $\nabla^2 g_\sigma(x)$ nahrazen tzv. Laplaciánem Gaussiánu (Laplacian of Gaussian, LoG)
- 2D gaussovská funkce je

$$L(x, y, \sigma) = g_\sigma(x, y) = \frac{1}{2\pi\sigma} \cdot e^{-\frac{x^2+y^2}{\sigma^2}}$$

- Laplacián je operace

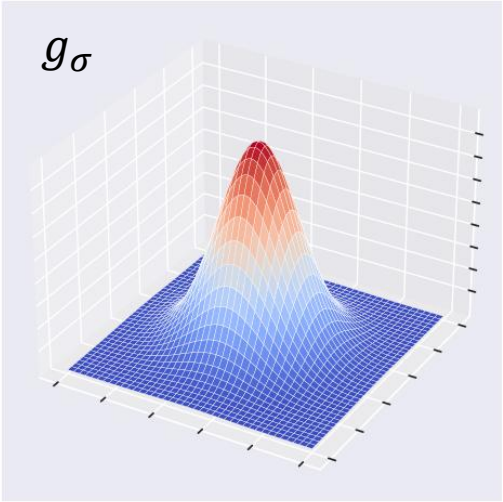
$$\nabla^2 = \frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2}$$

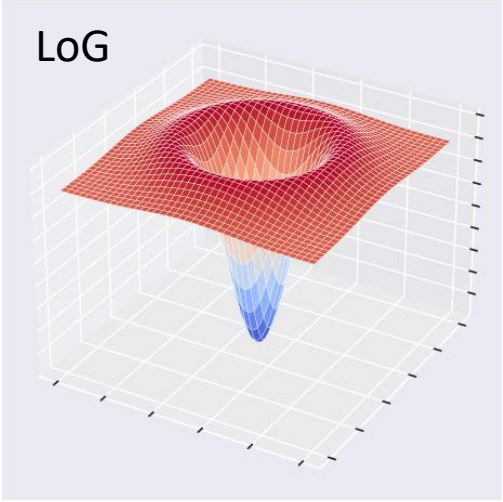
- LoG je

$$\nabla^2 g_\sigma = \frac{1}{\pi\sigma^4} \cdot \left(\frac{x^2 + y^2}{2\sigma^2} - 1 \right) \cdot e^{-\frac{x^2+y^2}{2\sigma^2}}$$
$$= L_{xx}(x, y, \sigma) + L_{yy}(x, y, \sigma)$$

kde

$$L_{xx} = \frac{\partial^2 L}{\partial x^2} \quad L_{yy} = \frac{\partial^2 L}{\partial y^2}$$





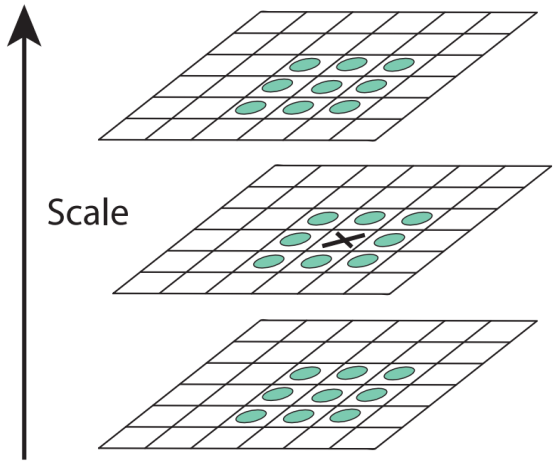
Detekce blobů ve 2D

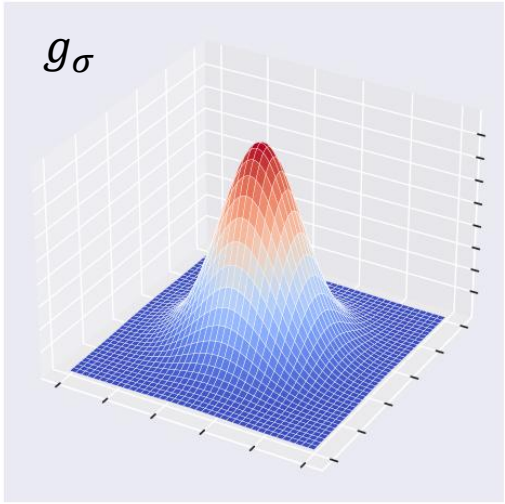
1. Obrázek $I(x, y)$ konvolvujeme s LoG filtry $\nabla^2 g_\sigma$ s různými

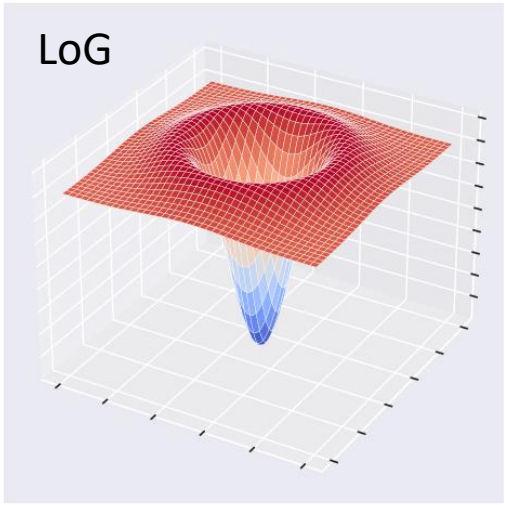
   $\sigma = \sigma_1, \ldots, \sigma_S$

   $$\nabla^2_{\text{norm}} L(x, y, \sigma) = \sigma^2 \cdot I(x, y) * \nabla^2 g_\sigma$$

2. Bloby, tj. jejich pozice a velikost, najdeme lokální maxima funkce $\nabla^2_{\text{norm}} L(x, y, \sigma)$

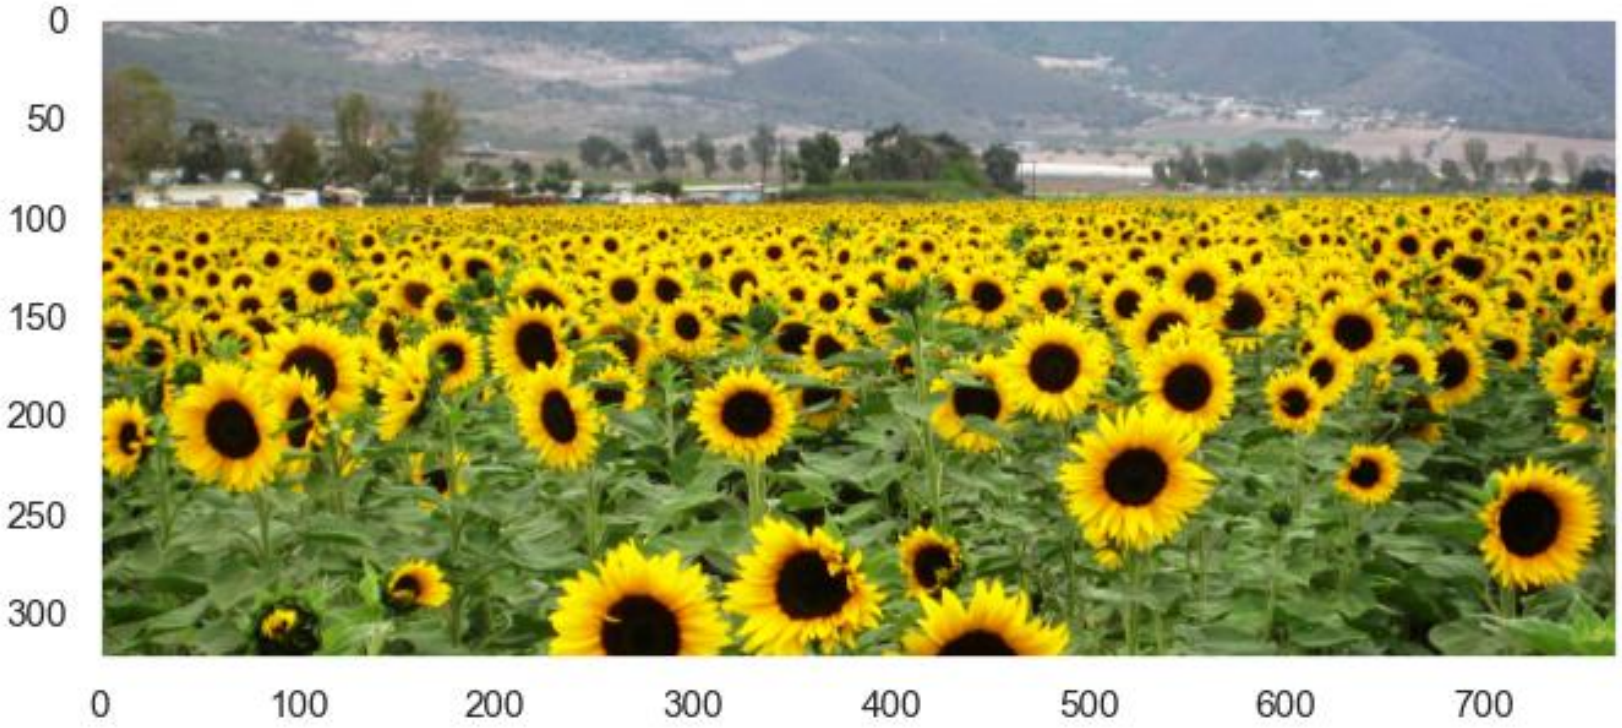






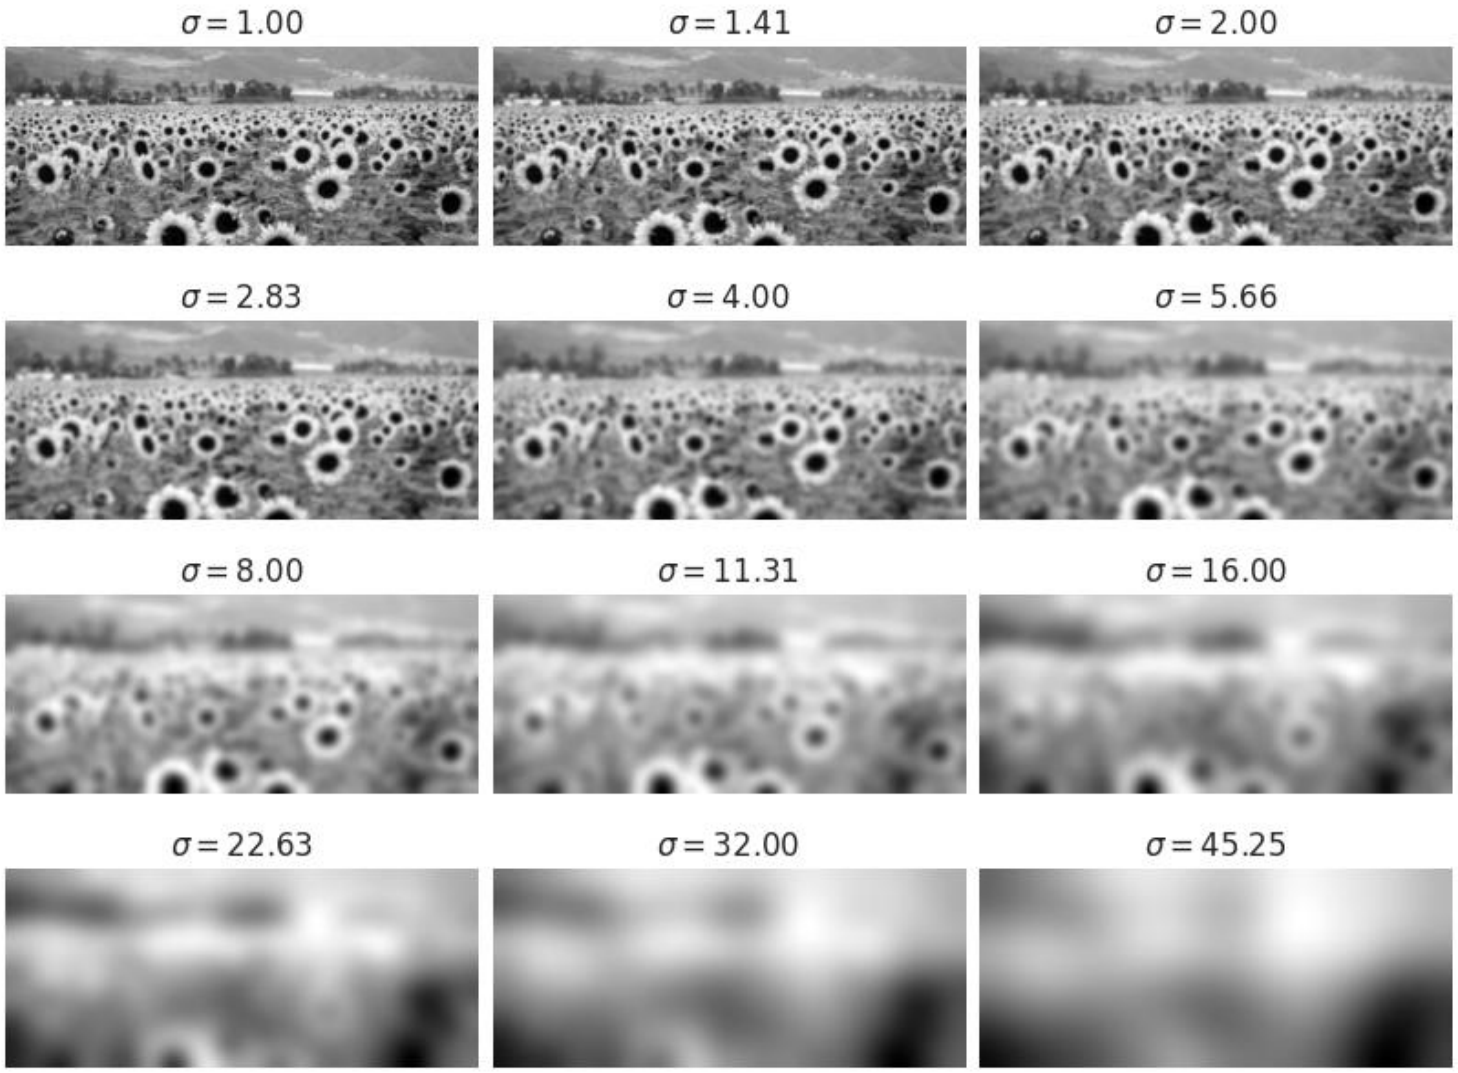
zdroj: https://www.cs.ubc.ca/~lowe/papers/ijcv04.pdf

Příklad



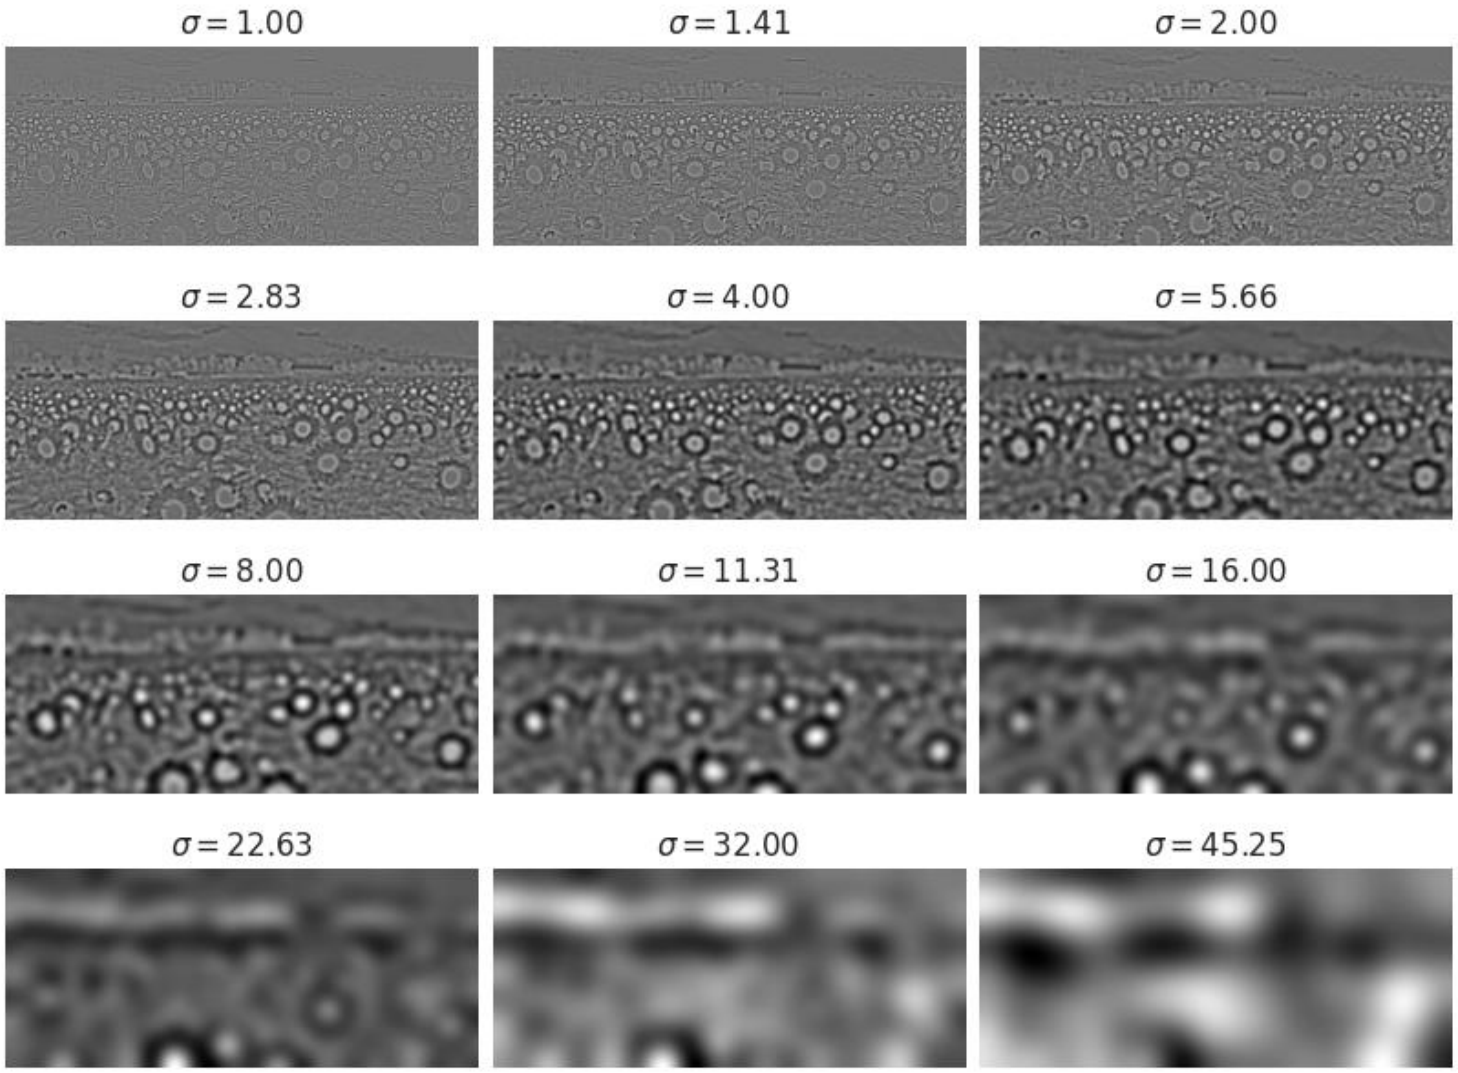
Prostor měřítek: $\sigma_k = \sigma_0 \cdot s^k$ (zde $s = \sqrt{2}$)

$L(x, y, \sigma) =$

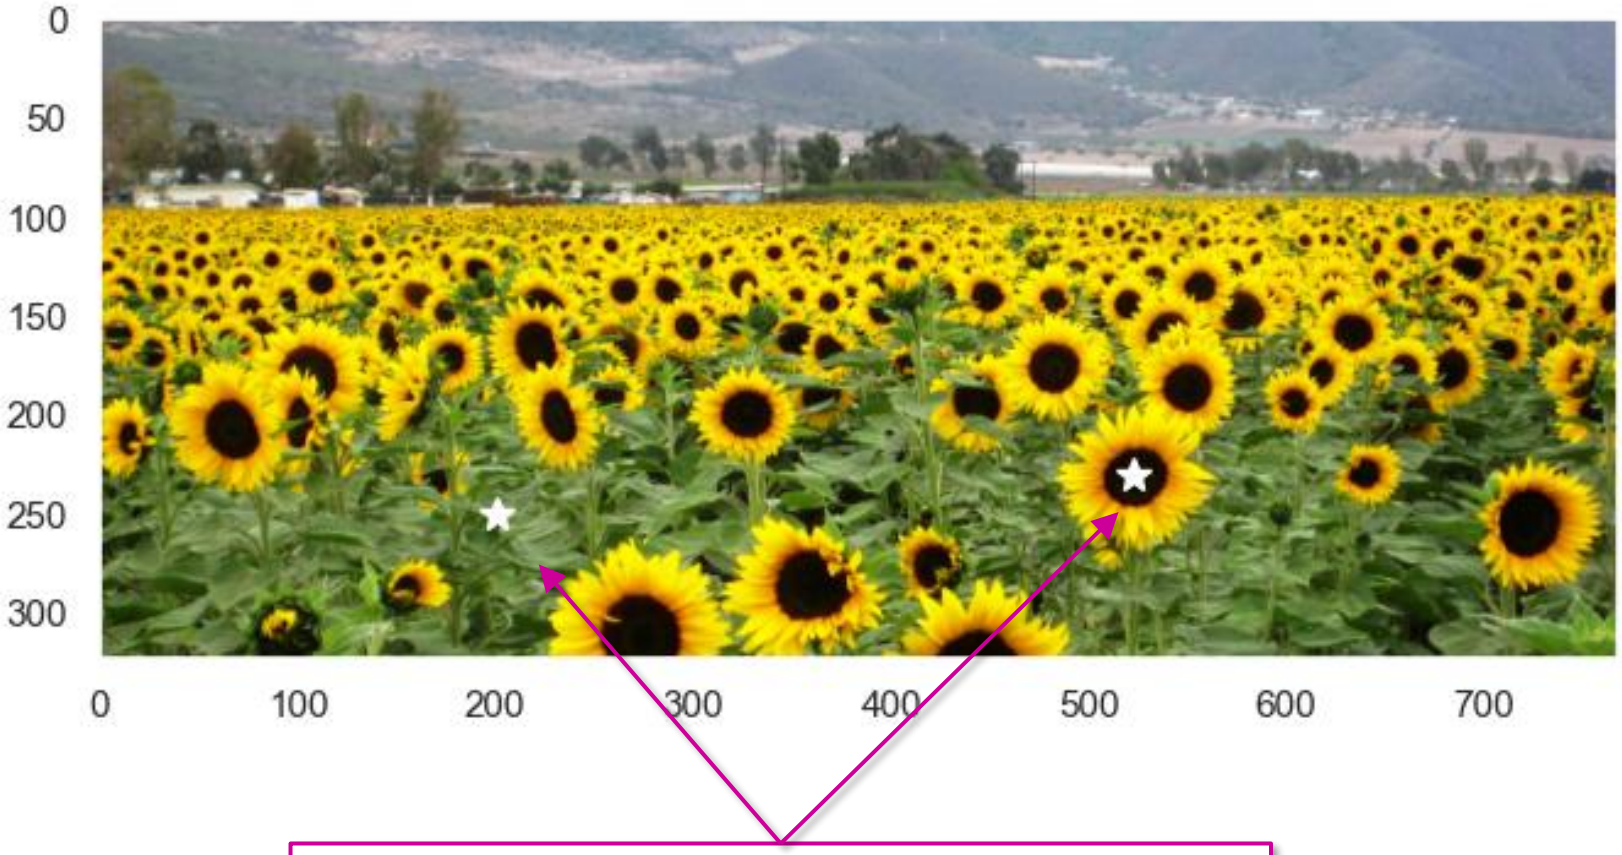


Odezvy na (norm.) LoG filtr pro všechny σ_k z prostoru měřítek

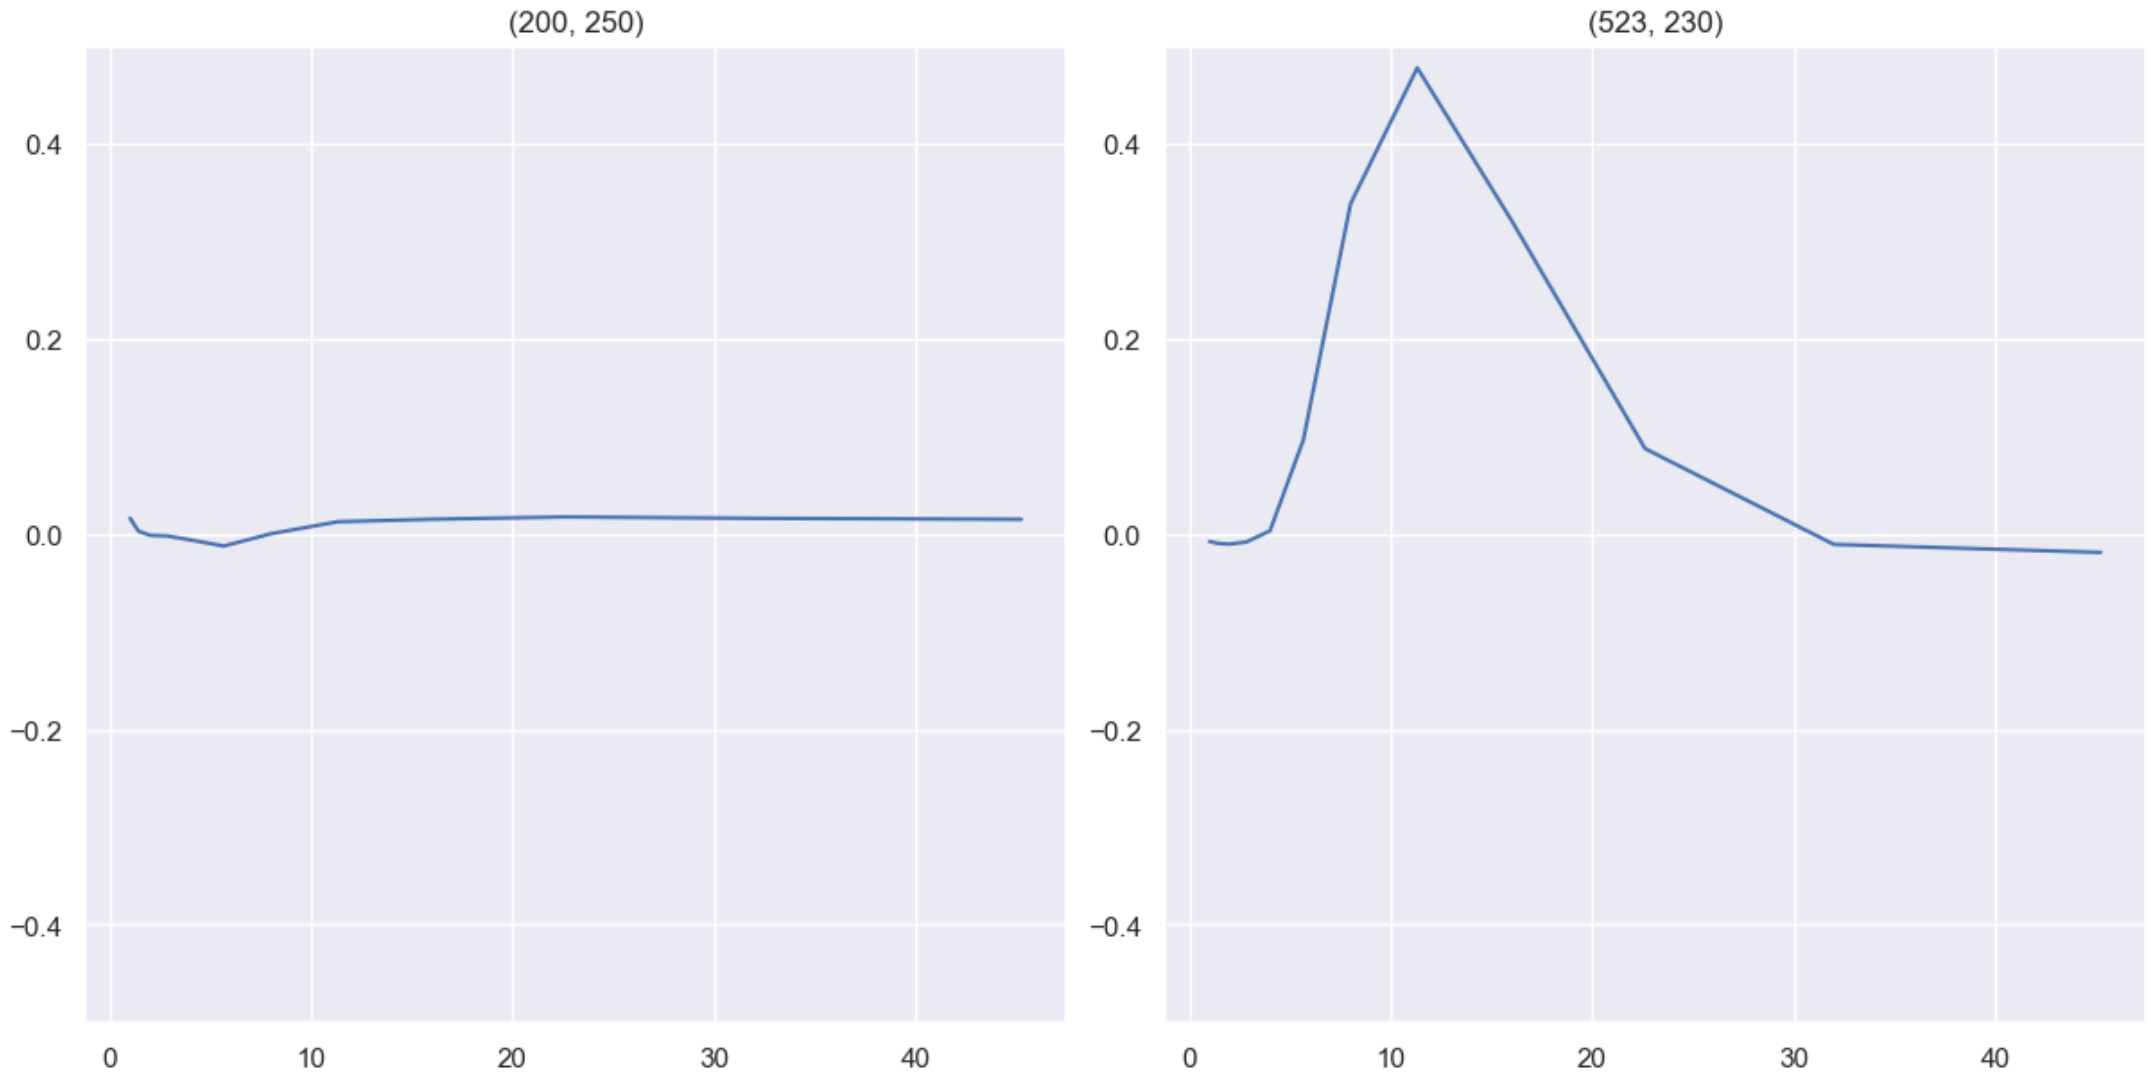
$$\sigma^2 \cdot \nabla^2 L(x, y, \sigma) =$$



Nalezení & prahování lokálních maxim



LoG odezva přes prostor měřítek ve vybraných bodech



Nalezení & prahování lokálních maxim



Další detektory blobů

- Rozdíl Gaussánů jako aproximace LoG

$$\nabla^2_{\text{norm}} L(x, y, \sigma) \approx \frac{\sigma}{\Delta\sigma} \cdot \big(L(x, y, \sigma + \Delta\sigma) - L(x, y, \sigma)\big)$$

- Determinant Hessiánu

$$\det H_{\text{norm}} L = \sigma^2 \cdot \left(L_{xx} \cdot L_{yy} - L_{xy}^2\right)$$

kde L_{xx} je druhá parciální derivace prostoru měřítek L podle x