Počítačové vidění

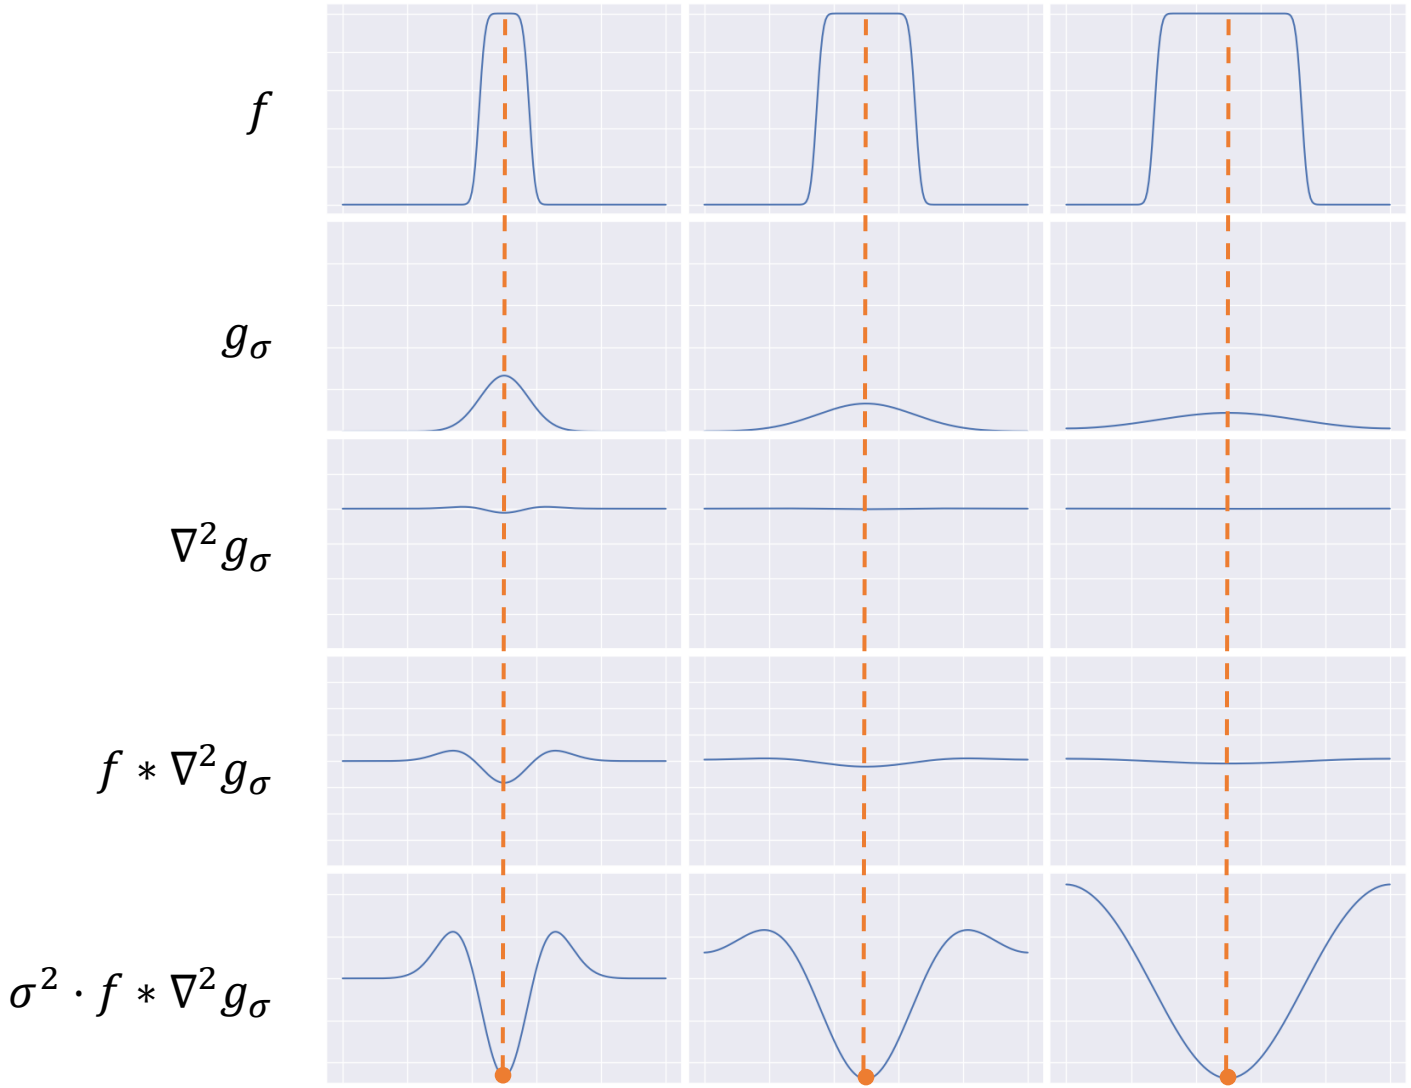
Lokální zájmové body a oblasti II

Minule



slide: https://slazebni.cs.illinois.edu/fall22/

Minule

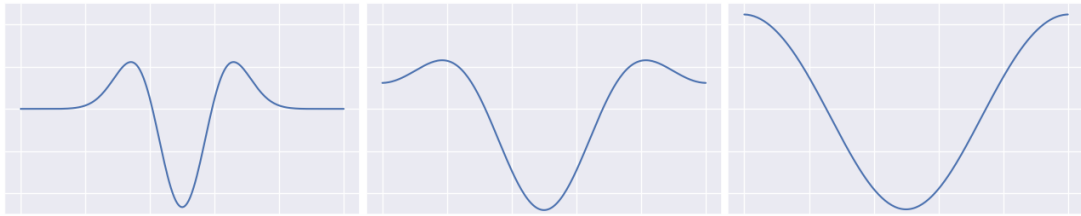


Zvýšíme σ

Bloby jsou lokalizovány pozicí a měřítkem = tzv. prostor měřítek (scale space)

slide: https://fpcv.cs.columbia.edu/

Minule



(x_A, σ_A) (x_B, σ_B) (x_C, σ_C)

$x_{\{A,B,C\}}$ … **Pozice blobu** v prostoru (v obraze pokud 2D)

$\sigma_{\{A,B,C\}}$ … **Charakteristické měřítko** blobu, tj. σ, pro kterou měřítkem normalizovaná odezva je maximální

Charakteristické měřítko ∝ velikost blobu

zdroj: https://fpcv.cs.columbia.edu/

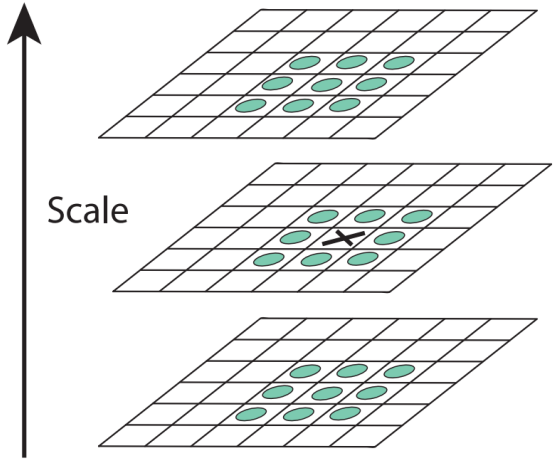
Minule

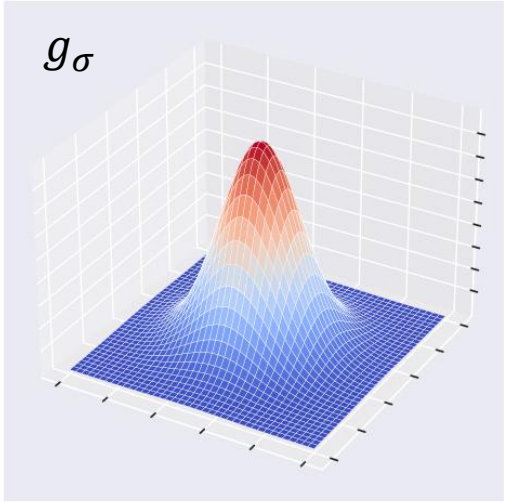
1. Obrázek $I(x, y)$ konvolvujeme s LoG filtry $\nabla^2 g_\sigma$ s různými

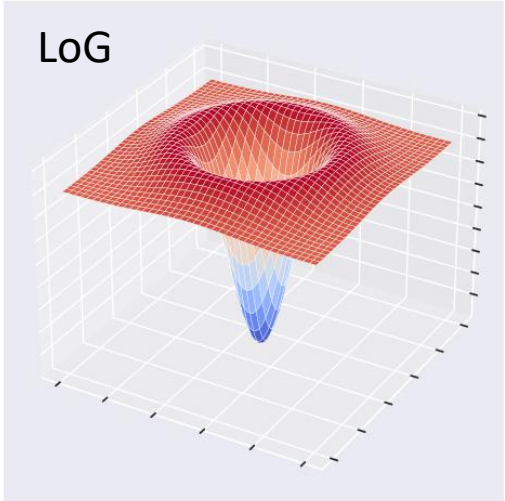
   $\sigma = \sigma_1, \ldots, \sigma_S$

   $$\nabla^2_{\text{norm}} L(x, y, \sigma) = \sigma^2 \cdot I(x, y) * \nabla^2 g_\sigma$$

2. Bloby, tj. jejich pozice a velikost, najdeme lokální maxima funkce $\nabla^2_{\text{norm}} L(x, y, \sigma)$







zdroj: https://www.cs.ubc.ca/~lowe/papers/ijcv04.pdf

Minule



SIFT detektor

Lokální příznaky SIFT (1999)

- Scale Invariant Feature Tranform
- Distinctive image features from scale-invariant keypoints (2004)
- Přes 70000 citací na Google Scholar
- Původní článek z roku 1999 jeden z prvních na téma rozpoznávání podobnosti obrázků na základě korespondence lokálních příznaků
- Velmi úspěšná & robustní metoda

SIFT přehled

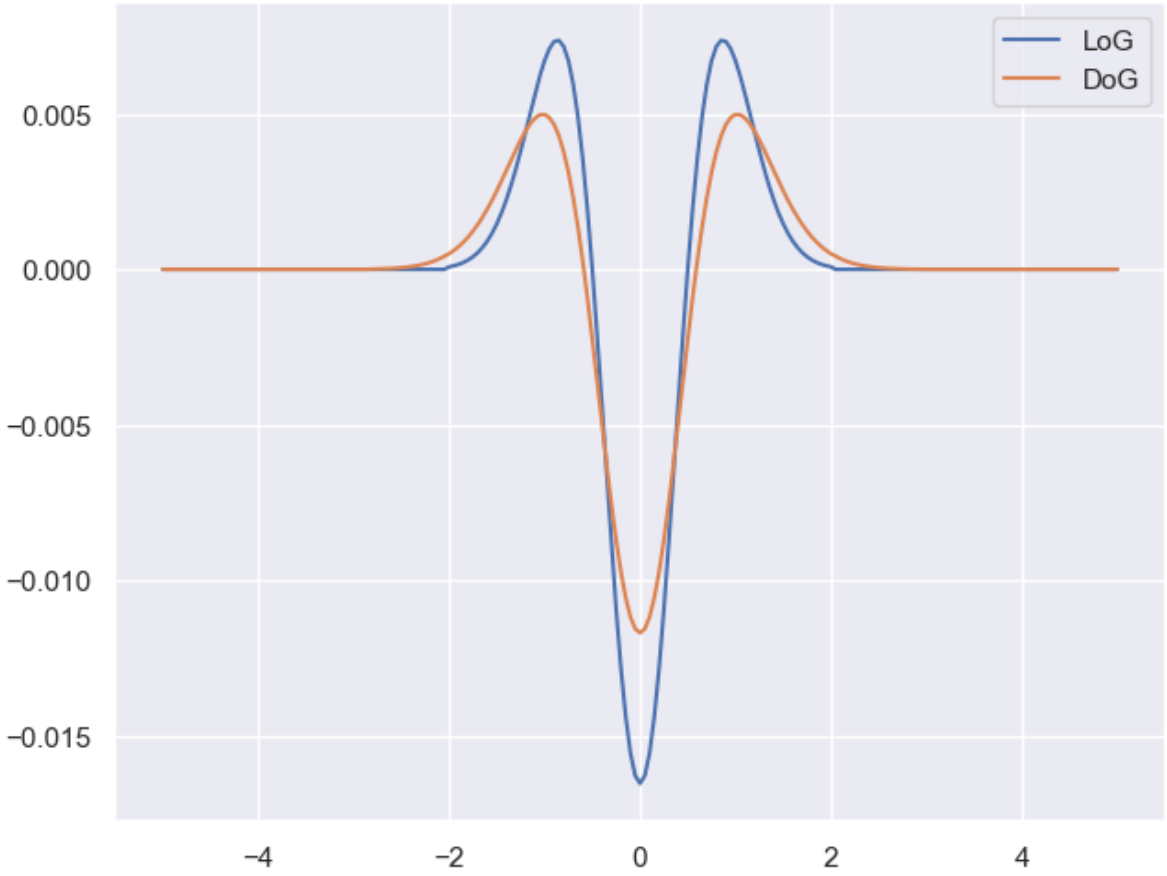
1. Detekce lokálních maxim v prostoru měřítek jako možných zájmových bodů
2. Lokalizace a filtrace zájmových bodů
3. Přiřazení orientace zájmovým bodům
4. Výpočet deskriptorů z okolí zájmových bodů

Detekce: aproximace NLoG rozdílem gaussiánů (DoG)

Laplacian of Gaussians (LoG)

Difference of Gaussians (DoG)

$$(k-1)\cdot\sigma^2\cdot\nabla^2 L(x,y,\sigma) \approx L(x,y,k\cdot\sigma) - L(x,y,\sigma)$$



Detekce: aproximace LoG rozdílem gaussiánů (DoG)

$\sigma_9 = 2 \cdot \sigma_5$ → $\sigma_9 = k^4 \cdot \sigma_5$

⋮

$\sigma_5 = \sigma_4$

$\sigma_4 = 2 \cdot \sigma_0$ → $\sigma_4 = k^4 \cdot \sigma_0$

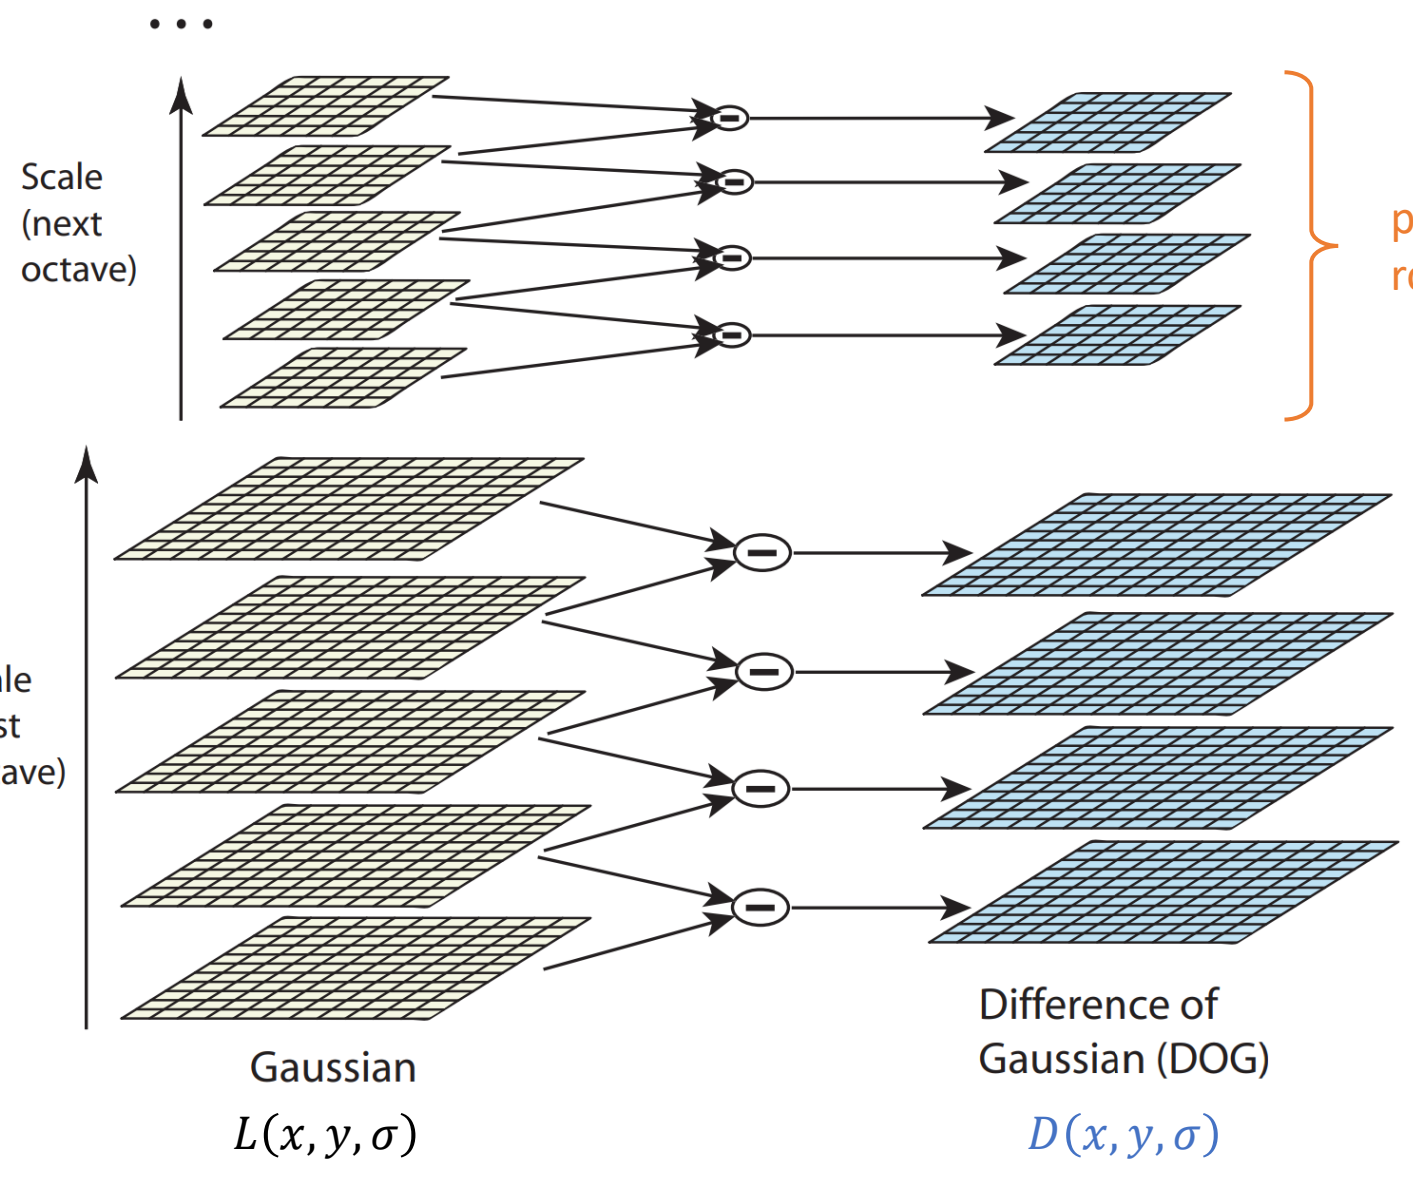
$\sigma_3 = k^3 \cdot \sigma_0$

$k = 2^{\frac{1}{4}}$

$\sigma_2 = k^2 \cdot \sigma_0$

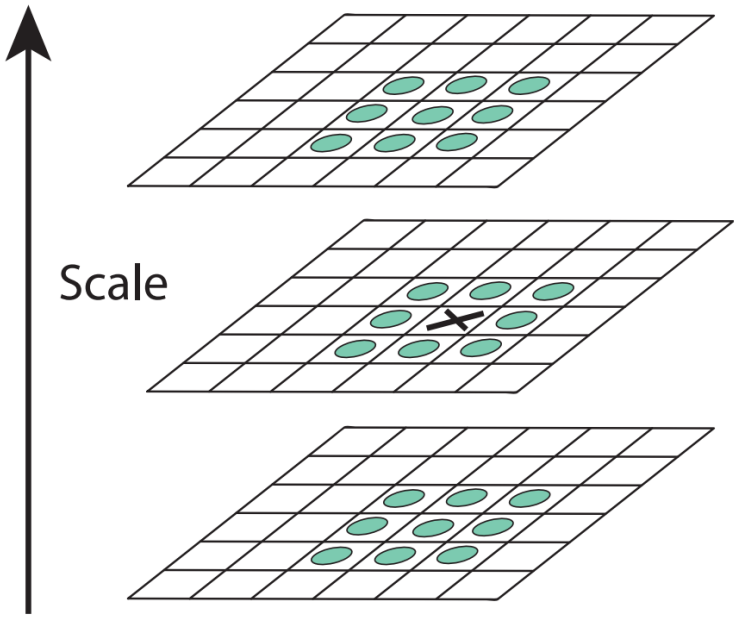
$\sigma_1 = k \cdot \sigma_0$

σ_0



Detekce lokálních maxim v prostoru měřítek

Bod je označen jako kandidát, pokud představuje lokální maximum nebo minimum v okolí 3x3x3



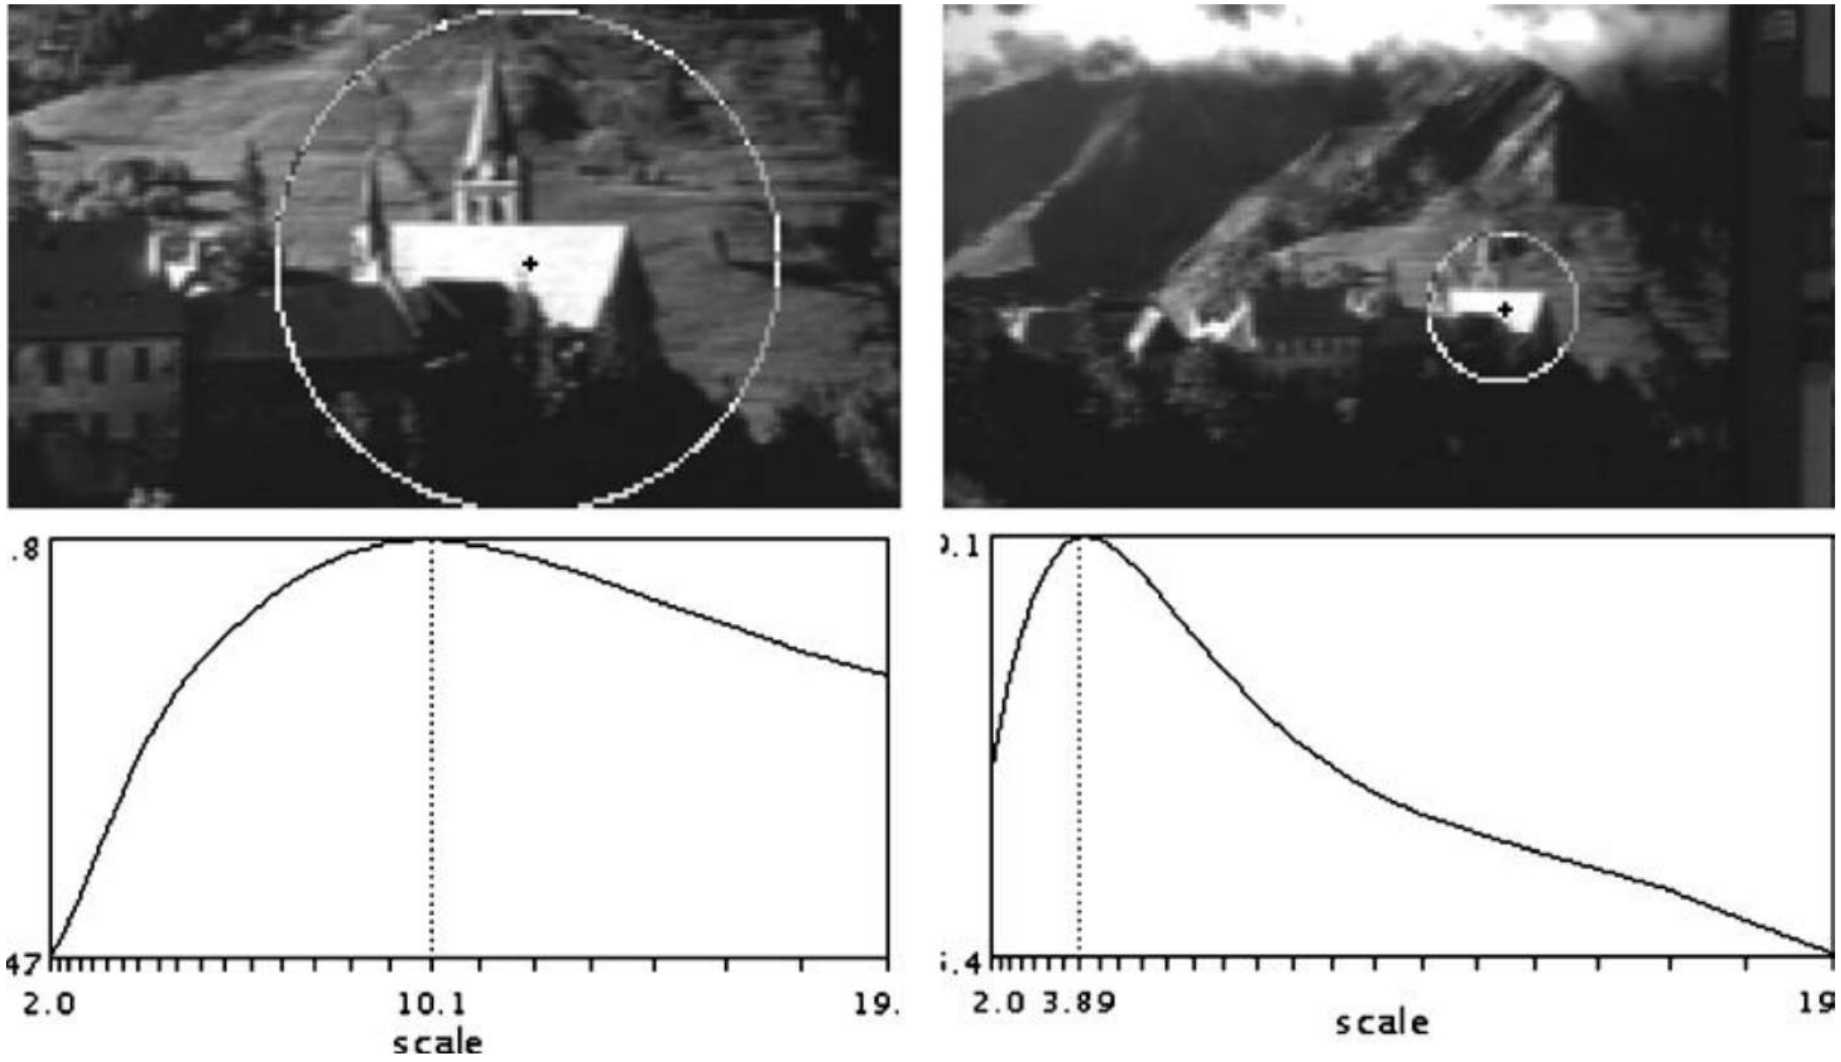
$k \cdot \sigma_k$

σ_k

$k^{-1} \cdot \sigma_k$

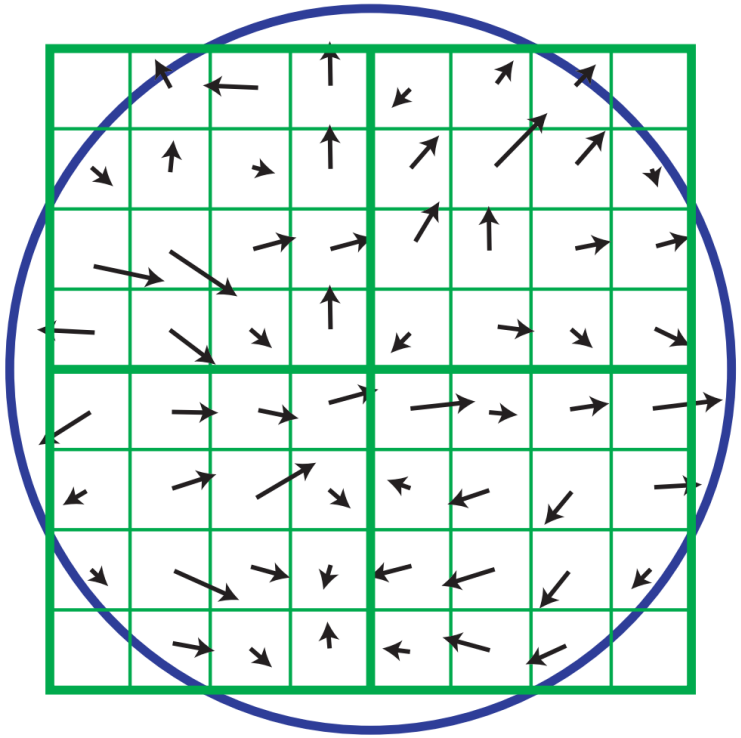
$D(x, y, \sigma)$

Invariance vůči měřítku

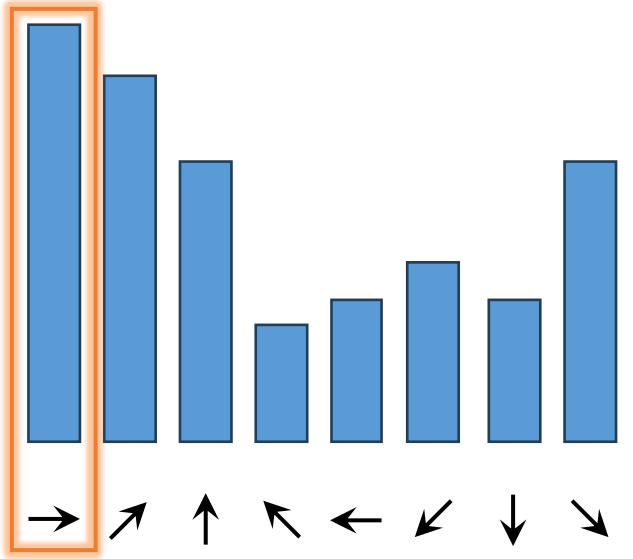


zdroj: Mikolajczyk & Schmid, “Scale & Affine Invariant Interest Point Detectors”

Orientace SIFT zájmových bodů (oblastí)

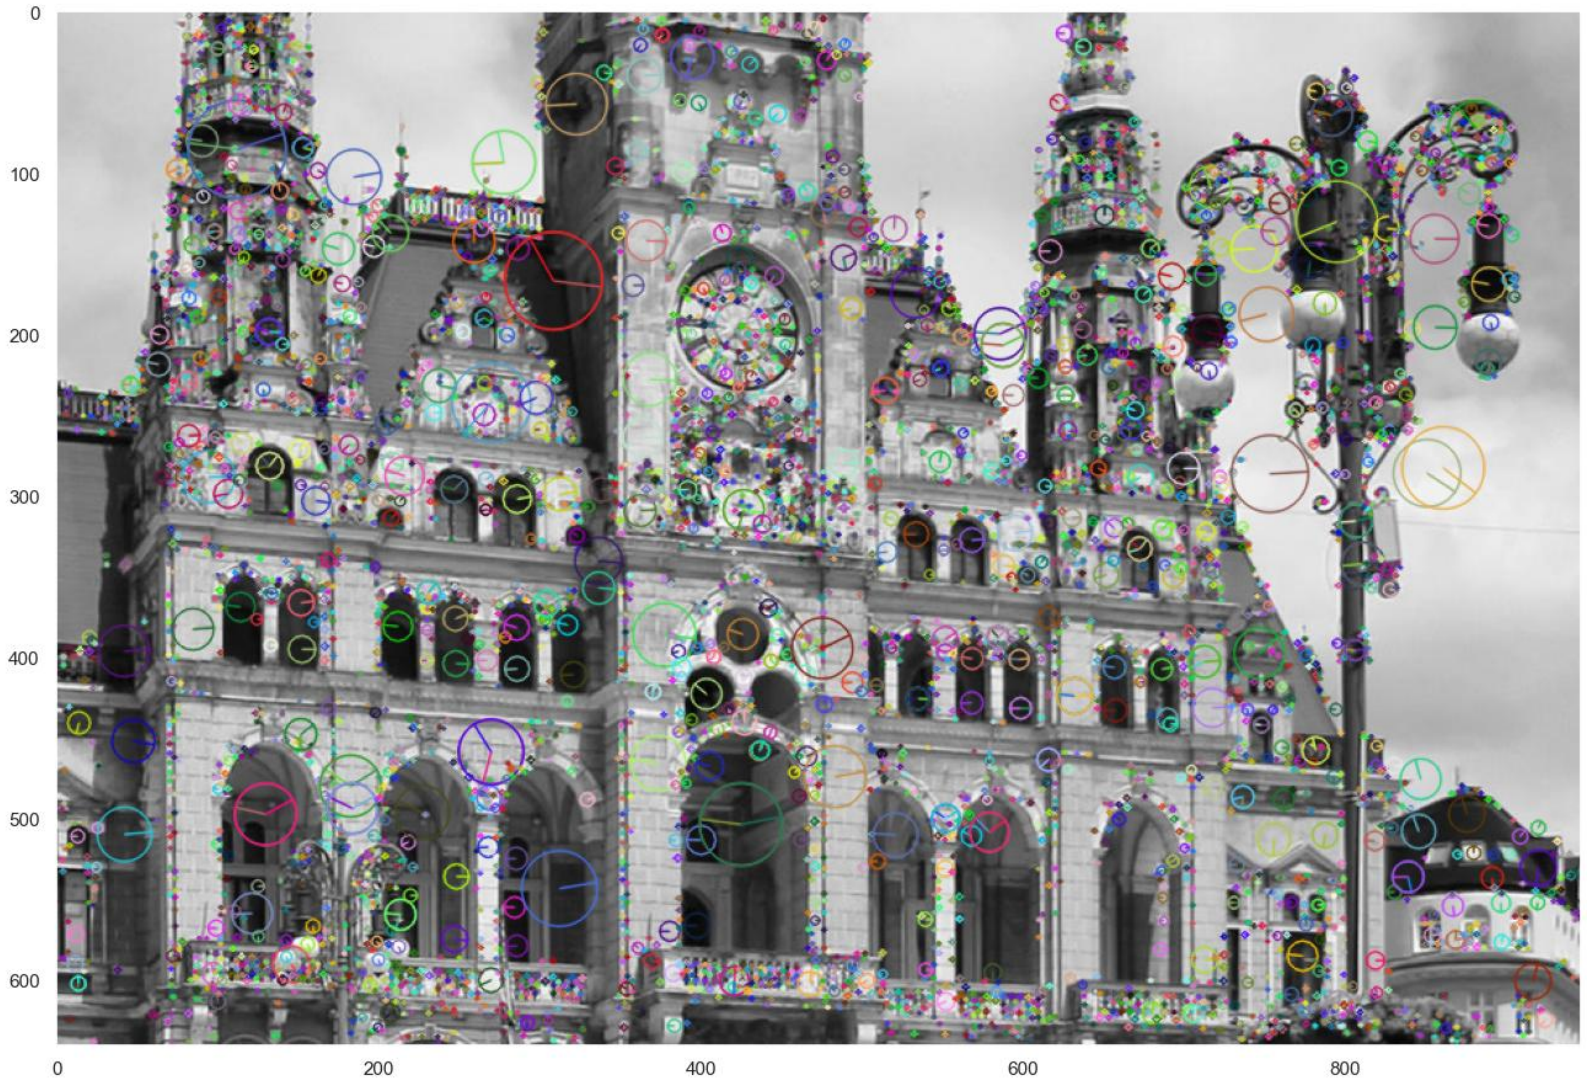


histogram orientací gradientů



položka histogramu s maximální hodnotou určuje orientaci bodu

Příklad detekce SIFT zájmových bodů



Implementační detaily a triky v detektoru SIFT

- Počet úrovní měřítek v oktávě $k = 4$
  - Zjištěno empiricky, body stabilní a opakovatelné
  - Navíc kvůli hledání lokálních extrémů se musí vytvořit $k + 3$ úrovní
  - S každou další oktávou se rozlišení sníží na polovinu, ale přesto nedojde ke ztrátě informace
- Sub-pixelová lokalizace bodů v prostoru i měřítku
  - Okolí každého bodu v D je aproximováno Taylorovým polynomem druhého řádu (paraboloidem)

$$D(\boldsymbol{x}) = D + \frac{\partial D^{\top}}{\partial \boldsymbol{x}} \cdot \boldsymbol{x} + \frac{1}{2} \cdot \boldsymbol{x}^{\top} \cdot \frac{\partial^2 D}{\partial \boldsymbol{x}^2} \cdot \boldsymbol{x}$$

  - Paraboloid má minimum v

$$\boldsymbol{x}^* = -\frac{\partial^2 D^{-1}}{\partial \boldsymbol{x}^2} \cdot \frac{\partial D}{\partial \boldsymbol{x}}$$

Implementační detaily a triky v detektoru SIFT

- Eliminace bodů podél hran
  - Založeno na výpočtu Hessiánu (matice druhých derivací) okolí bodu
  - Bod je ponechán, pouze pokud

$$\frac{\mathrm{trace}(\boldsymbol{H})^2}{\det(\boldsymbol{H})} < \frac{(r+1)^2}{r}$$

    kde $r = 10$ je empiricky zjištěný práh poměru vlastních čísel Hessiánu $\boldsymbol{H}$
- Přiřazení orientace bodům
  - Histogram má 36 binů
  - Každý příspěvek do histogramu je vážen gaussovským oknem se středem nad bodem a $\sigma_g = 1.5 \cdot \sigma$
  - Okolí maxima v histogramu se proloží parabolou a výsledná orientace je pozice jejího maxima
  - Pokud existuje druhé lokální maximum v histogramu, jehož hodnota je 80 % absolutního maxima, je vytvořena kopie bodu na stejné pozici s touto orientací

Implementační detaily a triky v SIFT

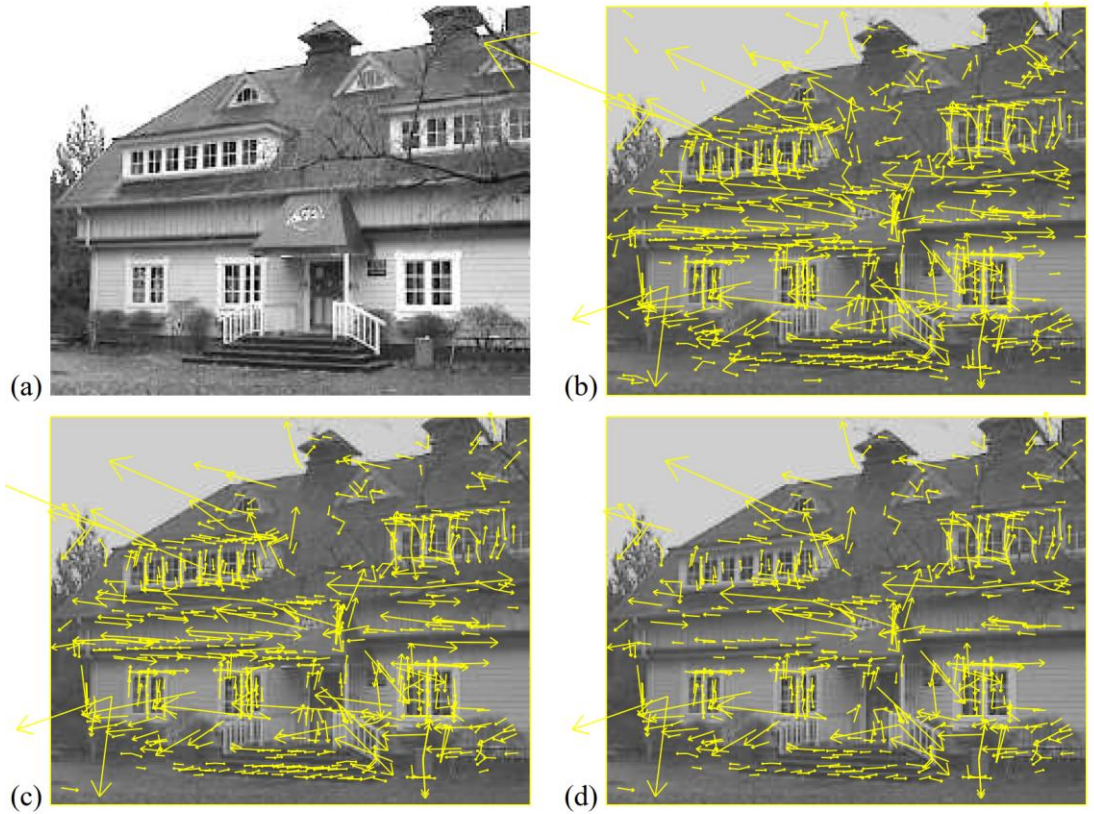


Figure 5: This figure shows the stages of keypoint selection. (a) The 233x189 pixel original image. (b) The initial 832 keypoints locations at maxima and minima of the difference-of-Gaussian function. Keypoints are displayed as vectors indicating scale, orientation, and location. (c) After applying a threshold on minimum contrast, 729 keypoints remain. (d) The final 536 keypoints that remain following an additional threshold on ratio of principal curvatures.

SIFT deskriptor

Histogram orientací gradientů

Okno kolem bodu rozděleno na 4x4 pod-oblastí (zde 2x2)

Příspěvky do histogramů váženy gaussovským oknem (modrá kružnice značí cca $\pm 1\sigma$)

8 binů (orientací) v histogramech

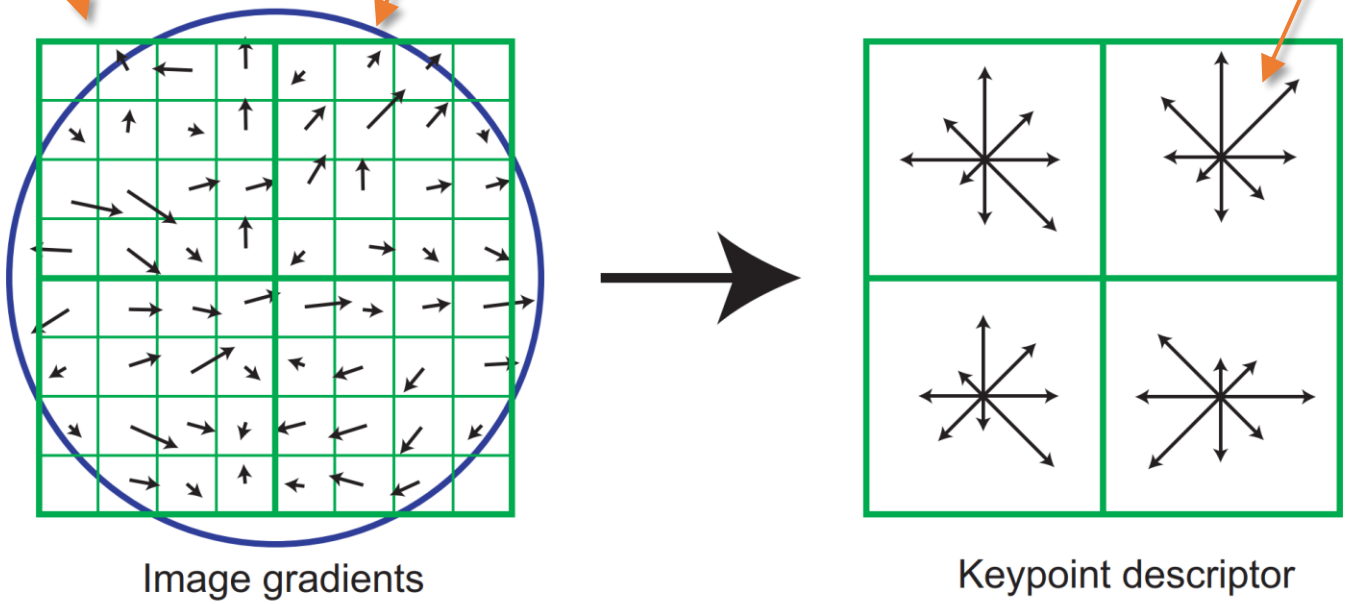


Image gradients

Keypoint descriptor

Gradienty relativně vůči orientaci bodu

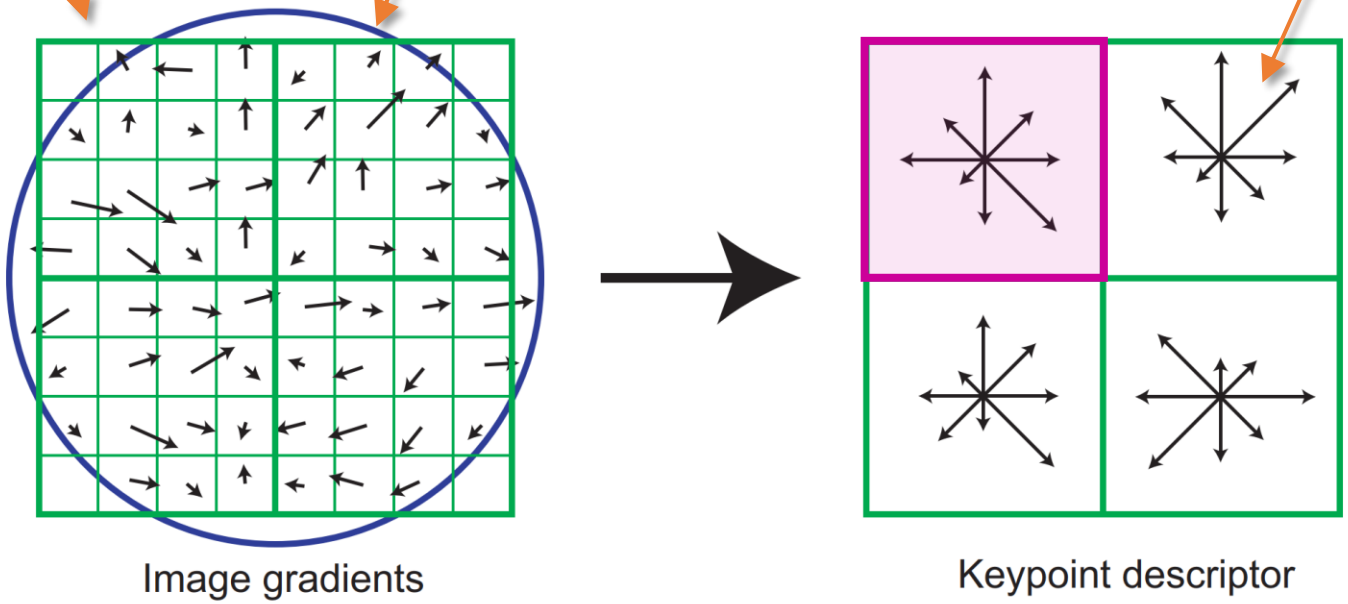
výsledný deskriptor je spojení histogramů pod-oblastí do jednoho vektoru

Histogram orientací gradientů

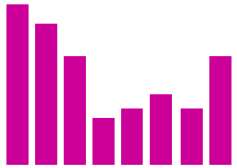
Okno kolem bodu rozděleno na 4x4 pod-oblastí (zde 2x2)

Příspěvky do histogramů váženy gaussovským oknem (modrá kružnice značí cca $\pm 1\sigma$)

8 binů (orientací) v histogramech



Gradienty relativně vůči orientaci bodu



výsledný deskriptor je spojení histogramů pod-oblastí do jednoho vektoru

Histogram orientací gradientů

Okno kolem bodu rozděleno na 4x4 pod-oblastí (zde 2x2)

Příspěvky do histogramů váženy gaussovským oknem (modrá kružnice značí cca $\pm 1\sigma$)

8 binů (orientací) v histogramech

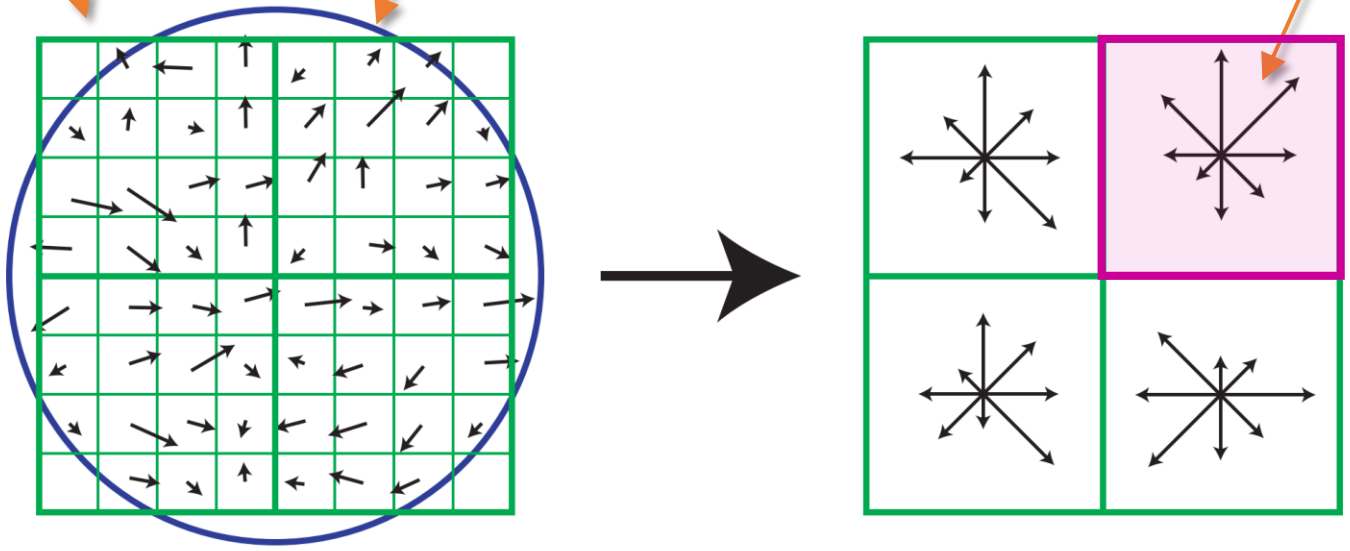
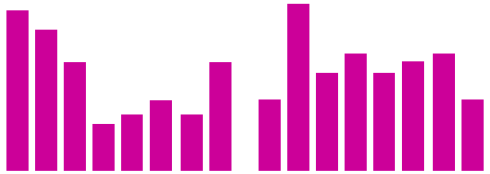


Image gradients

Keypoint descriptor

Gradienty relativně vůči orientaci bodu



výsledný deskriptor je spojení histogramů pod-oblastí do jednoho vektoru

Histogram orientací gradientů

Okno kolem bodu rozděleno na 4x4 pod-oblastí (zde 2x2)

Příspěvky do histogramů váženy gaussovským oknem (modrá kružnice značí cca $\pm 1\sigma$)

8 binů (orientací) v histogramech

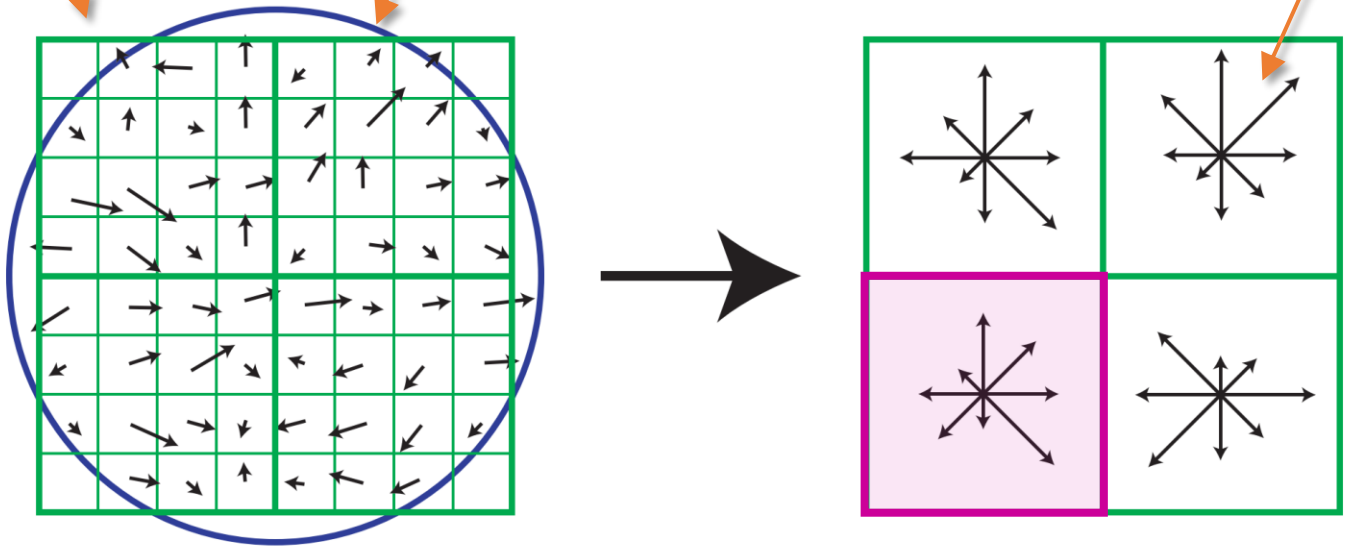
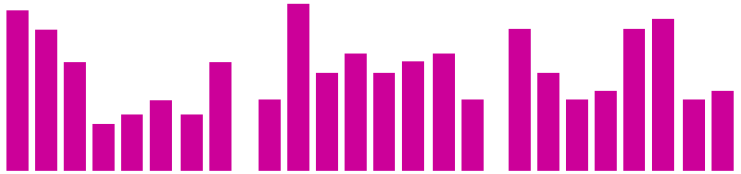


Image gradients

Keypoint descriptor

Gradienty relativně vůči orientaci bodu



výsledný deskriptor je spojení histogramů pod-oblastí do jednoho vektoru

Histogram orientací gradientů

Okno kolem bodu rozděleno na 2x2 pod-oblastí

Příspěvky do histogramů váženy gaussovským oknem (modrá kružnice značí cca $\pm 1\sigma$)

8 binů (orientací) v histogramech

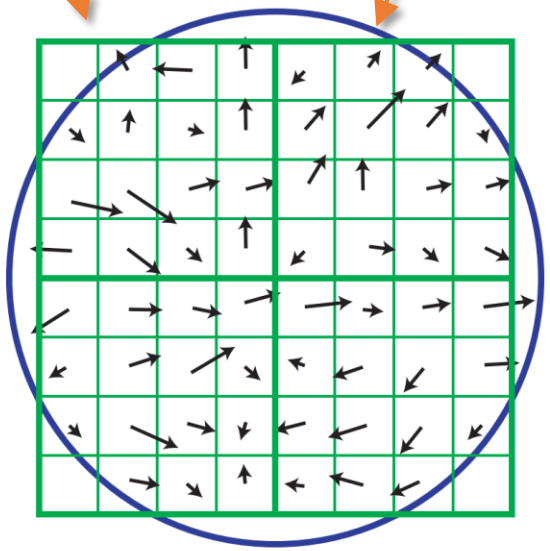
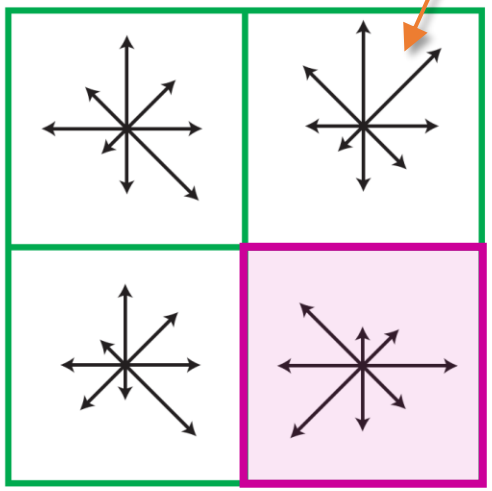


Image gradients

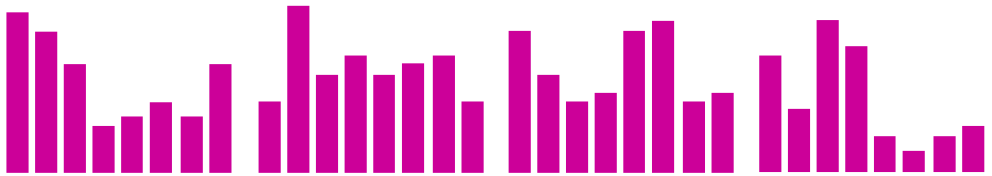


Keypoint descriptor

Celkově 2x2x8=32 “sloupečků”

Gradienty relativně vůči orientaci bodu

$\boldsymbol{d} =$



výsledný deskriptor je spojení histogramů pod-oblastí do jednoho vektoru $\boldsymbol{d} \in \mathbb{R}^{32}$

Implementační detaily a triky v deskriptoru SIFT

- Ve skutečnosti okno rozděleno na 4x4 pod-oblastí → vektor deskriptoru je dlouhý 4x4x8=128
- Příspěvky do gradientu váženy gaussovským oknem
- Pro snížení citlivosti na změny jasu je deskriptor normalizován na jednotkovou délku (normu)

$$\boldsymbol{d}_{\mathrm{norm}} = \frac{\boldsymbol{d}}{\|\boldsymbol{d}\|}$$

→ deskriptor je invariantní vůči afinní změně osvětlení

- Limitace vlivu neuniformní změny osvětlení prahováním prvků

$$\boldsymbol{d}'_{\mathrm{norm}} = \min(\boldsymbol{d}_{\mathrm{norm}}, 0.2)$$

a poté renormalizováním na jednotkovou normu

$$\boldsymbol{d}_{\mathrm{renorm}} = \frac{\boldsymbol{d}'_{\mathrm{norm}}}{\|\boldsymbol{d}'_{\mathrm{norm}}\|}$$

Deskriptory SIFT

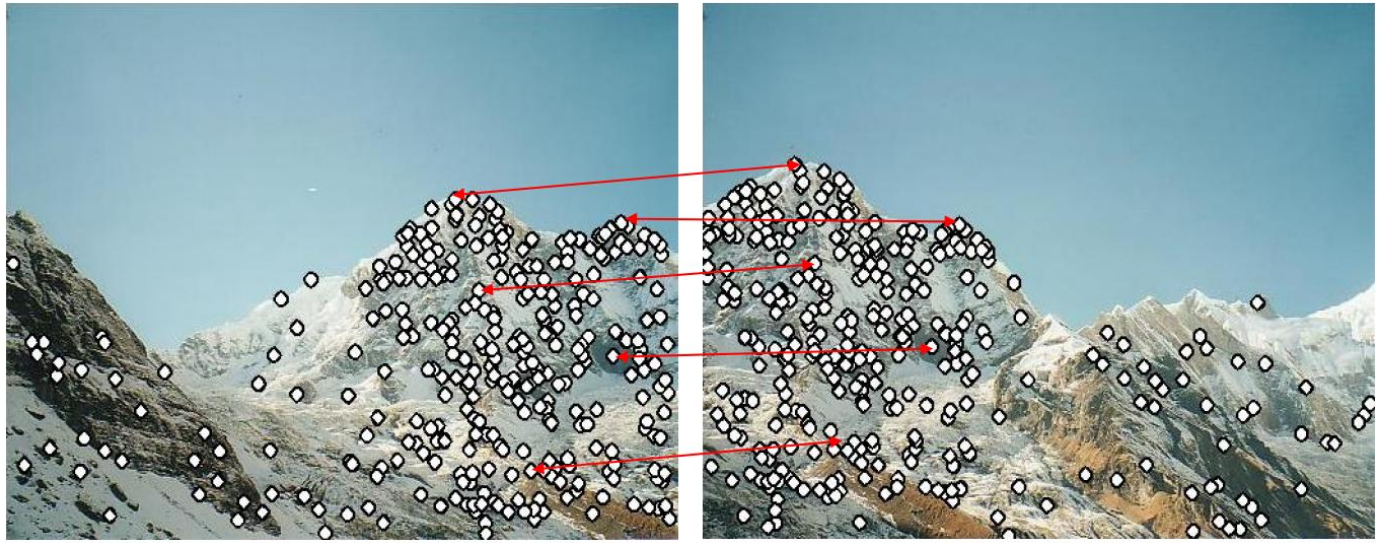




obrázek: https://www.cs.cornell.edu/courses/cs5670/2023sp/

Lokální korespondene mezi obrazy

Lokální korespondence



- Abychom mohli např. zarovnat obrazy, potřebujeme vědět, který zájmový bod na obraze 1 odpovídá jakému v obraze 2
- Nejjednodušší postup je hladový algoritmus, kdy ke každému $\boldsymbol{x}_q$ z "query" obrazu 1 přiřadíme nejpodobnější $\boldsymbol{x}$ z obrazu 2
- (Ne)podobnost může být např. L2 vzdálenost

$$d(\boldsymbol{x}_q, \boldsymbol{x}) = \|\boldsymbol{x}_q - \boldsymbol{x}\|$$

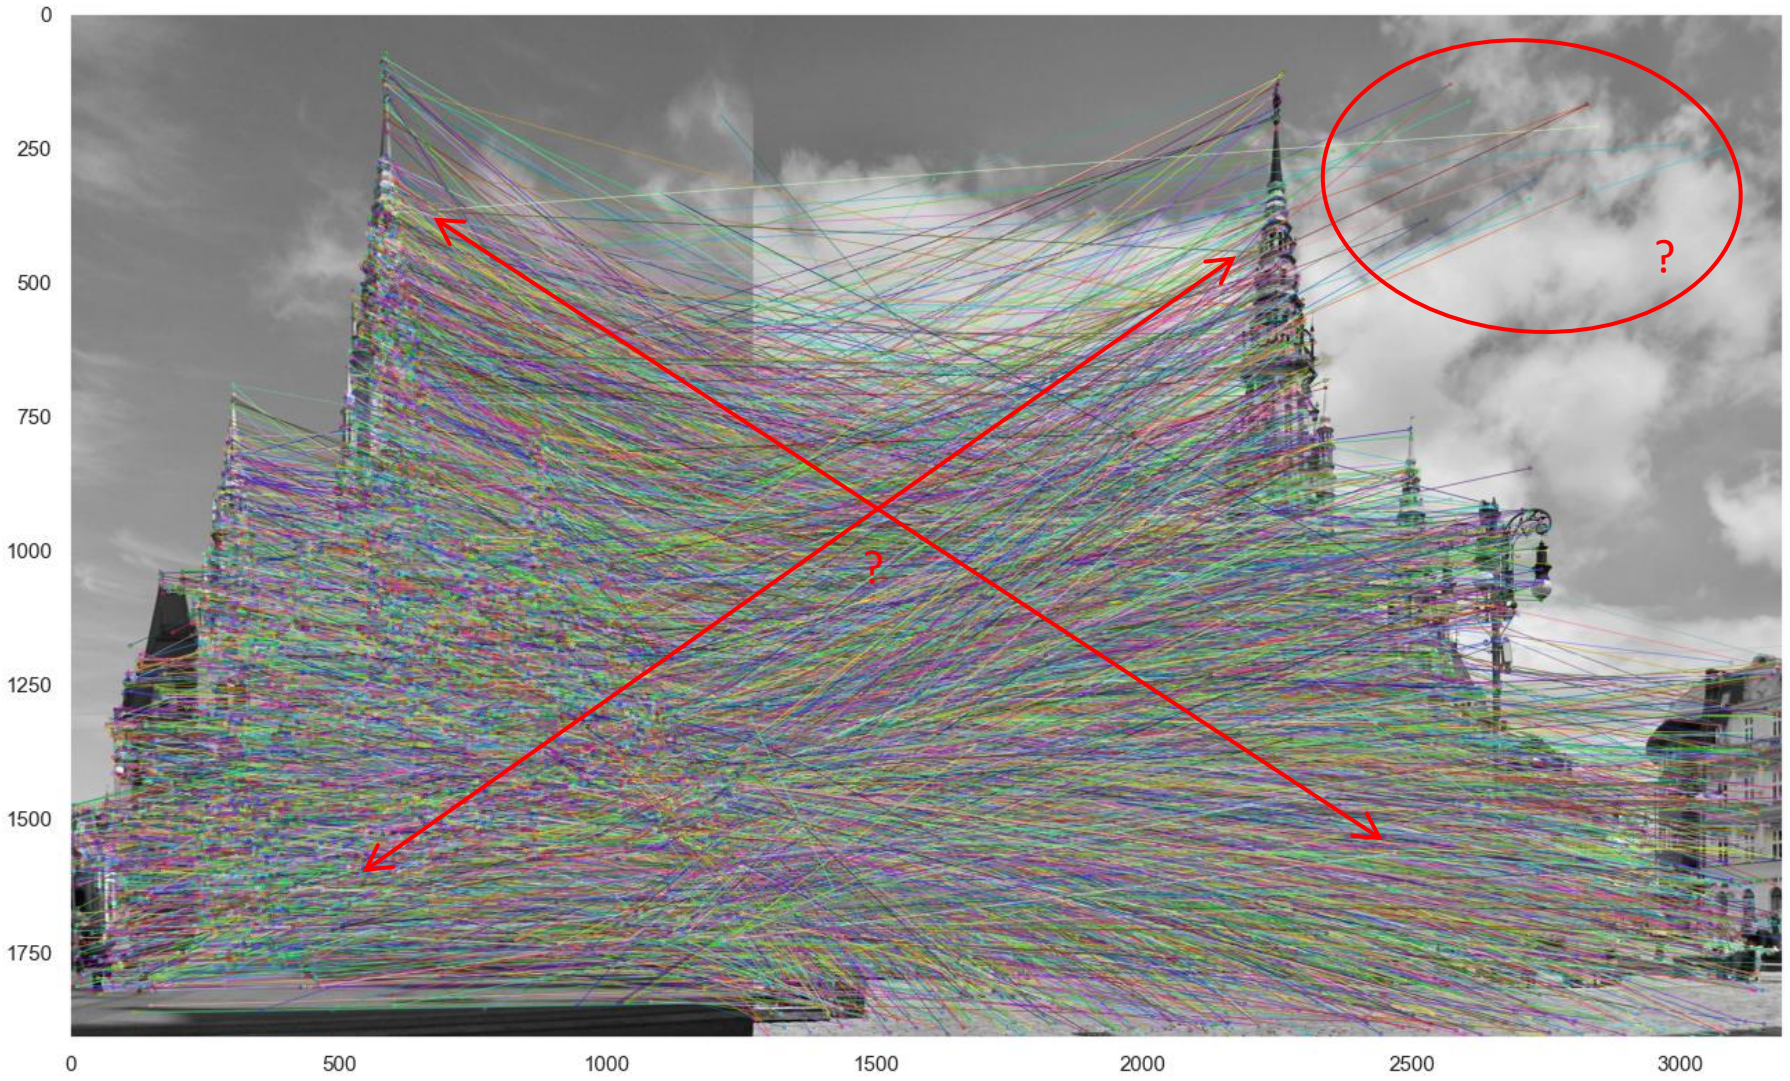
Lokální korespondence: vstupní obrazy



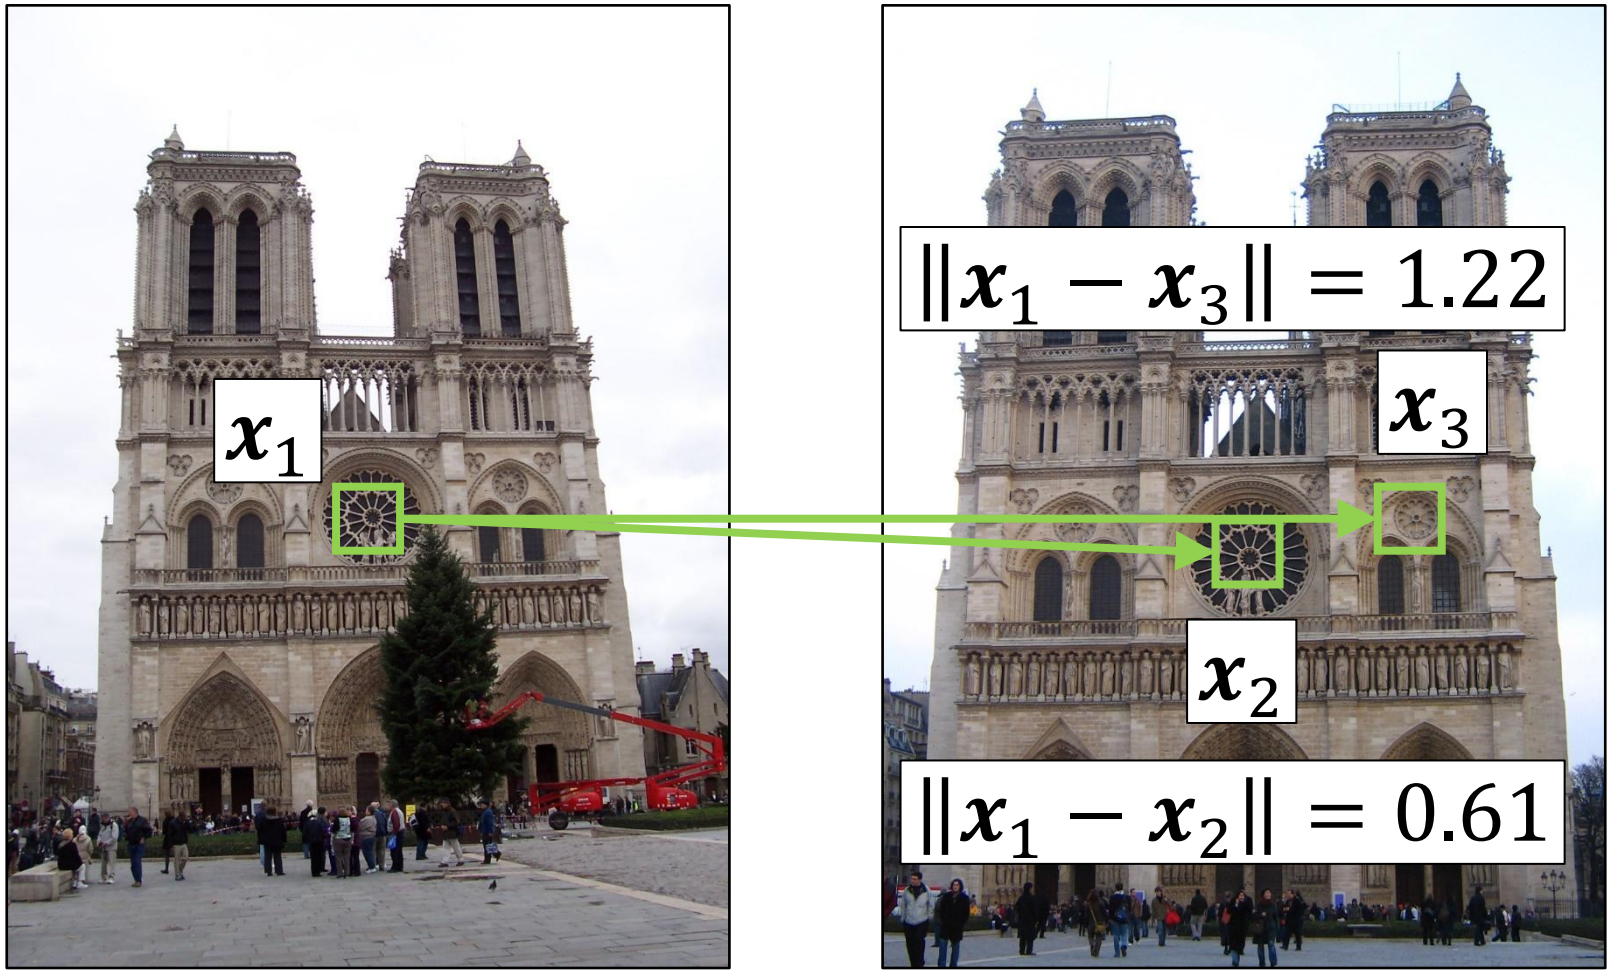
Lokální korespondence: zájmové body



Lokální korespondence: přiřazení nejpodobnějších bodů

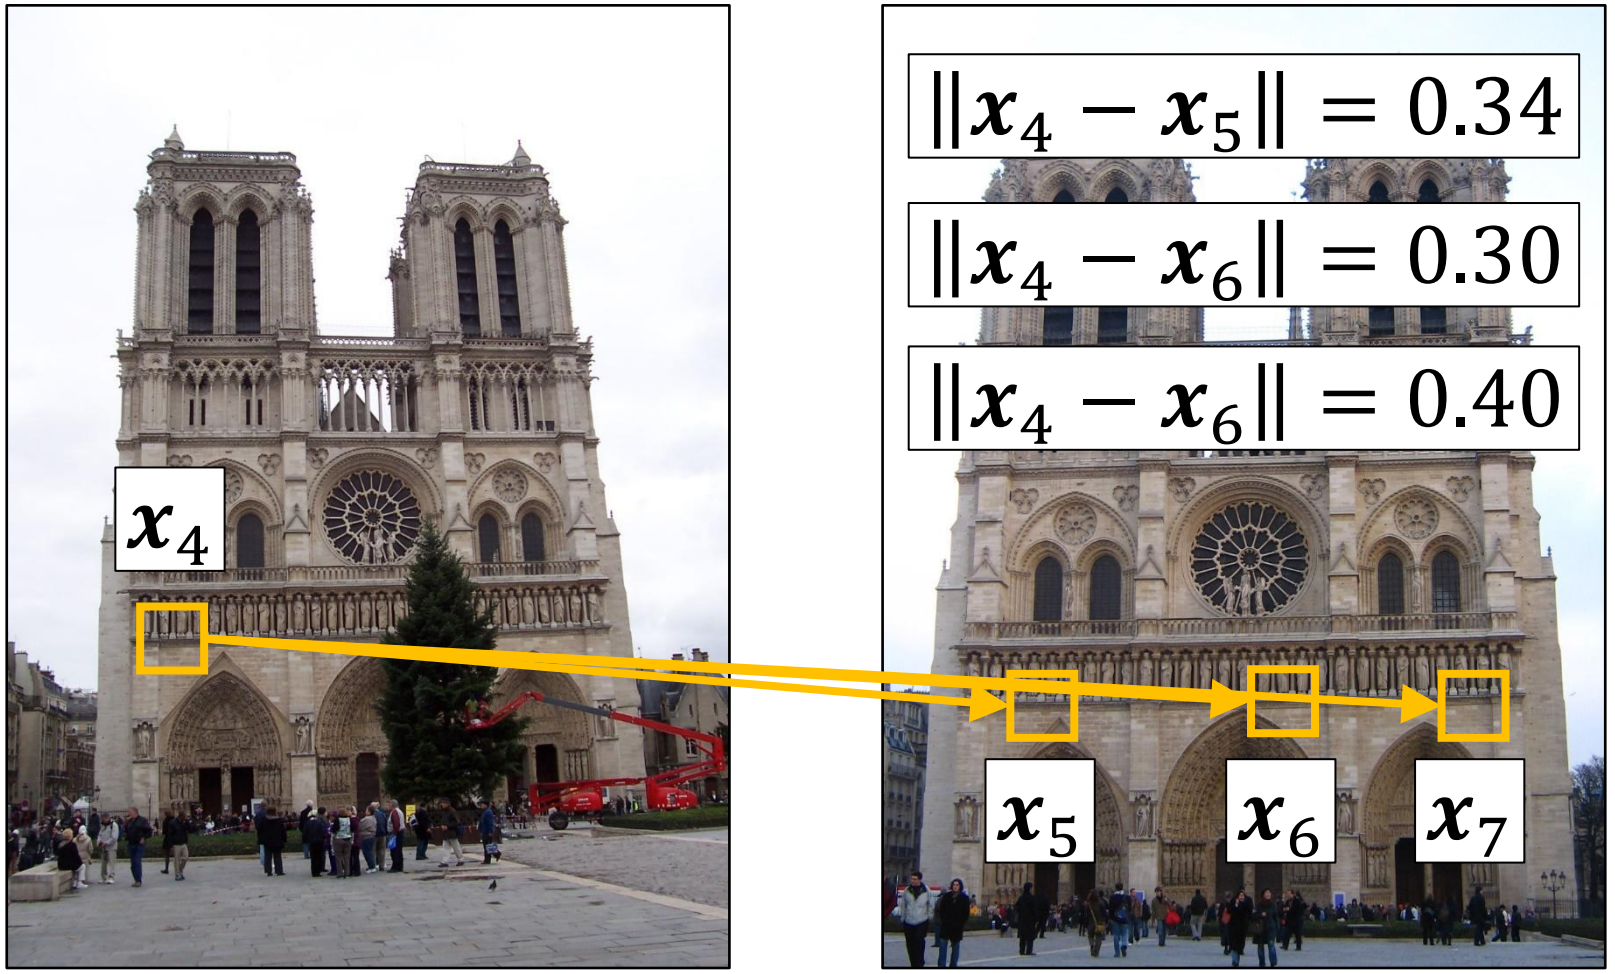


Jednoznačné přiřazení



slide: https://faculty.cc.gatech.edu/~hays/compvision/

Nejednoznačné přiřazení



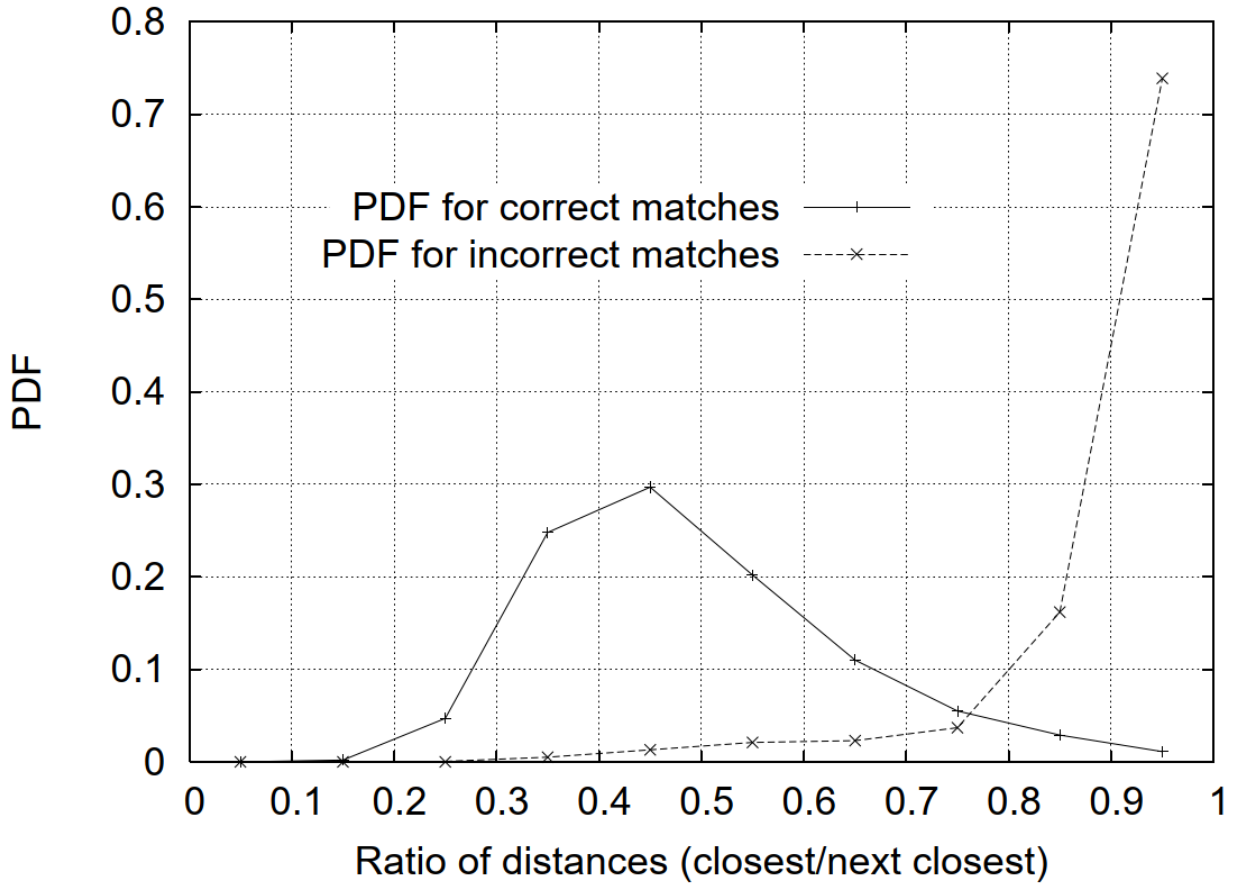
slide: https://faculty.cc.gatech.edu/~hays/compvision/

Poměr vzdáleností dvou nejbližších sousedů

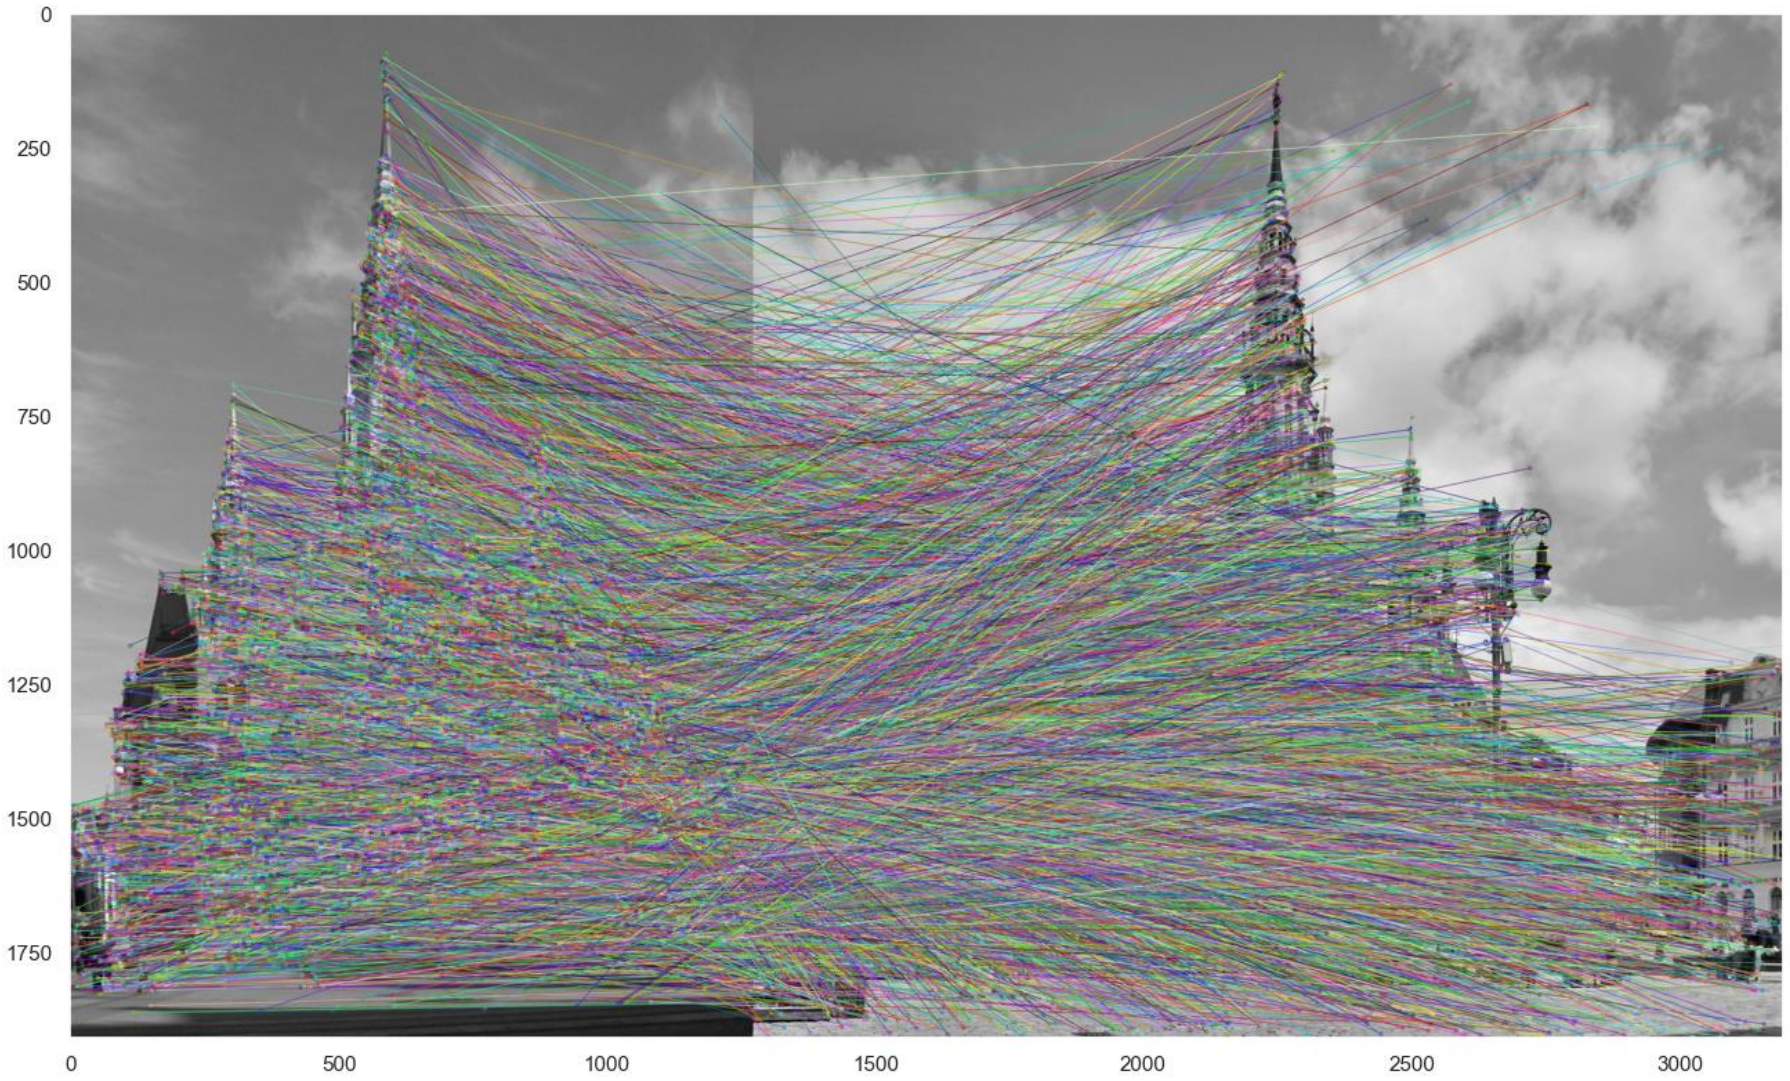
- Je obtížné stanovit práh na vzdálenost mezi $\boldsymbol{x}_q$ a nejbližším deskriptorem z druhého obrazu $\boldsymbol{x}_{1NN}$
- Namísto toho zvážíme ještě druhý nejpodobnější deskriptor $\boldsymbol{x}_{2NN}$
- Dobrý test, zda $\boldsymbol{x}_q$ a $\boldsymbol{x}_{1NN}$ reprezentují stejný bod, je poměr vzdáleností

$$r = \frac{\|\boldsymbol{x}_q - \boldsymbol{x}_{1NN}\|}{\|\boldsymbol{x}_q - \boldsymbol{x}_{2NN}\|}$$

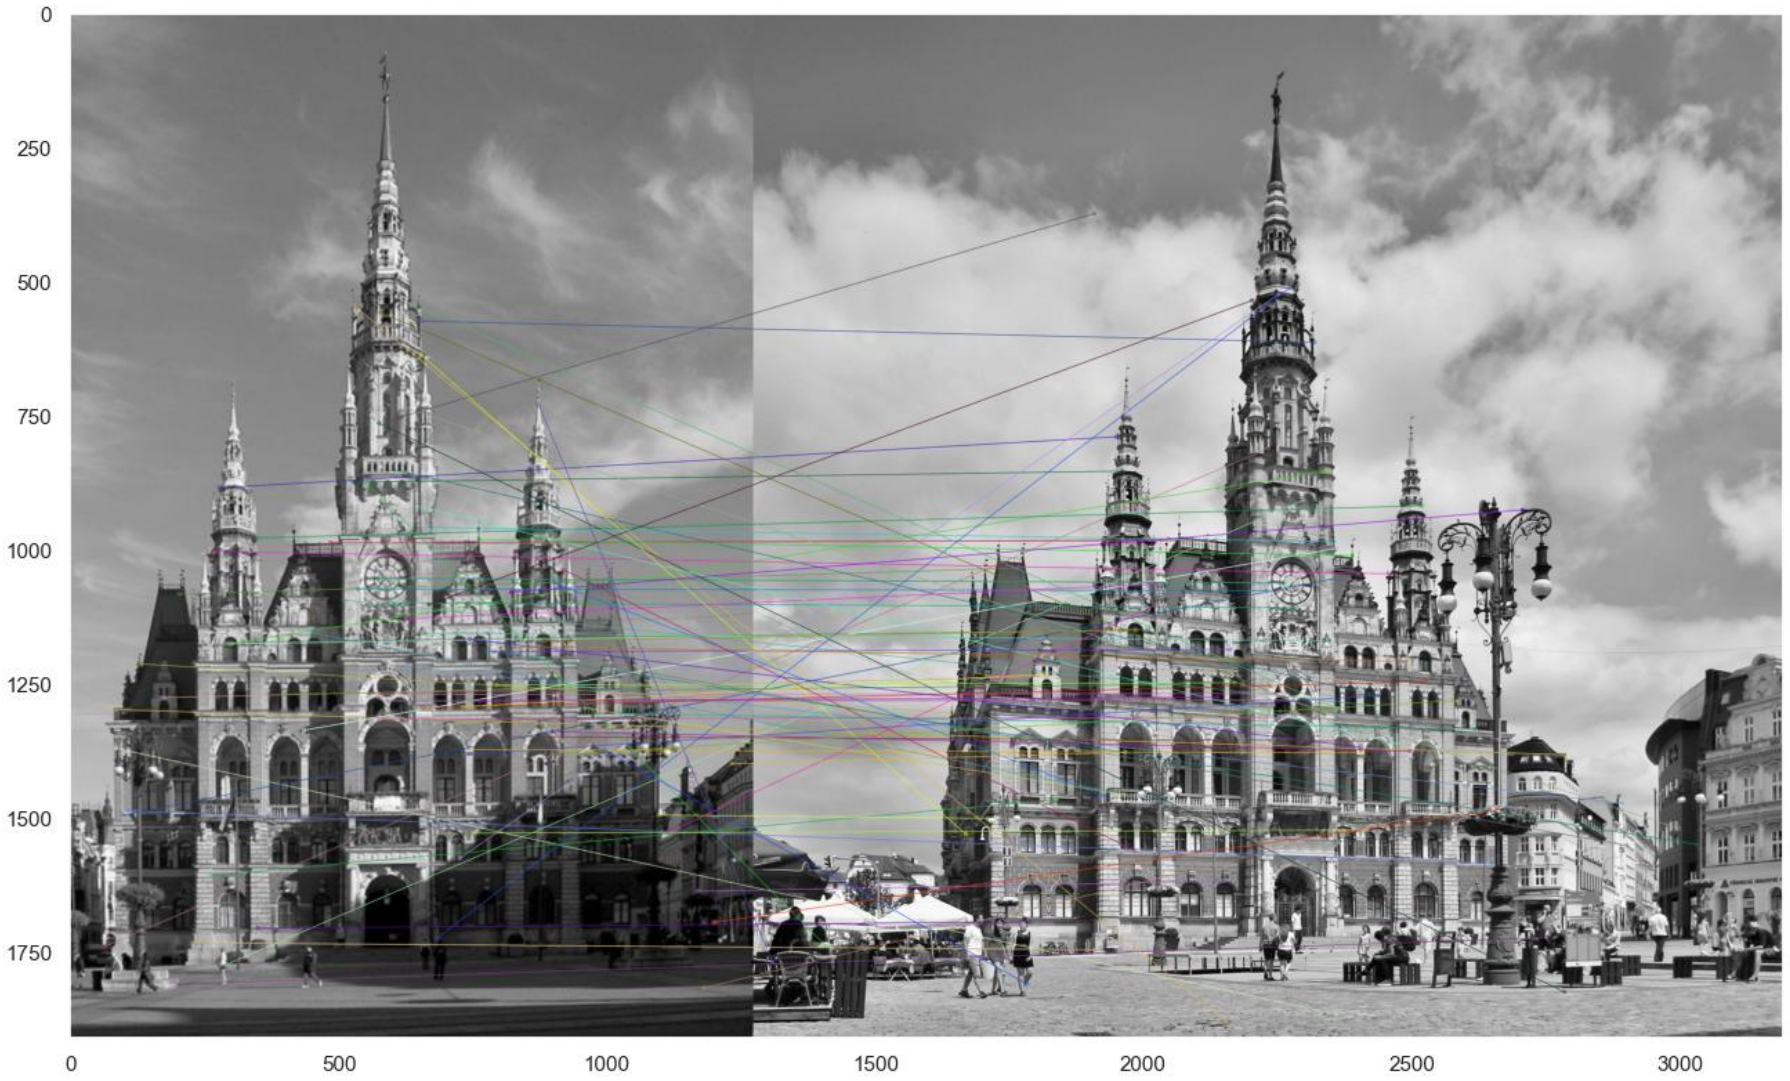
Poměr vzdáleností dvou nejbližších sousedů



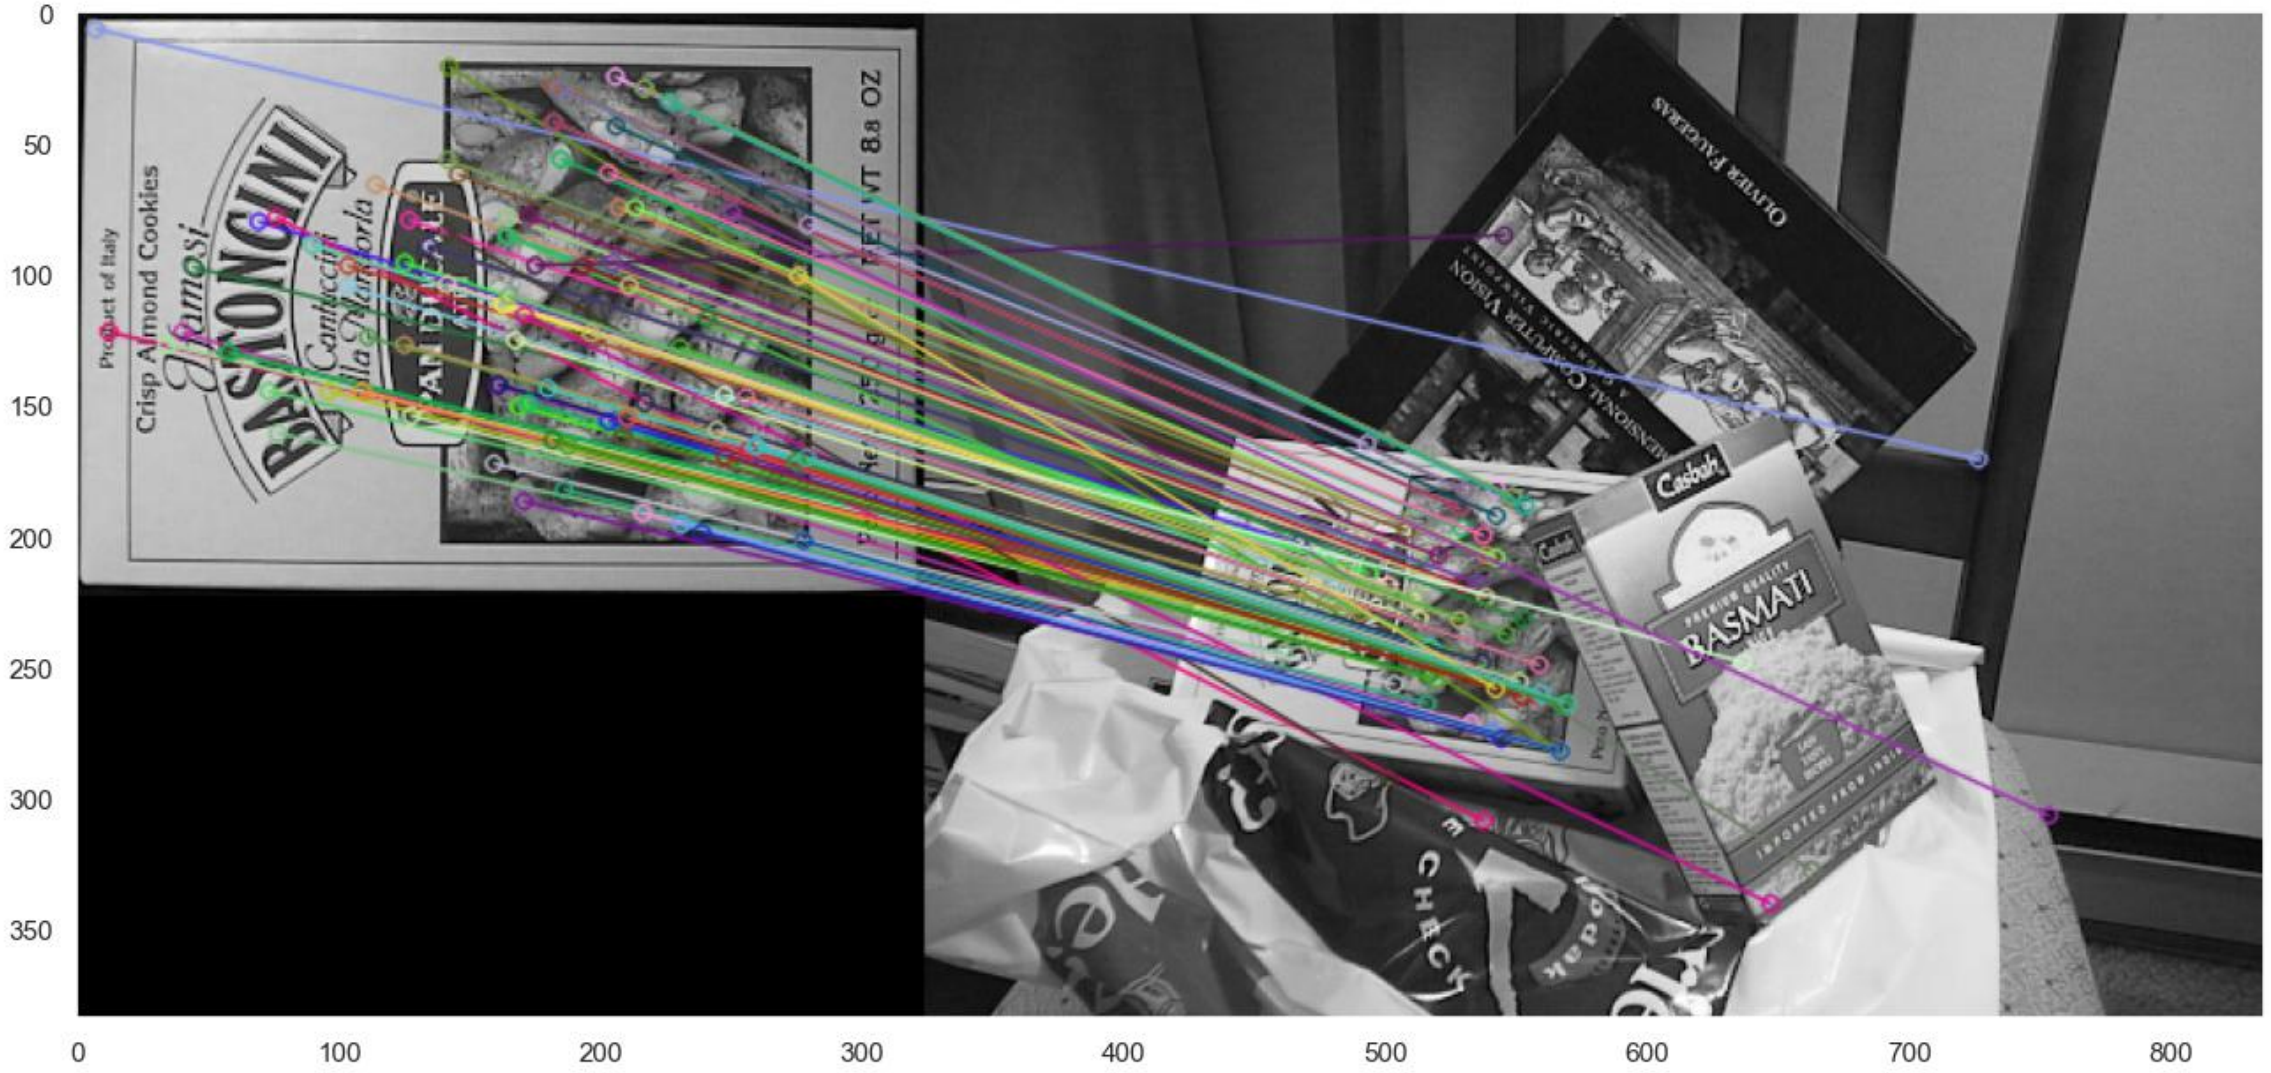
Poměr vzdáleností dvou nejbližších sousedů: před



Poměr vzdáleností dvou nejbližších sousedů: po



Poměr vzdáleností dvou nejbližších sousedů: po



Rychlé vyhledávání nejbližšího souseda

Problém: hledání nejbližšího souseda

- Pro každý deskriptor dotazu q hledáme v databázi $\{x_1, \ldots, x_N\}$ nejbližší (a druhý nejbližší pro test poměru vzdáleností)

$$\mathrm{NN}(q) = \arg\min_i(\|q - x_i\|)$$

- Hrubá síla: $O(N \cdot D)$ operací na jeden dotaz
- Párování dvou obrazů (2 × 1000 bodů): 10^6 vzdáleností → v pořádku
- Rozpoznávání v databázi obrazů, 3D rekonstrukce z tisíců snímků: miliony deskriptorů → příliš pomalé
- Řešení: indexové struktury a přibližné hledání (approximate nearest neighbour, ANN)

6.4 ms

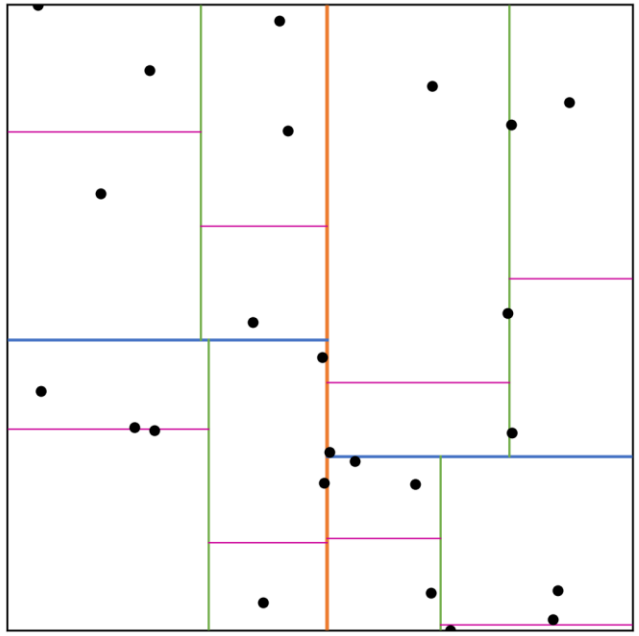
na jeden dotaz hrubou silou
databáze 106 594 SIFT deskriptorů

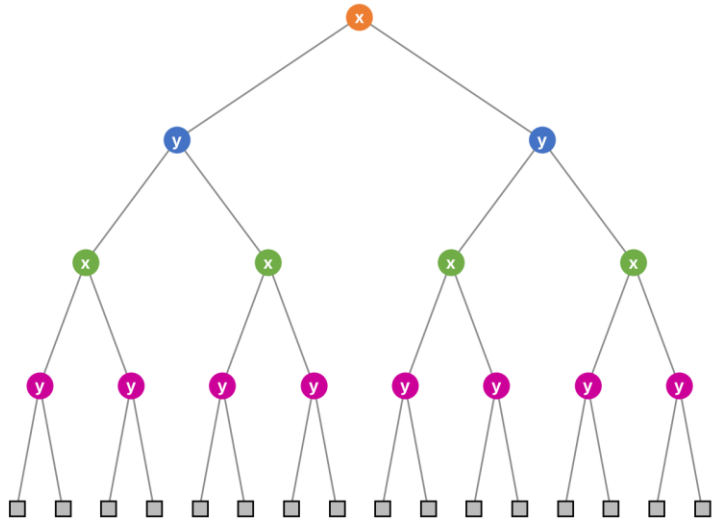
1 000 dotazů ≈ 6.4 s

OpenCV 5.0, 1 vlákno CPU

kd-strom: konstrukce

- Bentley (1975), Friedman, Bentley & Finkel (1977)
- Binární strom, který rekurzivně dělí prostor nadrovinami kolmými na osy
- V uzlu: zvolíme dimenzi (cyklicky nebo s největším rozptylem) a dělíme v mediánu
- Listy obsahují malý počet bodů
- Hloubka $O(\log N)$, konstrukce $O(N \log N)$





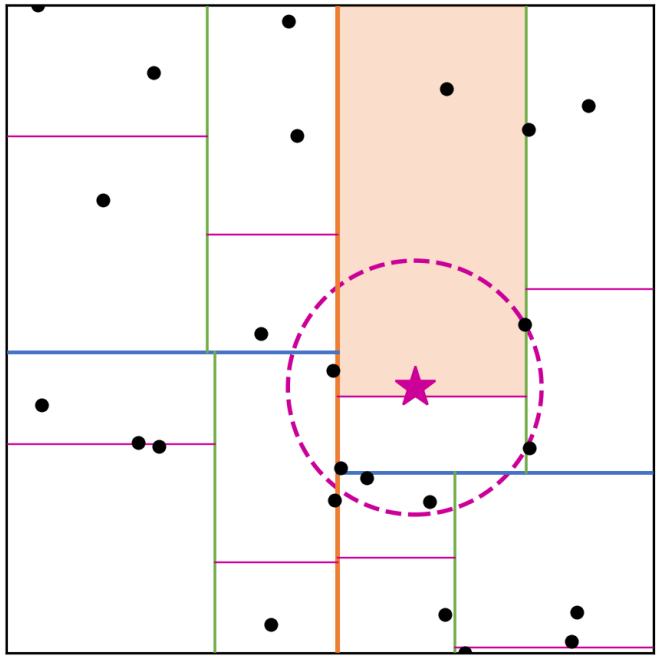
barva dělicí přímky = hloubka uzlu ve stromu

kd-strom: hledání nejbližšího souseda

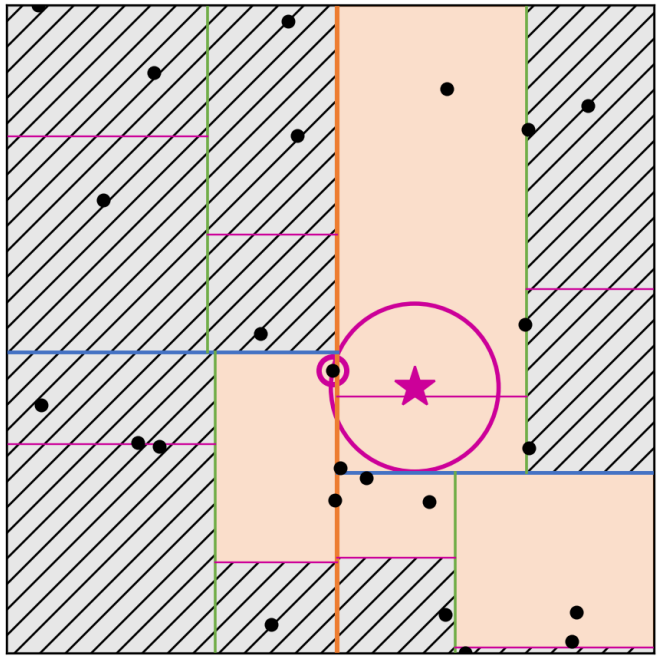
1. Sestup od kořene do listu, ve kterém leží dotaz → první kandidát, vzdálenost r
2. Návrat (backtracking): větev prohledáme, jen pokud její oblast protíná kouli o poloměru r kolem dotazu
3. Při nalezení bližšího bodu se r zmenší → lze ořezat více větví

V nízkých dimenzích průměrně $O(\log N)$ na dotaz

1) sestup do listu, kandidát



2) návrat: prohledáno 5 listů, zbytek ořezán

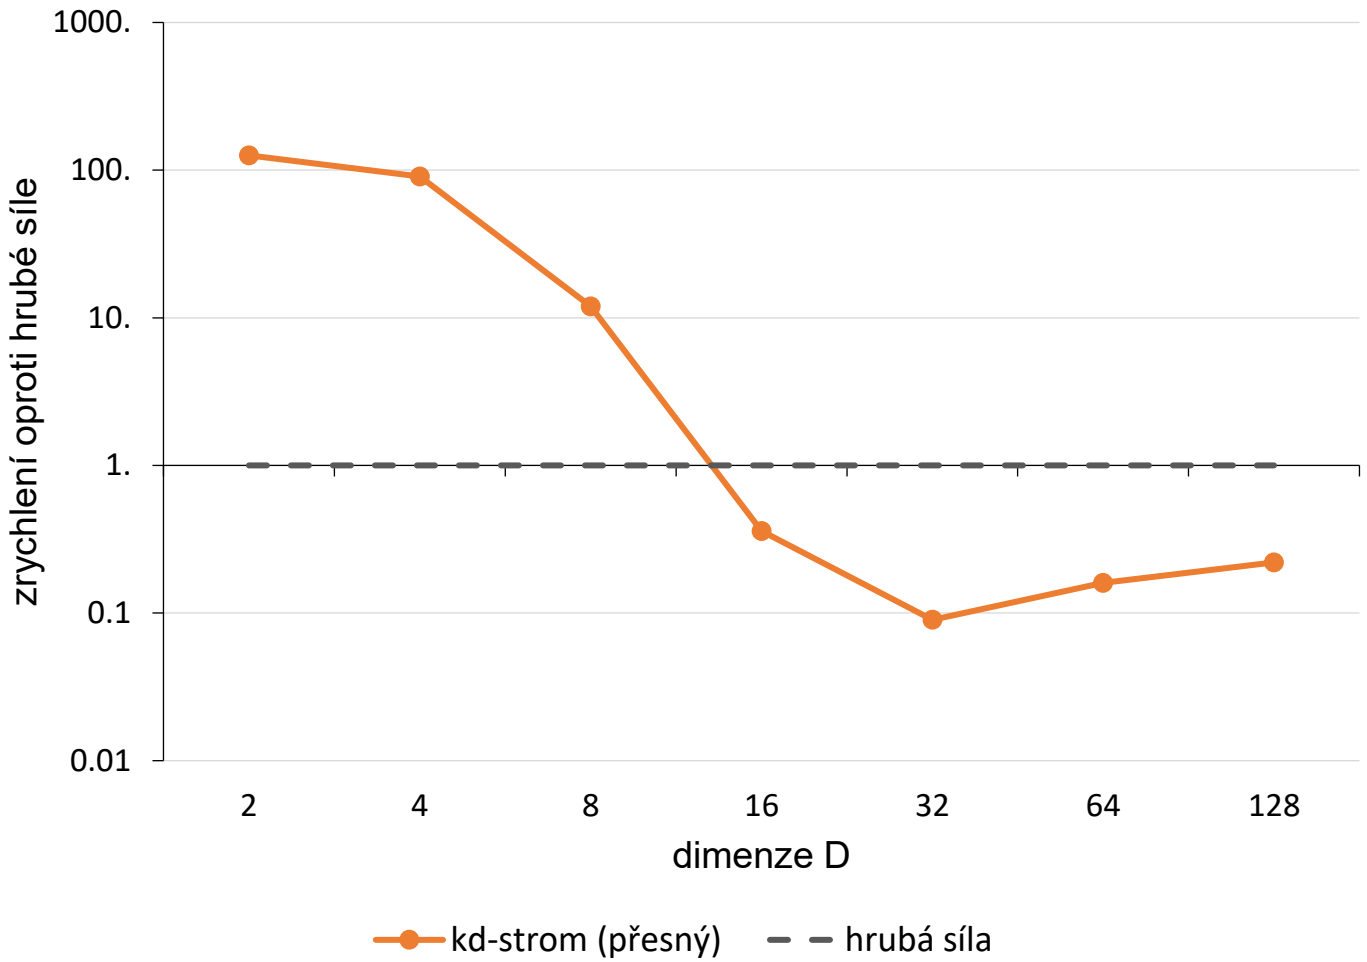


šrafovaně: oblasti ořezané bez výpočtu vzdáleností

Prokletí dimenzionality

- S rostoucí dimenzí protíná koule kolem dotazu stále více buněk
- Backtracking navštíví téměř všechny listy → žádné zrychlení
- Pro D > 10–20 je přesný kd-strom pomalejší než hrubá síla
- SIFT: 128 dimenzí, SuperPoint: 256 dimenzí

→ v praxi se používá přibližné hledání



vlastní experiment: 100 000 náhodných bodů, 300 dotazů, SciPy cKDTree vs. OpenCV BFMatcher

Přibližné hledání nejbližšího souseda

Best-Bin-First
Beis & Lowe (1997)

- větve prohledávány podle vzdálenosti od dotazu (prioritní fronta)
- hledání ukončeno po C navštívených listech
- SIFT (Lowe 2004): 200 kandidátů, cca 100× rychlejší, ztráta < 5 % správných shod

Náhodné kd-stromy
Silpa-Anan & Hartley (2008)

- několik kd-stromů současně
- dělicí dimenze náhodně z 5 dimenzí s největším rozptylem
- jedna společná prioritní fronta přes všechny stromy

Hierarchický k-means
Nistér & Stewénius (2006), Muja & Lowe (2009)

- v každém uzlu k-means shlukování na K center
- sestup do nejbližšího centra, prioritní fronta pro návrat
- základ „slovníkových stromů“ pro vyhledávání obrazů

přesnost × rychlost se řídí počtem kontrolovaných listů (parametr checks)

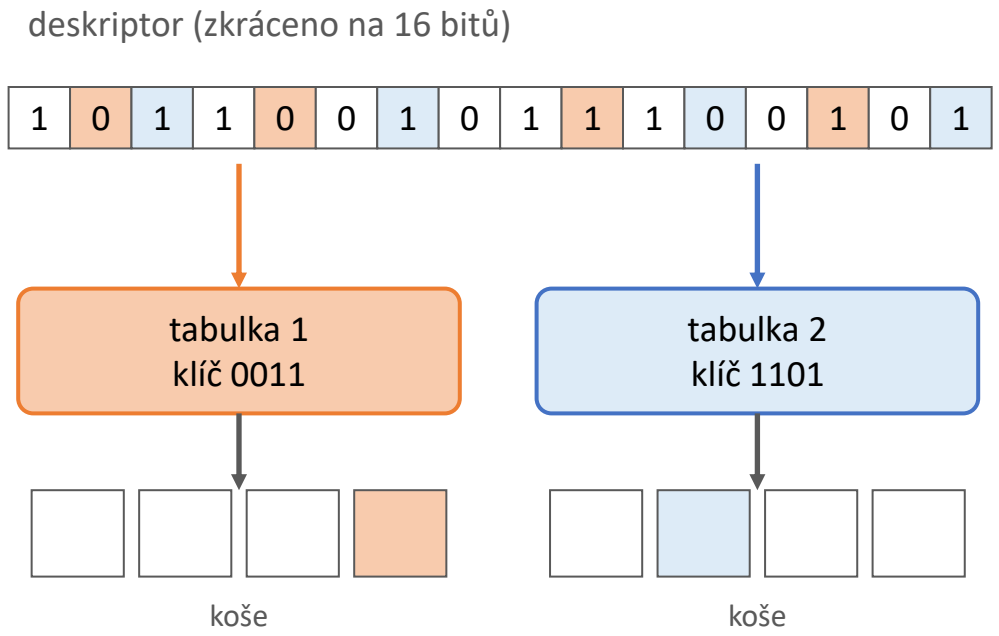
FLANN

- Fast Library for Approximate Nearest Neighbors
- Muja & Lowe (VISAPP 2009), rozšířeno v PAMI 2014; github.com/flann-lib/flann
- Implementuje náhodné kd-stromy, hierarchický k-means, LSH a jejich kombinace
- Automatický výběr algoritmu a parametrů pro požadovanou přesnost (s ohledem na čas stavby indexu, dotazu a paměť)
- Součást OpenCV: cv2.FlannBasedMatcher

```
FLANN_INDEX_KDTREE = 1
index_params = dict(algorithm=FLANN_INDEX_KDTREE, trees=5)
search_params = dict(checks=50)   # více kontrol = přesnější, ale pomalejší
flann = cv2.FlannBasedMatcher(index_params, search_params)
matches = flann.knnMatch(des1, des2, k=2)
good = [m for m, n in matches if m.distance < 0.7 * n.distance]
```

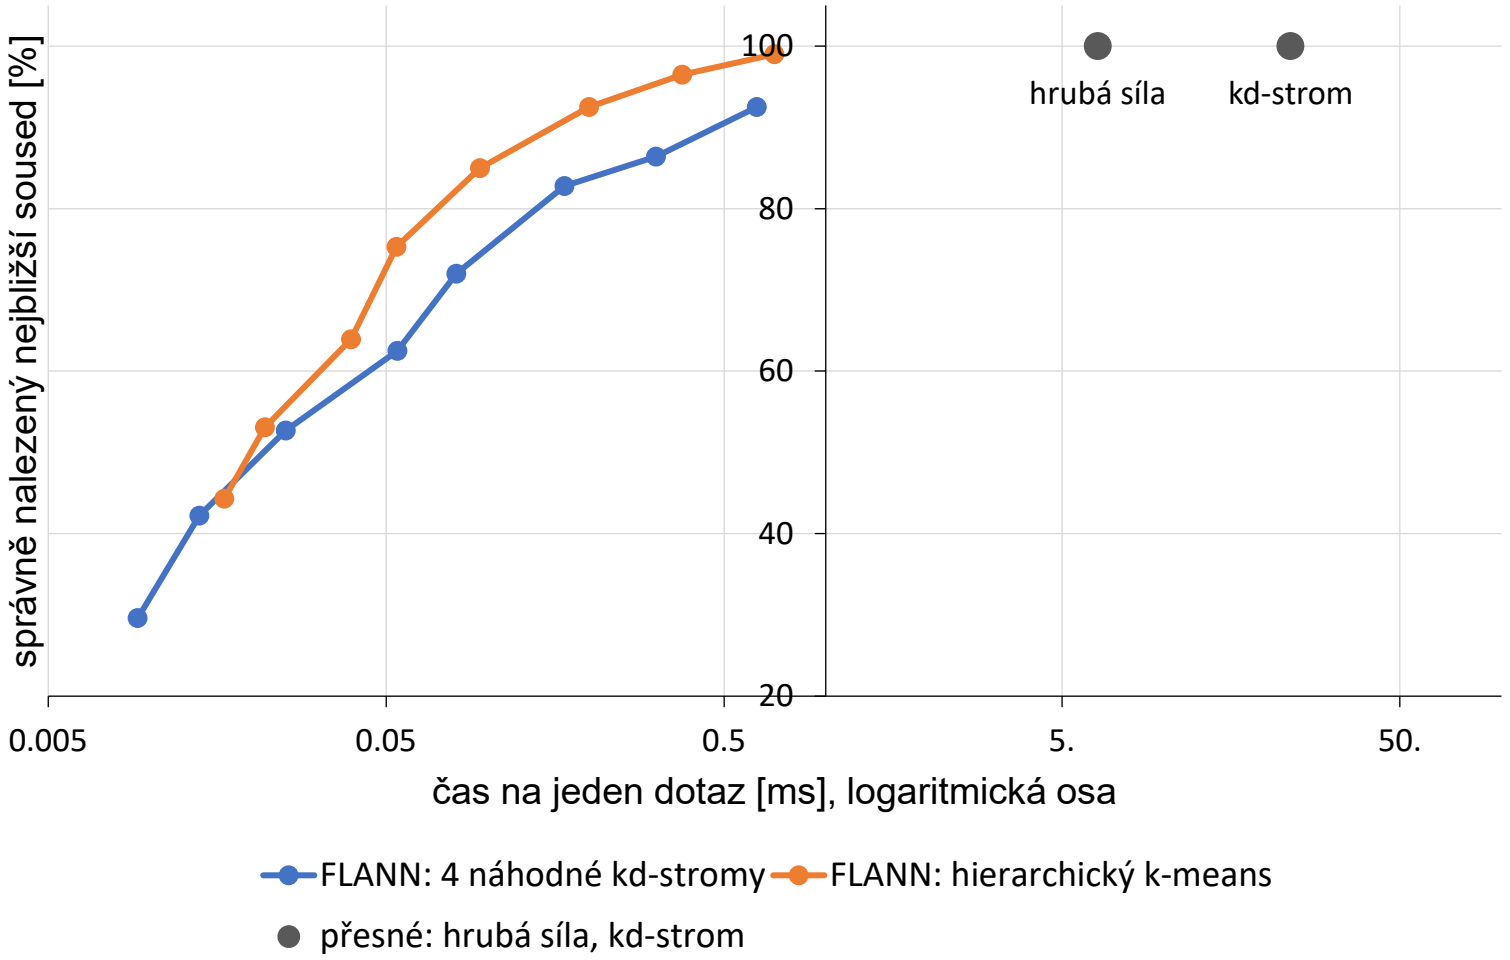
LSH pro binární deskriptory

- kd-stromy se pro Hammingův prostor nehodí
- Locality Sensitive Hashing: klíč = podmnožina k bitů deskriptoru → podobné deskriptory padnou s vysokou pravděpodobností do stejného koše
- L tabulek s různými podmnožinami bitů; kandidáti = sjednocení košů, pak přesná Hammingova vzdálenost
- Multi-probe LSH (Lv et al., 2007): prohledávají se i sousední koše lišící se v málo bitech → stačí méně tabulek
- OpenCV: algorithm=6 (FLANN_INDEX_LSH), table_number, key_size, multi_probe_level



kandidáti = deskriptory ve vybraných koších

Experiment: přesnost vs. rychlost



- databáze 106 594 SIFT deskriptorů
- 2000 dotazů z jiného obrazu
- body na křivkách: checks = 8 … 1024
- 1 vlákno CPU, OpenCV 5.0

k-means strom: 92.5 % správně a 32× rychleji než hrubá síla

přesný kd-strom je ve 128 dimenzích dokonce pomalejší než hrubá síla

Moderní knihovny pro přibližné hledání

Produktová kvantizace (PQ)

Jégou, Douze & Schmid (2011): vektor rozdělen na části, každá kvantována vlastním slovníkem → např. 128 float (512 B) zkomprimováno na 16 B, rychlý odhad vzdáleností z tabulek

FAISS (2017)

knihovna Meta AI: invertovaný index (IVF) + PQ, HNSW, výpočty na GPU; vyhledávání v miliardách vektorů

HNSW (2016)

Malkov & Yashunin: hierarchický graf „malého světa“, hladové procházení grafu od hrubé vrstvy k jemné; dnes velmi rozšířené

Další

ScaNN (Google), Annoy (Spotify), vektorové databáze; srovnání na ann-benchmarks.com

zdroj: https://ann-benchmarks.com

SURF

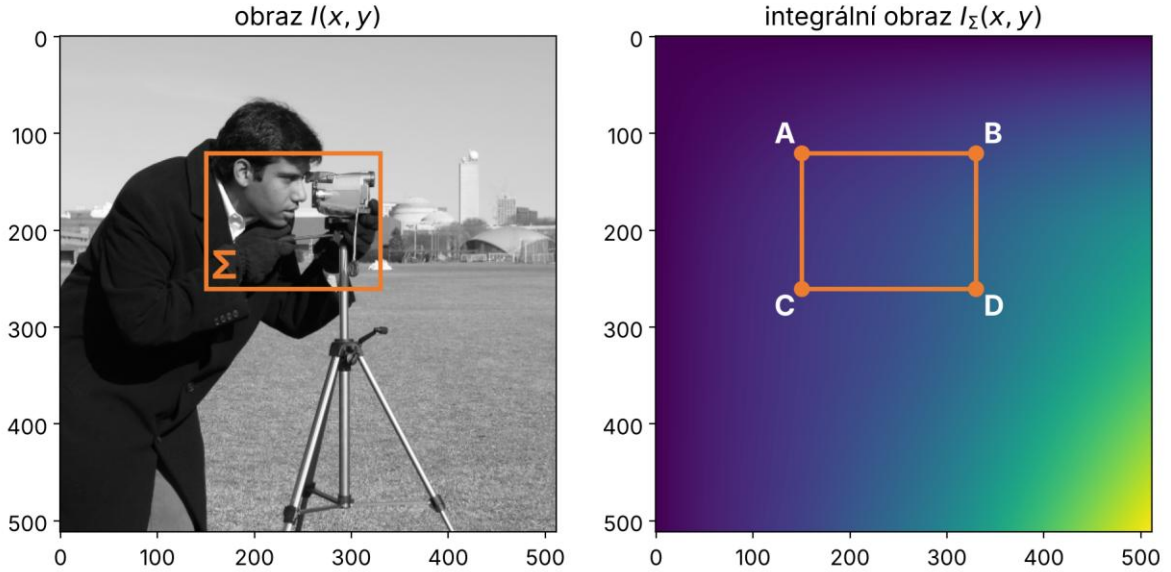
Lokální příznaky SURF (2006)

- Speeded-Up Robust Features
- SURF: Speeded Up Robust Features (ECCV 2006)
- H. Bay, T. Tuytelaars, L. Van Gool; rozšířená verze v CVIU 2008
- Cíl: podobná robustnost jako SIFT, ale výrazně rychlejší výpočet
- Hlavní myšlenky:
  - detektor založený na determinantu Hessiánu ("Fast-Hessian")
  - aproximace gaussovských derivací krabicovými (box) filtry
  - výpočet filtrů libovolné velikosti v konstantním čase pomocí integrálního obrazu
  - deskriptor z odezev Haarových vlnek, pouze 64 dimenzí

Integrální obraz

- Každý pixel obsahuje součet všech pixelů vlevo a nad ním
- Vypočten jedním průchodem obrazem
- Součet jasu v libovolném obdélníku pouze pomocí 4 přístupů do paměti a 3 operací
- Výpočetní náročnost nezávisí na velikosti obdélníku → filtry libovolné velikosti za konstantní čas
- Popularizován detektorem obličejů Viola & Jones (2001)

$$I_\Sigma(x,) = \sum_{i \le x} \sum_{j \le y} I(i,)$$



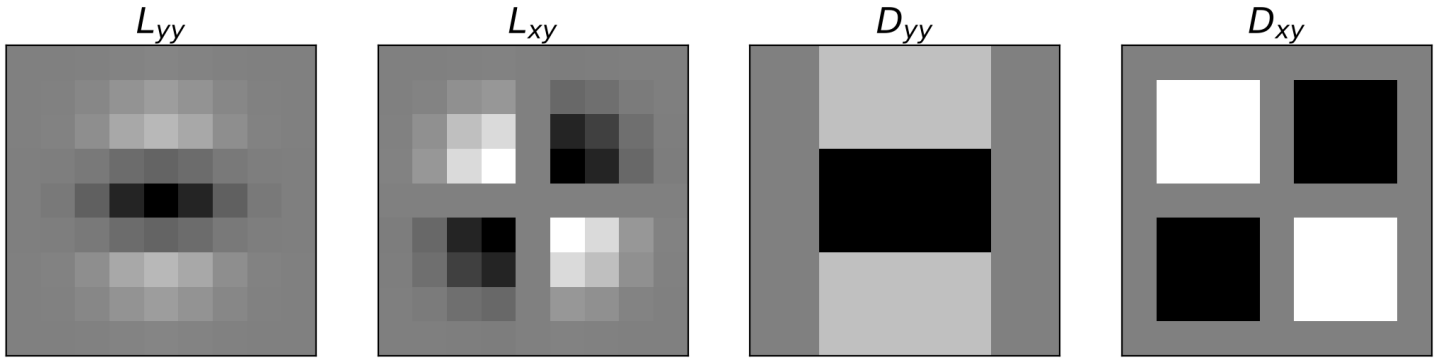
$$\sum_{ABDC} I = I_\Sigma(D) - I_\Sigma(B) - I_\Sigma(C) + I_\Sigma(A)$$

Detektor Fast-Hessian

- Hessova matice v bodě x a měřítku σ:
- $L_{xx}(x,\sigma)$ … konvoluce obrazu s druhou derivací gaussiánu $\partial^2 g_\sigma / \partial x^2$
- Zájmové body (bloby) = lokální maxima determinantu H
- SURF aproximuje derivace gaussiánu box filtry D_{xx}, D_{yy}, D_{xy} (filtr 9×9 ≈ σ = 1.2)
- Váha 0.9 kompenzuje chybu aproximace

$$H(x,y,\sigma) = \begin{bmatrix} L_{xx} & L_{xy} \\ L_{xy} & L_{yy} \end{bmatrix}$$

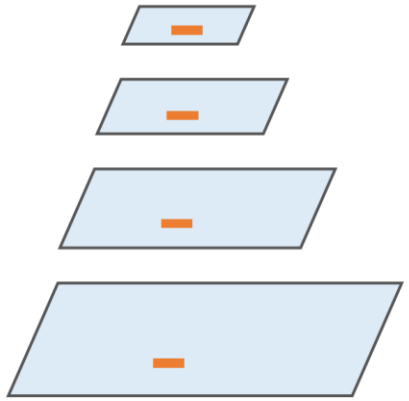
$$\det(H_{\text{approx}}) = D_{xx}D_{yy} - (0.9 \cdot D_{xy})^2$$



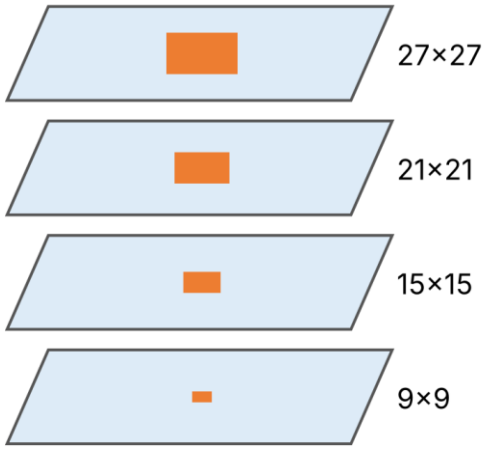
Prostor měřítek v SURF

- SIFT: obraz opakovaně rozmazáván a podvzorkován (pyramida), filtr stejný
- SURF: obraz se nemění, roste velikost filtru
  - 1. oktáva: 9×9, 15×15, 21×21, 27×27; další oktávy s dvojnásobným krokem
  - filtr velikosti N odpovídá měřítku $\sigma = 1.2 \cdot N/9$
- Díky integrálnímu obrazu má každá velikost filtru stejnou cenu, úrovně lze počítat paralelně
- Lokalizace: lokální maxima v okolí 3×3×3 + interpolace polohy a měřítka (jako SIFT)

SIFT: filtr konstantní, obraz se zmenšuje



SURF: obraz konstantní, filtr se zvětšuje

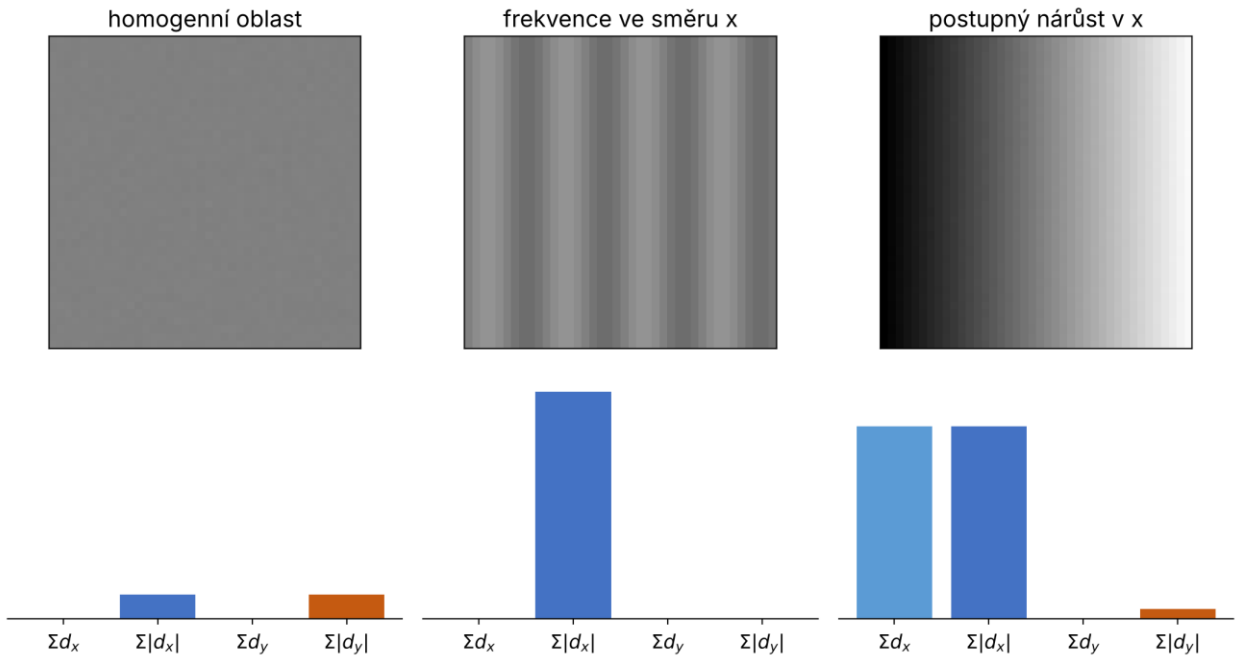


SURF deskriptor

- Čtvercové okno $20s \times 20s$ natočené podle orientace bodu
- Rozděleno na 4×4 pod-oblastí, v každé 5×5 vzorků odezev Haarových vlnek
- Pro každou pod-oblast 4 hodnoty:

$$\boldsymbol{v} = \left(\sum d_x , \sum d_y , \sum |d_x| , \sum |d_y| \right)$$

- 4 × 4 × 4 = 64 dimenzí (SIFT: 128), normalizace na jednotkovou délku → invariance vůči kontrastu
- SURF-128: sumy počítány zvlášť pro kladné a záporné odezvy



hodnoty v pro tři typické vzory v pod-oblasti

Porovnání SIFT a SURF

	SIFT	**SURF**
Detektor	extrémy DoG (aproximace LoG)	maxima determinantu Hessiánu
Prostor měřítek	pyramida rozmazaných obrazů	zvětšování box filtrů na integrálním obrazu
Orientace	histogram orientací gradientů (36 binů)	Haarovy vlnky, posuvná výseč π/3
Deskriptor	4×4 histogramy orientací gradientů (8 binů)	4×4 pod-oblasti × 4 sumy Haarových odezev
Dimenze	128	64 (příp. 128)
Párování	L2 vzdálenost	L2 vzdálenost + znaménko laplaciánu
Rychlost	1×	cca 3× rychlejší (dle autorů)

SURF urychluje stejné principy jako SIFT pomocí aproximací, kvalita jen o trochu horší

Binární deskriptory: BRIEF a ORB

BRIEF (2010)

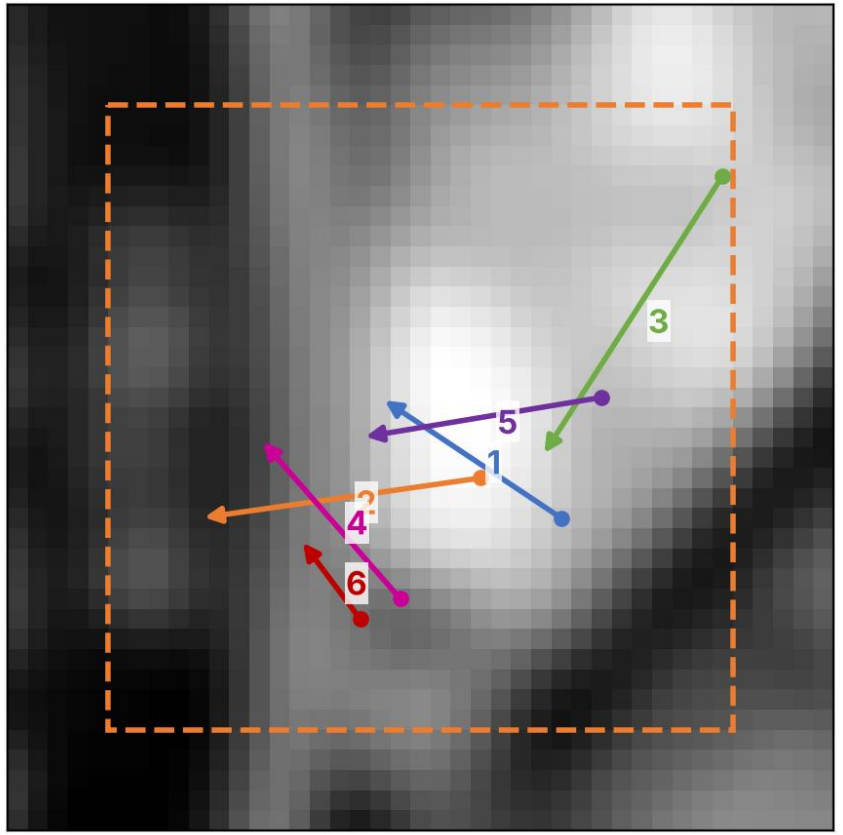
- Binary Robust Independent Elementary Features
- Calonder, Lepetit, Strecha, Fua (ECCV 2010)
- Pouze deskriptor, detektor libovolný (FAST, Harris, …)
- Okolí bodu p velikosti $S \times S$ nejprve vyhlazeno gaussiánem (9×9, $\sigma = 2$)
- Binární test pro dvojici pozic (x, y):

$$\tau(p; \boldsymbol{x}, \boldsymbol{y}) = \begin{cases} 1 & \text{pokud } p(\boldsymbol{x}) < p(\boldsymbol{y}) \\ 0 & \text{jinak} \end{cases}$$

- Deskriptor = n_d testů (typicky 128, 256 nebo 512):

$$f_{n_d}(p) = \sum_{1 \le i \le n_d} 2^{i-1} \tau(p; \boldsymbol{x}_i, \boldsymbol{y}_i)$$

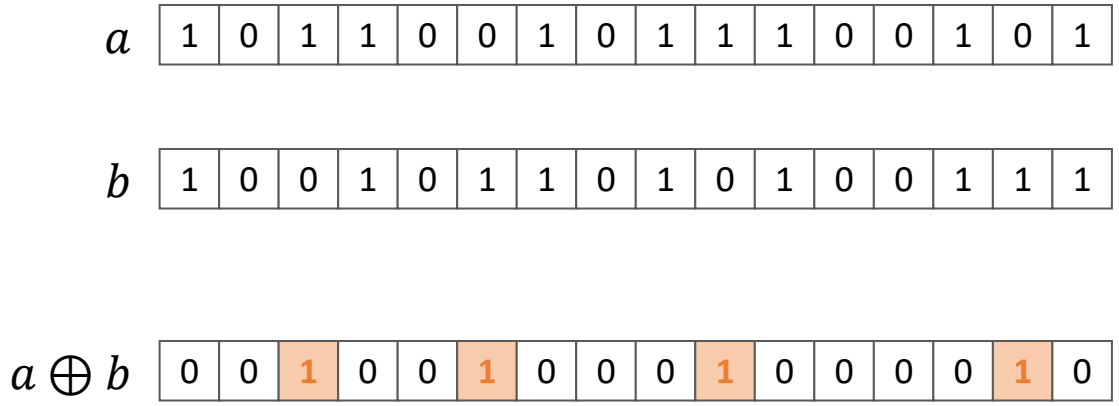
deskriptor je jedno velké binární číslo



testy 1-6 → bity 1 0 1 0 0 1

Binární deskriptory

- SIFT: 128 × float32 = 512 B na jeden bod, SURF: 256 B
- Tisíce bodů na obraz, porovnání L2 vzdáleností je výpočetně drahé
- Real-time aplikace, mobilní zařízení, SLAM, velké databáze obrazů
- Binární deskriptor = řetězec bitů, např. 256 b = 32 B
- Vzdálenost = Hammingova vzdálenost = počet rozdílných bitů
- XOR + popcount: jediná instrukce procesoru pro 64 bitů



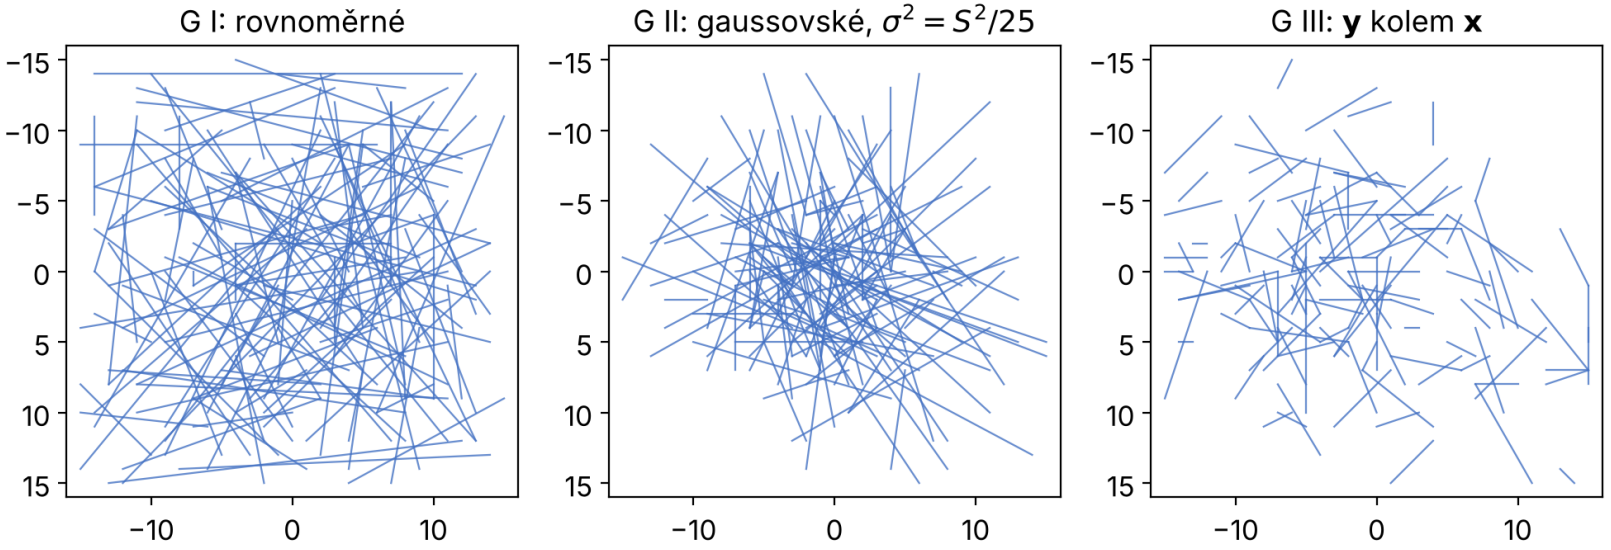
$$d_H(a,) = \text{popcount}(a \oplus b) = 5$$

porovnání binárních deskriptorů je řádově rychlejší než L2 vzdálenost

BRIEF: výběr dvojic pozic pro testy

- Pozice testů (x_i, y_i) jsou náhodně vybrány jednou předem a pro všechny body stejné
- Autoři porovnali 5 strategií výběru, nejlépe vychází izotropní gaussovské rozdělení se středem v bodě:

$$(\boldsymbol{x}_i, \boldsymbol{y}_i) \sim \text{ i.i.d. Gaussian}\left(0, \frac{S^2}{25}\right)$$



Vlastnosti BRIEF

Výhody

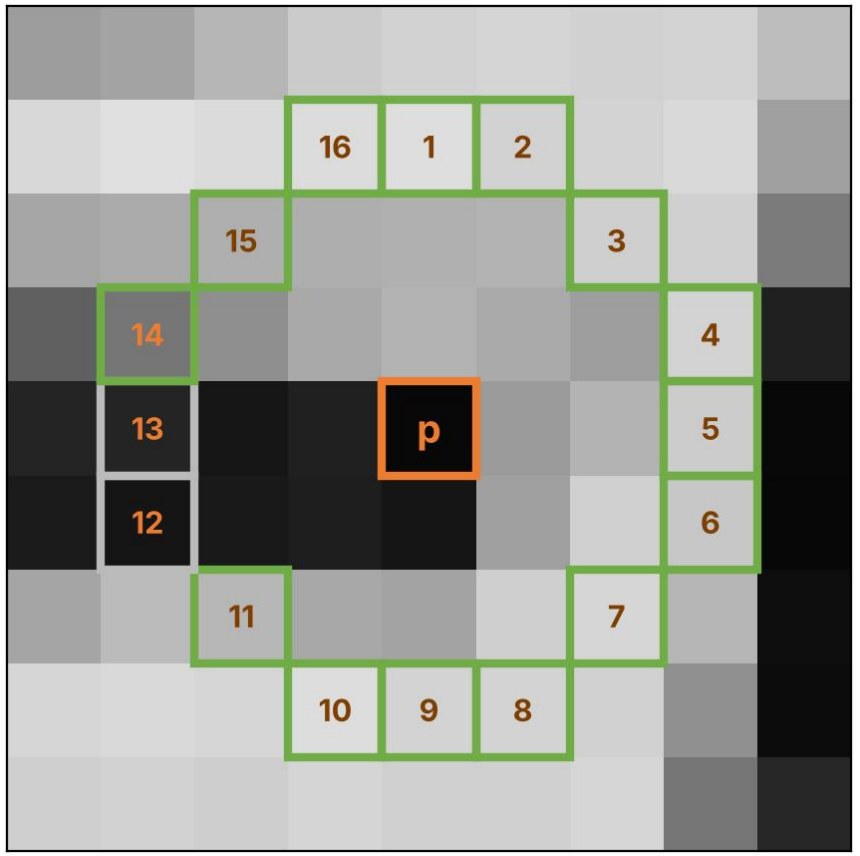
- extrémně rychlý výpočet: jen porovnání jasů
- rychlé párování Hammingovou vzdáleností
- kompaktní: 256 bitů = 32 B
- invariantní vůči monotónní změně jasu (záleží jen na pořadí jasů)

Nevýhody

- není invariantní vůči rotaci: úspěšnost párování prudce klesá již od natočení cca 10-15°
- není invariantní vůči změně měřítka
- nemá vlastní detektor ani orientaci (řeší ORB)

Připomenutí: FAST detektor rohů (2006)

- Features from Accelerated Segment Test, Rosten & Drummond
- Kruh 16 pixelů (Bresenhamova kružnice, poloměr 3) kolem kandidáta p
- p je roh, pokud existuje souvislý oblouk alespoň N pixelů, které jsou všechny jasnější než $I_p + t$, nebo všechny tmavší než $I_p - t$
- Nejčastěji FAST-9 ($N = 9$)
- Rychlé zamítnutí: nejprve se testují pixely 1, 9, 5 a 13
- Odezva FAST neodpovídá míře „rohovosti“ a reaguje i na hrany



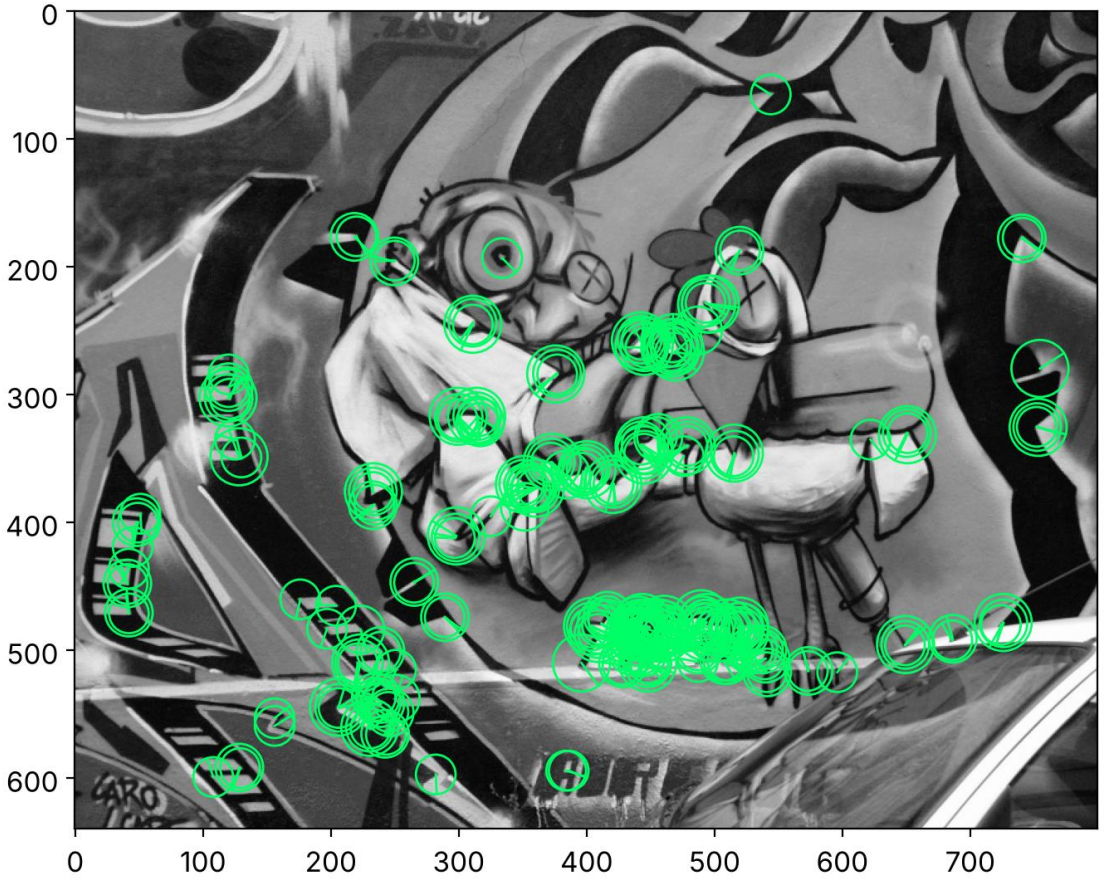
14 souvislých pixelů jasnějších než $I_p + t$ → roh

ORB (2011)

- Oriented FAST and Rotated BRIEF
- ORB: An efficient alternative to SIFT or SURF (ICCV 2011)
- E. Rublee, V. Rabaud, K. Konolige, G. Bradski (Willow Garage, autoři OpenCV)
- Volně použitelná (nepatentovaná) alternativa k SIFT a SURF (patenty obou vypršely kolem 2020)
- ORB = oFAST + rBRIEF
  - oFAST: detektor FAST + pyramida měřítek + orientace
  - rBRIEF: BRIEF natočený podle orientace + naučené binární testy
- Řádově rychlejší než SIFT, v mnoha úlohách srovnatelné výsledky
- Standardní volba v real-time systémech, např. ORB-SLAM

oFAST: detektor ORB

- FAST-9 na pyramidě obrazů (měřítko 1.2, 8 úrovní) → invariance vůči měřítku
- FAST reaguje i na hrany → body seřazeny podle Harrisova kritéria, ponecháno N nejlepších
- Každému bodu přiřazena orientace (těžiště intenzit, viz dále)
- Deskriptor počítán z oblasti 31×31 na příslušné úrovni pyramidy

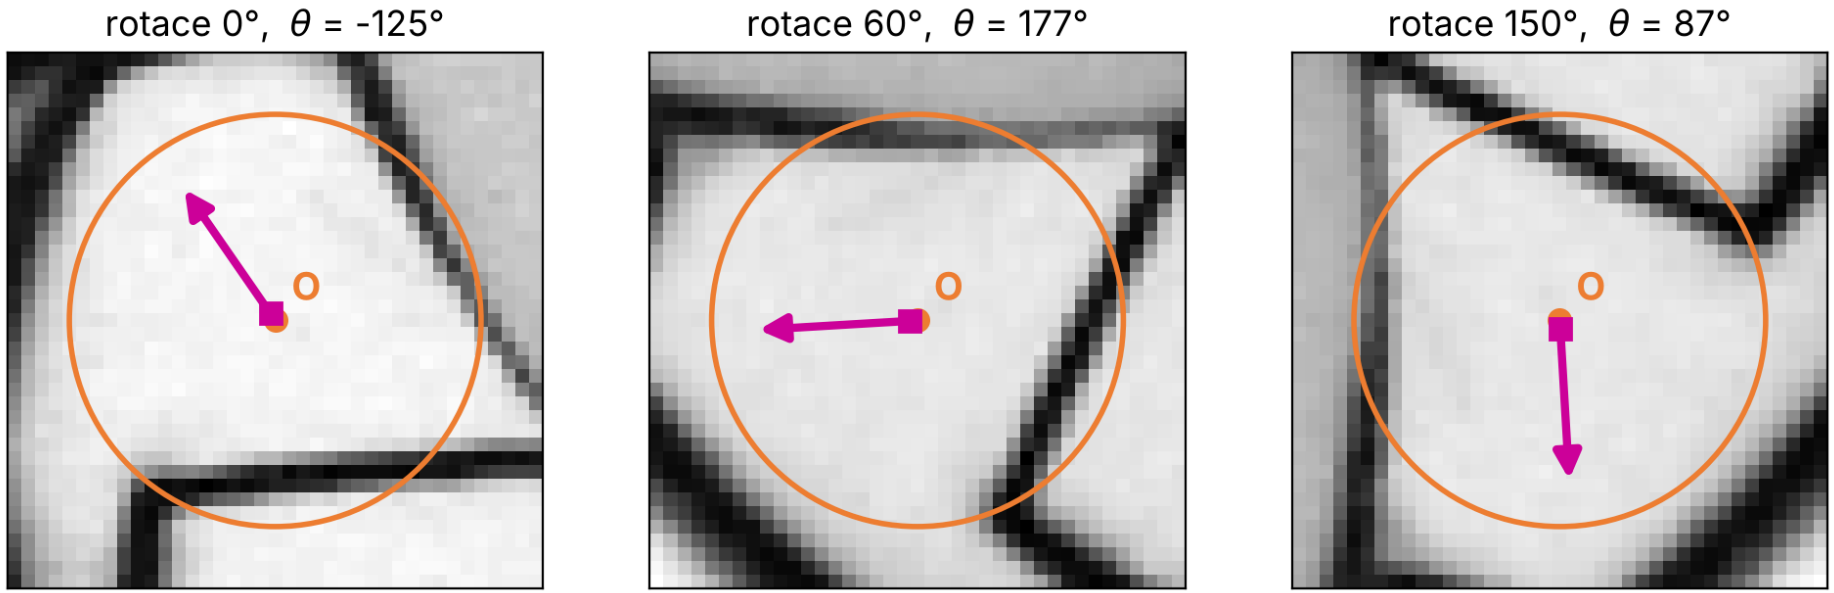


Orientace pomocí těžiště intenzit

- Momenty kruhového okolí bodu (poloměr r):
- Těžiště intenzit C a orientace θ = směr vektoru z bodu O do C:

$$m_{pq} = \sum_{x,y} x^p y^q I(x,y)$$

$$C = \left(\frac{m_{10}}{m_{00}}, \frac{m_{01}}{m_{00}} \right) \qquad \theta = \text{atan2}(m_{01}, m_{10})$$



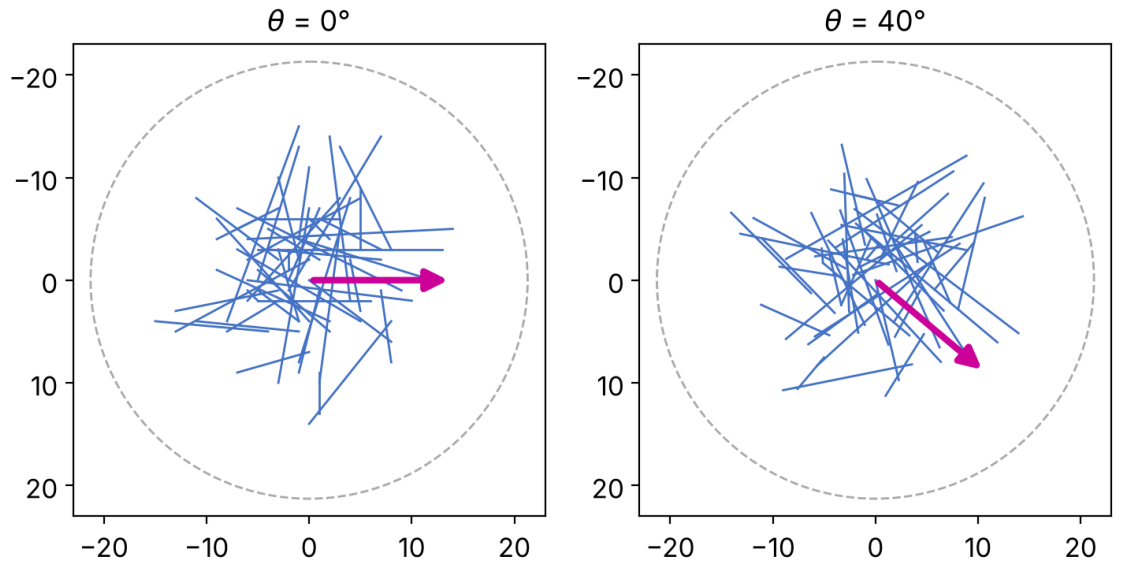
zdroj: https://www.robots.ox.ac.uk/~vgg/data/affine/

rBRIEF: natočení testů podle orientace

- Steered BRIEF: pozice testů otočeny o orientaci bodu θ

$$S_\theta = R_\theta S, \qquad S = \begin{pmatrix} \boldsymbol{x}_1 & \dots & \boldsymbol{x}_n \\ \boldsymbol{y}_1 & \dots & \boldsymbol{y}_n \end{pmatrix}$$

- Úhel diskretizován po 12° → předpočítané tabulky natočených vzorů
- Problém: natočené testy mají nižší rozptyl a jsou více korelované → horší rozlišitelnost deskriptorů



stejné testy, natočené podle orientace bodu

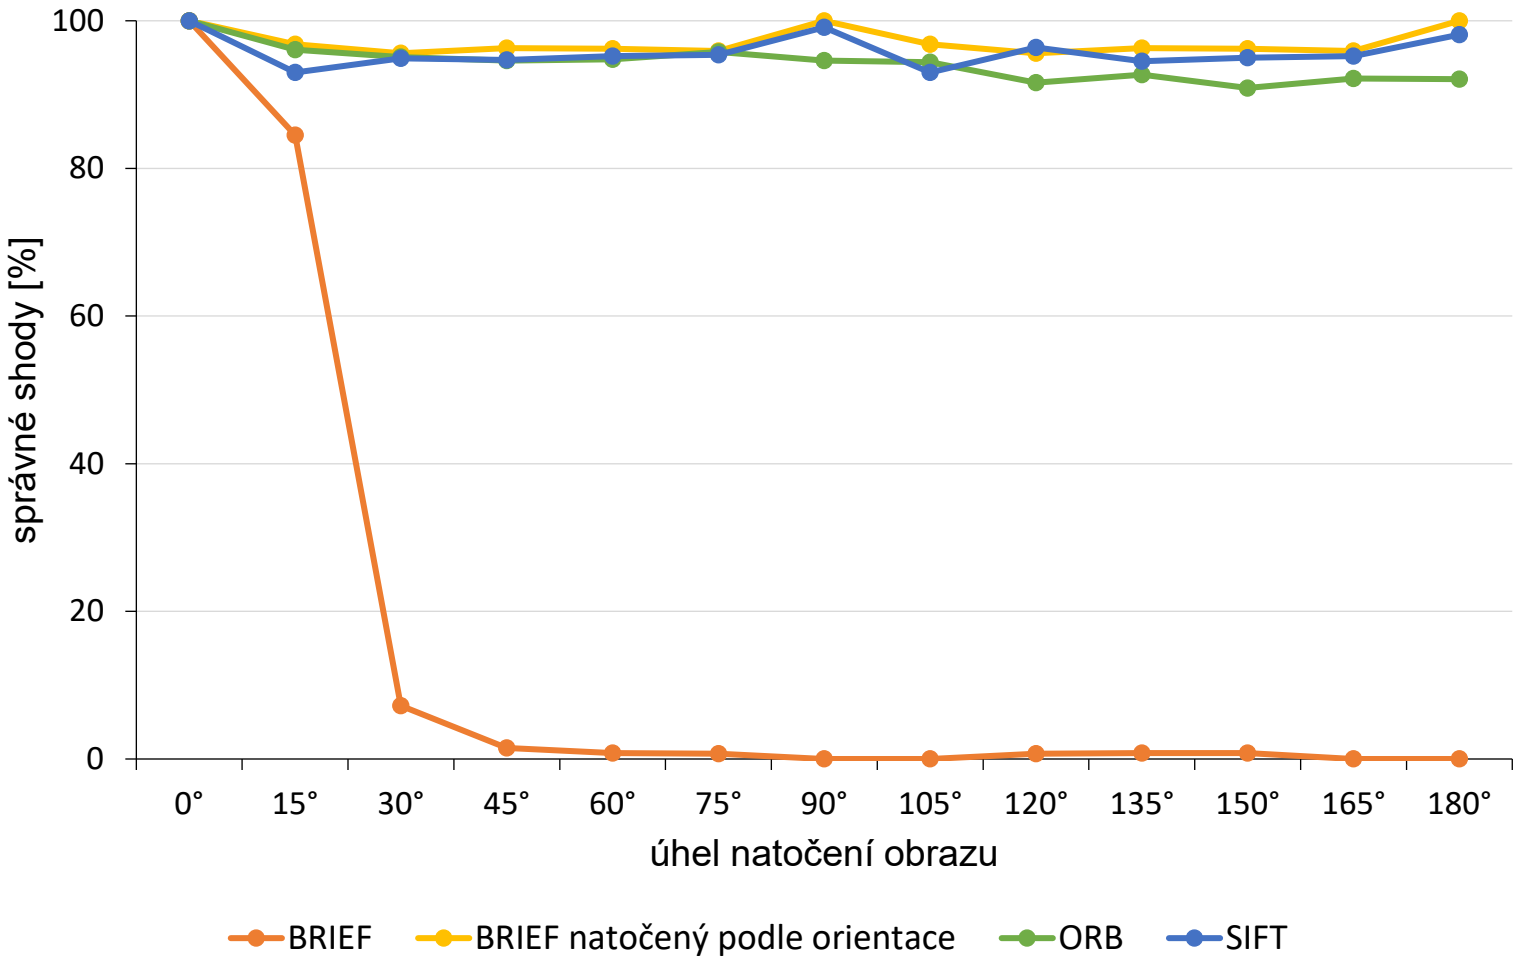
rBRIEF: učení binárních testů

- Cíl: testy s velkým rozptylem (průměr blízko 0.5) a malou vzájemnou korelací
- Trénovací množina cca 300 000 bodů (PASCAL VOC 2006), oblast 31×31, testy porovnávají průměry pod-oken 5×5 → 205 590 kandidátů

1. Spočítat test na všech trénovacích bodech a seřadit testy podle vzdálenosti průměru od 0.5
2. Hladově procházet seřazené testy; test přidat, pokud jeho korelace se všemi vybranými je menší než práh
3. Pokud není vybráno 256 testů, zvýšit práh a opakovat

- Výsledek: 256 nekorelovaných testů = 32 B deskriptor rBRIEF

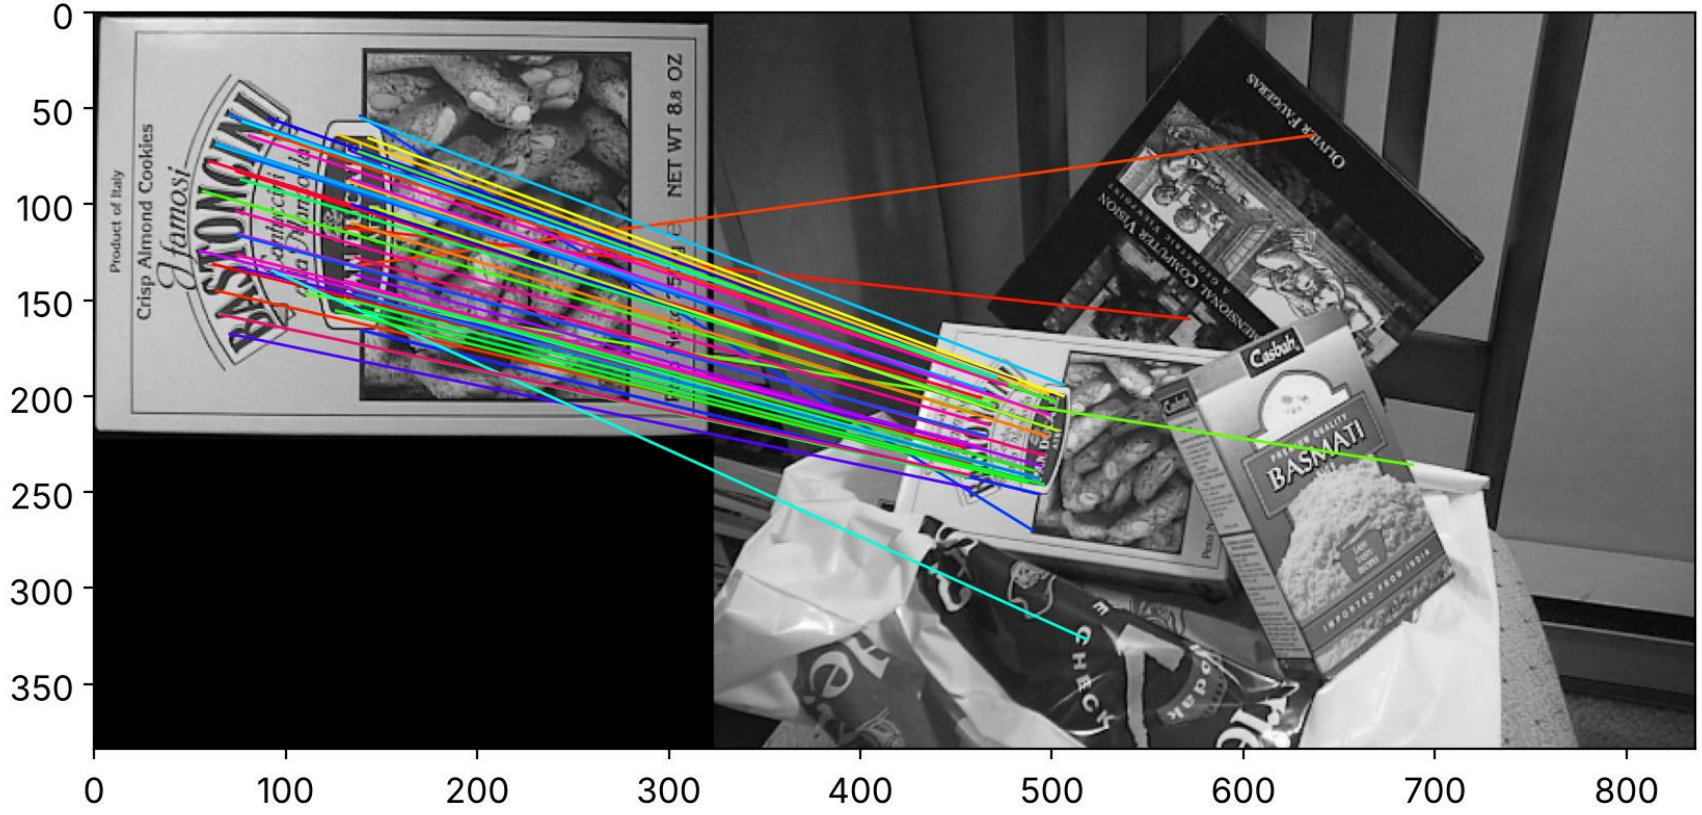
Invariance vůči rotaci: experiment



- Obraz otočen o úhel 0–180°
- 500 bodů, párování nejbližším sousedem s křížovou kontrolou
- Správná shoda: chyba < 4 px vůči známé transformaci

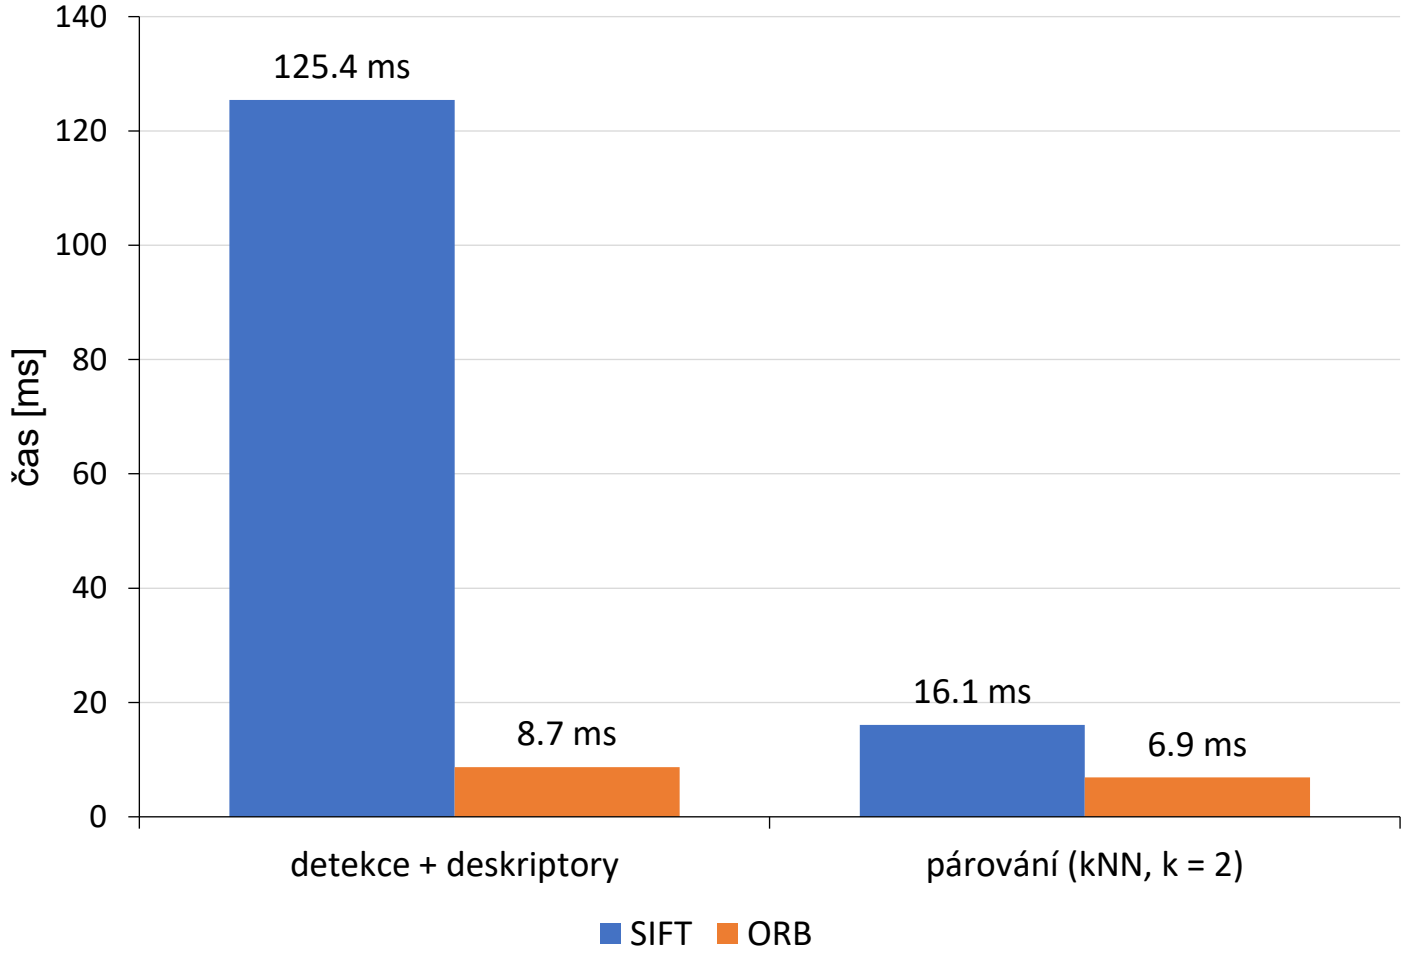
BRIEF selhává již při 30°, natočení testů podle orientace problém řeší

Příklad: párování ORB deskriptorů



1000 bodů ORB v každém obraze

Rychlost výpočtu: SIFT vs. ORB



- Obraz 800×640, 1000 bodů
- OpenCV 5.0, jedno vlákno CPU
- Deskriptor SIFT: 128 × float32 = 512 B
- Deskriptor ORB: 256 b = 32 B

ORB je cca 14× rychlejší při detekci a výpočtu deskriptorů a 16× úspornější v paměti

Další binární deskriptory

BRISK (2011)
Leutenegger, Chli, Siegwart

- detektor AGAST v prostoru měřítek
- pravidelný kruhový vzor vzorkování
- orientace z párů vzdálených bodů
- 512 bitů

FREAK (2012)
Alahi, Ortiz, Vandergheynst

- vzor inspirovaný sítnicí: hustý ve středu, řidší a více rozmazaný na okraji
- testy vybrány učením (jako ORB)
- kaskádové porovnání: hrubé → jemné
- 512 bitů

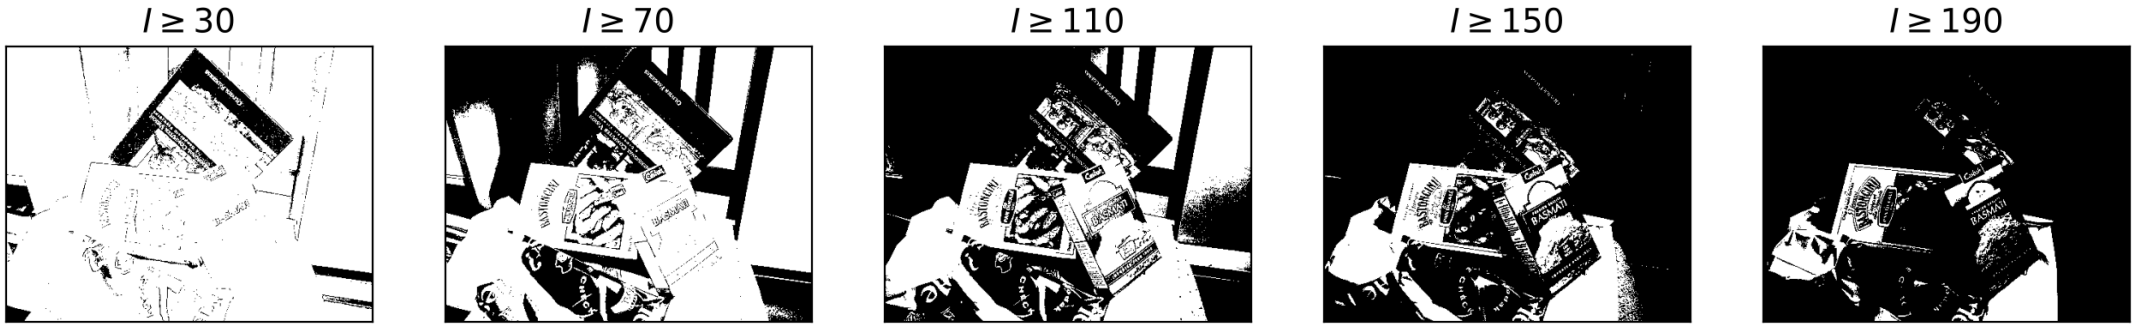
AKAZE (2013)
Alcantarilla, Nuevo, Bartoli

- nelineární prostor měřítek (anizotropní difúze) zachovává hrany
- deskriptor M-LDB: binární porovnání průměrů a gradientů v buňkách
- 486 bitů, volně v OpenCV

MSER

MSER (2002)

- Maximally Stable Extremal Regions
- Robust wide baseline stereo from maximally stable extremal regions (BMVC 2002)
- J. Matas, O. Chum, M. Urban, T. Pajdla (ČVUT Praha)
- Nedetekuje body, ale oblasti libovolného tvaru
- Myšlenka: prahujeme obraz všemi prahy $t = 0 \ldots 255$ a sledujeme souvislé komponenty
- Komponenty, které se v širokém rozsahu prahů téměř nemění, jsou stabilní → MSER



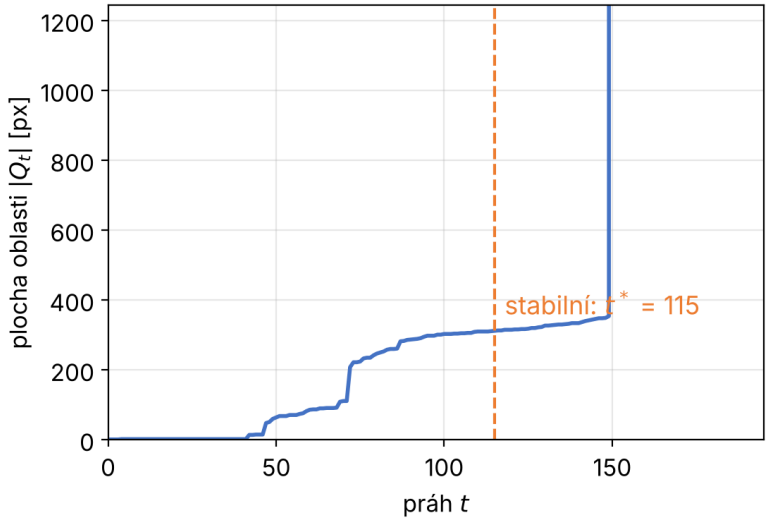
zdroj: https://github.com/opencv/opencv/tree/4.x/samples/data

Extremální oblasti a stabilita

- Extremální oblast Q: souvislá oblast, jejíž pixely jsou všechny jasnější (MSER+) nebo tmavší (MSER−) než pixely na její hranici ∂Q
- S rostoucím prahem t vznikají vnořené oblasti $Q_1 \subset Q_2 \subset \ldots$
- Stabilita = relativní změna plochy, MSER = lokální minimum $q(t)$

$$\forall p \in Q, \forall q \in \partial Q: \; I(p) > I(q)$$

$$q(t) = \frac{|Q_{t+\Delta} \setminus Q_{t-\Delta}|}{|Q_t|}$$



oblast Q_{t^*} (MSER−)



zdroj: https://github.com/opencv/opencv/tree/4.x/samples/data

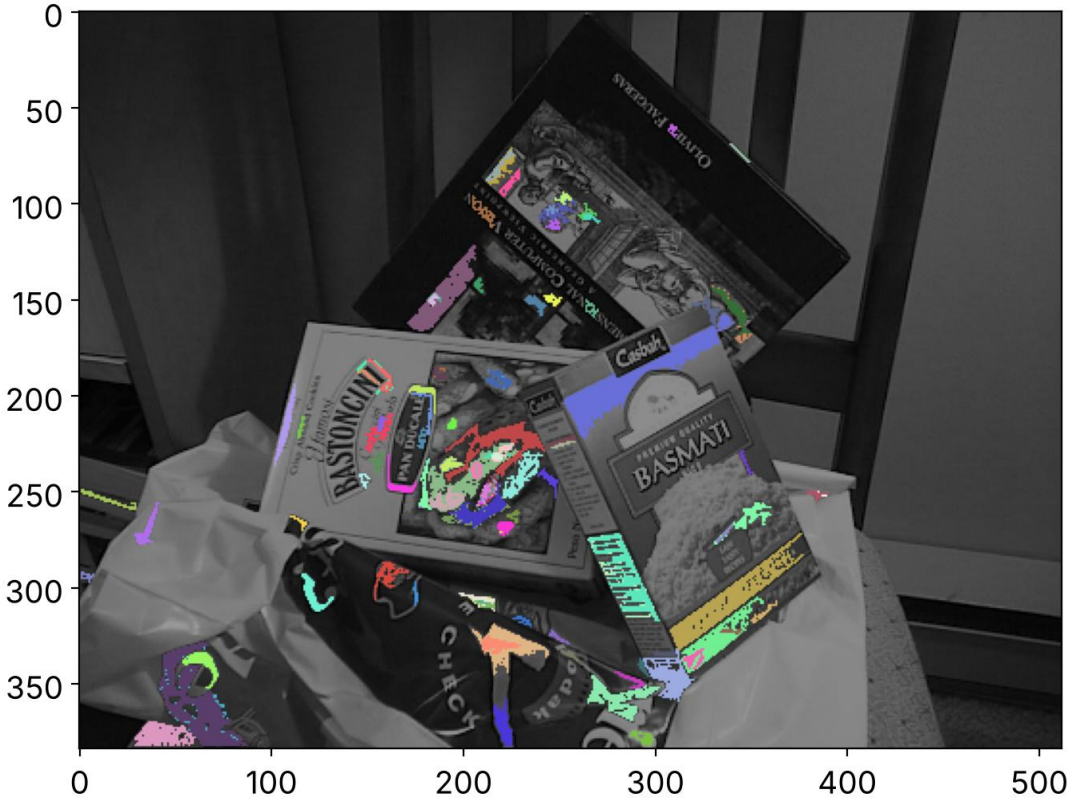
Výpočet MSER

1. Seřazení pixelů podle jasu (bucket sort, $O(n)$)
2. Přidávání pixelů od nejtmavšího, slučování sousedních komponent pomocí union-find

- Pro každou komponentu ukládána plocha $q(t)$ v závislosti na prahu → strom komponent

1. Spočítáme, jak se plocha $q(t)$ mění v závislosti na prahu $\psi(t) = \frac{(q(t+\Delta)-q(t-\Delta))}{q(t)}$
2. Výběr oblastí jako lokální minima $\psi(t)$
3. Totéž na invertovaném obraze → MSER+ i MSER−

Složitost téměř lineární, $O(n \log \log n)$
Nistér & Stewénius (2008): lineární algoritmus

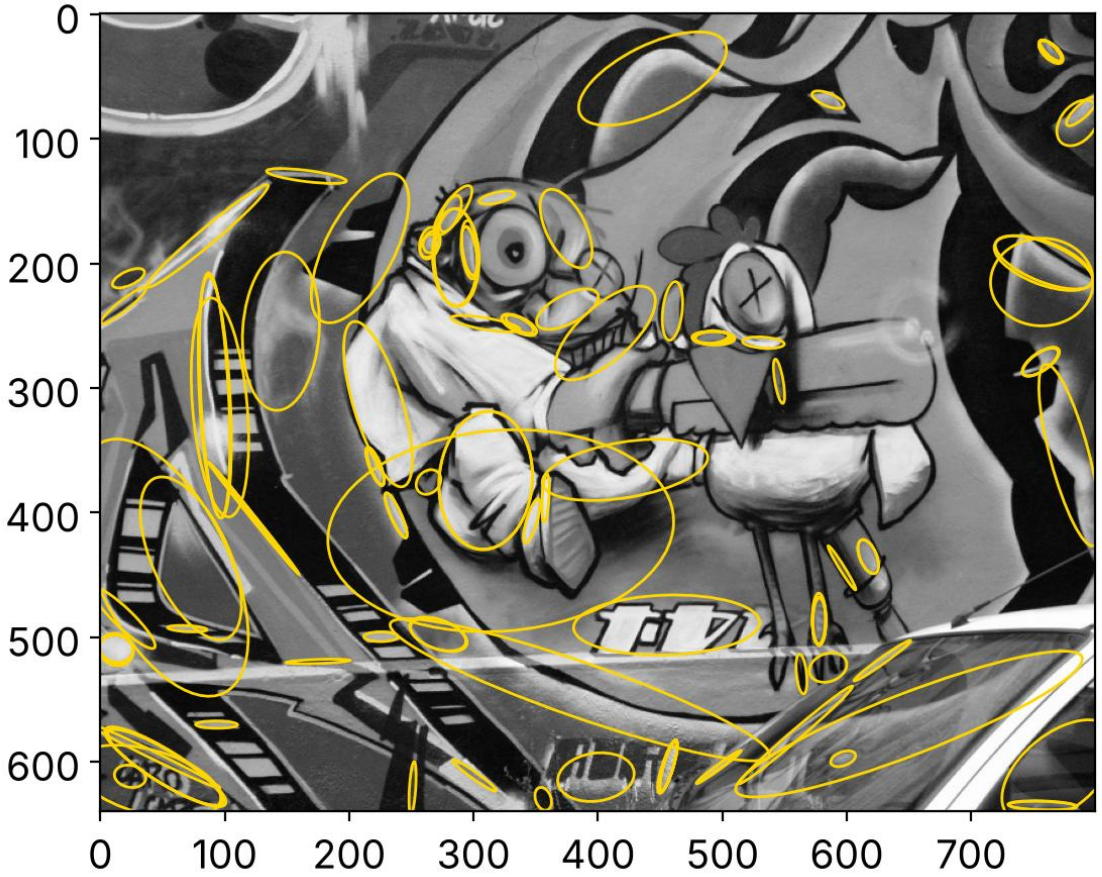


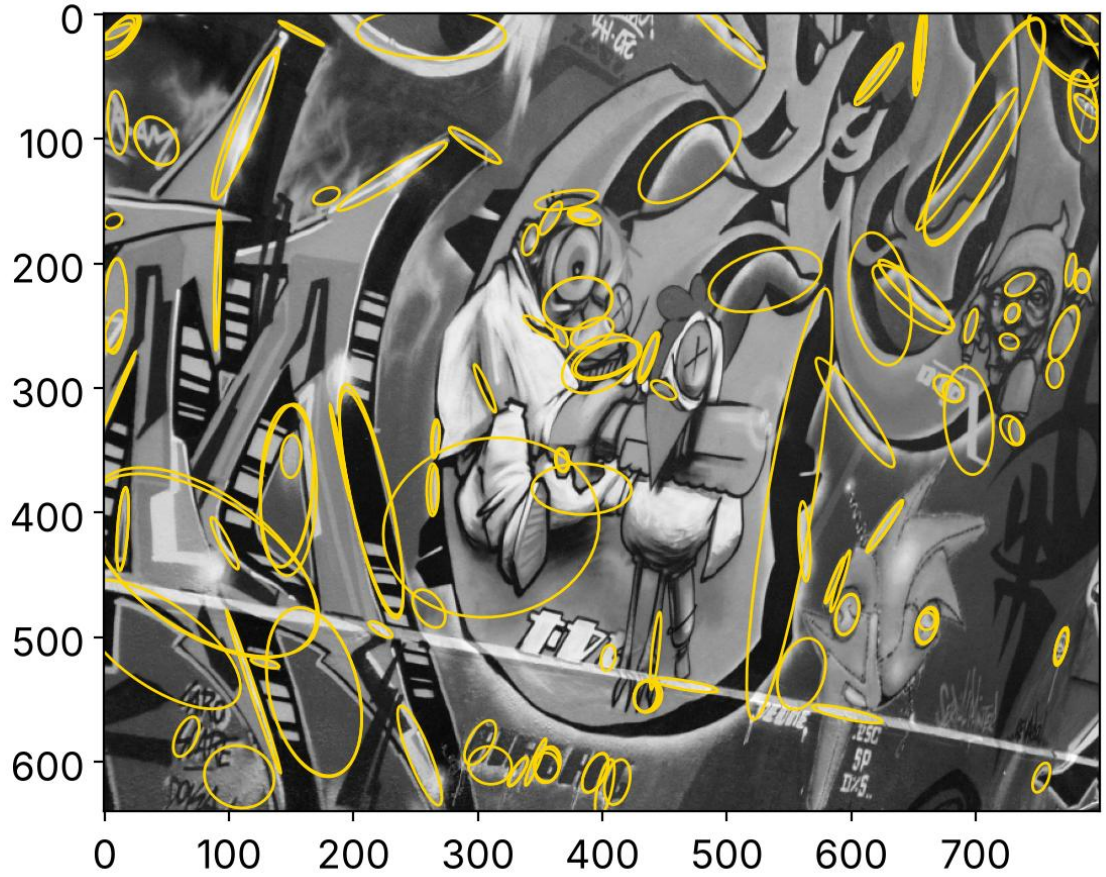
barevně: nalezené MSER oblasti

Vlastnosti MSER

- Invariantní vůči monotónní změně jasu (záleží jen na pořadí jasů)
- Kovariantní vůči spojitým geometrickým transformacím, které zachovávají sousednost pixelů (i afinní a projektivní)
- Detekuje malé i velké oblasti bez vyhlazování obrazu
- Vhodný pro strukturované scény (text, nápisy, značky), méně pro rozmazané a texturované obrazy
- Popis oblasti:
  - oblast aproximována elipsou pomocí momentů 2. řádu
  - elipsa normalizována na kruh → afinně invariantní okolí
  - z normalizovaného okolí vypočten deskriptor, např. SIFT

Příklad: MSER při změně úhlu pohledu



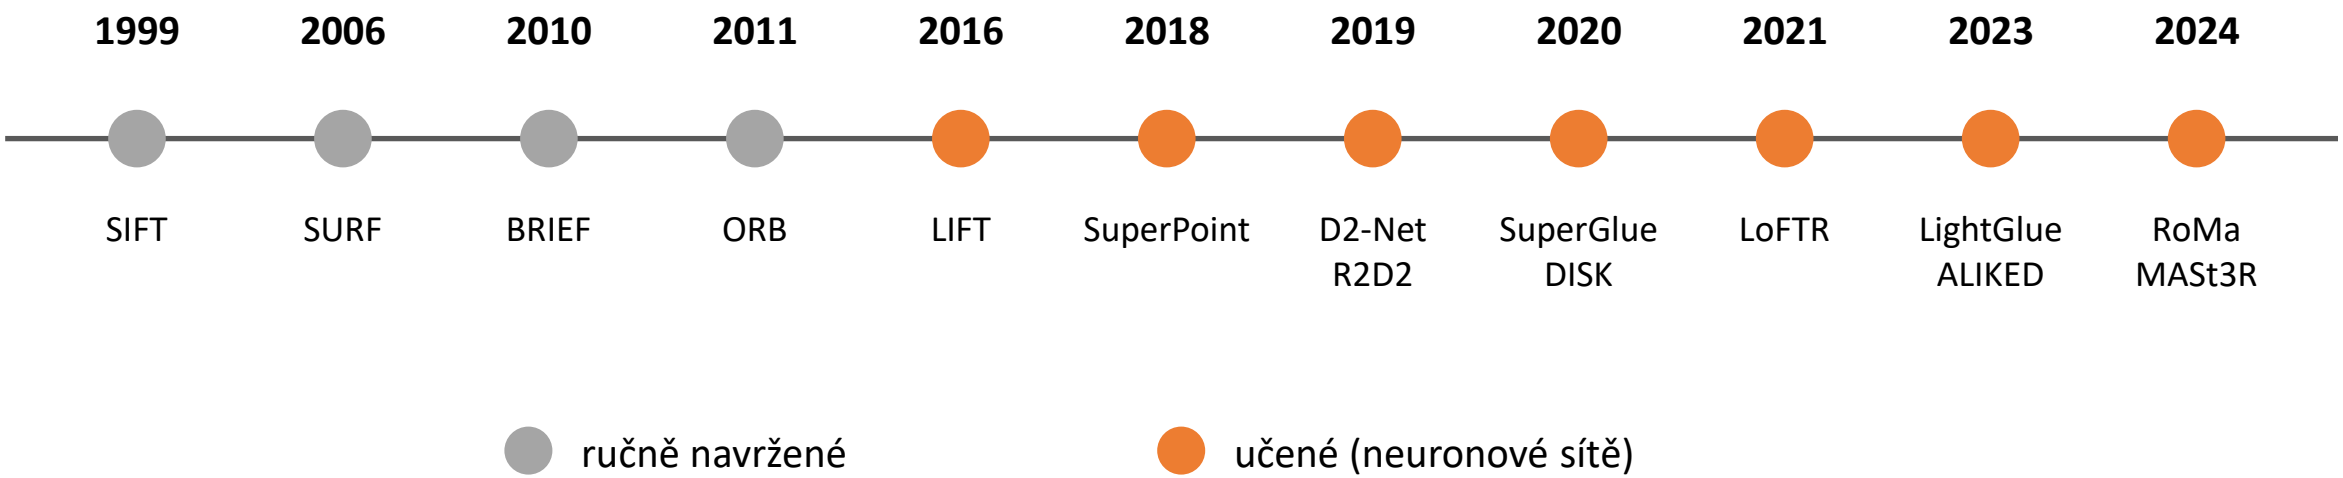


elipsy odpovídajících oblastí se mění kovariantně s transformací obrazu

Moderní metody: učené příznaky

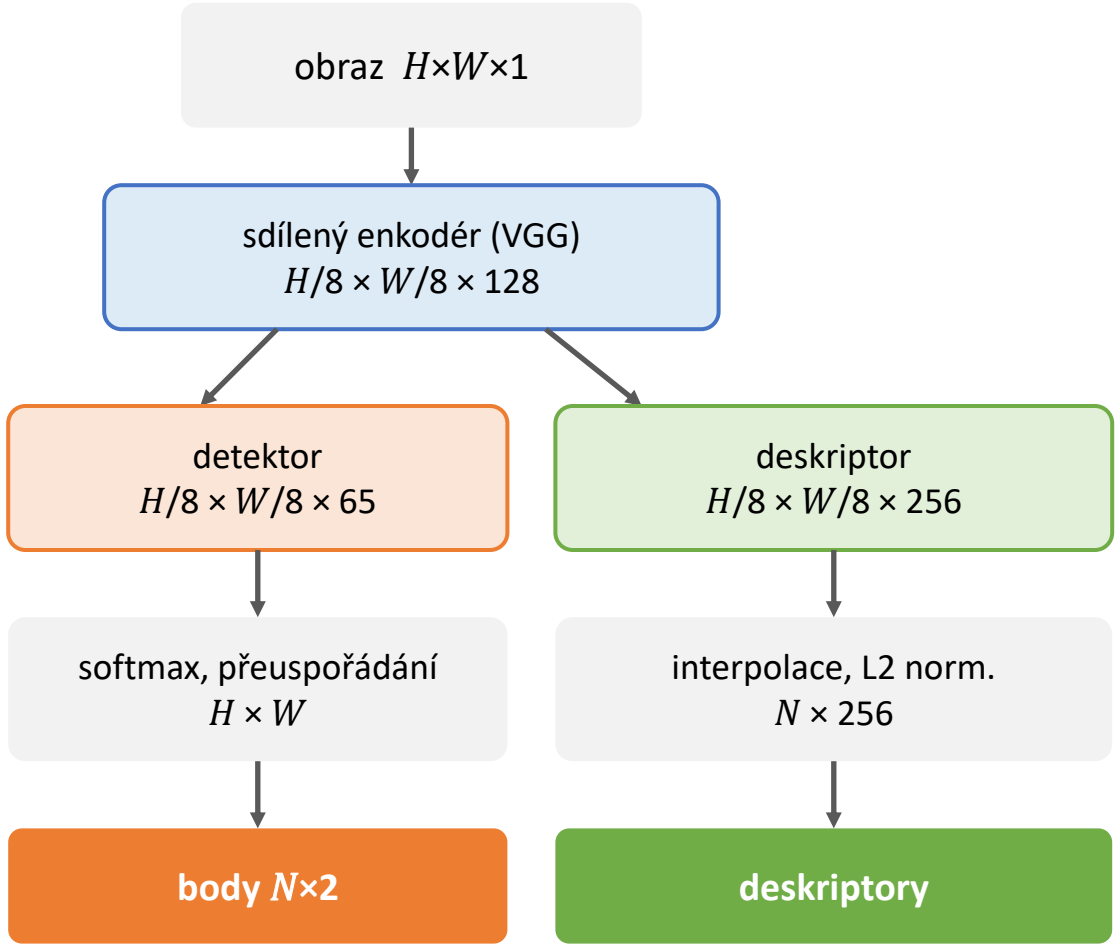
Od ručně navržených k učeným příznakům

- SIFT, SURF, ORB, MSER: ručně navržené (hand-crafted) postupy
- Problémy: velké změny osvětlení (den/noc), pohledu, ročních období, málo texturované scény
- Hluboké sítě se učí detektor, deskriptor a nově i samotné párování přímo z dat



SuperPoint (2018)

- DeTone, Malisiewicz, Rabinovich (CVPRW 2018)
- detektor i deskriptor v jedné síti
- Plně konvoluční síť, body i deskriptory v jednom průchodu celým obrazem
- Sdílený enkodér (VGG) zmenší obraz na $H/8 \times W/8$
- Hlava detektoru: 65 kanálů = 64 pozic v buňce 8×8 + „žádný bod“ → softmax → mapa $H \times W$
- Hlava deskriptoru: 256 kanálů → bikubická interpolace v pozicích bodů → L2 normalizace



SuperPoint: samo-učené trénování

Problém: neexistuje anotace „správných“ zájmových bodů v reálných obrazech

1

MagicPoint
síť trénovaná na syntetických tvarech (trojúhelníky, krychle, šachovnice), kde jsou rohy známé

→

2

Homografická adaptace
reálný obraz (MS-COCO) transformován stovkami náhodných homografií; detekce zpětně transformovány a sečteny → pseudo-anotace

→

3

Společné trénování
detektor i deskriptor na dvojicích obraz - obraz po homografii, kde jsou korespondence známé

žádná ruční anotace zájmových bodů není potřeba (self-supervised)

článek: [arXiv:1712.07629]

Příklad: SIFT vs. SuperPoint vs. DISK

SIFT (DoG): 1000 bodů



SuperPoint: 1000 bodů



DISK: 1000 bodů



1000 nejsilnějších bodů; učené detektory preferují jiné struktury než DoG

obrázek: https://www.robots.ox.ac.uk/~vgg/data/affine/ (modely: LightGlue-ONNX)

Přehled metod

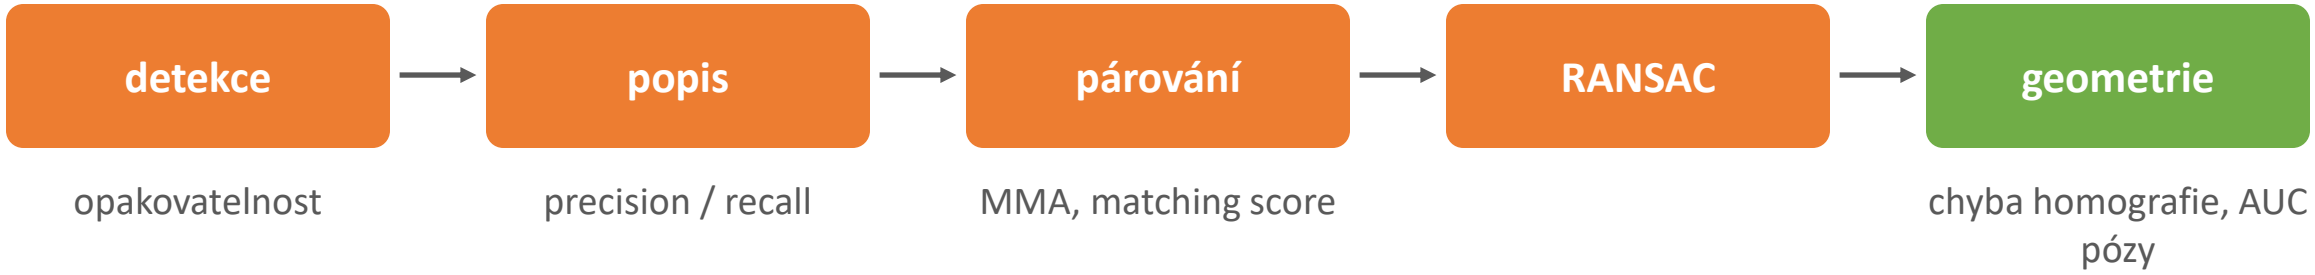
Metoda	Rok	Detektor	Deskriptor	Velikost	Vzdálenost
SIFT	1999	extrémy DoG	histogramy orientací gradientů	128 × float	L2
SURF	2006	det. Hessiánu (box filtry)	sumy Haarových vlnek	64 × float	L2
BRIEF	2010	– (libovolný)	binární testy	256 b	Hamming
ORB	2011	FAST + Harris, pyramida	rBRIEF (naučené testy)	256 b	Hamming
MSER	2002	extremální oblasti	– (např. SIFT po normalizaci)	–	–
SuperPoint	2018	CNN	CNN	256 × float	L2 / kosinová
DISK	2020	CNN	CNN	128 × float	L2
LoFTR	2021	bez detektoru	transformer, husté shody	–	–

příště: odhad geometrické transformace z korespondencí (homografie, RANSAC)

Benchmarky lokálních příznaků

Jak hodnotit lokální příznaky?

- Detektor: opakovatelnost (repeatability) – najdou se stejné body / oblasti v obou obrazech?
- Deskriptor: rozlišitelnost – precision a recall párování, podíl správných shod
- Celý řetězec: přesnost odhadnuté geometrie (homografie, relativní póza kamery, lokalizace)
- Potřebujeme ground truth: známou homografii (rovinné scény) nebo hloubku a pózy kamer (3D scény)



Opakovatelnost detektoru

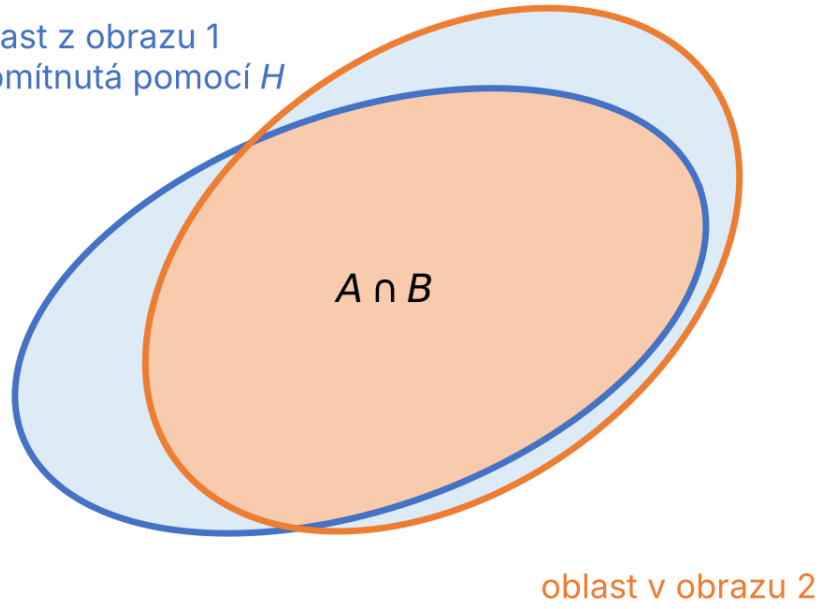
- Mikolajczyk et al. (IJCV 2005): A comparison of affine region detectors
- Oblasti z obrazu 1 promítneme známou homografií H do obrazu 2
- Korespondence = překryvová chyba oblastí $\varepsilon_0 < 40$ %

$$\varepsilon_0 = 1 - \frac{|A \cap B|}{|A \cup B|}$$

- Opakovatelnost (jen v části scény viditelné v obou obrazech):

$$r = \frac{\text{počet korespondencí}}{\min(n_1, n_2)}$$

Pro body bez tvaru: vzdálenost po promítnutí < ε px



zde ε_0 = 32 % → korespondence

Oxford Affine dataset (2005)

- Mikolajczyk, Tuytelaars, Schmid, Zisserman, Matas, Schaffalitzky, Kadir, Van Gool (IJCV 2005) a Mikolajczyk & Schmid: A performance evaluation of local descriptors (PAMI 2005)
- 8 sekvencí po 6 obrazech, rovinné scény → známé homografie
- Změny: úhel pohledu (graf, wall), měřítko a rotace (boat, bark), rozmazání (bikes, trees), JPEG komprese (ubc), osvětlení (leuven)
- Dlouho standardní benchmark, dnes příliš malý a „nasycený“



graf: obraz 1



graf: obraz 3 (změna pohledu cca 30°)

obrázek: https://www.robots.ox.ac.uk/~vgg/data/affine/

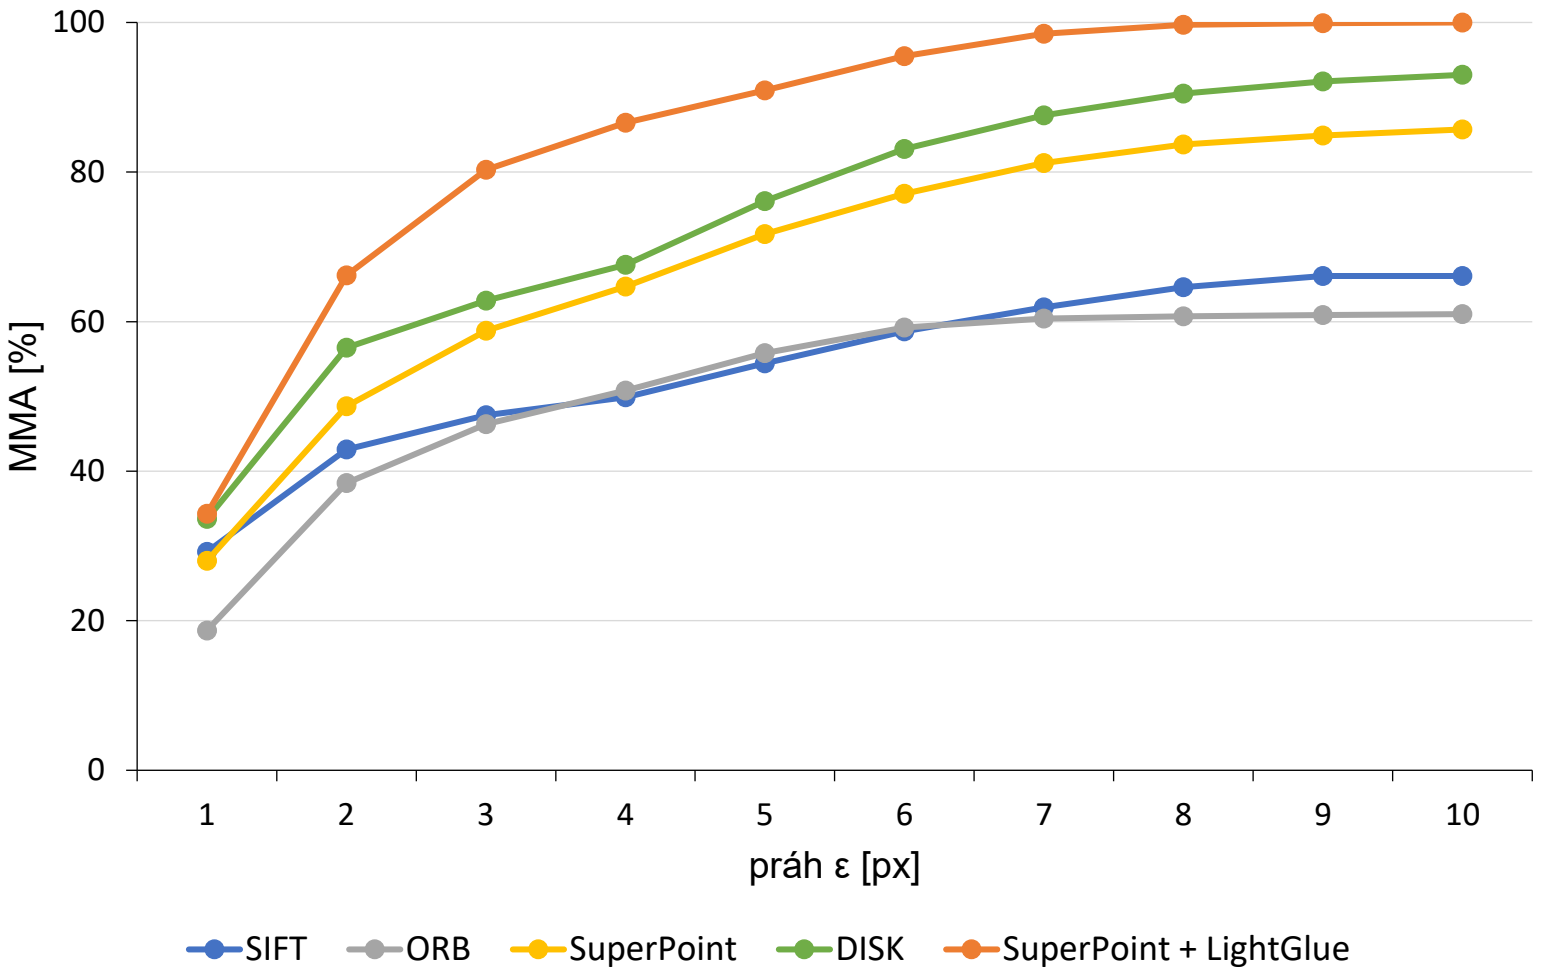
HPatches (2017)

- Balntas, Lenc, Vedaldi, Mikolajczyk (CVPR 2017)
- 116 sekvencí po 6 obrazech: 57 se změnou osvětlení, 59 se změnou úhlu pohledu, známé homografie
- Původně 3 úlohy pro deskriptory na vyříznutých oblastech: verifikace, párování, vyhledávání
- Dnes nejčastěji celý řetězec detekce + popis + vzájemně nejbližší sousedé → MMA (mean matching accuracy) pro prahy 1–10 px (D2-Net, 2019)

$$\mathrm{MMA}(\varepsilon) = \frac{1}{|M|} \sum_{i \in M} [\|H\boldsymbol{x}_i - \boldsymbol{x}_i'\| < \varepsilon]$$

- Další metrika: přesnost odhadu homografie (průměrná chyba rohů obrazu < ε px)

Příklad: MMA na páru graf 1 → 3



- max. 2000 bodů na obraz
- párování vzájemně nejbližšími sousedy (LightGlue: vlastní párování)
- správnost podle známé homografie

učené metody jsou přesnější hlavně při volnějších prazích

pouze jeden pár obrazů – ilustrace metriky, ne benchmark

obrázky: https://www.robots.ox.ac.uk/~vgg/data/affine/

Benchmarky na reálných 3D scénách

- MegaDepth (Li & Snavely, CVPR 2018): fotografie památek z internetu, hloubky a pózy z 3D rekonstrukce (COLMAP)
- ScanNet (Dai et al., CVPR 2017): RGB-D videa interiérů, málo textury, opakující se struktury
  - metrika: AUC chyby relativní pózy kamery pro prahy 5°, 10° a 20° (SuperGlue, LoFTR, LightGlue)
- Aachen Day-Night (Sattler et al., CVPR 2018): vizuální lokalizace, noční dotazy proti databázi pořízené ve dne
  - metrika: % dotazů lokalizovaných s chybou do (0.25 m, 2°), (0.5 m, 5°), (5 m, 10°)
- InLoc (Taira et al., CVPR 2018): lokalizace v interiérech

Přehled benchmarků

Benchmark	Rok	Data	Ground truth	Typická metrika
Oxford Affine	2005	8 × 6 obrazů, rovinné scény	homografie	opakovatelnost, precision / recall
HPatches	2017	116 × 6 obrazů, rovinné scény	homografie	MMA, přesnost homografie
ScanNet	2017	RGB-D videa interiérů	hloubkový senzor + póza	AUC pózy @ 5°/10°/20°
MegaDepth	2018	památky z internetu	3D rekonstrukce (SfM)	AUC pózy @ 5°/10°/20°
Aachen Day-Night	2018	město, den / noc	SfM model	% lokalizovaných dotazů
IMC (PhotoTourism)	2020–	památky z internetu	SfM (COLMAP)	mAA pózy