Počítačové vidění

Geometrické transformace a jejich odhad, registrace obrazu pomocí lokálních korespondencí

Geometrické transformace

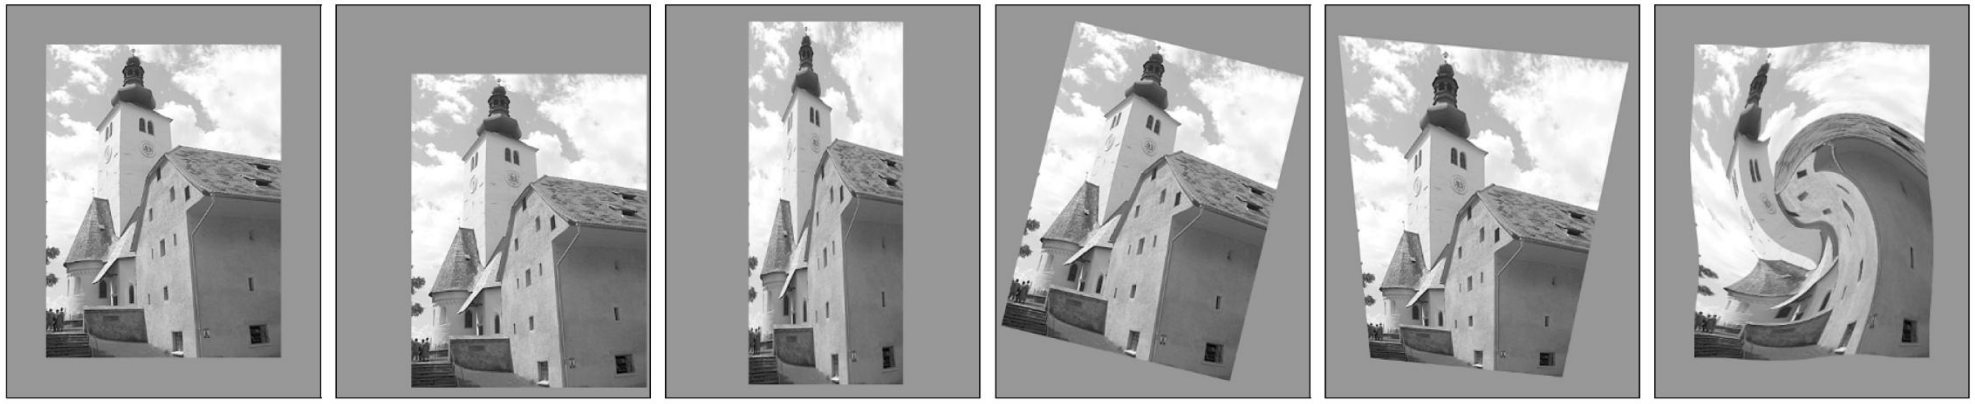


- Původní obrázek $I(x, y)$ transformujeme na nový obrázek $I'(x', y')$
- Každý pixel s původní pozicí (x, y) přemístíme na novou pozici (x', y') dle

$$x' = T_x(x, y)$$
$$y' = T_y(x, y)$$

zdroj: https://imagingbook.com/books/english-edition-hardcover/

Geometrické transformace

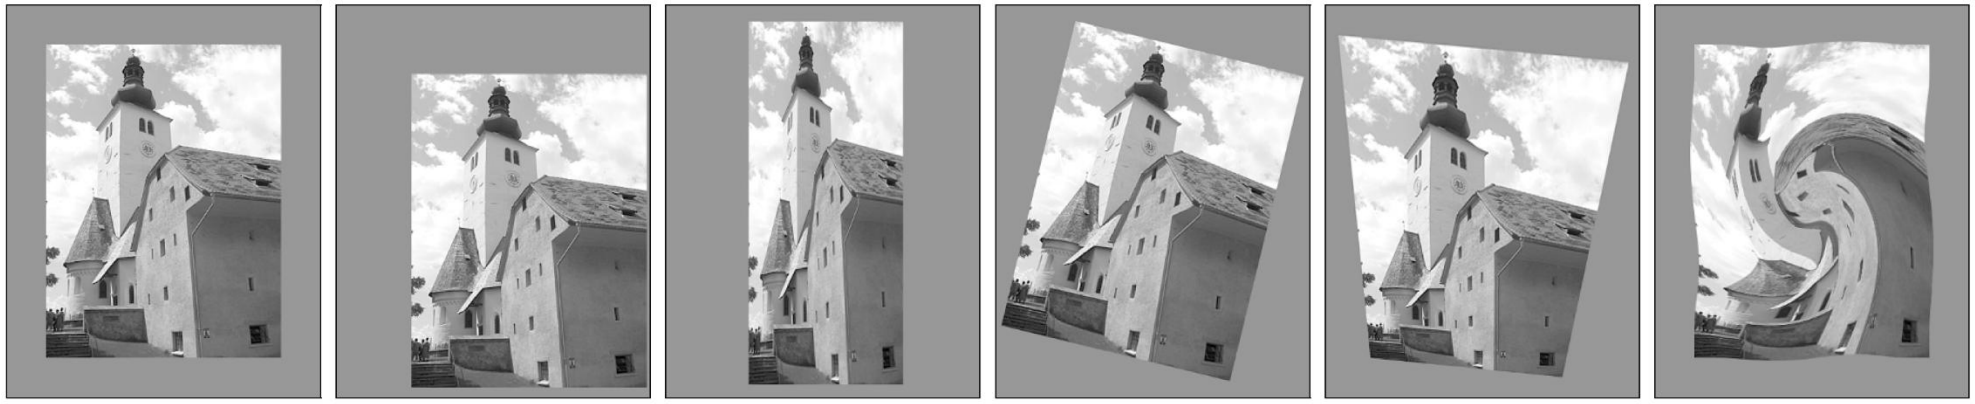


Posun (translace)

$$x' = x + t_x$$
$$y' = y + t_y$$

zdroj: https://imagingbook.com/books/english-edition-hardcover/

Geometrické transformace



$I(x, y)$

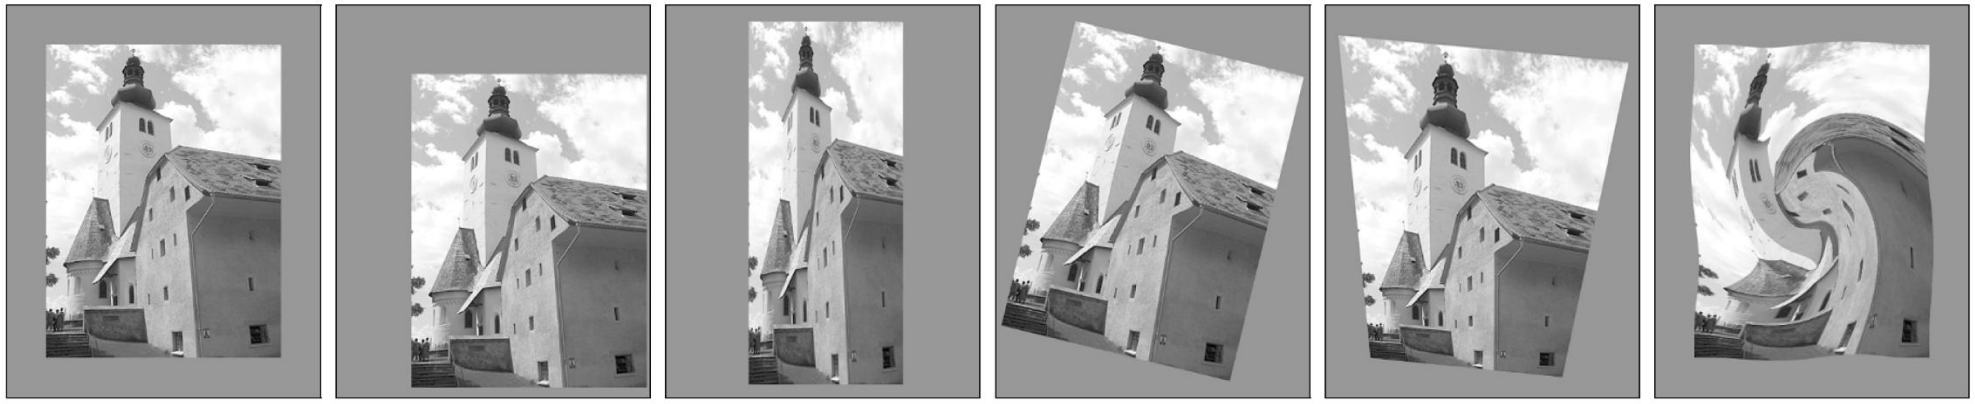
$I'(x', y')$

Změna měřítka (škálování)

$$x' = s_x \cdot x$$
$$y' = s_y \cdot y$$

zdroj: https://imagingbook.com/books/english-edition-hardcover/

Geometrické transformace



$I(x, y)$

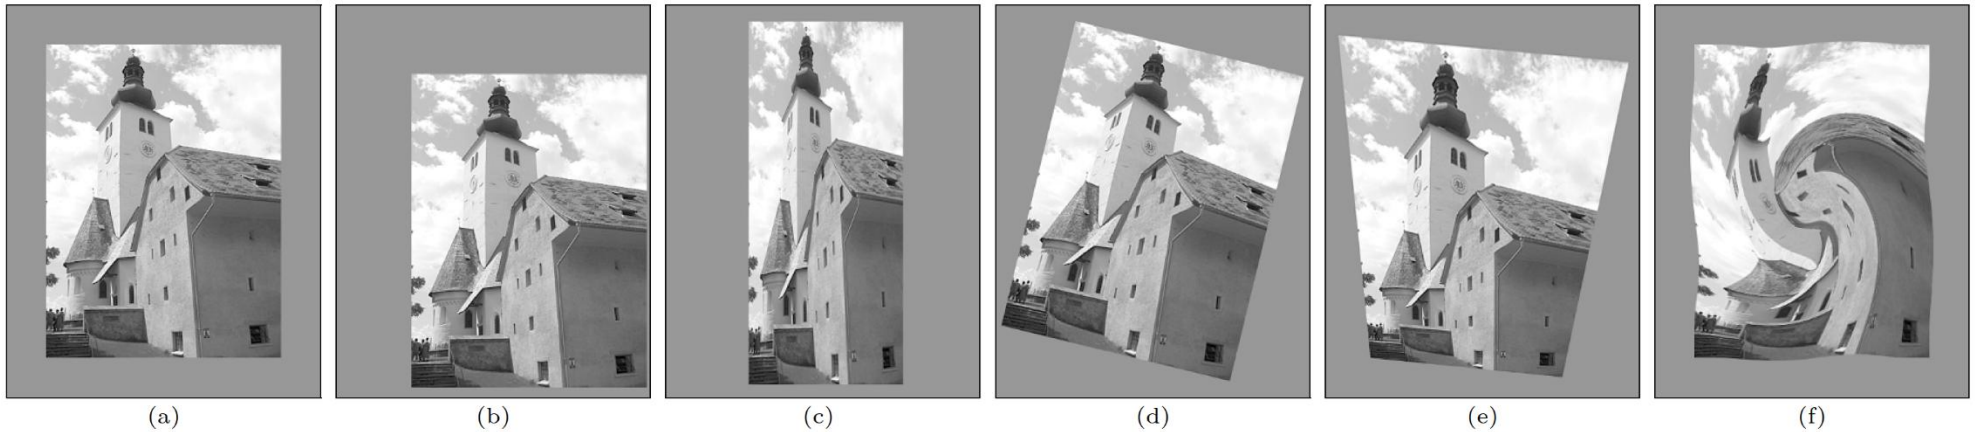
$I'(x', y')$

Otočení (rotace)

$$x' = x \cdot \cos(\alpha) - y \cdot \sin(\alpha)$$
$$y' = x \cdot \sin(\alpha) + y \cdot \cos(\alpha)$$

zdroj: https://imagingbook.com/books/english-edition-hardcover/

Geometrické transformace



Projektivní transformace (homografie)

$$x' = \frac{a_{1,1} \cdot x + a_{1,2} \cdot y + a_{1,3}}{a_{3,1} \cdot x + a_{3,2} \cdot y + a_{3,3}}$$

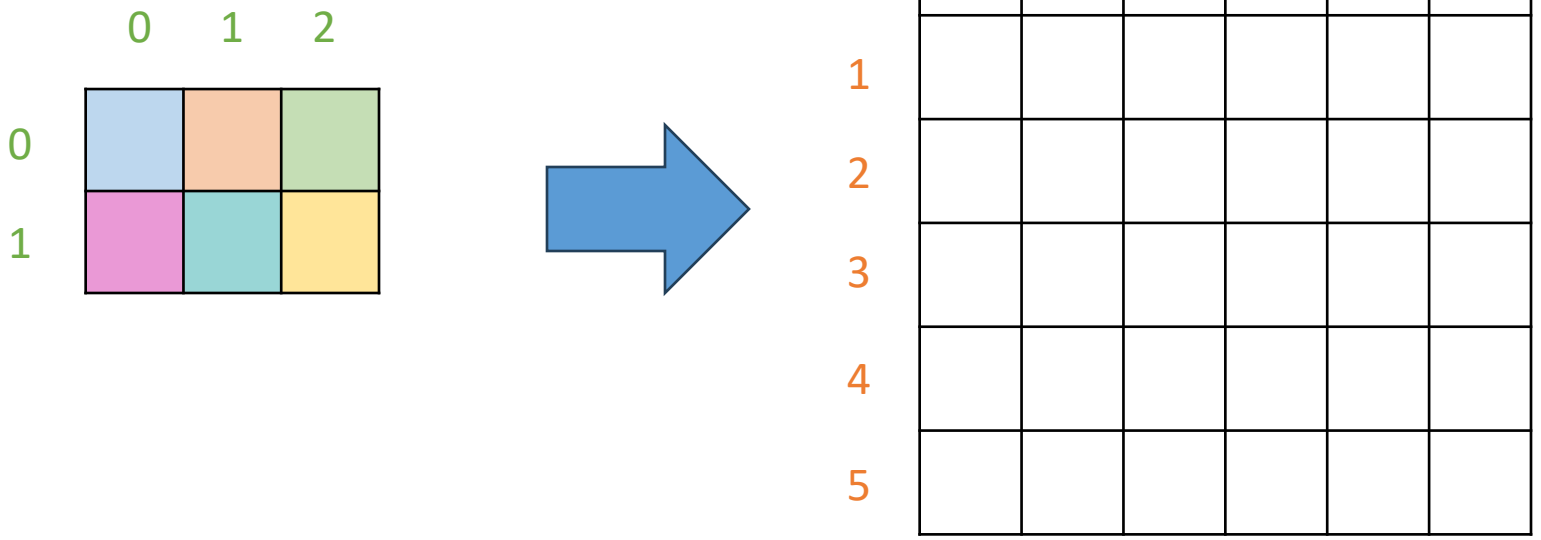
$$y' = \frac{a_{2,1} \cdot x + a_{2,2} \cdot y + a_{2,3}}{a_{3,1} \cdot x + a_{3,2} \cdot y + a_{3,3}}$$

zdroj: https://imagingbook.com/books/english-edition-hardcover/

Příklad: zvětšení obrázku

Změna měřítka (škálování)

$$x' = 2 \cdot x$$
$$y' = 3 \cdot y$$

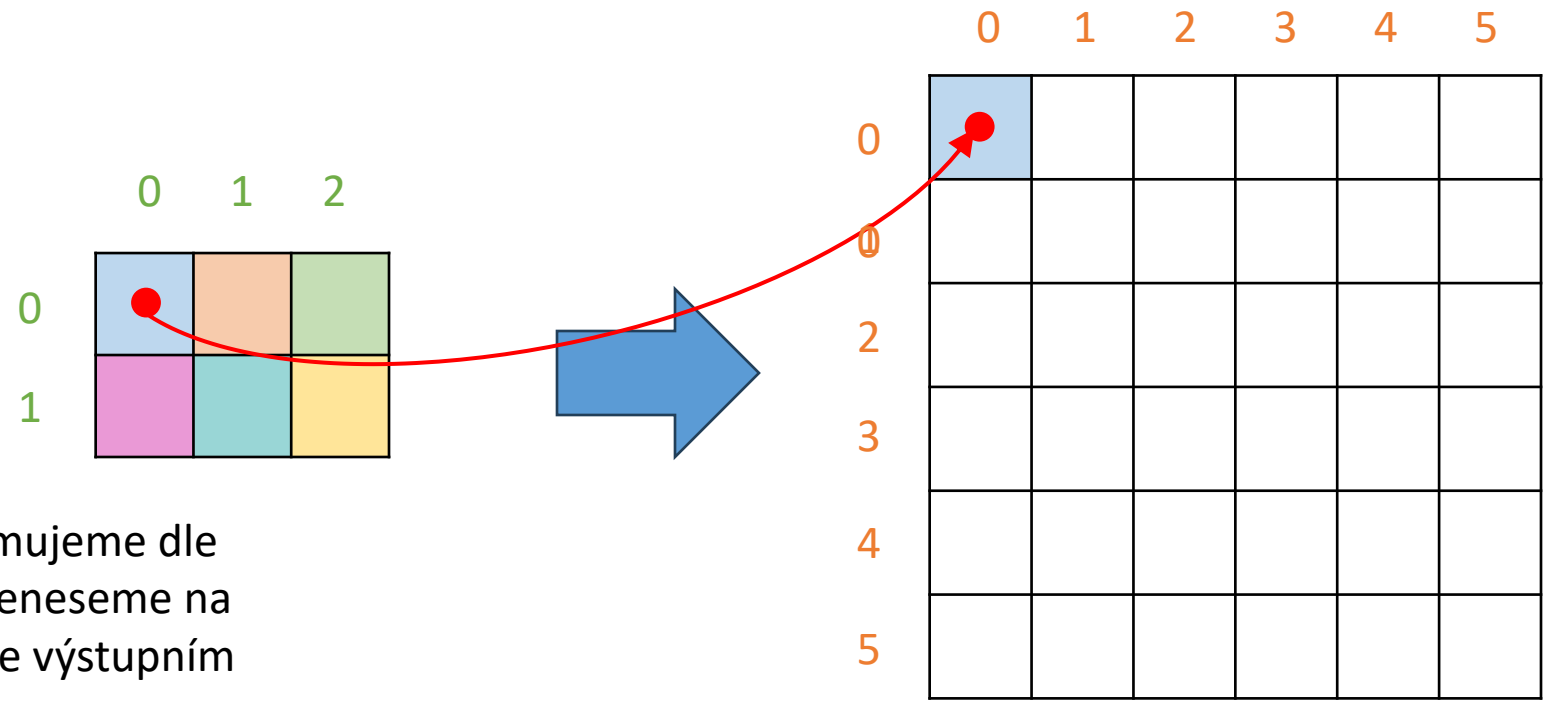


inicializujeme na nuly

Příklad: zvětšení obrázku

Změna měřítka (škálování)

$$x' = 2 \cdot x$$
$$y' = 3 \cdot y$$

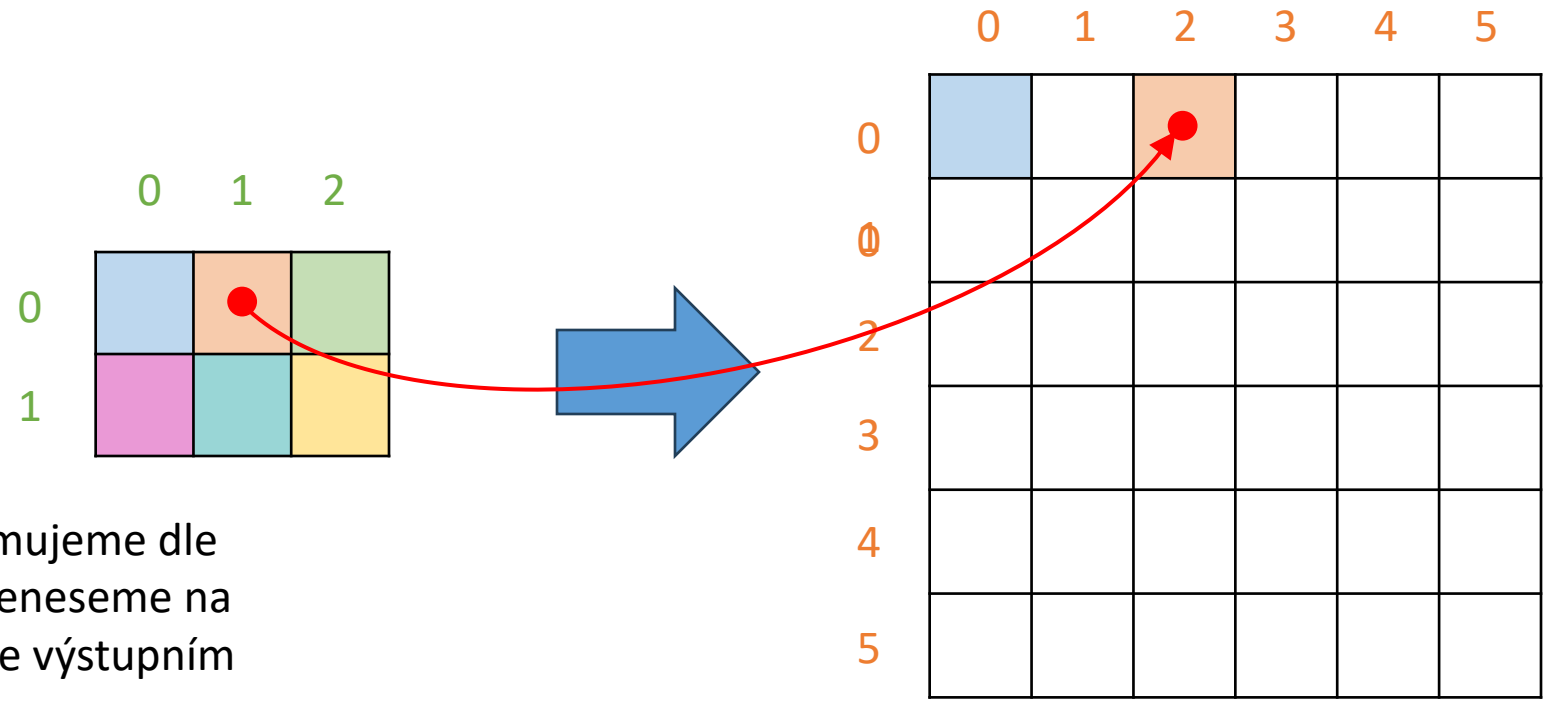


každý pixel transformujeme dle rovnic a hodnotu přeneseme na odpovídající místo ve výstupním obrázku

Příklad: zvětšení obrázku

Změna měřítka (škálování)

$$x' = 2 \cdot x$$
$$y' = 3 \cdot y$$

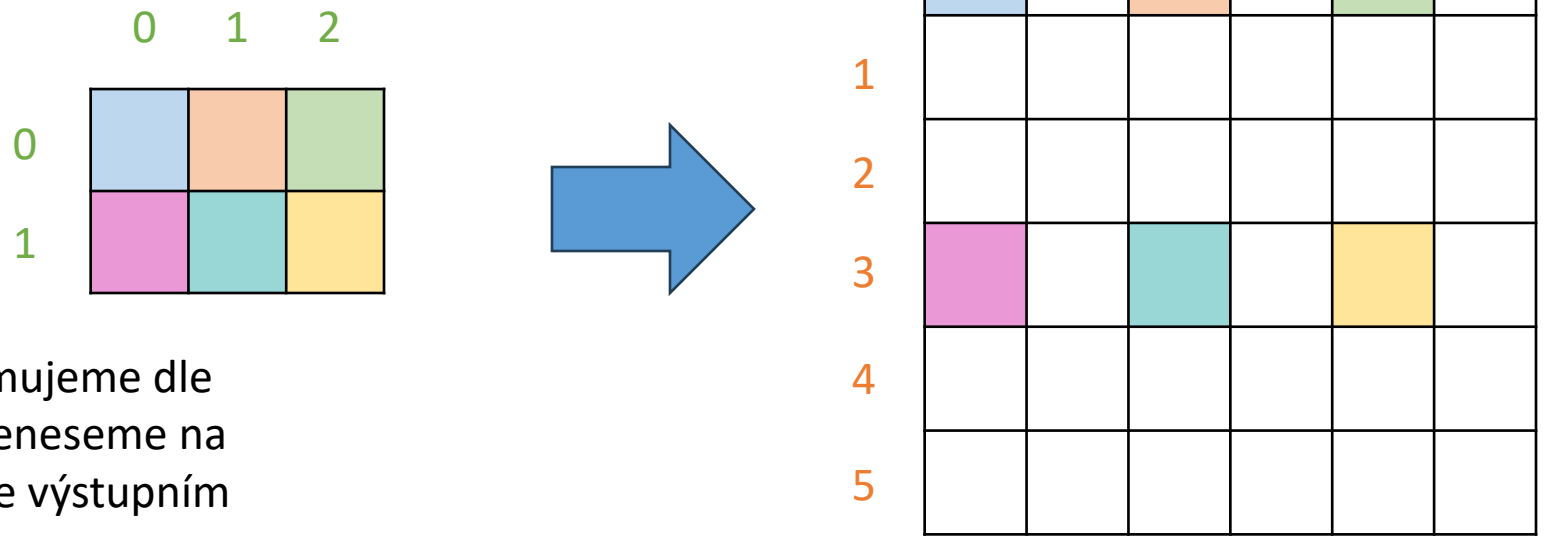


každý pixel transformujeme dle rovnic a hodnotu přeneseme na odpovídající místo ve výstupním obrázku

Příklad: zvětšení obrázku

Změna měřítka (škálování)

$$x' = 2 \cdot x$$
$$y' = 3 \cdot y$$

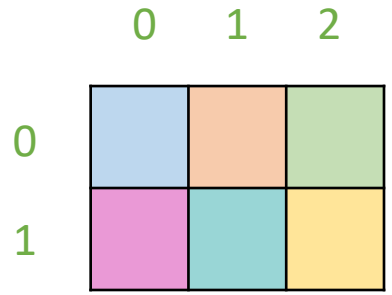


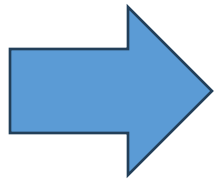
každý pixel transformujeme dle rovnic a hodnotu přeneseme na odpovídající místo ve výstupním obrázku

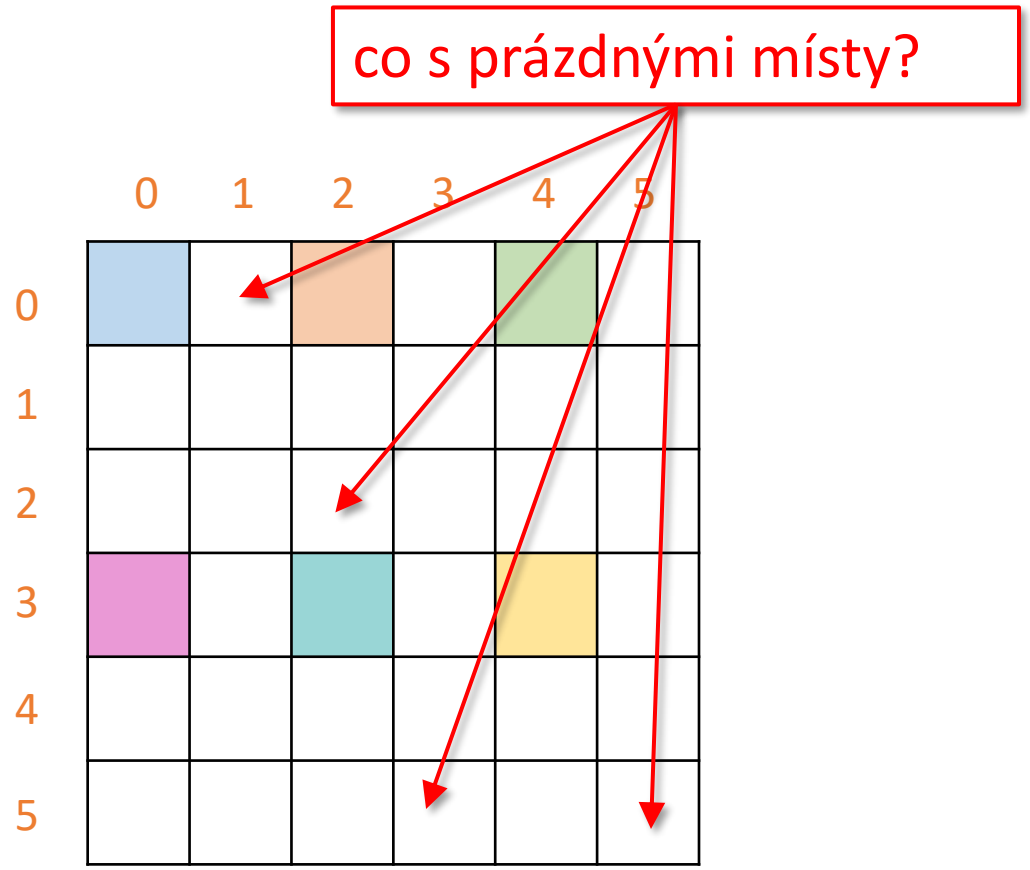
Příklad: zvětšení obrázku

Změna měřítka (škálování)

$$x' = 2 \cdot x$$
$$y' = 3 \cdot y$$







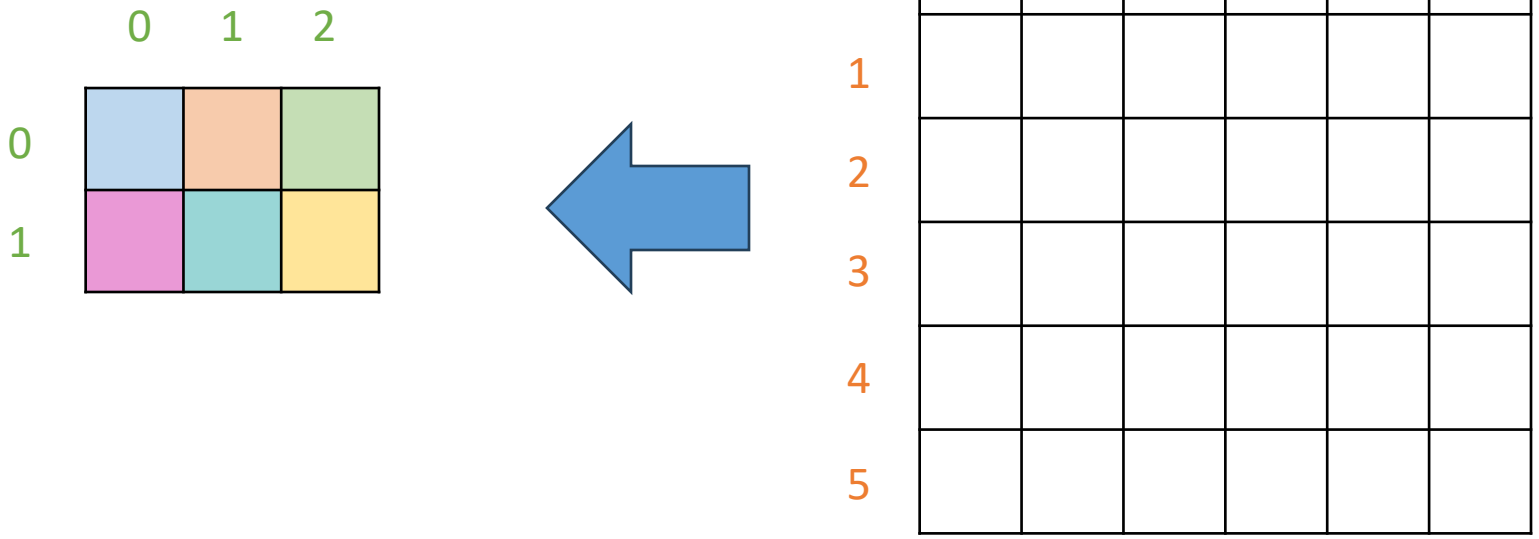
každý pixel transformujeme dle rovnic a hodnotu přeneseme na odpovídající místo ve výstupním obrázku

Příklad: zvětšení obrázku

Změna měřítka (škálování)

$$x = \frac{x'}{2}$$

$$y = \frac{y'}{3}$$

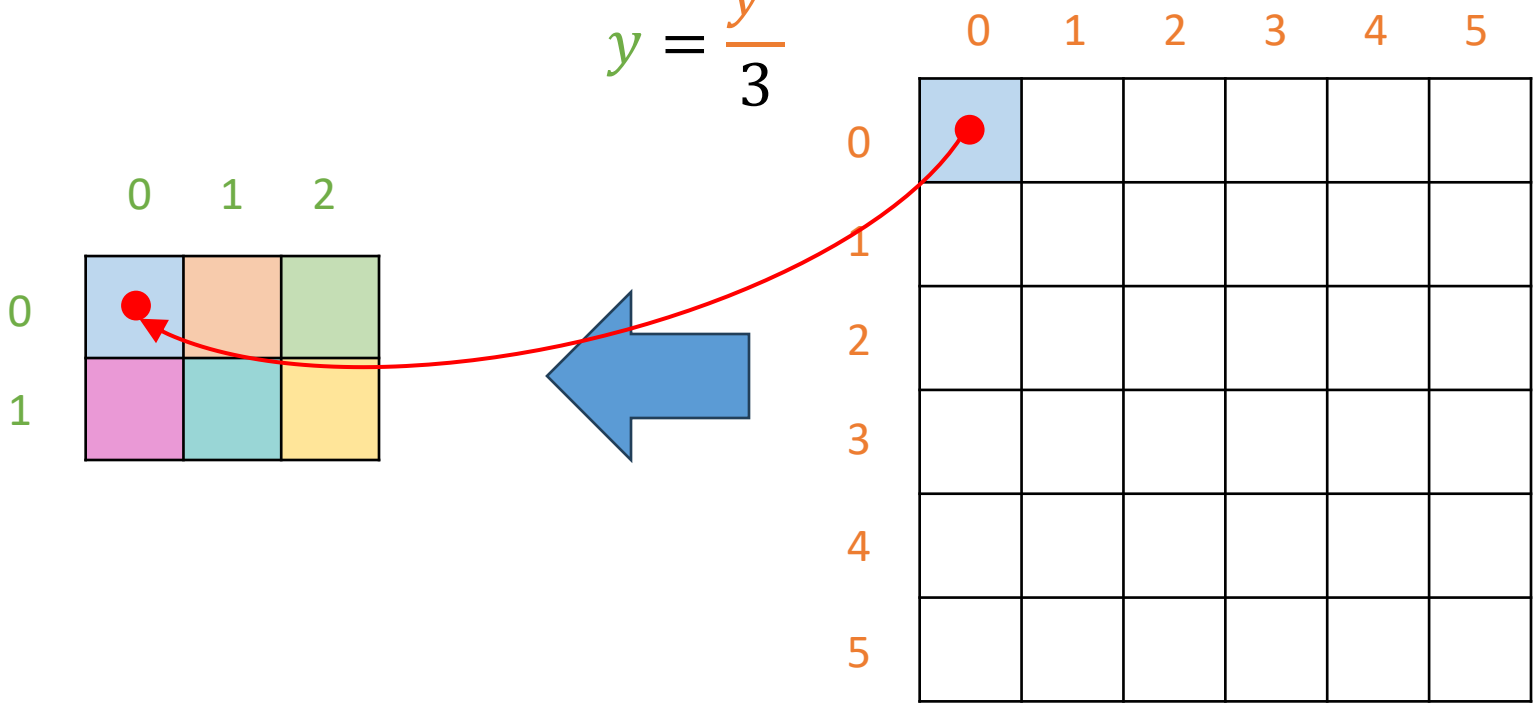


Příklad: zvětšení obrázku

Změna měřítka (škálování)

$$x = \frac{x'}{2}$$

$$y = \frac{y'}{3}$$

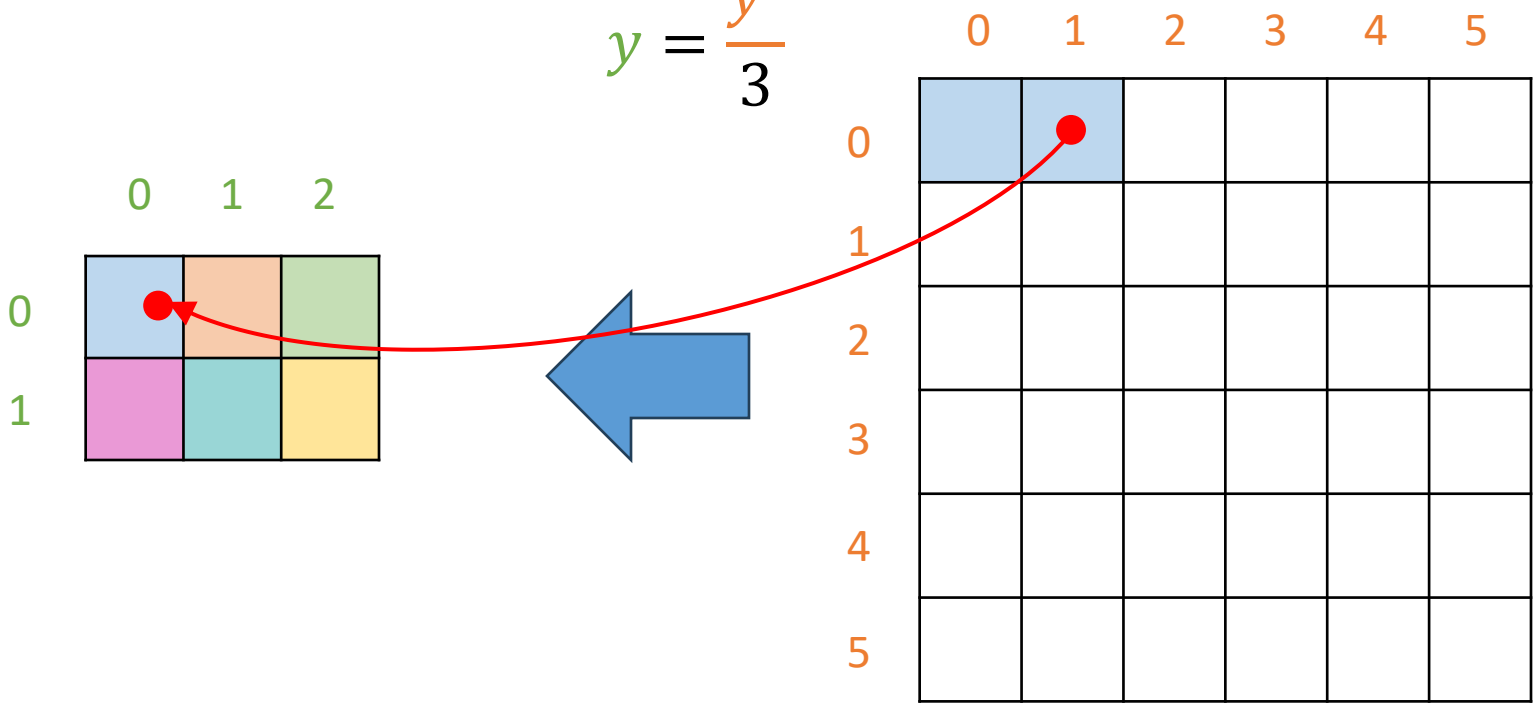


Příklad: zvětšení obrázku

Změna měřítka (škálování)

$$x = \frac{x'}{2}$$

$$y = \frac{y'}{3}$$

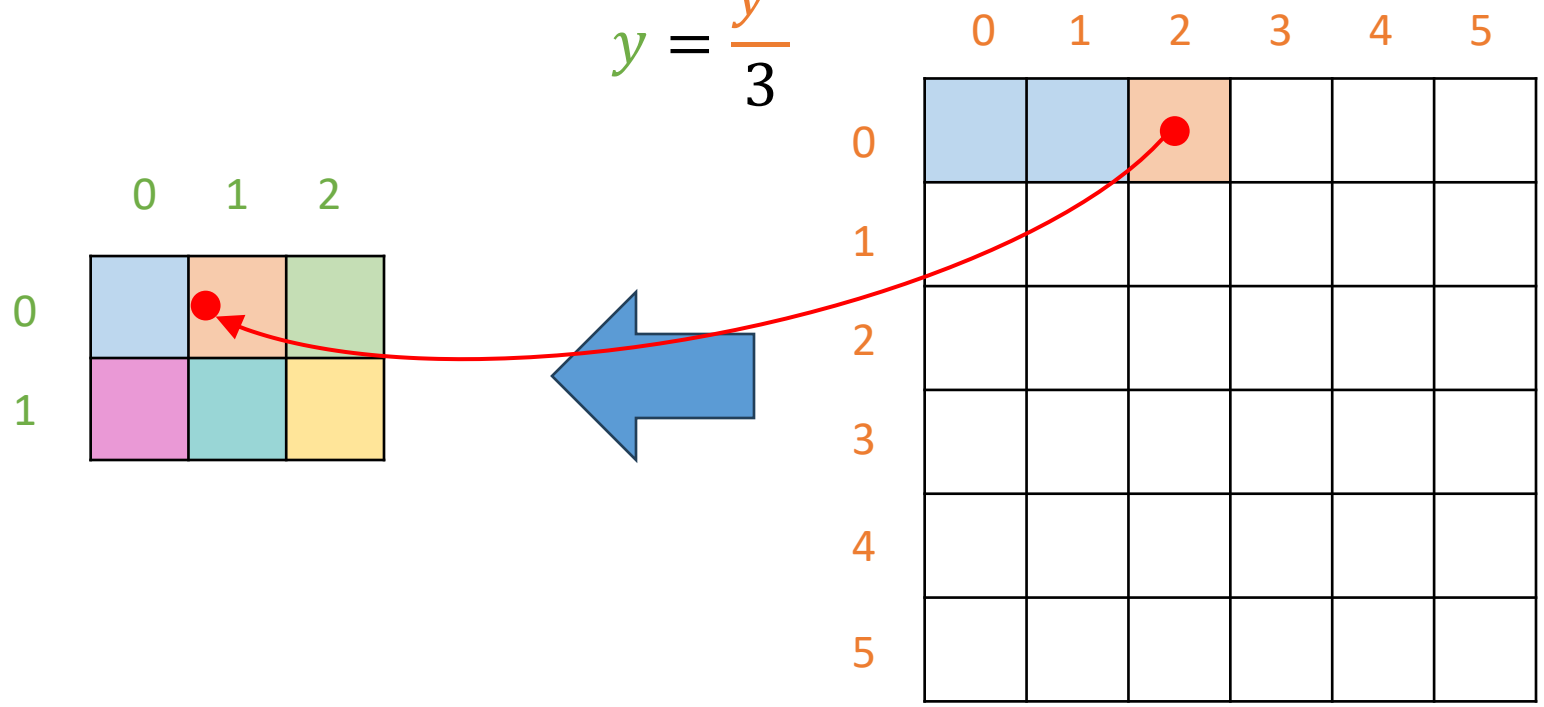


Příklad: zvětšení obrázku

Změna měřítka (škálování)

$$x = \frac{x'}{2}$$

$$y = \frac{y'}{3}$$

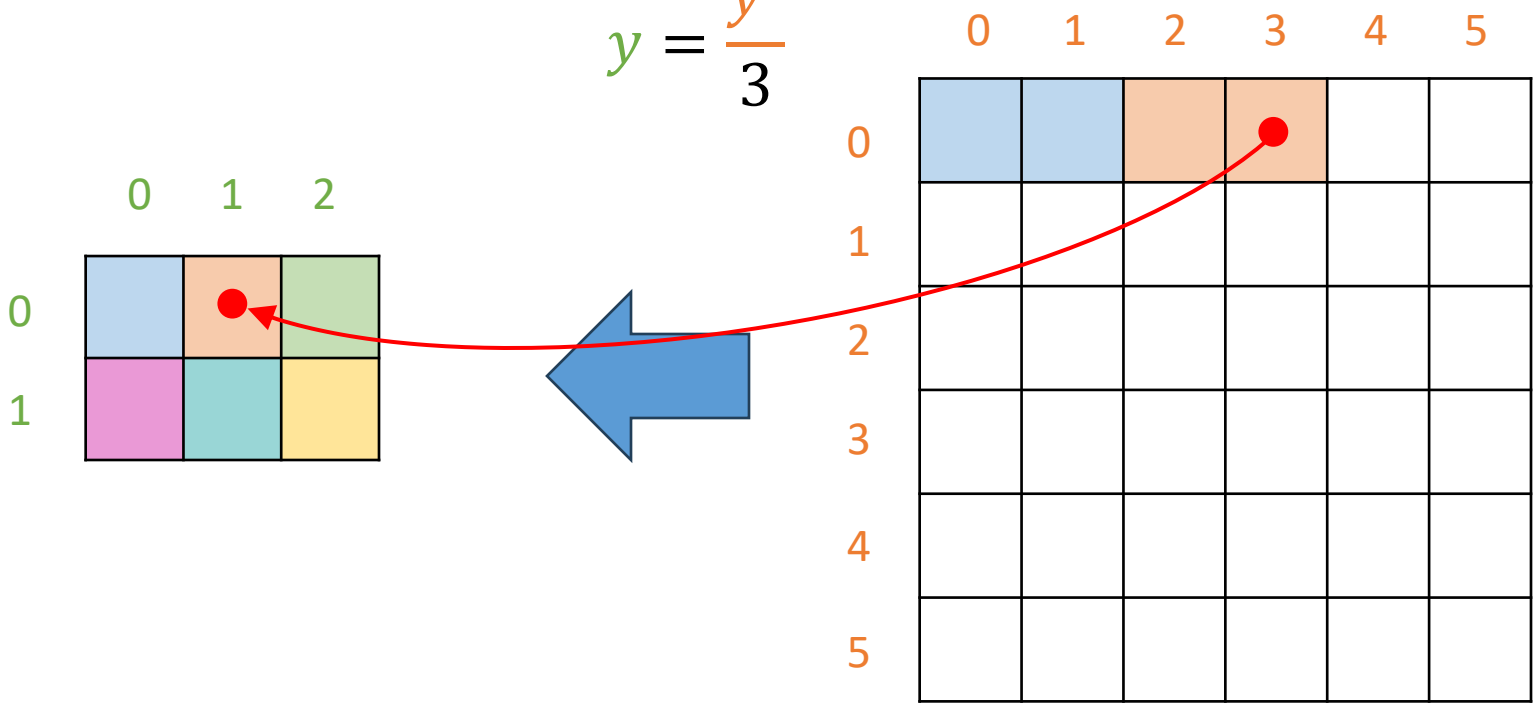


Příklad: zvětšení obrázku

Změna měřítka (škálování)

$$x = \frac{x'}{2}$$

$$y = \frac{y'}{3}$$

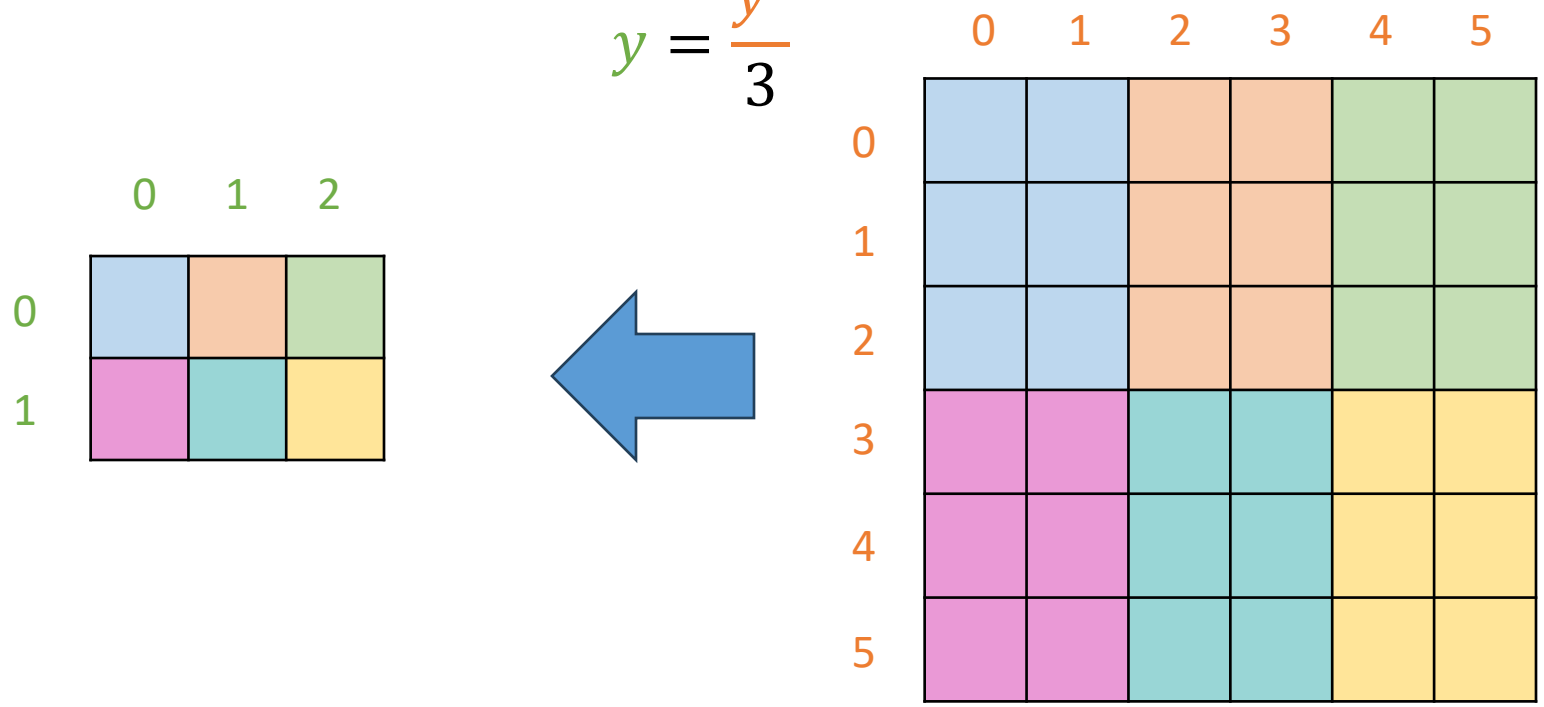


Příklad: zvětšení obrázku

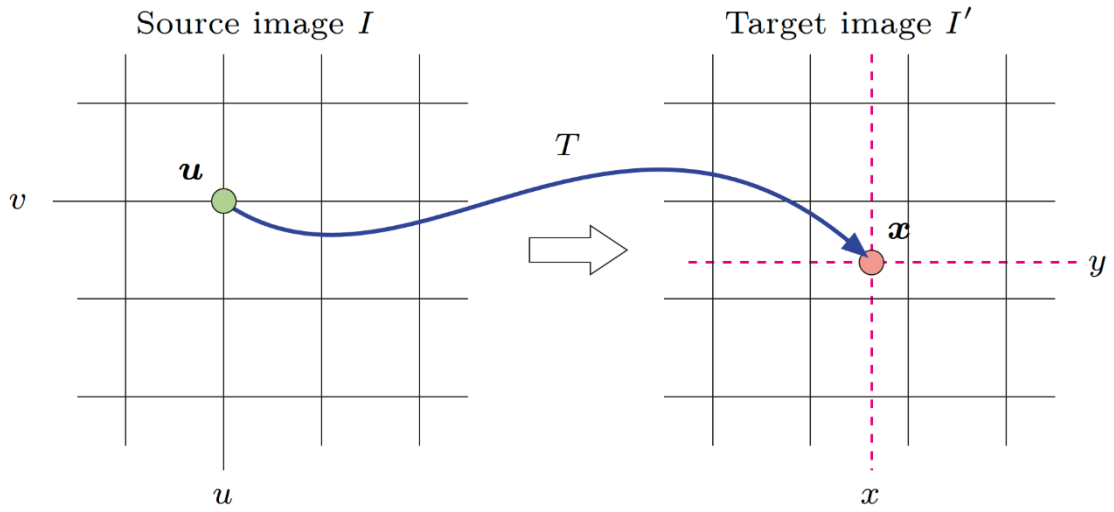
Změna měřítka (škálování)

$$x = \frac{x'}{2}$$

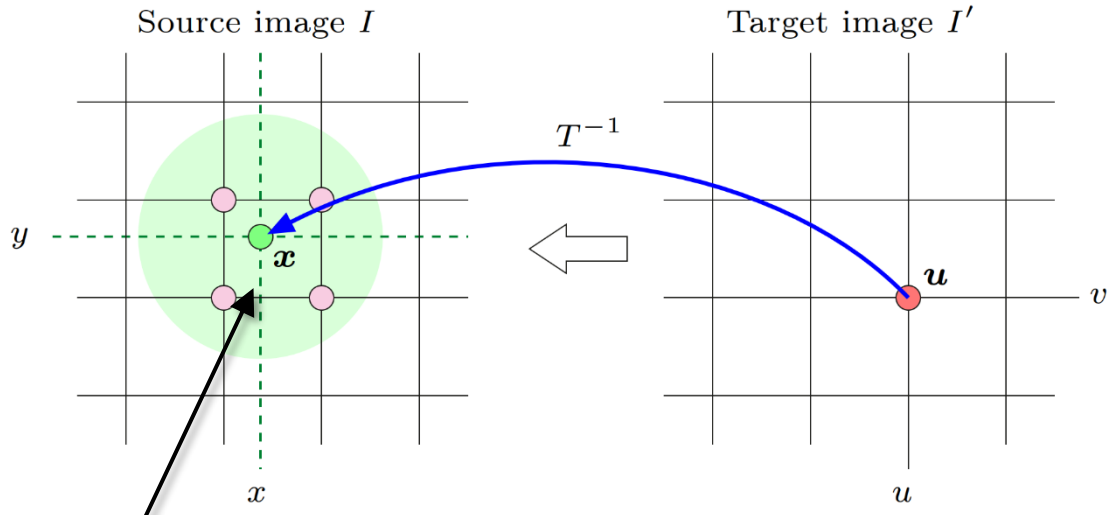
$$y = \frac{y'}{3}$$



Dopředné vs zpětné mapování



(a) Forward mapping



(b) Inverse mapping

Obecně vyjde při zpětném mapování neceločíselná souřadnice “mimo mřížku” → výslednou hodnotu **interpolujeme** z okolí

zdroj: https://imagingbook.com/books/english-edition-hardcover/

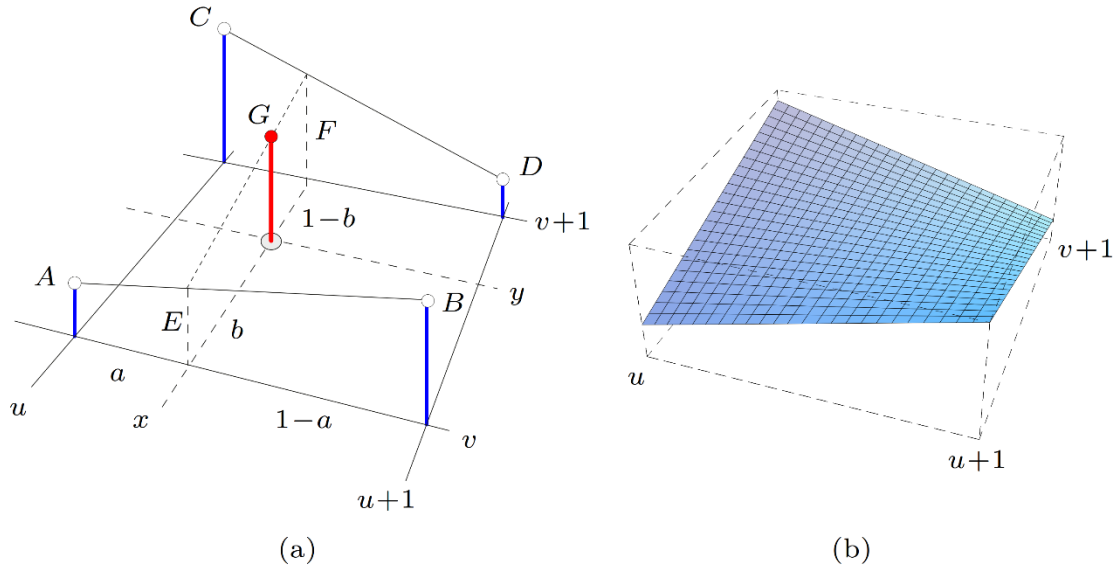
Interpolace

- Interpolace nejbližším sousedem = zaokrouhlení souřadnic

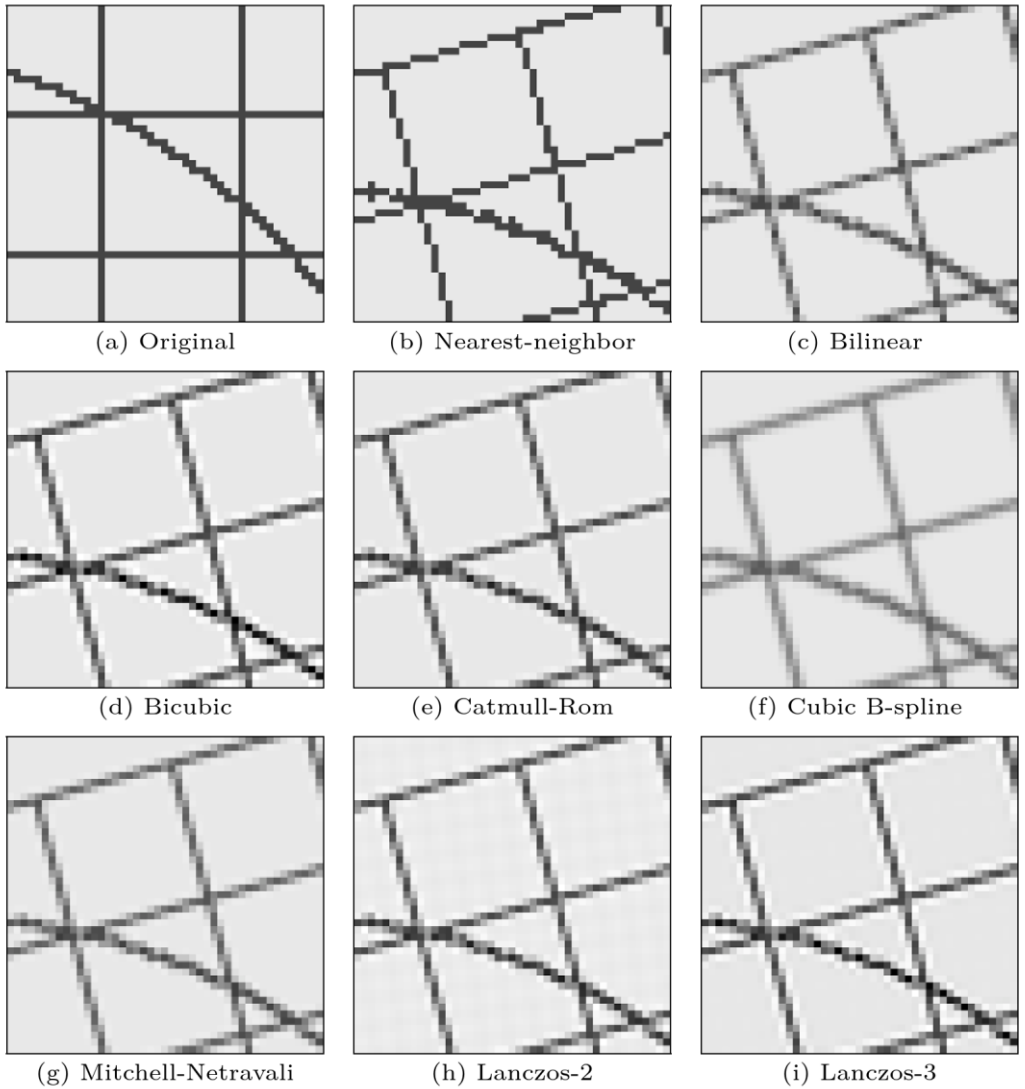
$$\tilde{I}(x, y) = I(\text{round}(x), \text{round}(y))$$

- Lineární interpolace = vážený průměr okolí (váha každého bodu je přímo úměrná jeho blízkosti (x, y))

$$\begin{aligned}\tilde{I}(x, y) = &(1-a)\cdot(1-b)\cdot I(\lfloor x\rfloor, \lfloor y\rfloor)\\ &+a\cdot(1-b)\cdot I(\lfloor x\rfloor+1, \lfloor y\rfloor)\\ &+(1-a)\cdot b\cdot I(\lfloor x\rfloor, \lfloor y\rfloor+1)\\ &+a\cdot b\cdot I(\lfloor x\rfloor+1, \lfloor y\rfloor+1)\end{aligned}$$



Interpolace



zdroj: https://imagingbook.com/books/english-edition-hardcover/

Homogenní souřadnice

- Pozici pixelu s kartézskými souřadnicemi (x, y) můžeme vyjádřit jako vektor

$$\bar{\boldsymbol{x}} = \begin{bmatrix} \bar{x} \\ \bar{y} \\ \bar{z} \end{bmatrix} \in \mathbb{R}^3$$

  tzv. homogenních souřadnic, přičemž body lišící se pouze přenásobením považujeme za ekvivalentní, tj. $\bar{\boldsymbol{x}} \equiv c \cdot \bar{\boldsymbol{x}}$

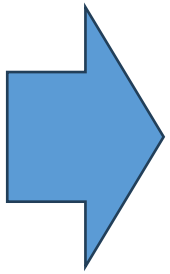
- Z homogenních souřadnic dostaneme zpět kartézské souřadnice vydělením $\bar{z}$, tj.

$$x = \bar{x}/\bar{z}$$
$$y = \bar{y}/\bar{z}$$

Změna měřítka v kartézských a homogenních souřadnicích

1. Transformace v kartézských souřadnicích

$$x' = s_x \cdot x$$
$$y' = s_y \cdot y$$



1. Převod na homogenní souřadnice

$$\bar{x} = x$$
$$\bar{y} = y$$
$$\bar{z} = 1$$

2. Transformace v homogenních souřadnicích

$$\begin{bmatrix} \bar{x}' \\ \bar{y}' \\ \bar{z}' \end{bmatrix} = \begin{bmatrix} s_x & 0 & 0 \\ 0 & s_y & 0 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} \bar{x} \\ \bar{y} \\ \bar{z} \end{bmatrix}$$

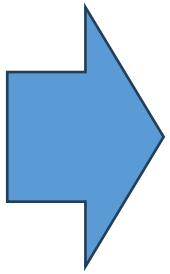
3. Převod na kartézské souřadnice

$$x' = \frac{\bar{x}'}{\bar{z}'} \qquad y' = \frac{\bar{y}'}{\bar{z}'}$$

Rotace v kartézských a homogenních souřadnicích

1. Transformace v kartézských souřadnicích

$$x' = x \cdot \cos(\alpha) - y \cdot \sin(\alpha)$$
$$y' = x \cdot \sin(\alpha) + y \cdot \cos(\alpha)$$



1. Převod na homogenní souřadnice

$$\bar{x} = x$$
$$\bar{y} = y$$
$$\bar{z} = 1$$

2. Transformace v homogenních souřadnicích

$$\begin{bmatrix} \bar{x}' \\ \bar{y}' \\ \bar{z}' \end{bmatrix} = \begin{bmatrix} \cos(\alpha) & -\sin(\alpha) & 0 \\ \sin(\alpha) & \cos(\alpha) & 0 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} \bar{x} \\ \bar{y} \\ \bar{z} \end{bmatrix}$$

3. Převod na kartézské souřadnice

$$x' = \frac{\bar{x}'}{\bar{z}'} \qquad y' = \frac{\bar{y}'}{\bar{z}'}$$

Transformace v homogenních souřadnicích

1. Převod na homogenní souřadnice

$$\bar{\boldsymbol{x}} = \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

2. Transformace v homogenních souřadnicích

$$\bar{\boldsymbol{x}}' = \boldsymbol{A} \cdot \bar{\boldsymbol{x}}$$

3. Převod na kartézské souřadnice

$$x' = \frac{\bar{x}'}{\bar{z}'} \qquad y' = \frac{\bar{y}'}{\bar{z}'}$$

1. Převod na homogenní souřadnice

$$\bar{x} = x$$
$$\bar{y} = y$$
$$\bar{z} = 1$$

2. Transformace v homogenních souřadnicích

$$\begin{bmatrix} \bar{x}' \\ \bar{y}' \\ \bar{z}' \end{bmatrix} = \begin{bmatrix} a_{1,1} & a_{1,2} & a_{1,3} \\ a_{2,1} & a_{2,2} & a_{2,3} \\ a_{3,1} & a_{3,2} & a_{3,3} \end{bmatrix} \cdot \begin{bmatrix} \bar{x} \\ \bar{y} \\ \bar{z} \end{bmatrix}$$

3. Převod na kartézské souřadnice

$$x' = \frac{\bar{x}'}{\bar{z}'} \qquad y' = \frac{\bar{y}'}{\bar{z}'}$$

Proč homogenní souřadnice?

- Zjednodušuje **řetězení transformací**
- Např. měřítko + rotace

při řetězení transformací a násobení matic pozor na pořadí

$$\begin{bmatrix}\bar{x}'\\ \bar{y}'\\ \bar{z}'\end{bmatrix} = \underbrace{\begin{bmatrix}\cos(\alpha) & \sin(\alpha) & 0\\ -\sin(\alpha) & \cos(\alpha) & 0\\ 0 & 0 & 1\end{bmatrix}}_{\text{rotace}} \cdot \underbrace{\begin{bmatrix}s_x & 0 & 0\\ 0 & s_y & 0\\ 0 & 0 & 1\end{bmatrix}}_{\text{měřítko}} \cdot \begin{bmatrix}\bar{x}\\ \bar{y}\\ \bar{z}\end{bmatrix} = \underbrace{\begin{bmatrix}s_x \cdot \cos(\alpha) & s_y \cdot \sin(\alpha) & 0\\ -s_x \cdot \sin(\alpha) & s_y \cdot \cos(\alpha) & 0\\ 0 & 0 & 1\end{bmatrix}}_{\text{rotace + měřítko}} \cdot \begin{bmatrix}\bar{x}\\ \bar{y}\\ \bar{z}\end{bmatrix}$$

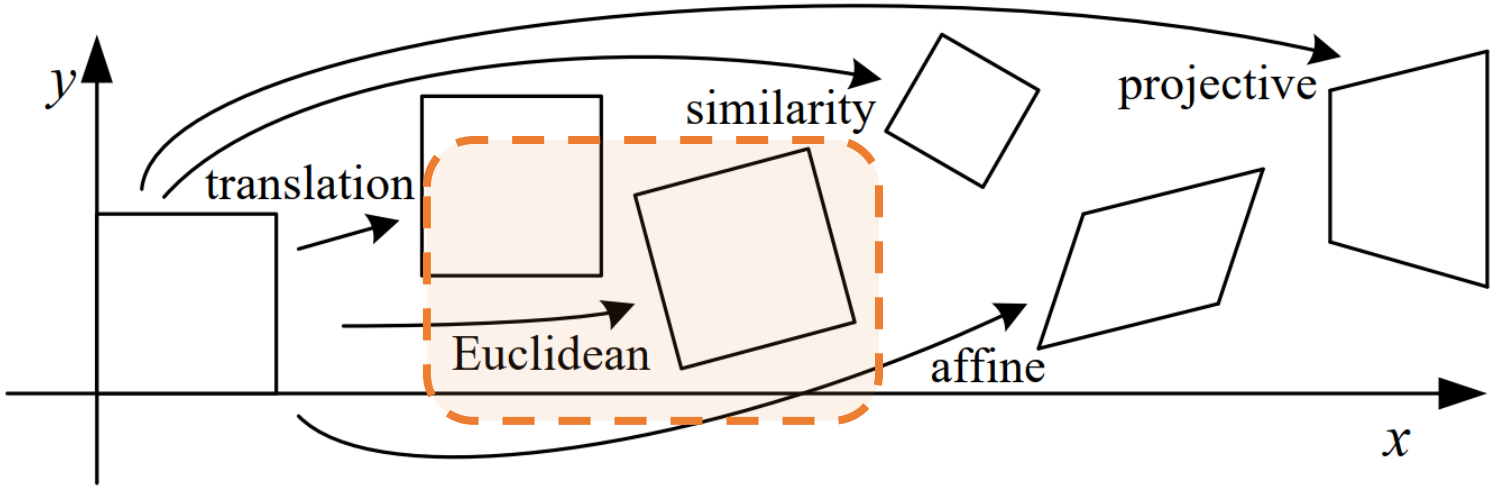
- Zjednodušuje **invertování transformací**

$$\bar{\boldsymbol{x}}' = \boldsymbol{A} \cdot \bar{\boldsymbol{x}} \quad \rightarrow \quad \bar{\boldsymbol{x}} = \boldsymbol{A}^{-1} \cdot \bar{\boldsymbol{x}}'$$

Hierarchie transformací: euklidovská transformace (“rigid”)

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} \epsilon \cdot \cos(\alpha) & -\sin(\alpha) & t_x \\ \epsilon \cdot \sin(\alpha) & \cos(\alpha) & t_y \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}, \epsilon = \pm 1 \qquad \boldsymbol{A} = \begin{bmatrix} \boldsymbol{R} & \boldsymbol{t} \\ \boldsymbol{0}^\top & 1 \end{bmatrix}$$

- Reprezentuje: posun, rotaci, příp. zrcadlení
- Zachovává: eukl. vzdálenosti, úhly (pokud $\epsilon = 1$, jinak zrcadlí), plochy
- Počet volných parametrů: 3

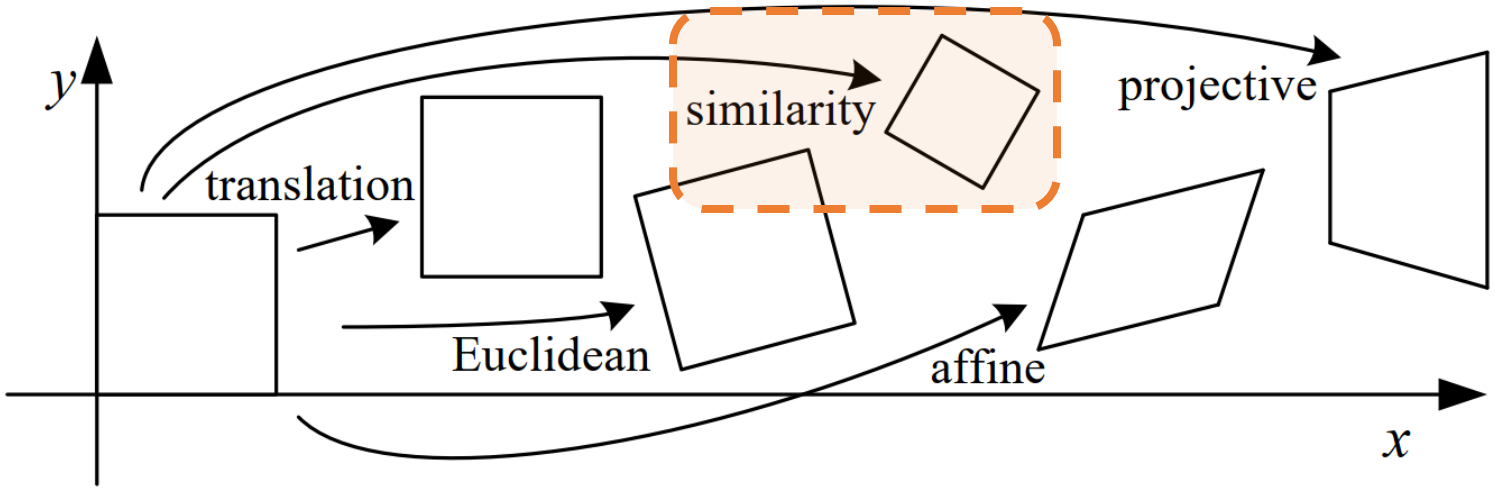


zdroj: https://szeliski.org/Book/

Hierarchie transformací: podobnostní transformace (similarity)

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} s \cdot \cos(\alpha) & -s \cdot \sin(\alpha) & t_x \\ s \cdot \sin(\alpha) & s \cdot \cos(\alpha) & t_y \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \qquad \boldsymbol{A} = \begin{bmatrix} s \cdot \boldsymbol{R} & \boldsymbol{t} \\ \boldsymbol{0}^\top & 1 \end{bmatrix}$$

- Reprezentuje: posun, rotaci, izotropní škálování a jejich kombinace
- Zachovává: úhly, poměr vzdáleností
- Počet volných parametrů: 4

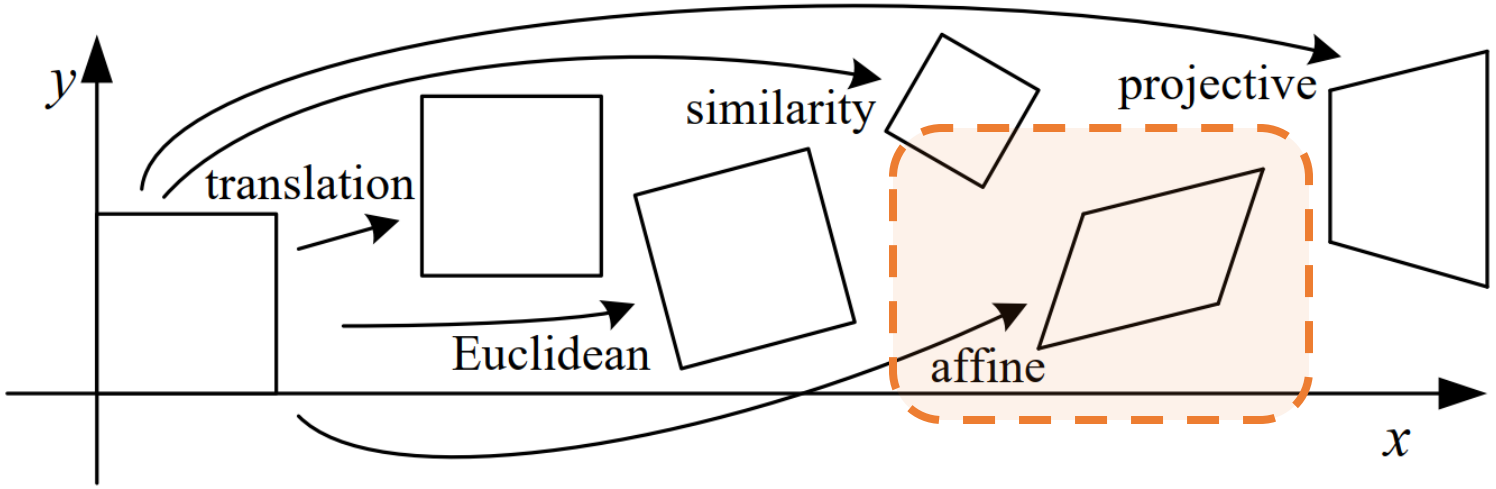


zdroj: https://szeliski.org/Book/

Hierarchie transformací: afinní transformace

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} a_{1,1} & a_{1,2} & t_x \\ a_{2,1} & a_{2,2} & t_y \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \qquad \boldsymbol{A} = \begin{bmatrix} \boldsymbol{A}' & \boldsymbol{t} \\ \boldsymbol{0}^\top & 1 \end{bmatrix}$$

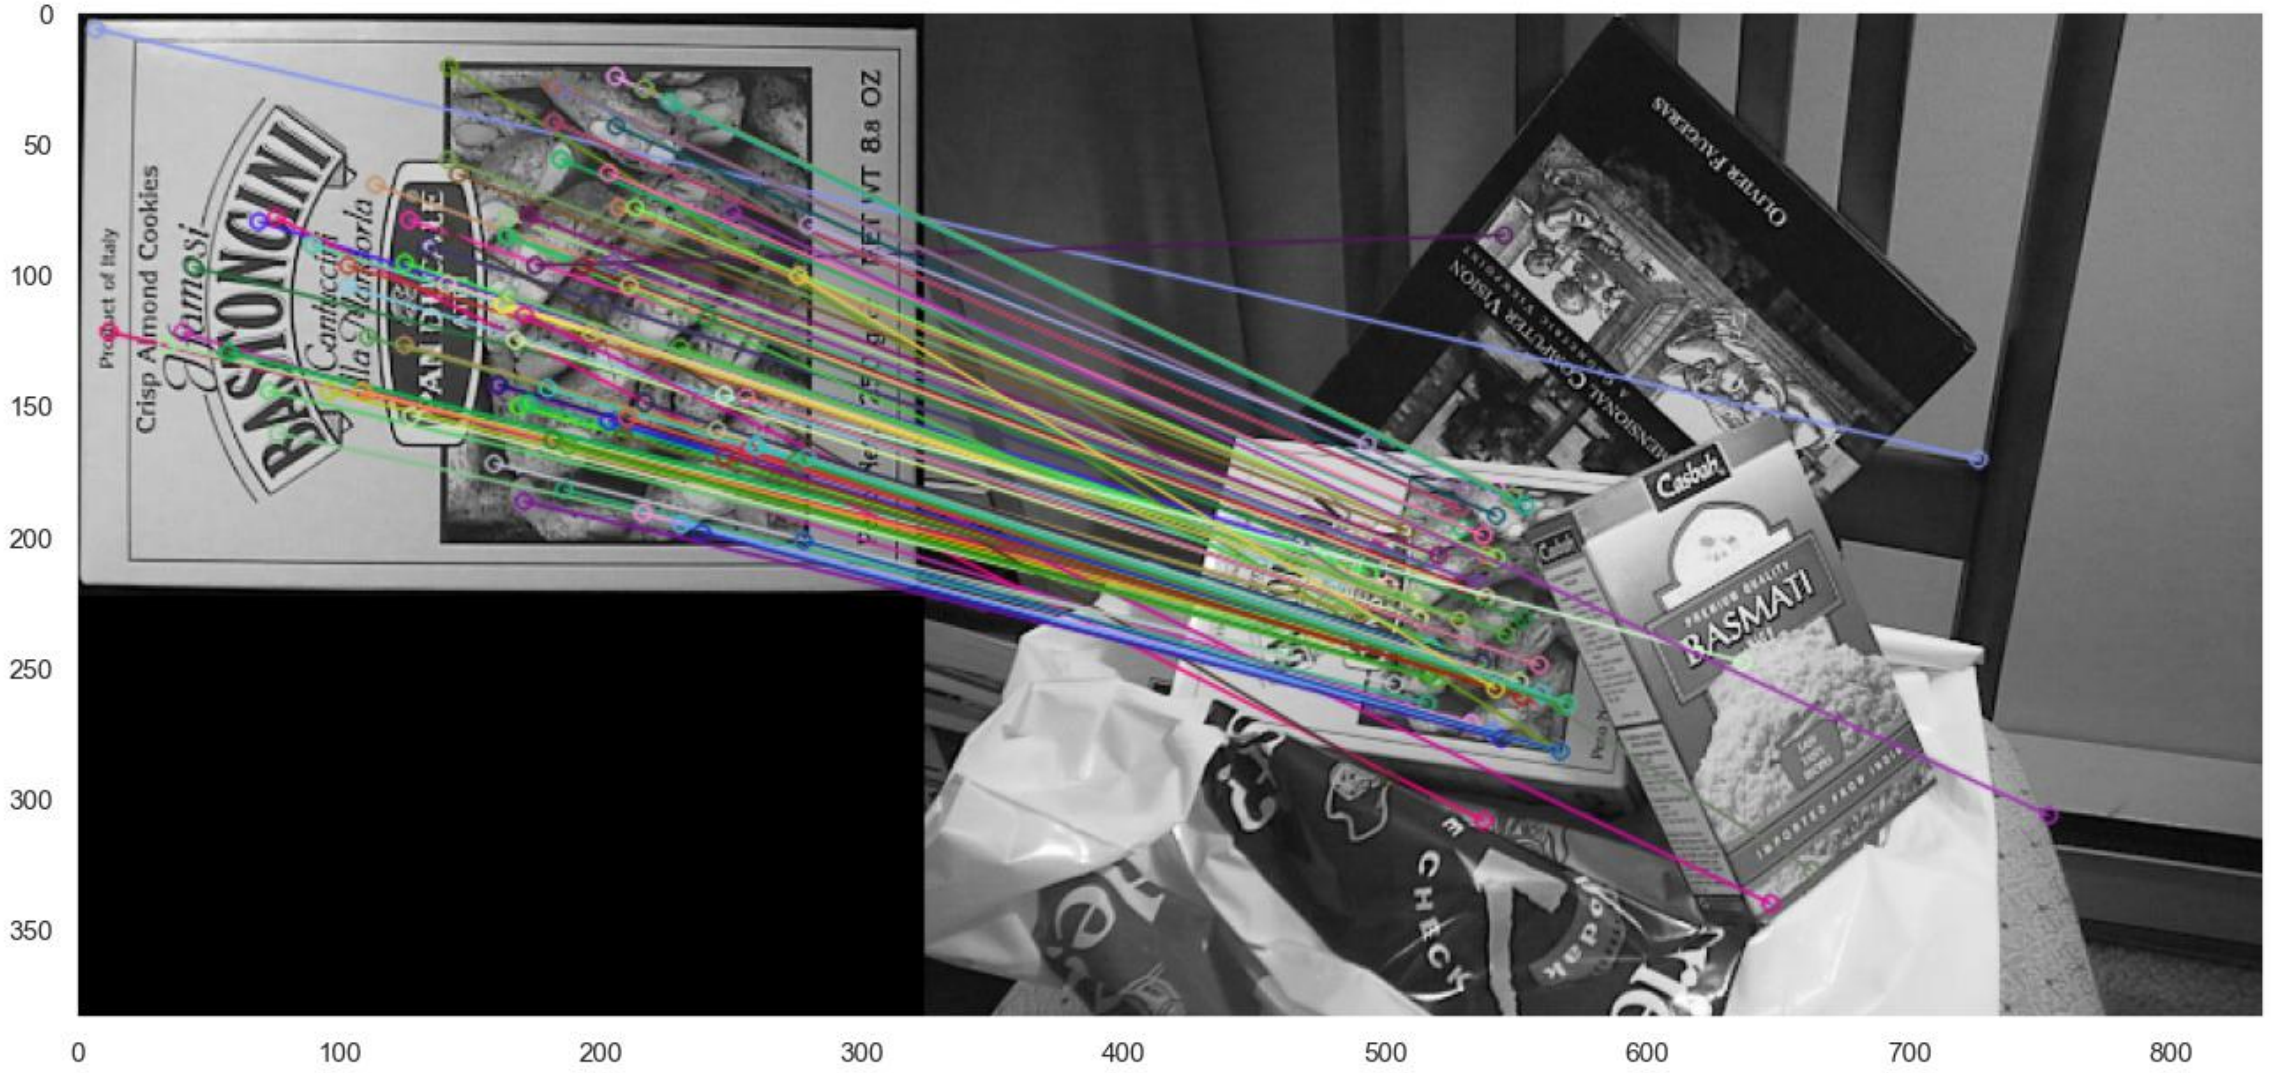
- Reprezentuje: posun, rotaci, neizotropní škálování, zkosení a jejich kombinace
- Zachovává: paralelita přímek, poměr vzdáleností na rovnoběžkách, poměr ploch
- Počet volných parametrů: 6



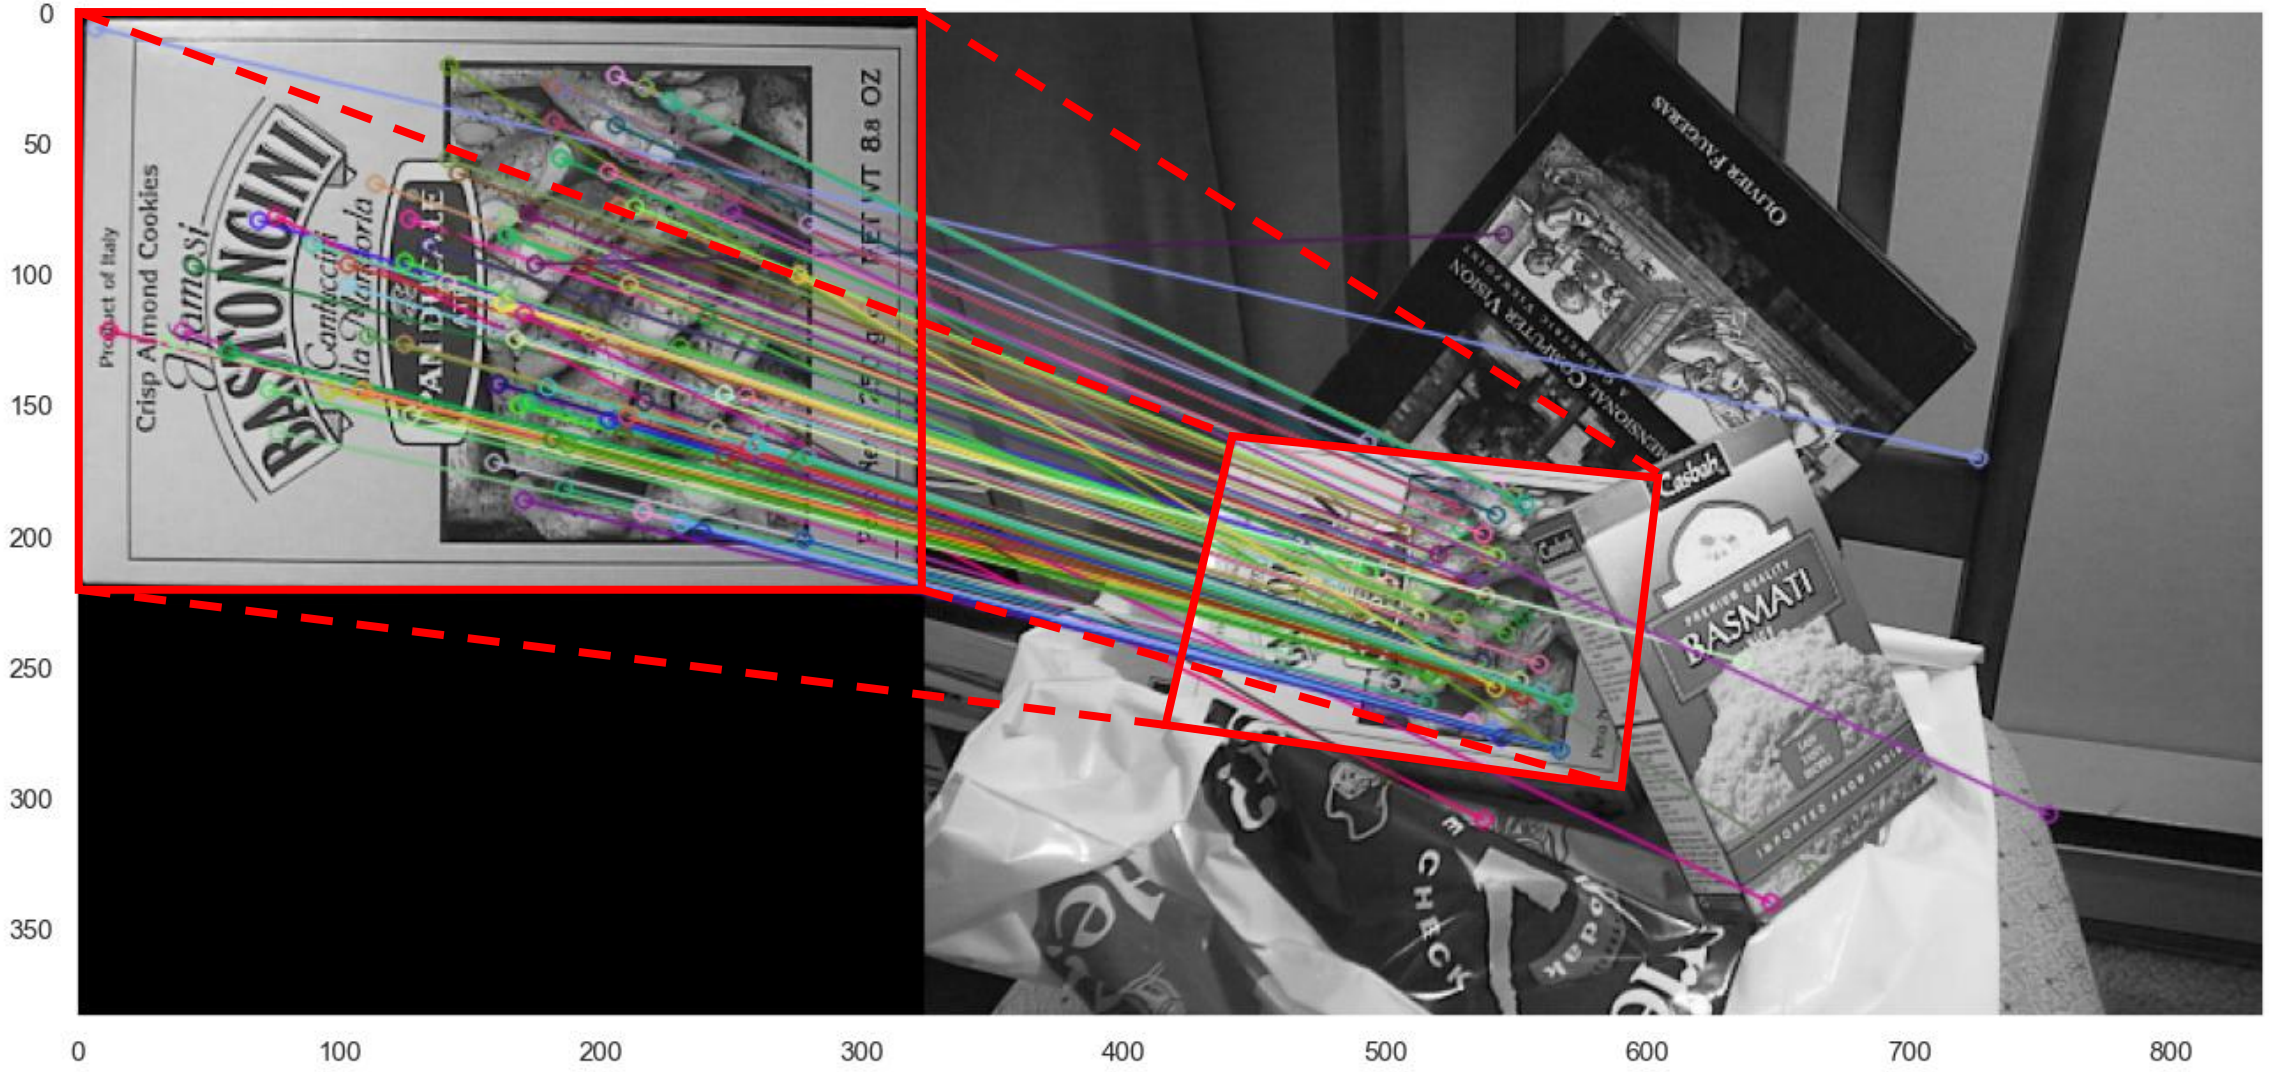
zdroj: https://szeliski.org/Book/

Odhad geometrické transformace mezi obrazy

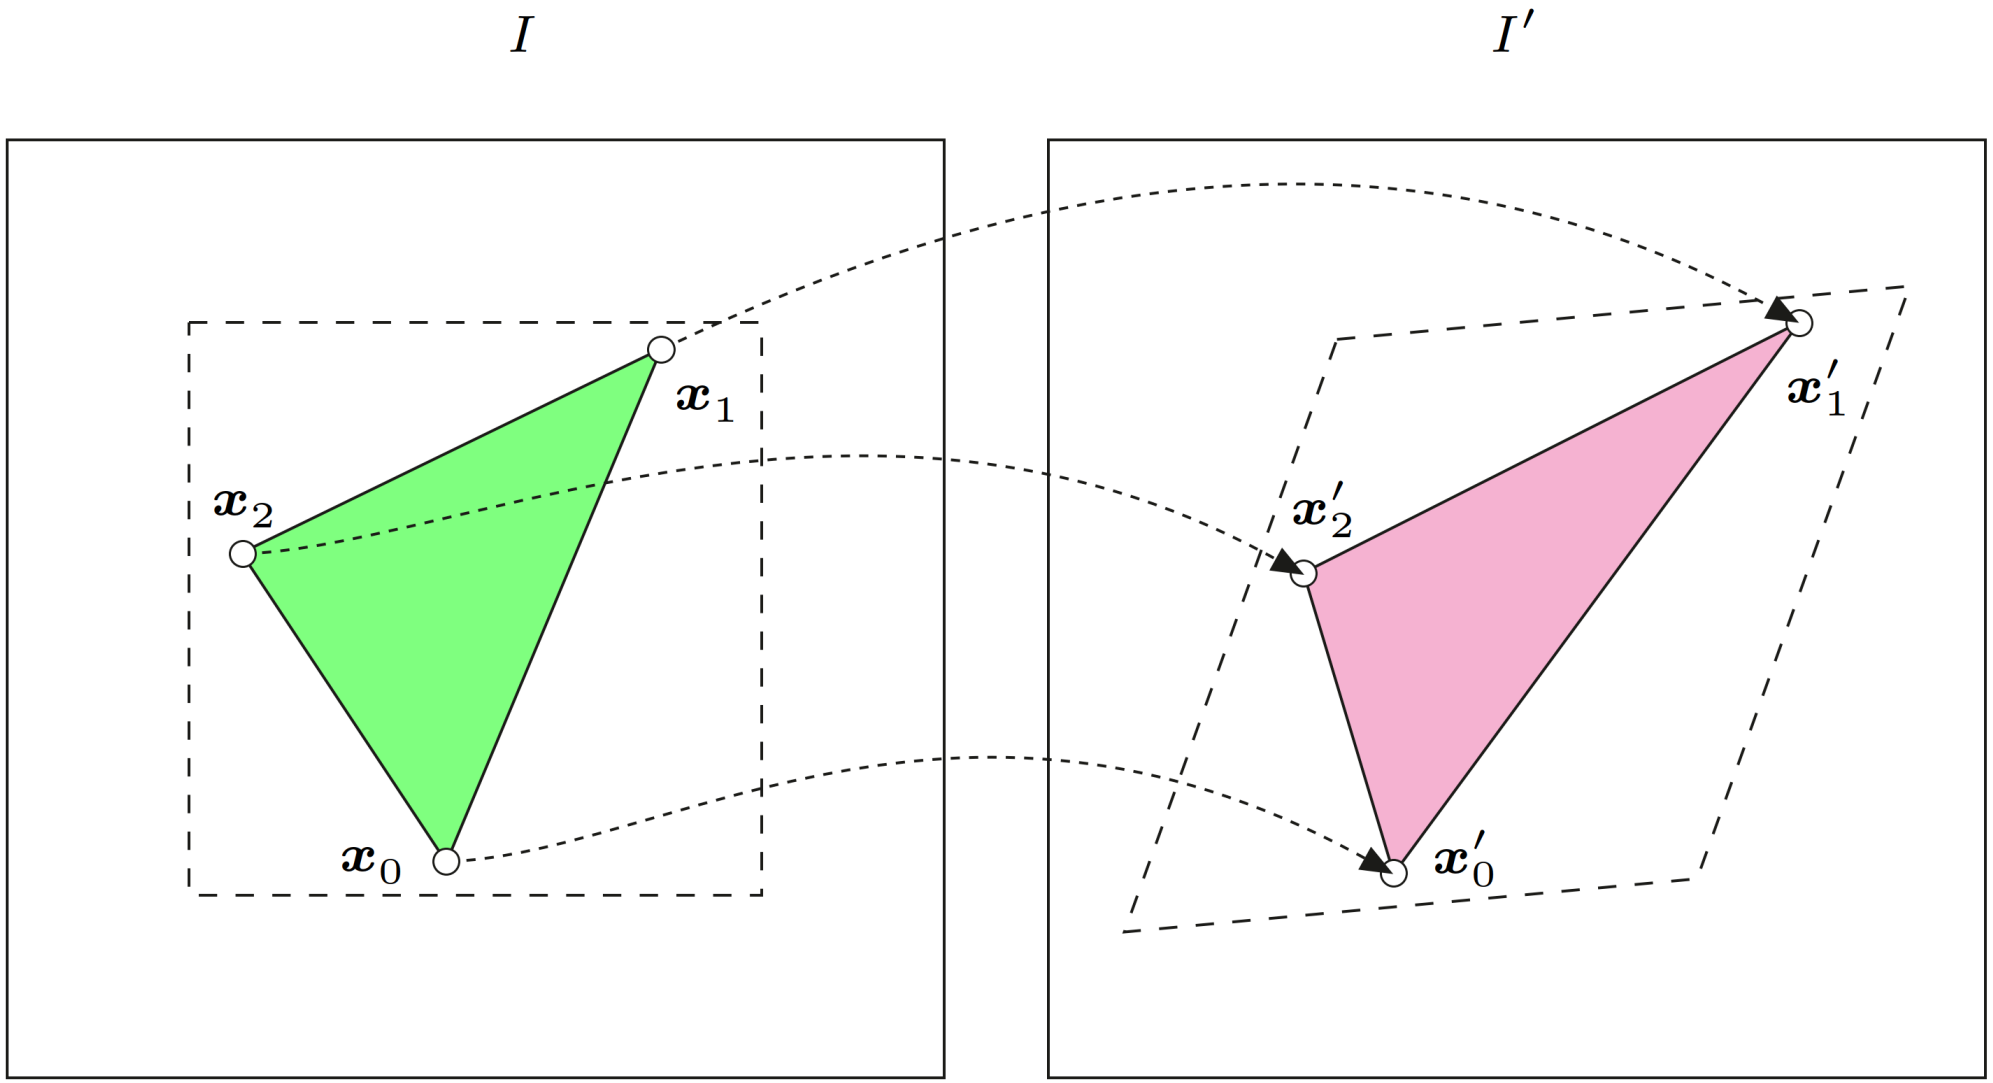
Párové korespondence



Párové korespondence: transformace?



Afinní transformace



Odhad afinní transformace z lokálních korespondencí

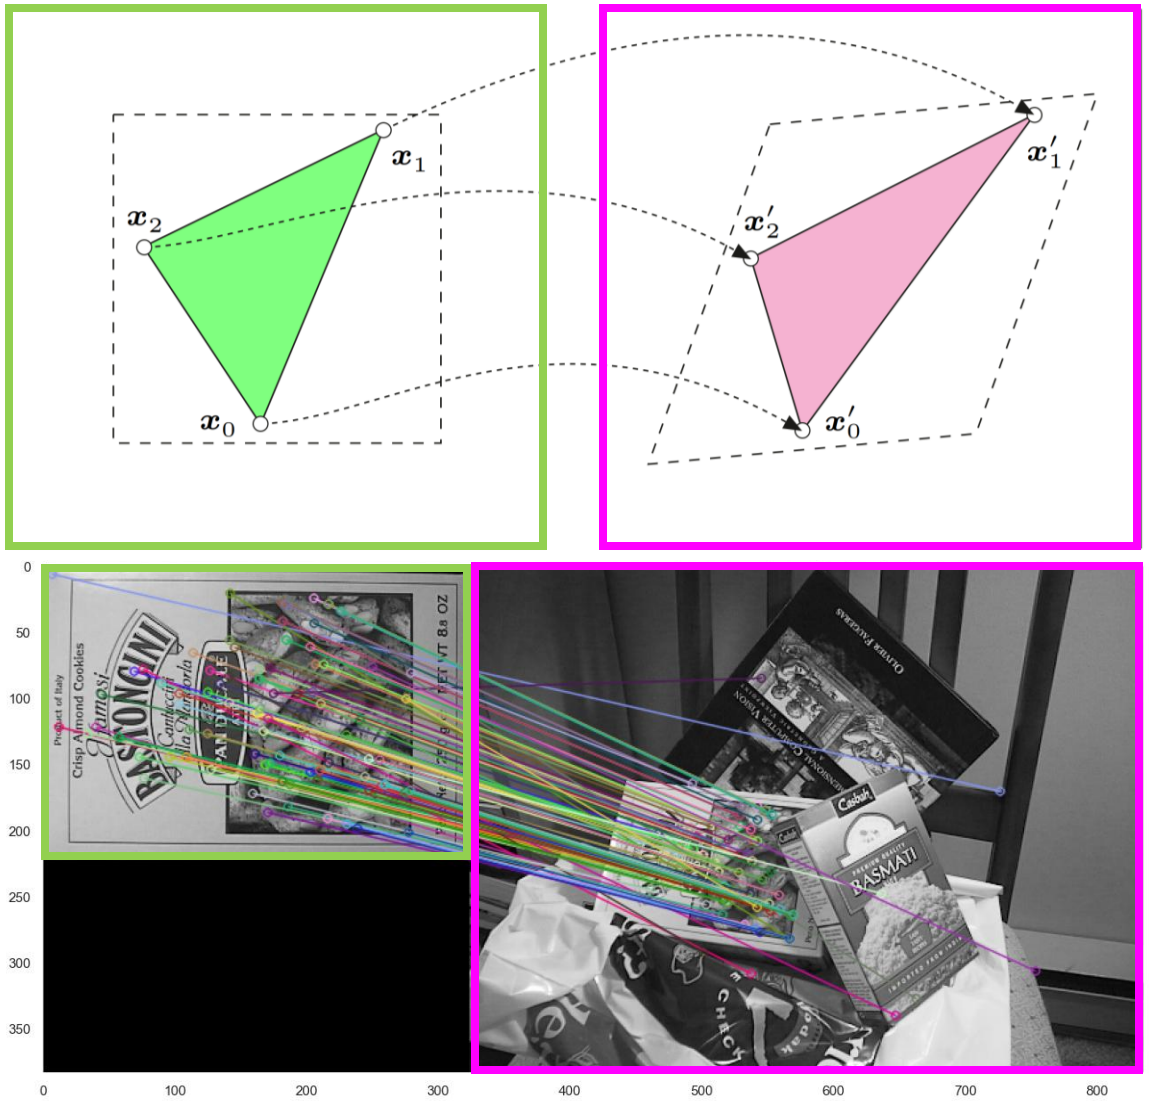
- Transformace je

neznámé

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} a_{1,1} & a_{1,2} & a_{1,3} \\ a_{2,1} & a_{2,2} & a_{2,3} \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

- Můžeme přepsat jako

$$\begin{bmatrix} x & y & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & x & y & 1 \end{bmatrix} \cdot \begin{bmatrix} a_{1,1} \\ a_{1,2} \\ a_{1,3} \\ a_{2,1} \\ a_{2,2} \\ a_{2,3} \end{bmatrix} = \begin{bmatrix} x' \\ y' \end{bmatrix}$$



Odhad afinní transformace z lokálních korespondencí

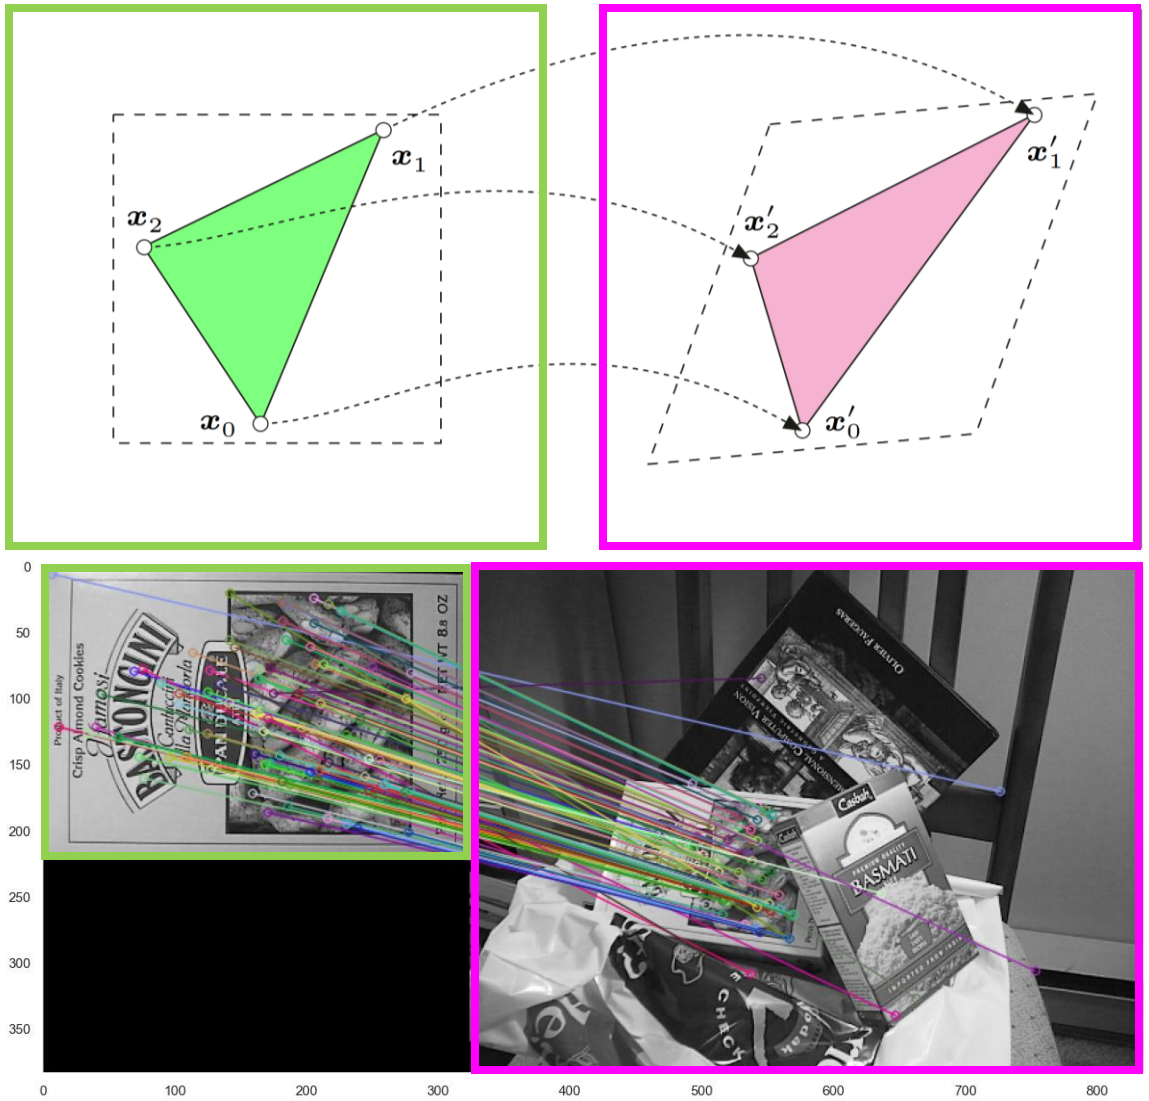
- Transformace je

neznámé

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} a_{1,1} & a_{1,2} & a_{1,3} \\ a_{2,1} & a_{2,2} & a_{2,3} \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

- Pro trojici bodů zároveň

$$\begin{bmatrix} x_0 & y_0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & x_0 & y_0 & 1 \\ x_1 & y_1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & x_1 & y_1 & 1 \\ x_2 & y_2 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & x_2 & y_2 & 1 \end{bmatrix} \cdot \begin{bmatrix} a_{1,1} \\ a_{1,2} \\ a_{1,3} \\ a_{2,1} \\ a_{2,2} \\ a_{2,3} \end{bmatrix} = \begin{bmatrix} x'_0 \\ y'_0 \\ x'_1 \\ y'_1 \\ x'_2 \\ y'_2 \end{bmatrix}$$



Odhad afinní transformace z lokálních korespondencí

- Transformace je

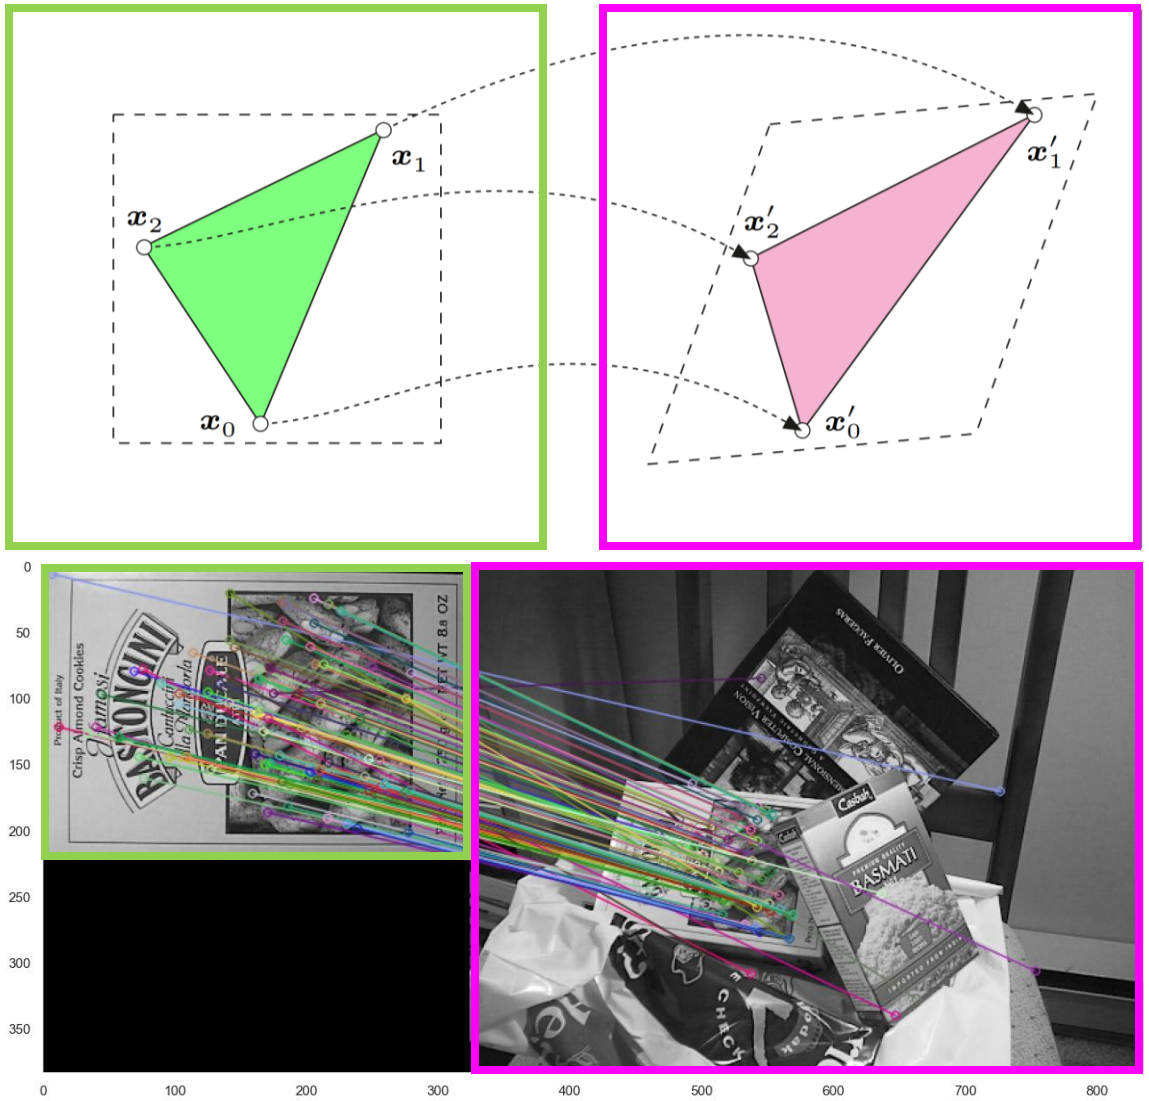
neznámé

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} a_{1,1} & a_{1,2} & a_{1,3} \\ a_{2,1} & a_{2,2} & a_{2,3} \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

- Pro trojici bodů zároveň

$$\begin{bmatrix} x_0 & y_0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & x_0 & y_0 & 1 \\ x_1 & y_1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & x_1 & y_1 & 1 \\ x_2 & y_2 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & x_2 & y_2 & 1 \end{bmatrix} \cdot \begin{bmatrix} a_{1,1} \\ a_{1,2} \\ a_{1,3} \\ a_{2,1} \\ a_{2,2} \\ a_{2,3} \end{bmatrix} = \begin{bmatrix} x'_0 \\ y'_0 \\ x'_1 \\ y'_1 \\ x'_2 \\ y'_2 \end{bmatrix}$$

- Parametry = řešení soustavy $\boldsymbol{X} \cdot \boldsymbol{a} = \overline{\boldsymbol{x}}$



Odhad pomocí nejmenších čtverců

- Obvykle máme více korespondencí, než potřebujeme

$$2N \left\{ \begin{bmatrix} x_1 & y_1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & x_1 & y_1 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_N & y_N & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & x_N & y_N & 1 \end{bmatrix} \cdot \begin{bmatrix} a_{1,1} \\ a_{1,2} \\ a_{1,3} \\ a_{2,1} \\ a_{2,2} \\ a_{2,3} \end{bmatrix} = \begin{bmatrix} x'_1 \\ y'_1 \\ \vdots \\ x'_N \\ y'_N \end{bmatrix} \right\} 2N$$

- V soustavě

$$\boldsymbol{X} \cdot \boldsymbol{a} = \boldsymbol{x'}$$

je potom více rovnic než neznámých proměnných

- Soustavu lze řešit ve smyslu nejmenších čtverců

$$\boldsymbol{a}^* = \underset{\boldsymbol{a}}{\operatorname{argmin}} \|\boldsymbol{X} \cdot \boldsymbol{a} - \boldsymbol{x'}\|^2$$

např. pseudo-inverzí jako

$$\boldsymbol{a}^* = (\boldsymbol{X}^\top \cdot \boldsymbol{X})^{-1} \cdot \boldsymbol{X}^\top \cdot \boldsymbol{x'}$$

nebo SVD rozkladem

$$\boldsymbol{X} = \boldsymbol{U} \cdot \Sigma \cdot \boldsymbol{V}^\top \quad \rightarrow \quad \boldsymbol{a}^* = \boldsymbol{V} \cdot \Sigma^{-1} \cdot \boldsymbol{U}^\top \cdot \boldsymbol{x'}$$

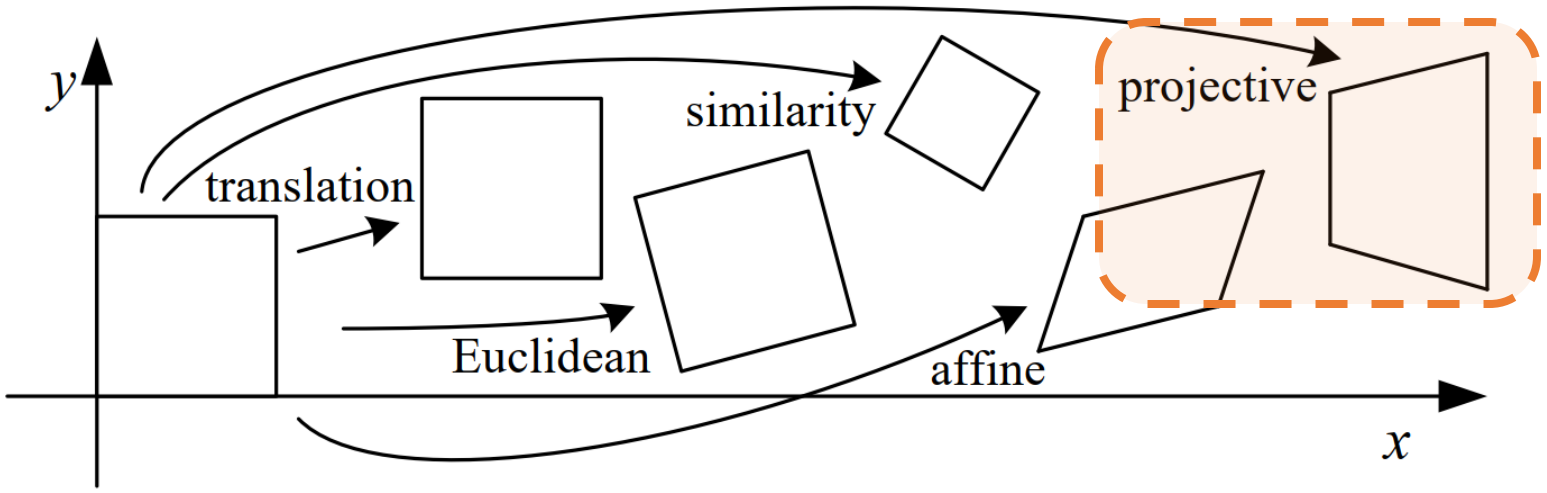
Projektivní transformace

- Projektivní transformace (homografie) má podobu

$$\begin{bmatrix} \bar{x}' \\ \bar{y}' \\ \bar{z}' \end{bmatrix} = \begin{bmatrix} a_{1,1} & a_{1,2} & a_{1,3} \\ a_{2,1} & a_{2,2} & a_{2,3} \\ a_{3,1} & a_{3,2} & a_{3,3} \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

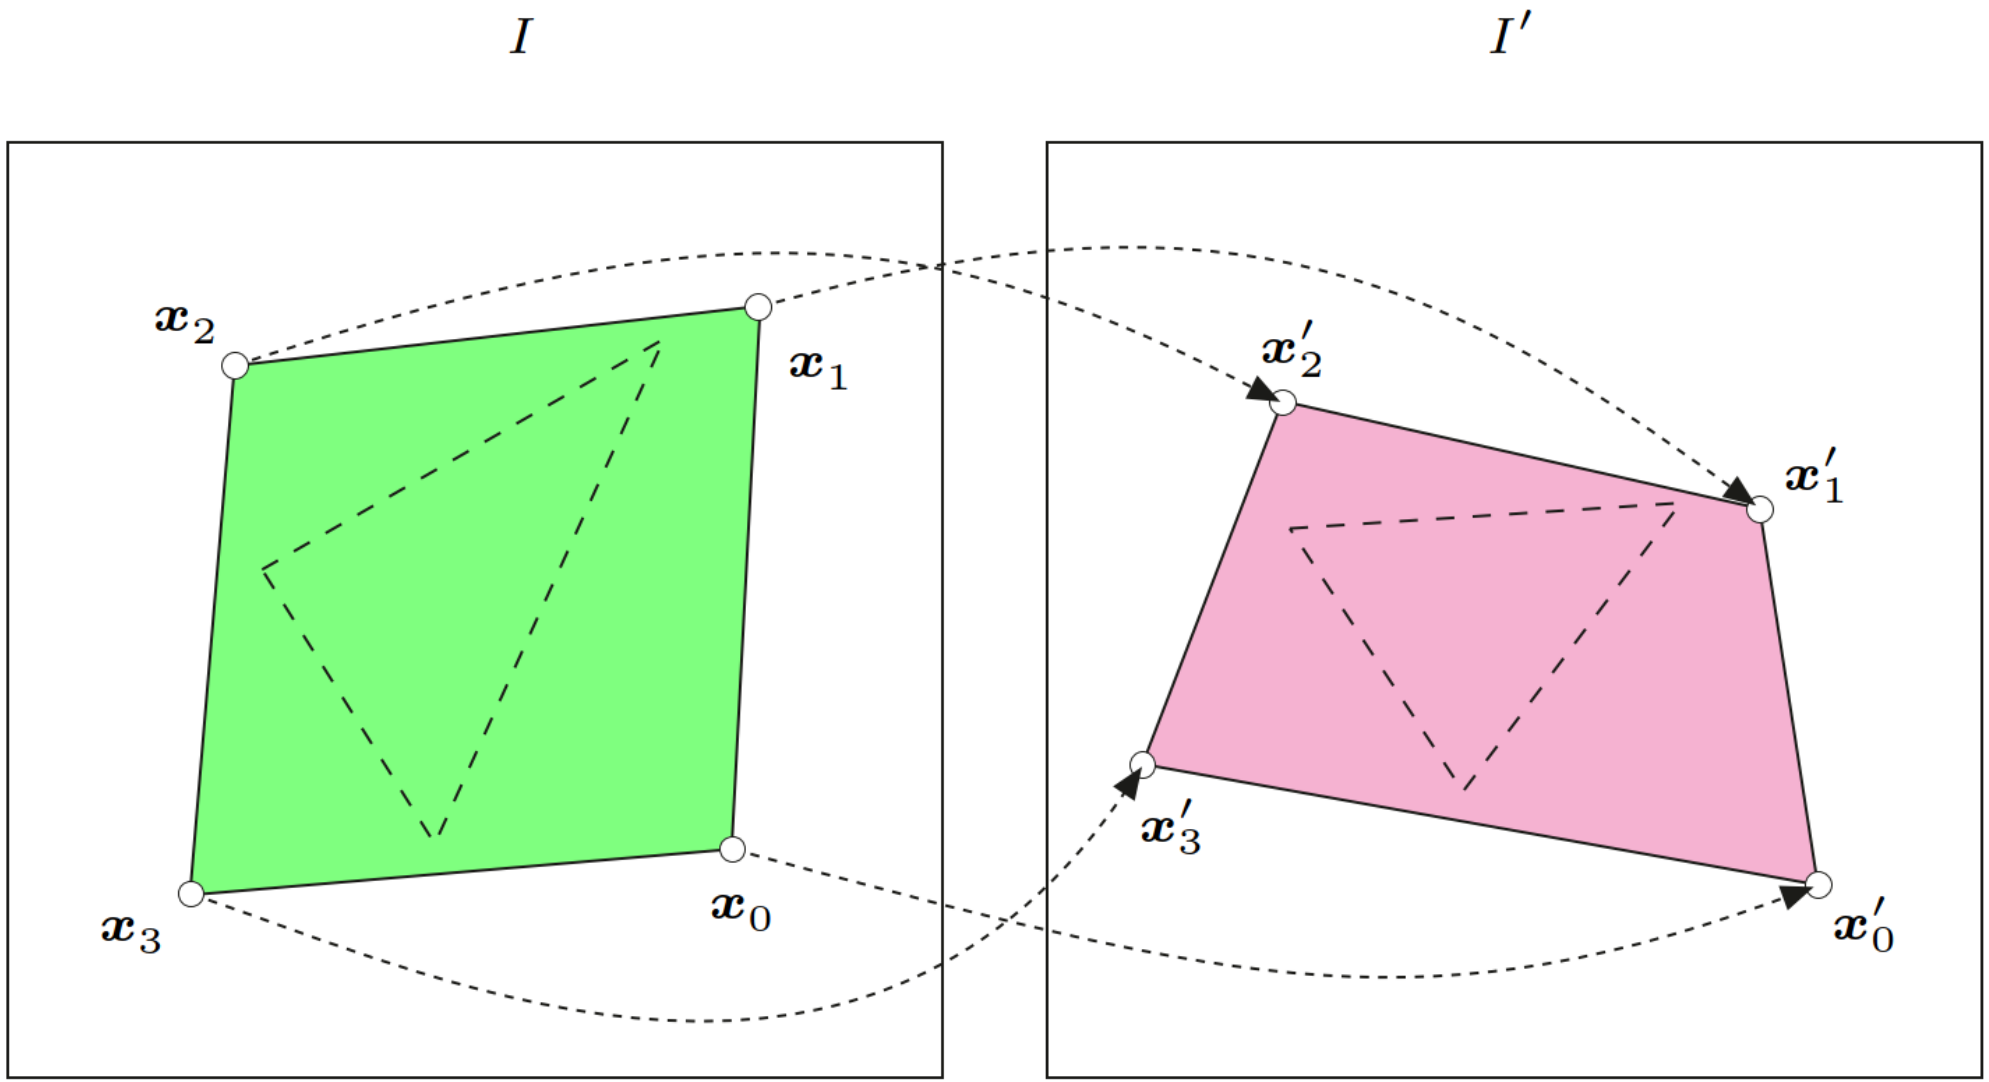
a poté

$$x' = \bar{x}'/\bar{z}' \qquad y' = \bar{y}'/\bar{z}'$$



obrázek: https://szeliski.org/Book/

Projektivní transformace



Odhad projektivní transformace z lokálních korespondencí

- Transformace je

neznámé

$$\begin{bmatrix} \bar{x}' \\ \bar{y}' \\ \bar{z}' \end{bmatrix} = \begin{bmatrix} a_{1,1} & a_{1,2} & a_{1,3} \\ a_{2,1} & a_{2,2} & a_{2,3} \\ a_{3,1} & a_{3,2} & 1 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

díky dělení při převodu zpět do kartézských souřadnic nezáleží na měřítku → $a_{3,3} = 1$

- Můžeme po dělení $\bar{z}'$ přepsat jako

$$\begin{bmatrix} x_0 & y_0 & 1 & 0 & 0 & 0 & -x_0 \cdot x_0' & -y_0 \cdot x_0' \\ 0 & 0 & 0 & x_0 & y_0 & 1 & -x_0 \cdot y_0' & -y_0 \cdot y_0' \\ x_1 & y_1 & 1 & 0 & 0 & 0 & -x_1 \cdot x_1' & -y_1 \cdot x_1' \\ 0 & 0 & 0 & x_1 & y_1 & 1 & -x_1 \cdot y_1' & -y_1 \cdot y_1' \\ x_2 & y_2 & 1 & 0 & 0 & 0 & -x_2 \cdot x_2' & -y_2 \cdot x_2' \\ 0 & 0 & 0 & x_2 & y_2 & 1 & -x_2 \cdot y_2' & -y_2 \cdot y_2' \\ x_3 & y_3 & 1 & 0 & 0 & 0 & -x_3 \cdot x_3' & -y_3 \cdot x_3' \\ 0 & 0 & 0 & x_3 & y_3 & 1 & -x_3 \cdot y_3' & -y_3 \cdot y_3' \end{bmatrix} \cdot \begin{bmatrix} a_{1,1} \\ a_{1,2} \\ a_{1,3} \\ a_{2,1} \\ a_{2,2} \\ a_{2,3} \\ a_{3,1} \\ a_{3,2} \end{bmatrix} = \begin{bmatrix} x_0' \\ y_0' \\ x_1' \\ y_1' \\ x_2' \\ y_2' \\ x_3' \\ y_3' \end{bmatrix}$$

- A vyřešit soustavu $\boldsymbol{X} \cdot \boldsymbol{a} = \bar{\boldsymbol{x}}$ → opět např. pseudoinverzí nebo SVD rozkladem

Direct linear transform (DLT)

- Volba $a_{3,3} = 1$ (předchozí slide) selže, pokud je skutečné $a_{3,3}$ blízké nule
- Proto ponecháme všech 9 neznámých a matici hledáme až na měřítko
- Transformace je

$$x' = \frac{a_{1,1}x + a_{1,2}y + a_{1,3}}{a_{3,1}x + a_{3,2}y + a_{3,3}} \qquad y' = \frac{a_{2,1}x + a_{2,2}y + a_{2,3}}{a_{3,1}x + a_{3,2}y + a_{3,3}}$$

- Po vynásobení jmenovatelem získáme **dvě lineární rovnice** s nulovou pravou stranou

$$a_{1,1}x + a_{1,2}y + a_{1,3} - a_{3,1}xx' - a_{3,2}yx' - a_{3,3}x' = 0$$
$$a_{2,1}x + a_{2,2}y + a_{2,3} - a_{3,1}xy' - a_{3,2}yy' - a_{3,3}y' = 0$$

každá korespondence → 2 rovnice

Direct linear transform (DLT)

- Rovnice pro N korespondencí zapíšeme maticově

$$\begin{bmatrix} x_1 & y_1 & 1 & 0 & 0 & 0 & -x_1x_1' & -y_1x_1' & -x_1' \\ 0 & 0 & 0 & x_1 & y_1 & 1 & -x_1y_1' & -y_1y_1' & -y_1' \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_N & y_N & 1 & 0 & 0 & 0 & -x_Nx_N' & -y_Nx_N' & -x_N' \\ 0 & 0 & 0 & x_N & y_N & 1 & -x_Ny_N' & -y_Ny_N' & -y_N' \end{bmatrix} \cdot \begin{bmatrix} a_{1,1} \\ a_{1,2} \\ a_{1,3} \\ a_{2,1} \\ a_{2,2} \\ a_{2,3} \\ a_{3,1} \\ a_{3,2} \\ a_{3,3} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ 0 \end{bmatrix}$$

matice je určena jen až na měřítko → 8 stupňů volnosti

- Homogenní soustava $\boldsymbol{X} \cdot \boldsymbol{a} = 0$, kde $\boldsymbol{X}$ má rozměr $2N \times 9$
- Triviální řešení $\boldsymbol{a} = 0$ nás nezajímá → hledáme řešení s jednotkovou normou $\|\boldsymbol{a}\| = 1$

Direct linear transform (DLT)

- Úloha nejmenších čtverců s omezením

$$\boldsymbol{a}^* = \underset{\boldsymbol{a}}{\operatorname{argmin}} \|\boldsymbol{X} \cdot \boldsymbol{a}\|^2 \quad \text{za podmínky} \quad \|\boldsymbol{a}\| = 1$$

- Řešení pomocí SVD rozkladu matice $\boldsymbol{X}$

$$\boldsymbol{X} = \boldsymbol{U} \cdot \Sigma \cdot \boldsymbol{V}^\top \quad \rightarrow \quad \boldsymbol{a}^* = \boldsymbol{v}_9$$

$\boldsymbol{v}_9$ = poslední sloupec $\boldsymbol{V}$ = pravý singulární vektor příslušný nejmenšímu singulárnímu číslu σ_9

- Homografie má 8 stupňů volnosti → stačí 4 korespondence (žádné 3 body na přímce)
- Pro $N > 4$ dostaneme řešení ve smyslu nejmenších čtverců (algebraické chyby)

```
_, _, Vt = np.linalg.svd(X)
A = Vt[-1].reshape(3, 3)   # poslední řádek Vᵀ
```

DLT v praxi: normalizace a zpřesnění

Normalizace souřadnic (Hartley, 1997)

- Prvky $\boldsymbol{X}$ mají v pixelech řádově různou velikost (1 vs. $xx' \approx 10^6$) → špatně podmíněná úloha
- Body posuneme do těžiště (μ_x, μ_y) a škálujeme na průměrnou vzdálenost √2

$$\boldsymbol{T} = \begin{bmatrix} s & 0 & -\cdot\,\mu_x \\ 0 & s & -\cdot\,\mu_y \\ 0 & 0 & 1 \end{bmatrix}, \qquad s = \frac{\sqrt{2}}{\bar{d}}$$

- DLT spočteme z normalizovaných bodů ($\boldsymbol{T}$ pro $\boldsymbol{x}$, $\boldsymbol{T}'$ pro $\boldsymbol{x}'$) a výsledek převedeme zpět

$$\boldsymbol{A} = \boldsymbol{T}'^{-1} \cdot \widetilde{\boldsymbol{A}} \cdot \boldsymbol{T}$$

Nelineární zpřesnění

- DLT minimalizuje algebraickou chybu $\|\boldsymbol{X}\cdot\boldsymbol{a}\|$, ne vzdálenost v pixelech
- Výsledek použijeme jako počáteční odhad a minimalizujeme reprojekční chybu (Levenberg–Marquardt)

$$\boldsymbol{A}^* = \underset{\boldsymbol{A}}{\operatorname{argmin}} \sum_{i=1}^{N} \|\boldsymbol{x}_i' - (\boldsymbol{A} \cdot \bar{\boldsymbol{x}}_i)\|^2$$

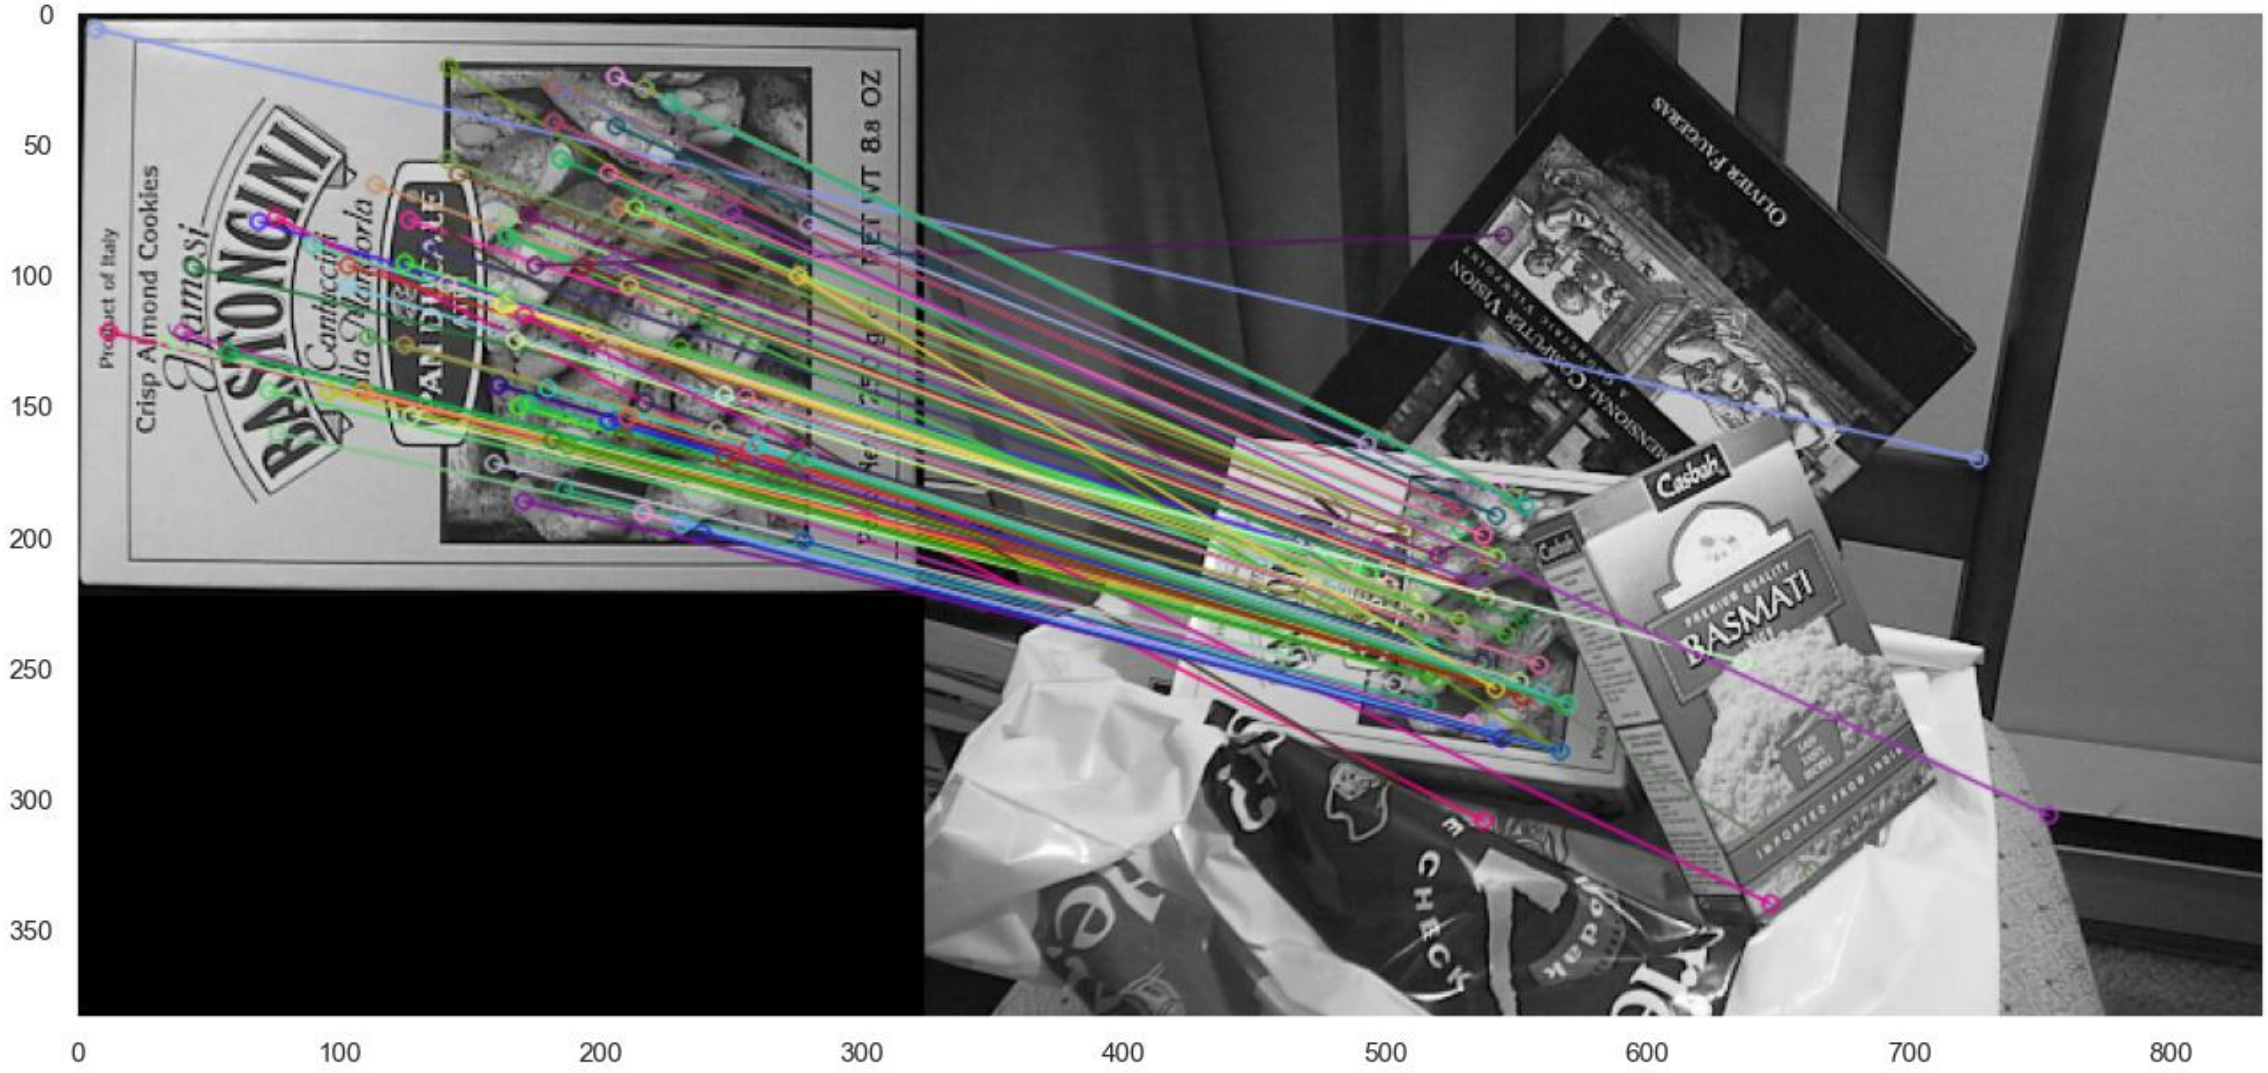
$\pi(\cdot)$ … převod z homogenních do kartézských souřadnic

`cv2.findHomography` = normalizovaný DLT + (RANSAC) + LM zpřesnění na inlierech

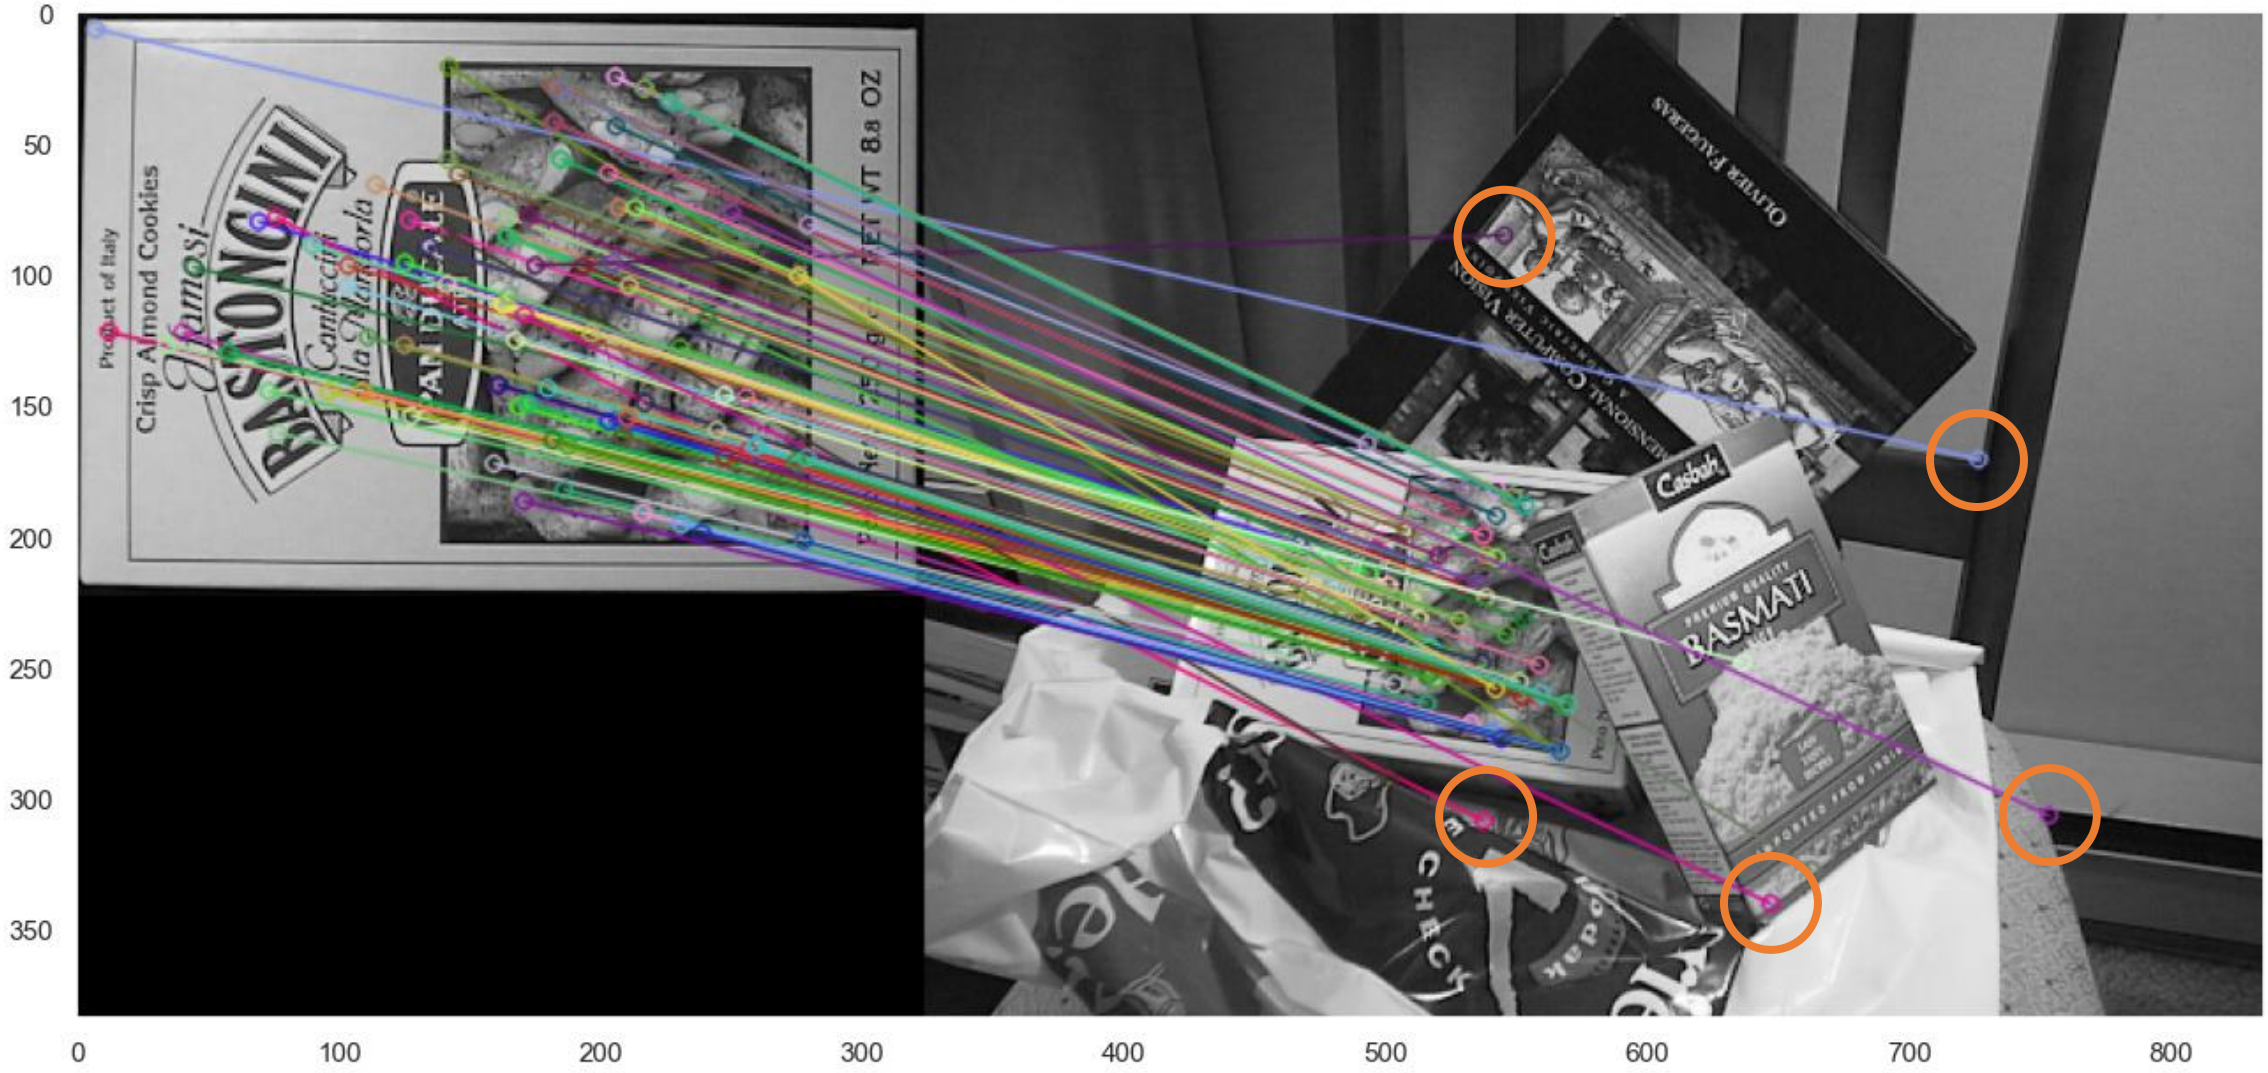
Odhad transformace za přítomnosti chyb v korespondencích

Random Sample consensus (RANSAC)

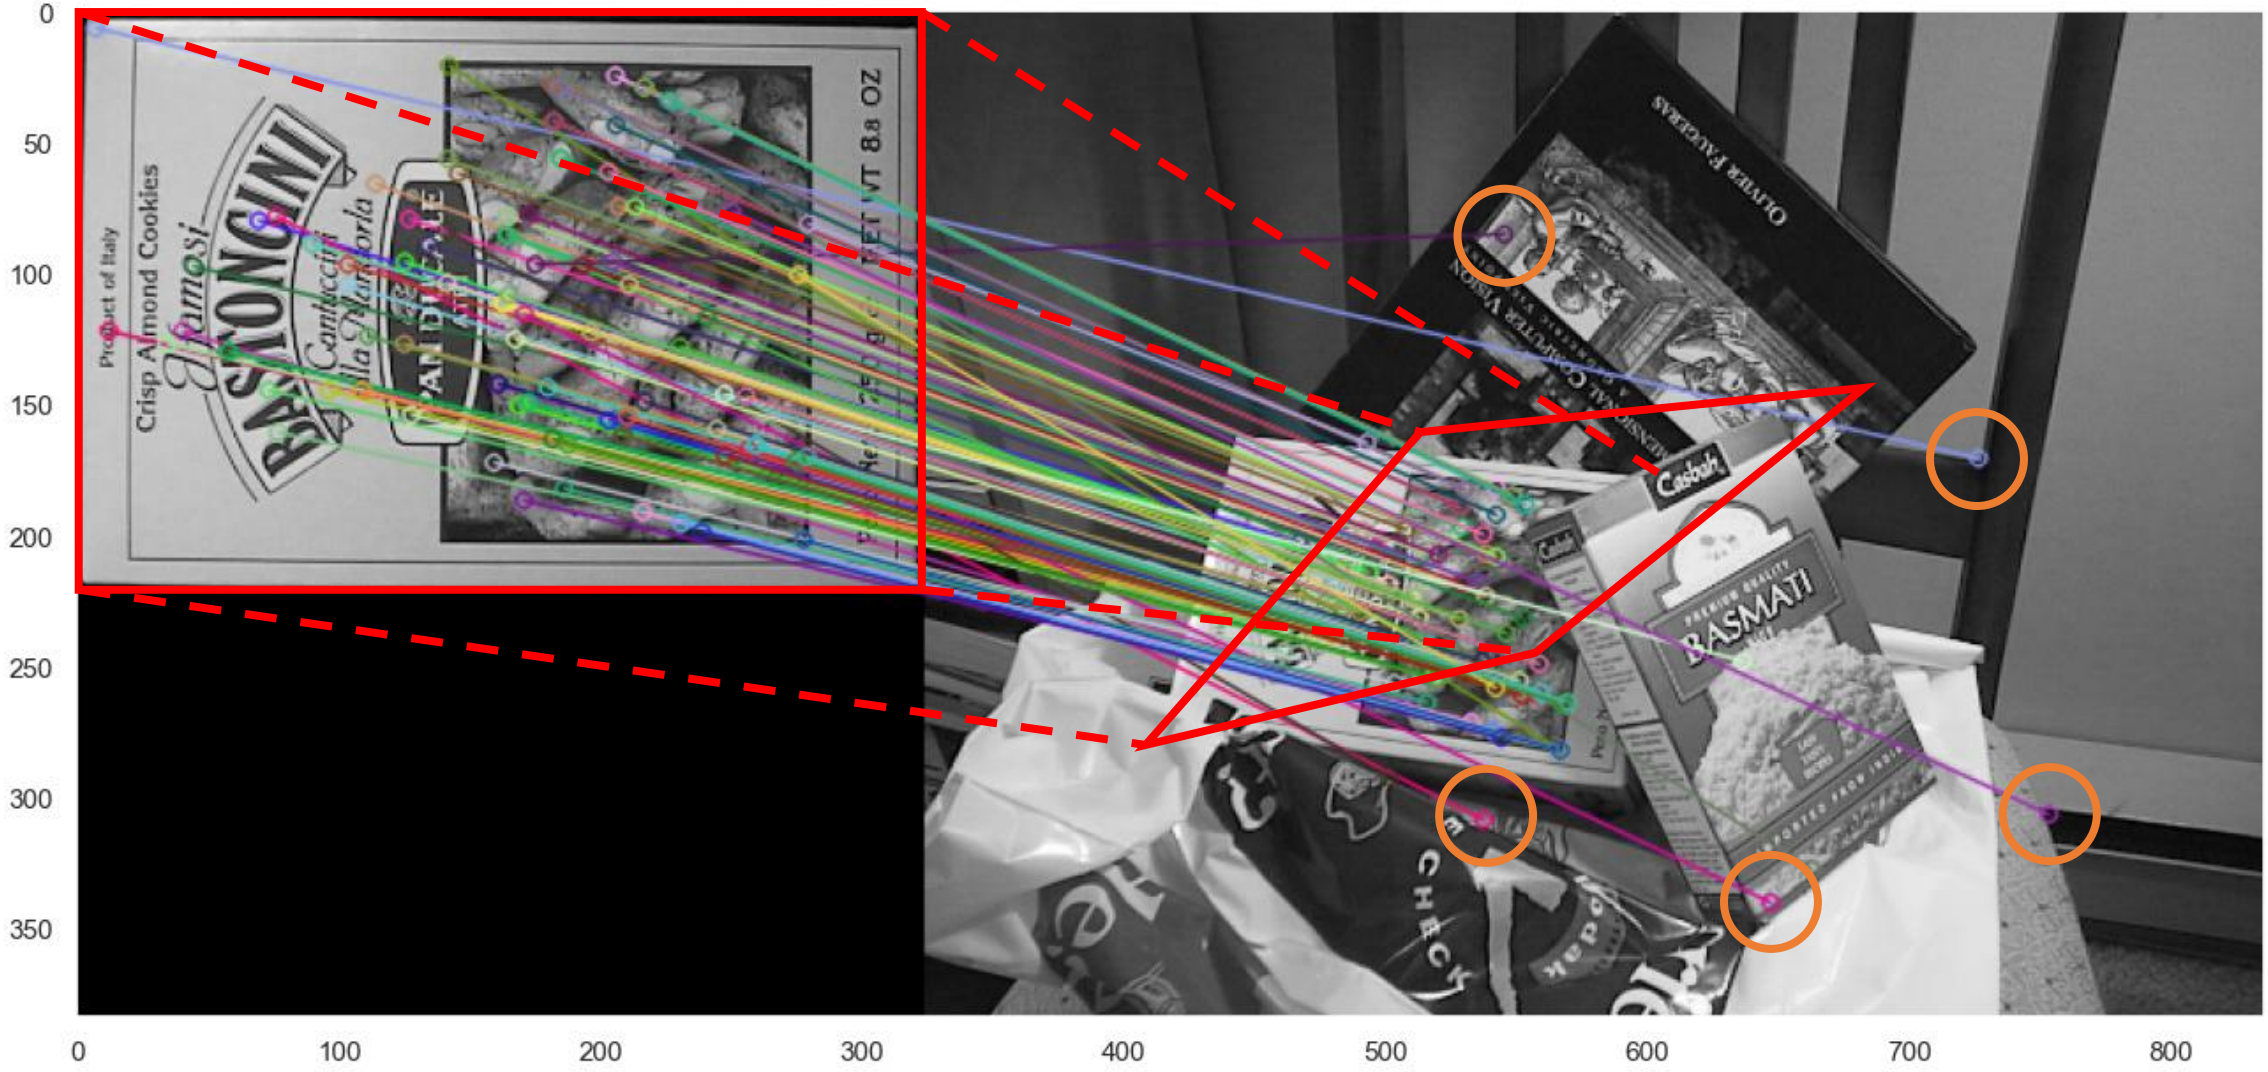
Chyby v korespondencích



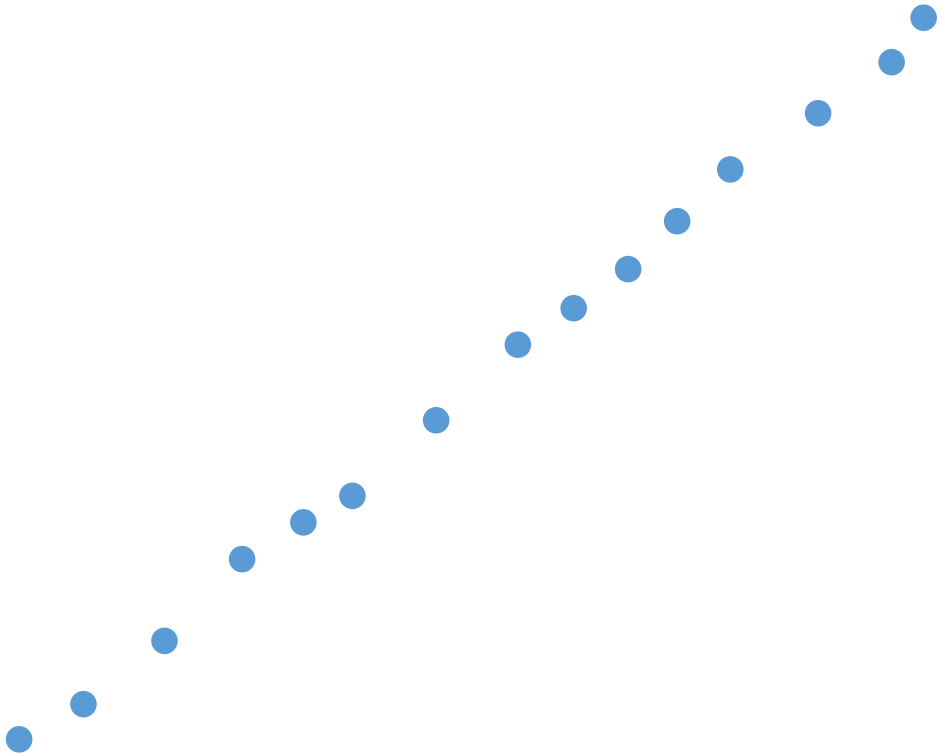
Chyby v korespondencích



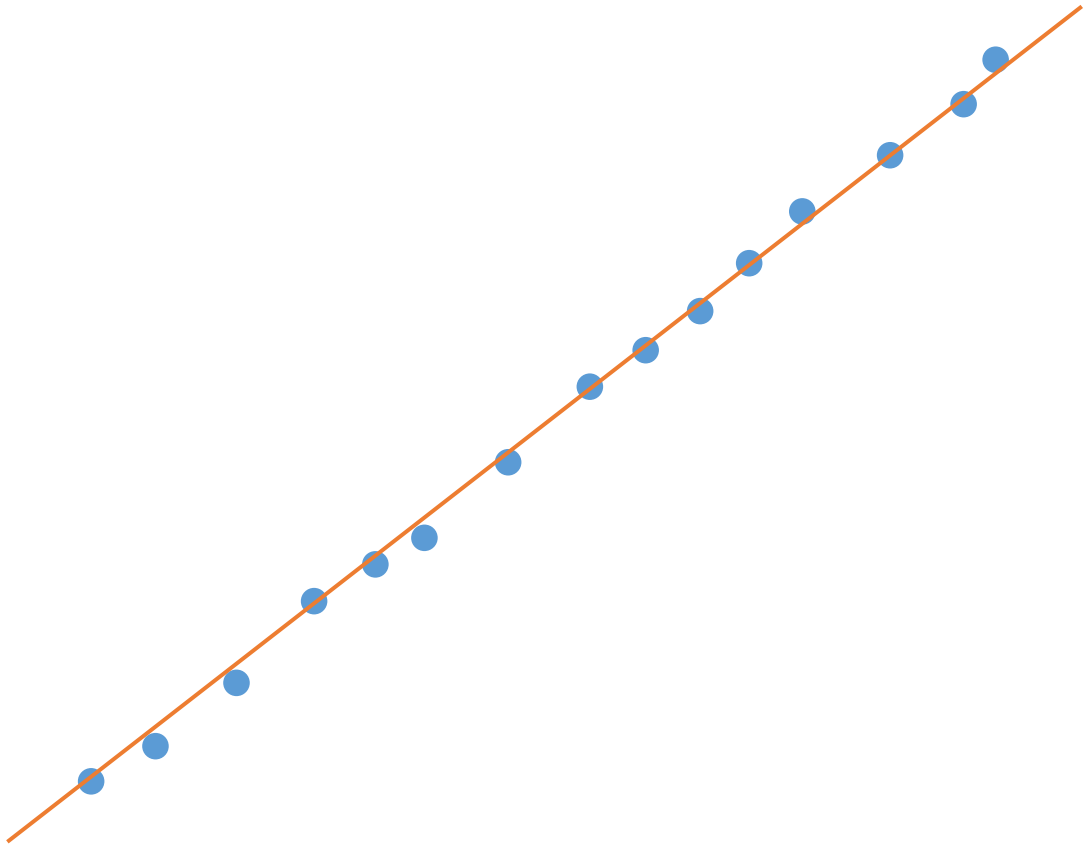
Chyby v korespondencích: fit



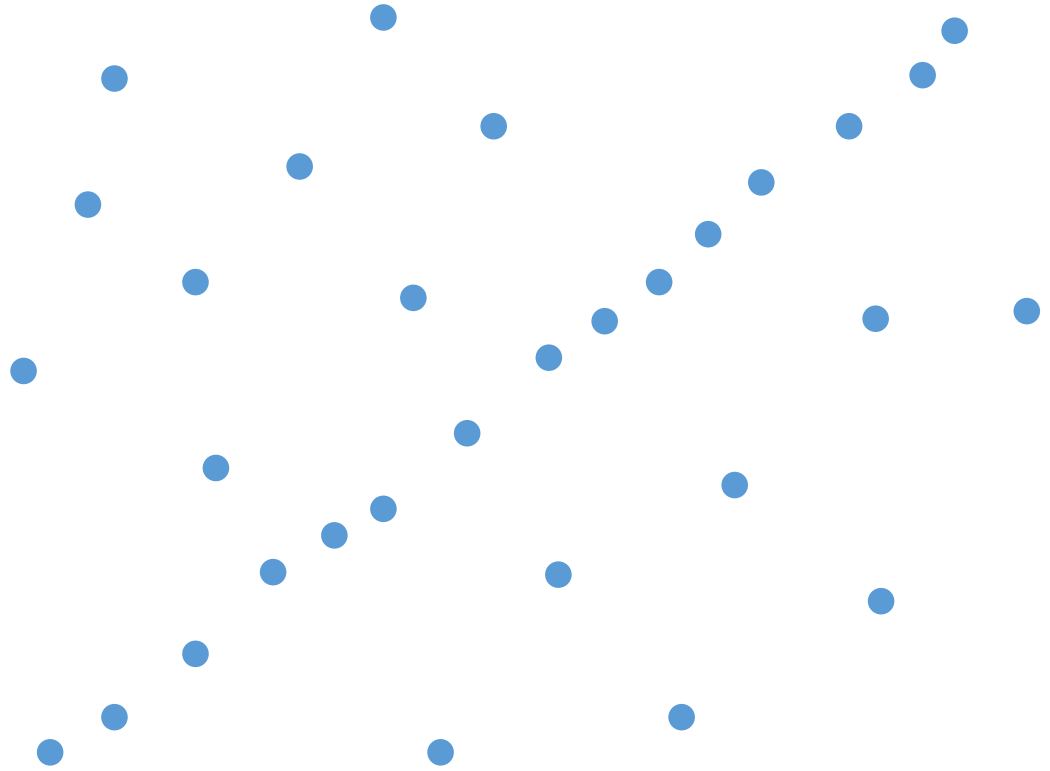
Lineární regrese metodou nejmenších čtverců



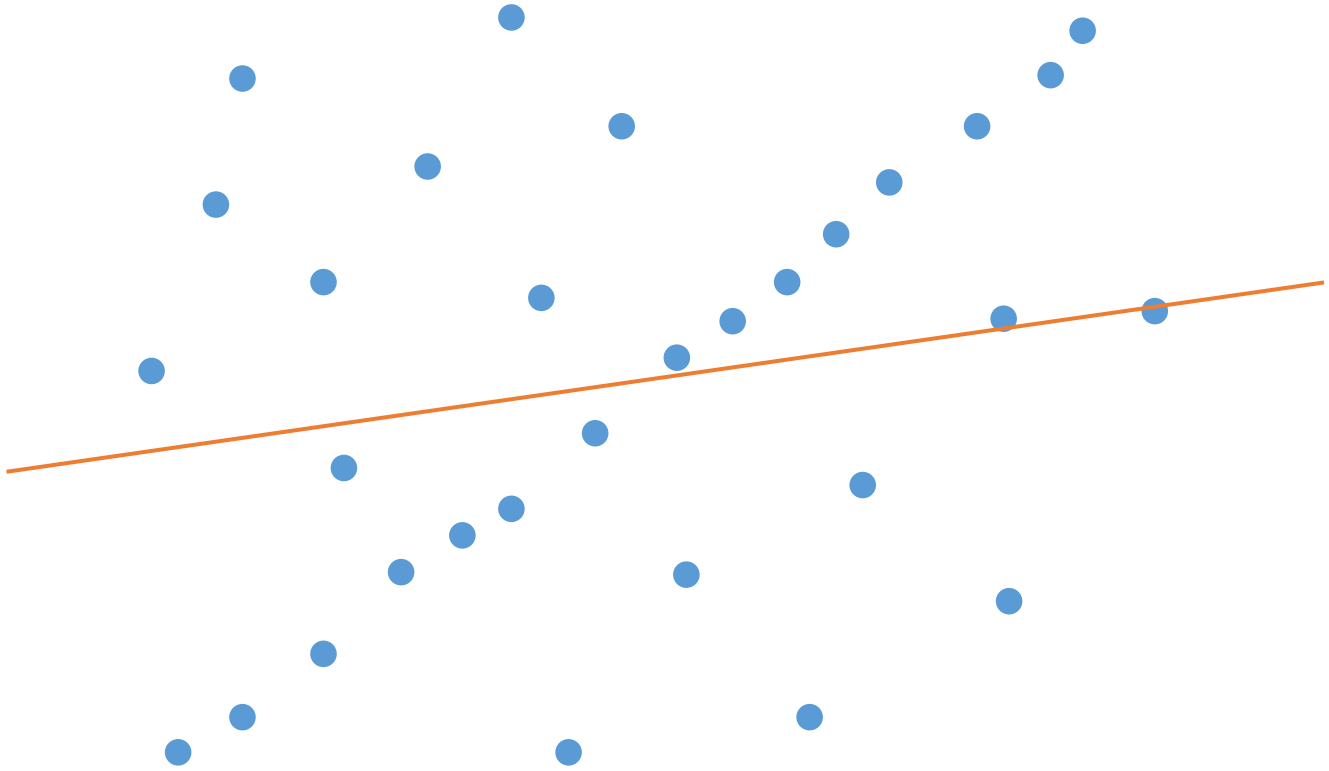
Lineární regrese metodou nejmenších čtverců



Lineární regrese metodou nejmenších čtverců s outliery



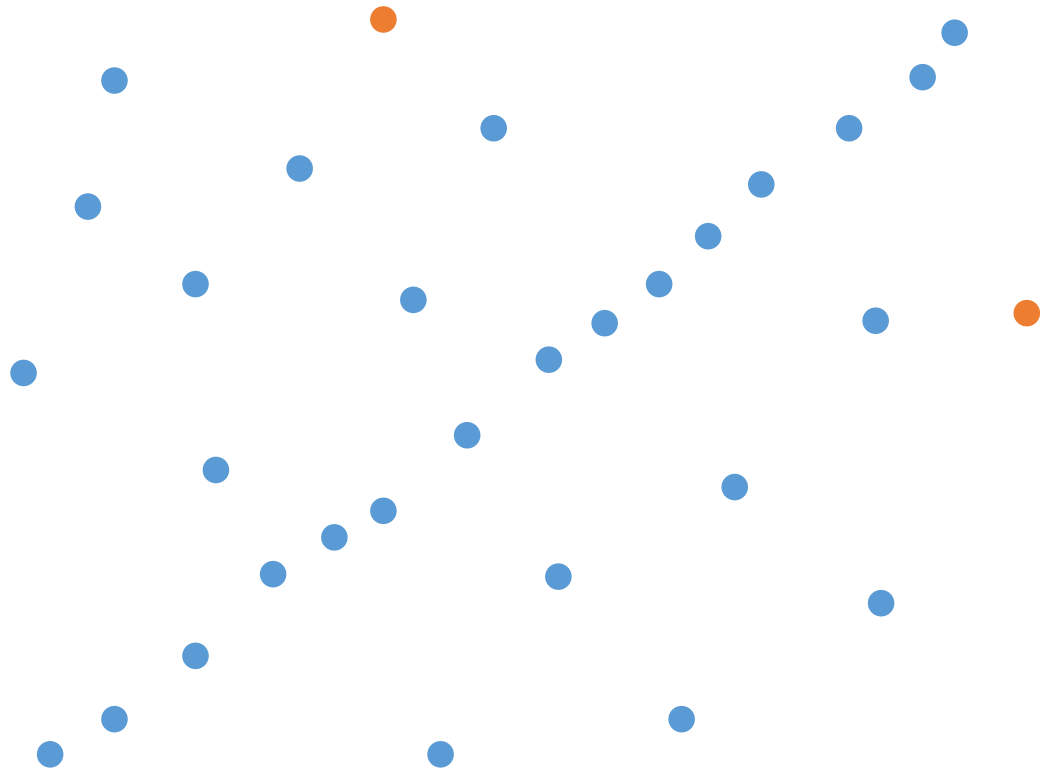
Lineární regrese metodou nejmenších čtverců s outliery



Random Sample Consensus (RANSAC)

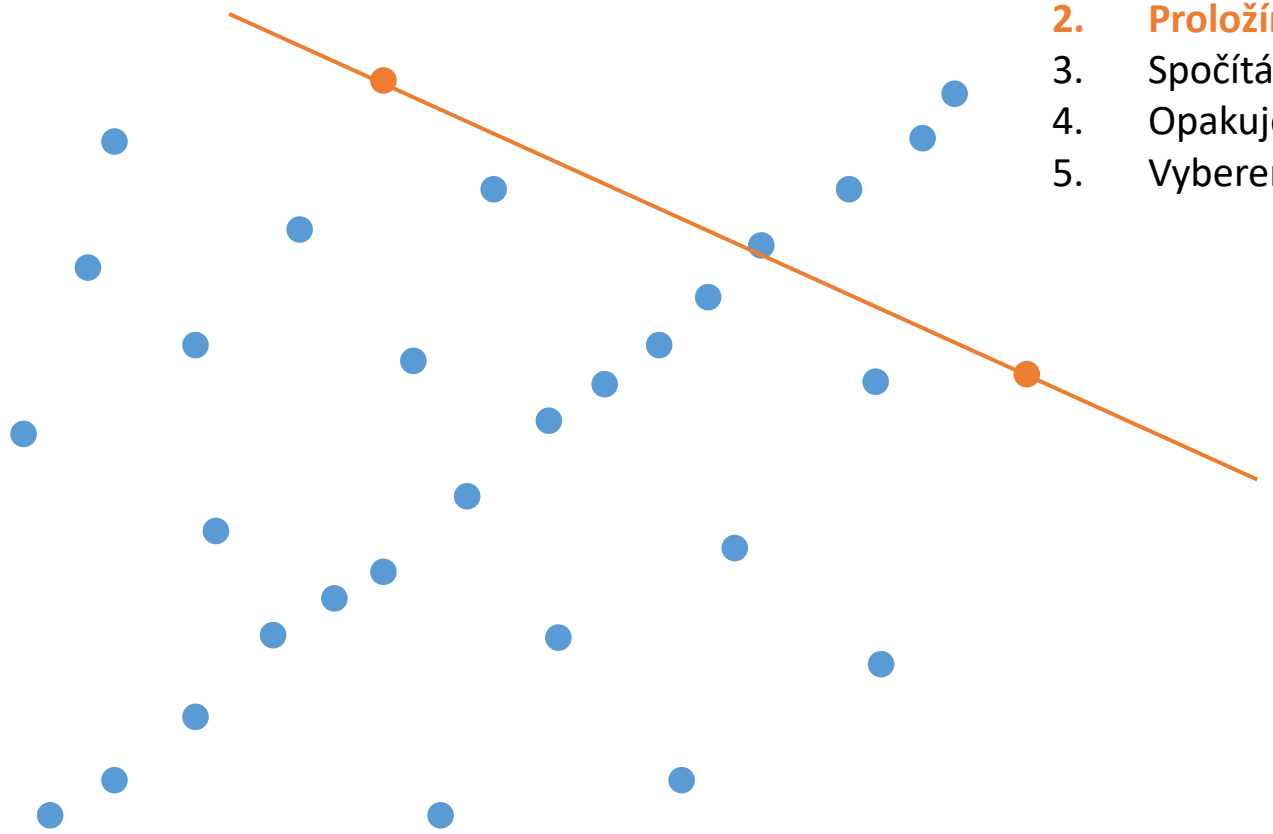
1. Náhodně vybereme P bodů
2. Proložíme modelem
3. Spočítáme body konzistentní s modelem
4. Opakujeme body 1.-3.
5. Vybereme nejlepší model

Random Sample Consensus (RANSAC)



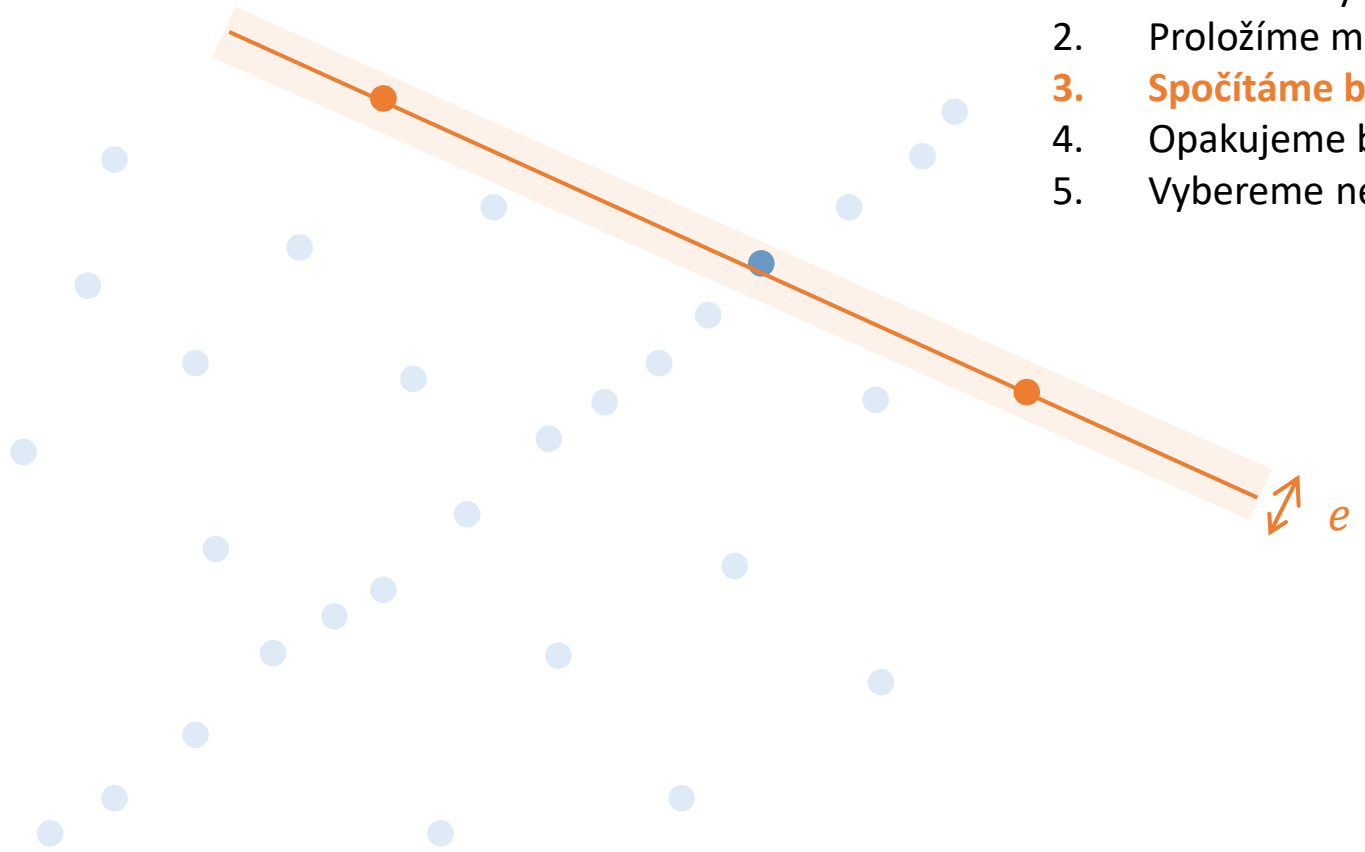
1. **Náhodně vybereme P bodů**
2. Proložíme modelem
3. Spočítáme body konzistentní s modelem
4. Opakujeme body 1.-3.
5. Vybereme nejlepší model

Random Sample Consensus (RANSAC)



1. Náhodně vybereme P bodů
2. **Proložíme modelem**
3. Spočítáme body konzistentní s modelem
4. Opakujeme body 1.-3.
5. Vybereme nejlepší model

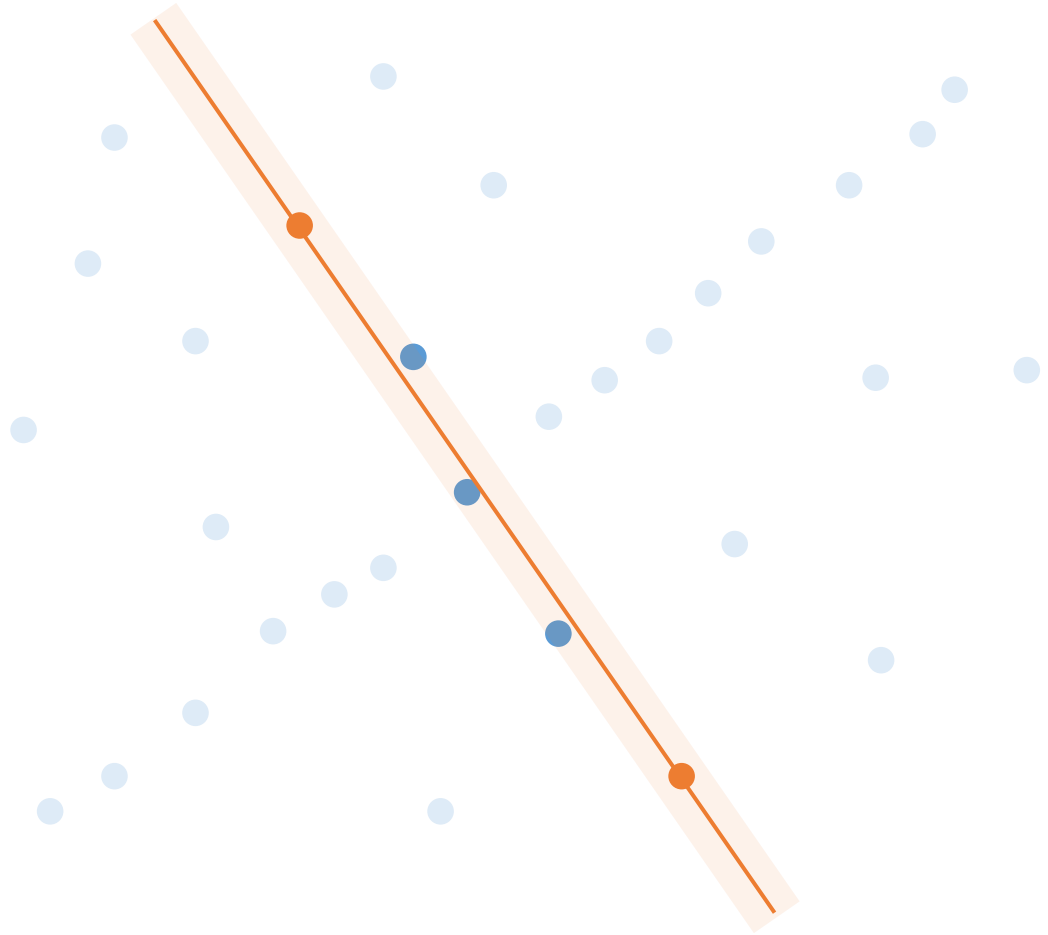
Random Sample Consensus (RANSAC)



1. Náhodně vybereme P bodů
2. Proložíme modelem
3. **Spočítáme body konzistentní s modelem**
4. Opakujeme body 1.-3.
5. Vybereme nejlepší model

#inliers = 3

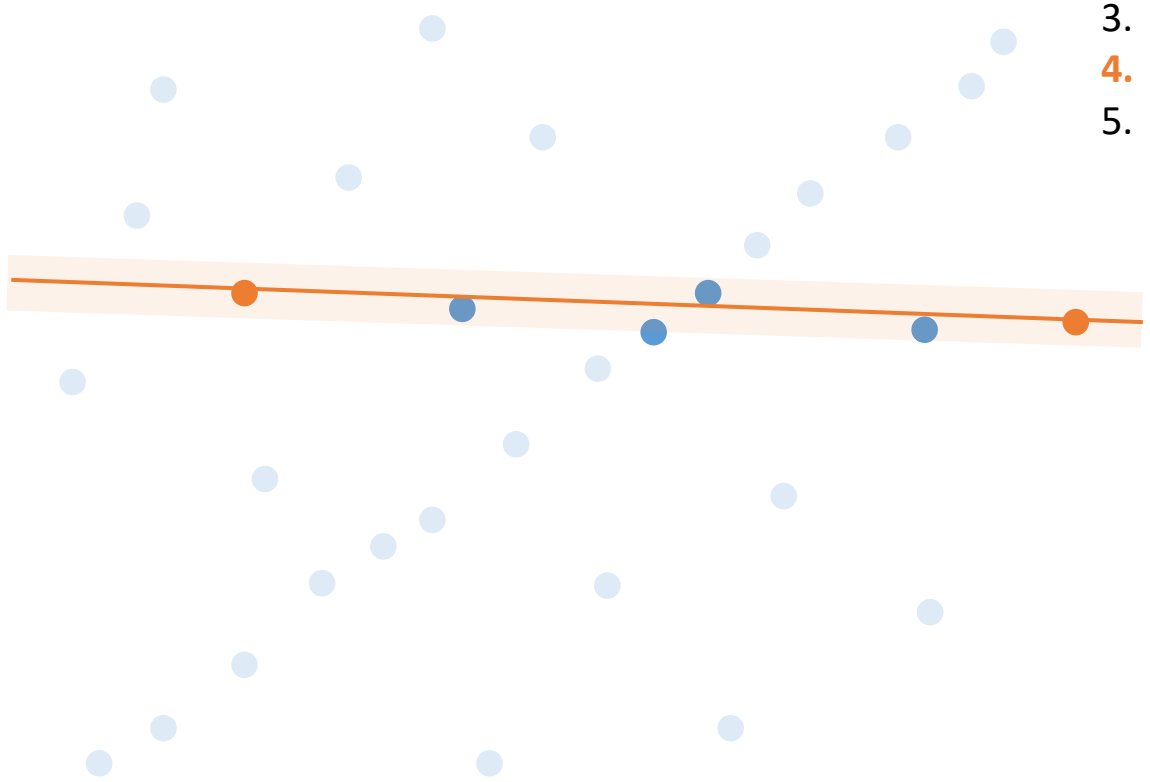
Random Sample Consensus (RANSAC)



1. Náhodně vybereme P bodů
2. Proložíme modelem
3. Spočítáme body konzistentní s modelem
4. **Opakujeme body 1.-3.**
5. Vybereme nejlepší model

#inliers = 5

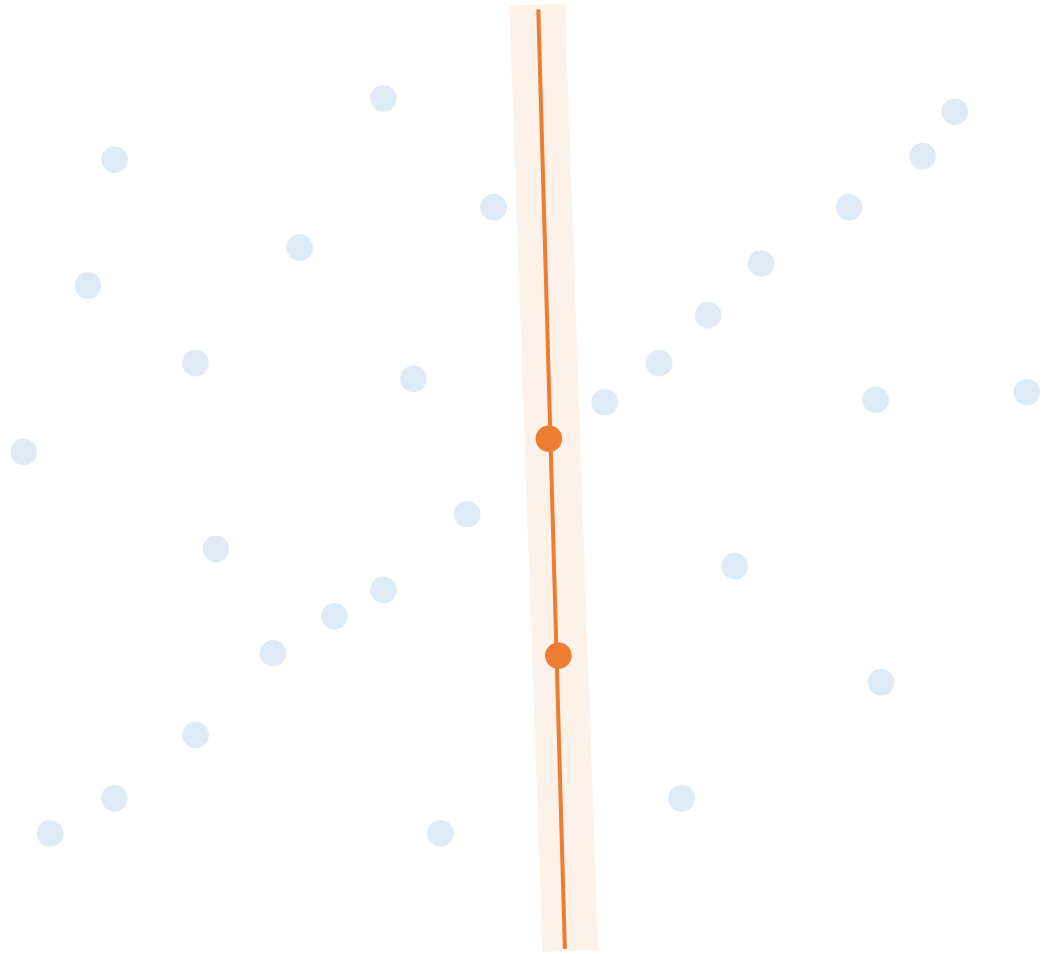
Random Sample Consensus (RANSAC)



1. Náhodně vybereme P bodů
2. Proložíme modelem
3. Spočítáme body konzistentní s modelem
4. **Opakujeme body 1.-3.**
5. Vybereme nejlepší model

#inliers = 6

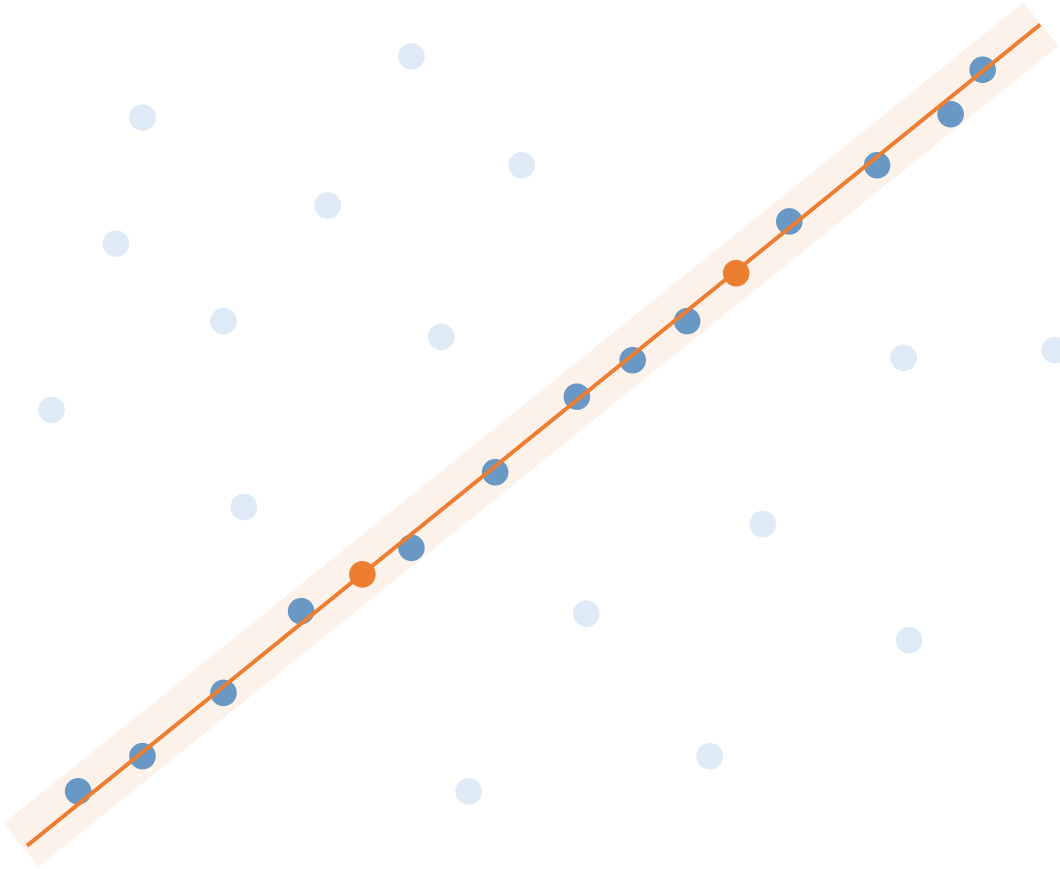
Random Sample Consensus (RANSAC)



1. Náhodně vybereme P bodů
2. Proložíme modelem
3. Spočítáme body konzistentní s modelem
4. **Opakujeme body 1.-3.**
5. Vybereme nejlepší model

#inliers = 2

Random Sample Consensus (RANSAC)



1. Náhodně vybereme P bodů
2. Proložíme modelem
3. Spočítáme body konzistentní s modelem
4. **Opakujeme body 1.-3.**
5. Vybereme nejlepší model

#inliers = 15

Hyperparametry RANSAC

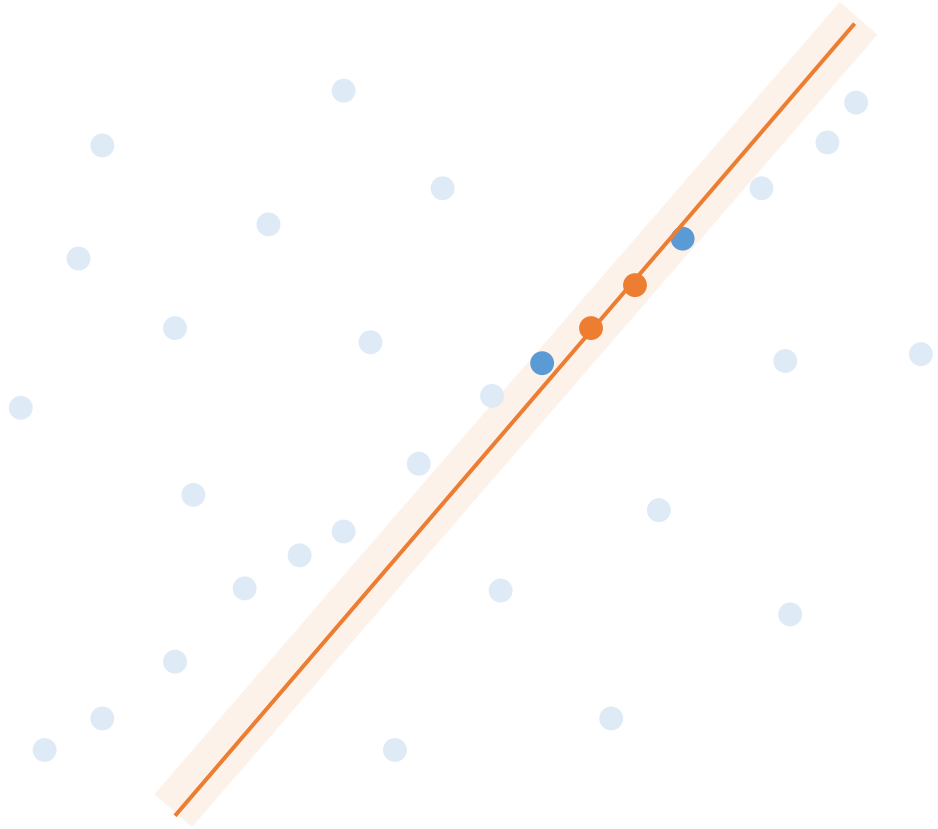
- Počet bodů P, které budeme náhodně vybírat
  - Nejčastěji nejmenší možný – např. pro přímku 2, pro homografii 4 korespondence
- Práh e na max. vzdálenost od modelu
  - Např. při předpokladu gaussovské odchylky bodů na základě sigma
- Velikost konsenzu
  - Kolik min. bodů (poměr vůči všem) z celkového datasetu by mělo odpovídat modelu, abychom považovali model za úspěšně nalezený
- Celkový počet iterací T
  - Vybereme T tak, aby např. existovala $p = 99\%$ pravděpodobnost, že se nám podaří vybrat P inlierů
  - Za předpokladu poměru outlierů v datasetu r lze počet iterací stanovit jako

$$(1 - (1 - r)^P)^T = 1 - p$$

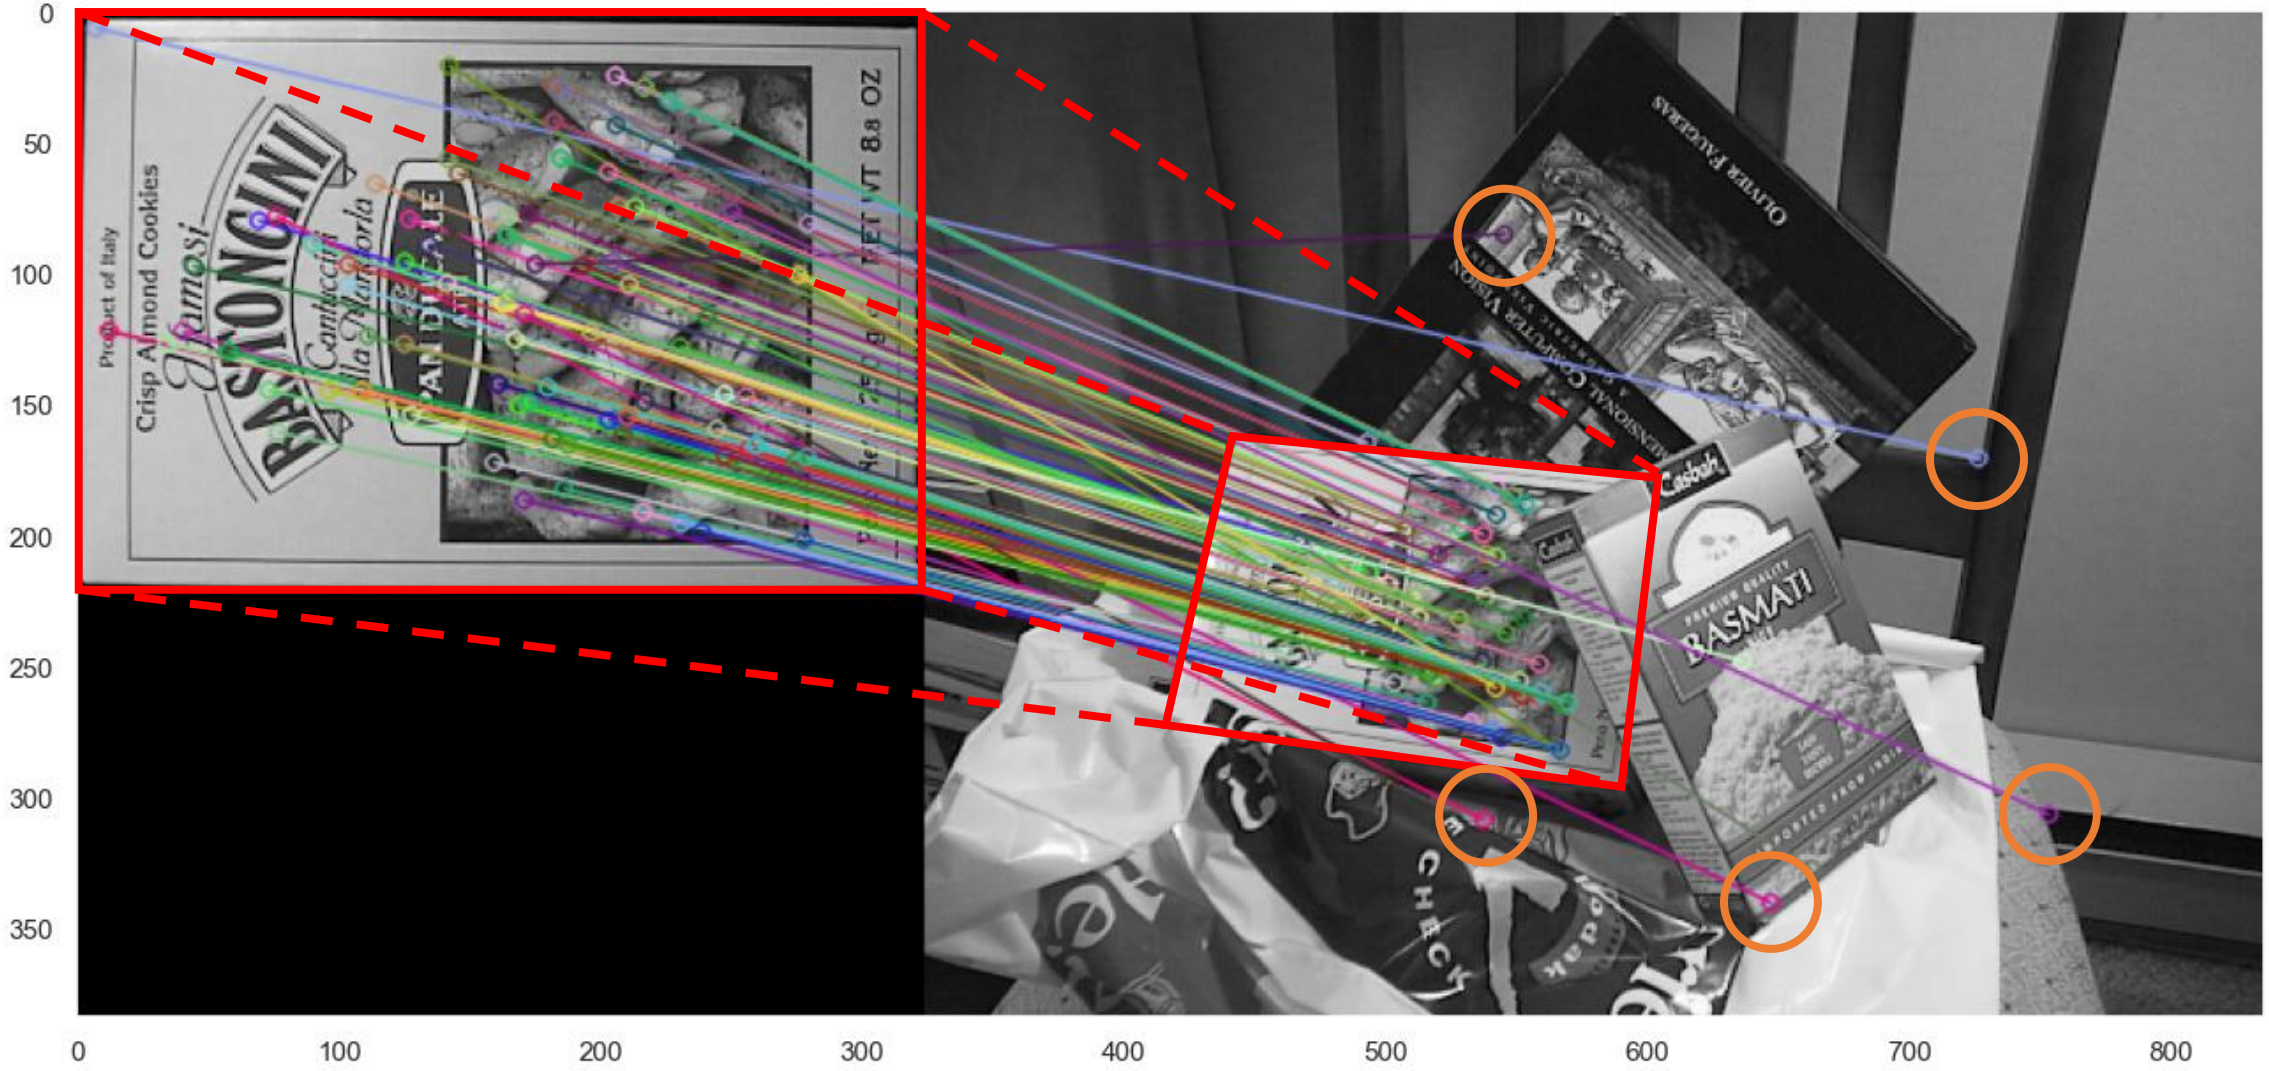
$$T = \frac{\log(1 - p)}{\log(1 - (1 - r)^P)}$$

Výhody a nevýhody RANSAC

- Výhody
  - Jednoduché a obecné
  - Obvykle funguje dobře
- Nevýhody
  - Závislé na zvolených hyperparametrech
  - Počet potřebných iterací závisí na poměru outlierů r exponenciálně
  - Někdy min. počet vzorkovaných bodů nestačí pro dobrý počáteční odhad



Odhad homografie pomocí RANSAC



Varianty RANSAC

Varianta	Hlavní myšlenka	OpenCV
MSAC (Torr, Zisserman 2000)	Místo počtu inlierů minimalizuje omezenou kvadratickou chybu → rozliší i modely se stejným počtem inlierů	skóre v USAC
MLESAC (Torr, Zisserman 2000)	Maximalizuje věrohodnost: inliery ~ Gaussovo, outliery ~ rovnoměrné rozdělení	–
PROSAC (Chum, Matas 2005)	Vzorkuje přednostně nejkvalitnější korespondence (např. dle poměrového testu) → výrazně méně iterací	USAC_PROSAC
LO-RANSAC (Chum, Matas, Kittler 2003)	Lokální optimalizace: nový nejlepší model přepočítá ze všech jeho inlierů (iterativně)	USAC_DEFAULT
GC-RANSAC (Baráth, Matas 2018)	Lokální optimalizace s prostorovou koherencí inlierů (graph-cut)	USAC_ACCURATE
MAGSAC++ (Baráth et al. 2020)	Bez pevného prahu e: marginalizace přes neznámou úroveň šumu σ	USAC_MAGSAC

- Adaptivní ukončení: počet iterací T průběžně přepočítáváme z poměru inlierů dosud nejlepšího modelu
- USAC (Raguram et al. 2013): jednotný rámec kombinující tyto techniky

řada variant vznikla na ČVUT v Praze

Least Median of Squares (LMedS)

Potřebuje alespoň 50% poměr inlierů

RANSAC

1. Náhodně vybereme P bodů
2. Proložíme modelem
3. Spočítáme body konzistentní s modelem
4. Opakujeme body 1.-3.
5. Vybereme nejlepší model

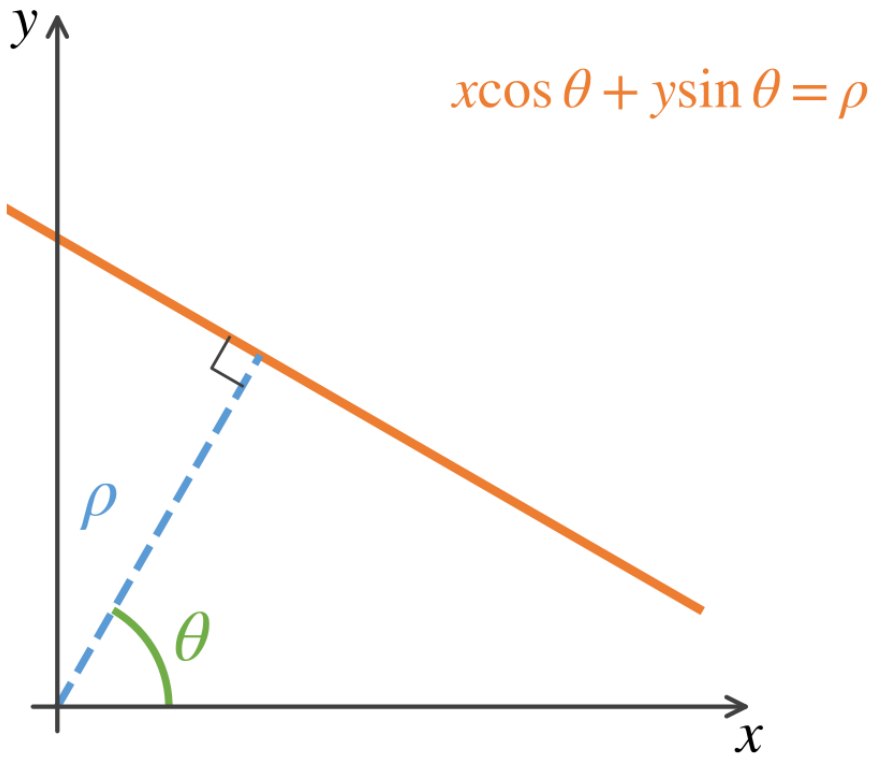
LMedS

1. Náhodně vybereme P bodů
2. Proložíme modelem
3. Spočítáme medián odchylky všech bodů od modelu
4. Opakujeme body 1.-3.
5. Vybereme nejlepší model

Houghova transformace

Houghova transformace

- Detekce parametrických tvarů (přímky, kružnice, …) v hranovém obraze
- **Hlasování:** každý hranový bod hlasuje pro všechny přímky, které jím procházejí
- Parametrizace $y=kx+q$ je nevhodná: svislé přímky → $k\to\infty$
- Proto normálová (Hessova) parametrizace

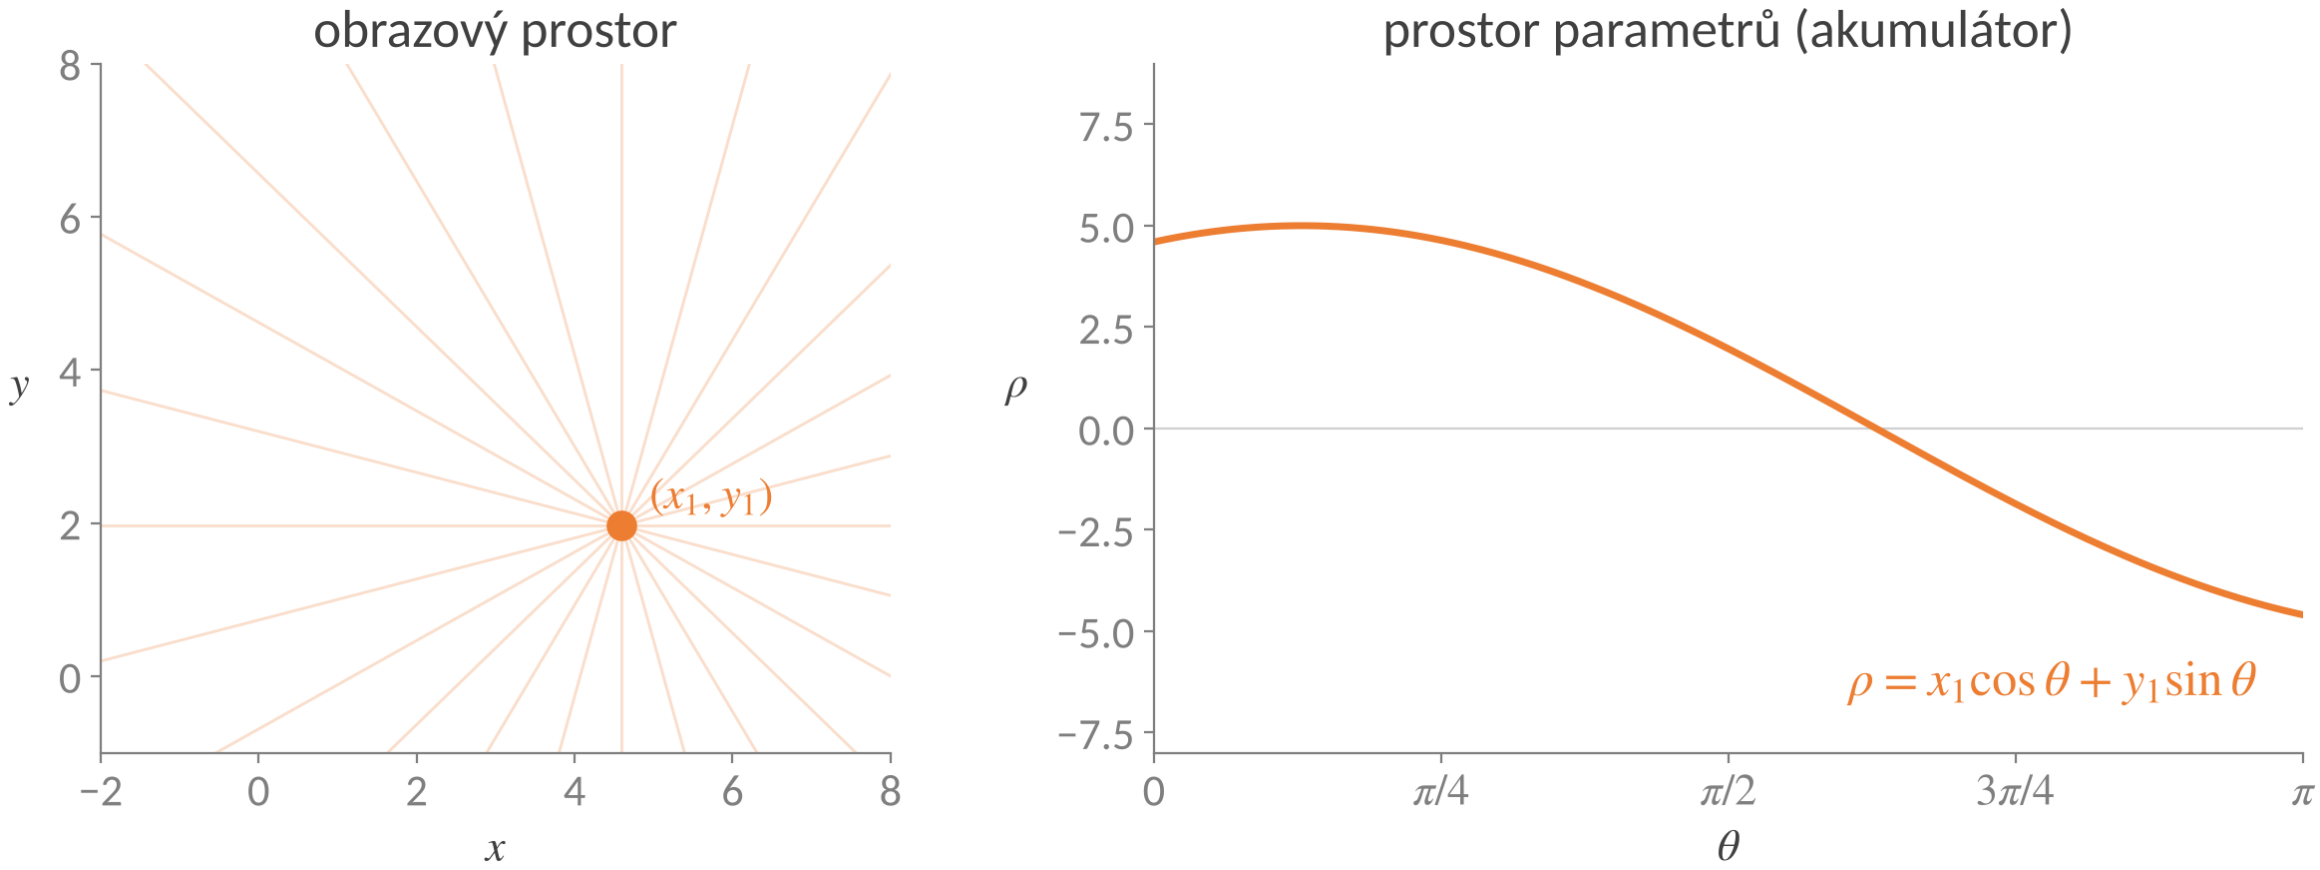


$$\rho = \cdot \cos(\theta) + \cdot \sin(\theta)$$

$$\theta \in [0,\pi), \quad \rho \in [-\rho_{max}, \rho_{max}]$$

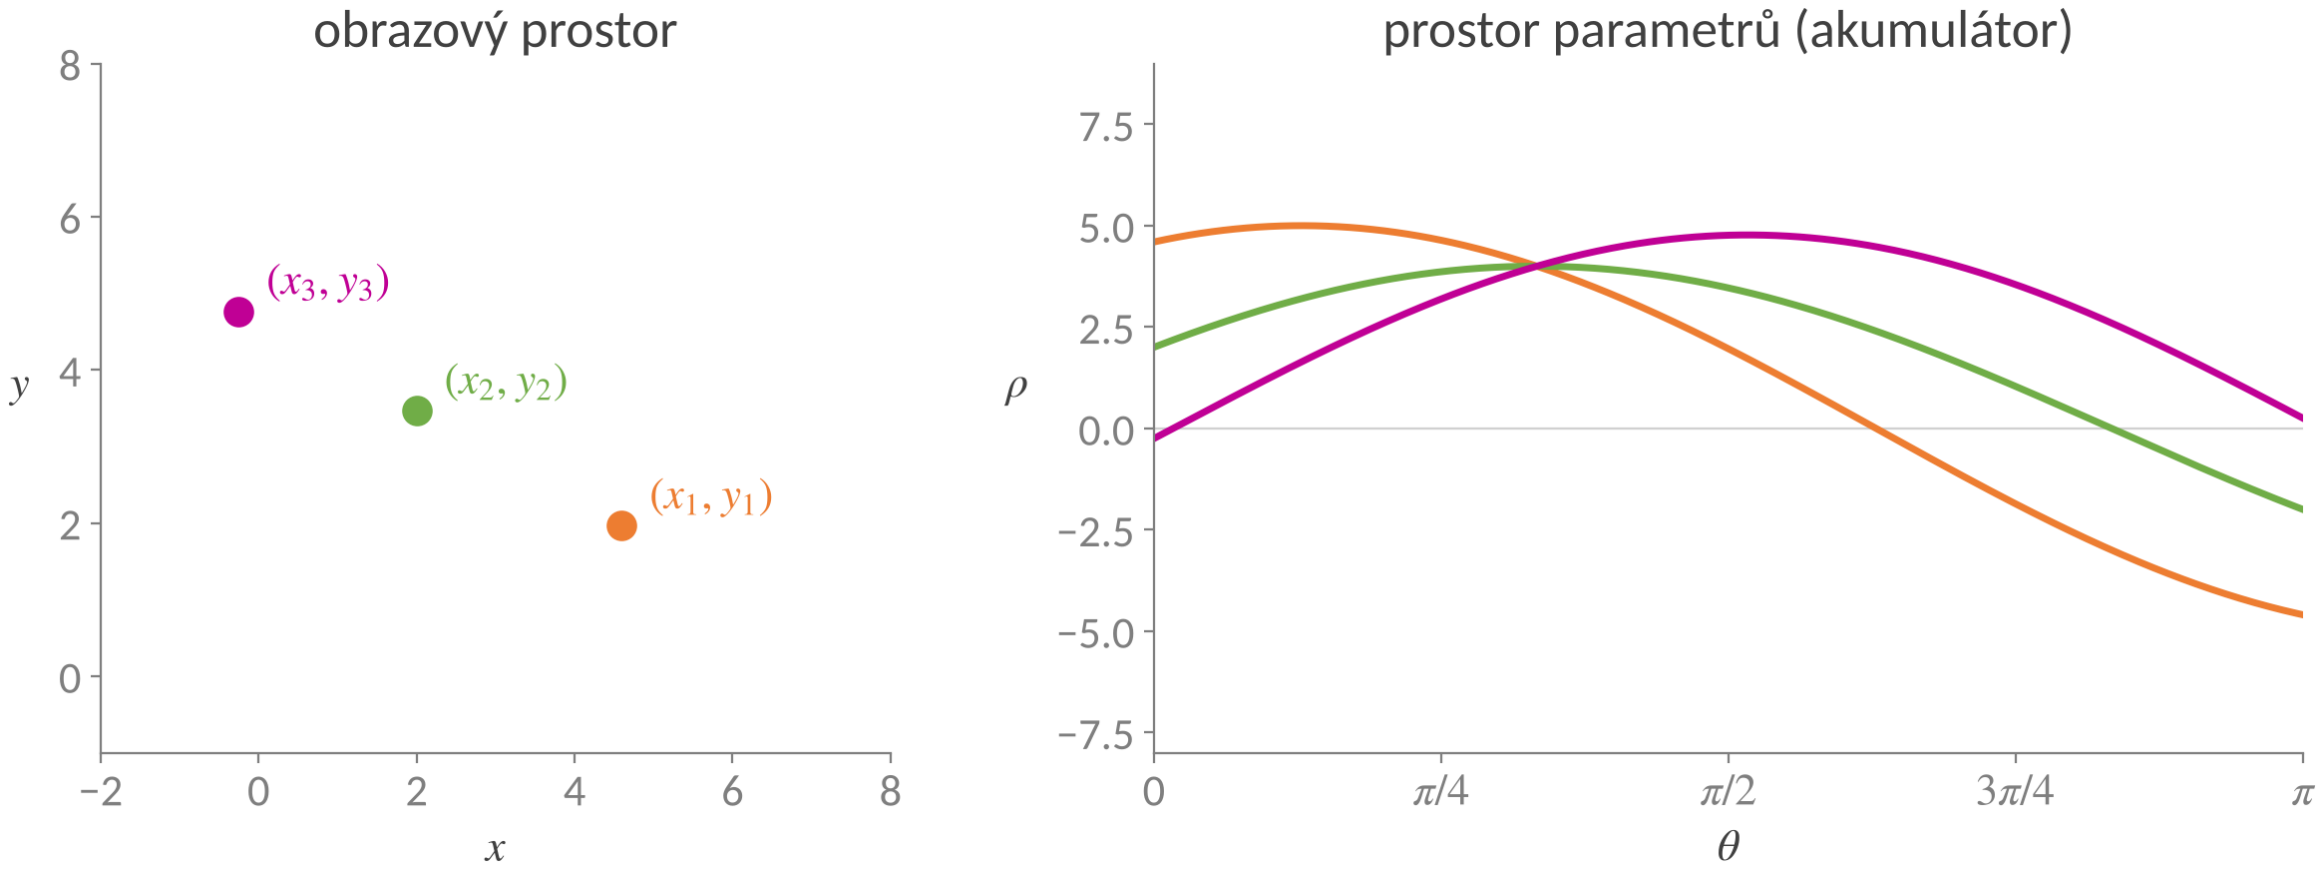
P. Hough: US patent 3 069 654 (1962); R. Duda, P. Hart: CACM 15(1), 1972

Houghova transformace: prostor parametrů



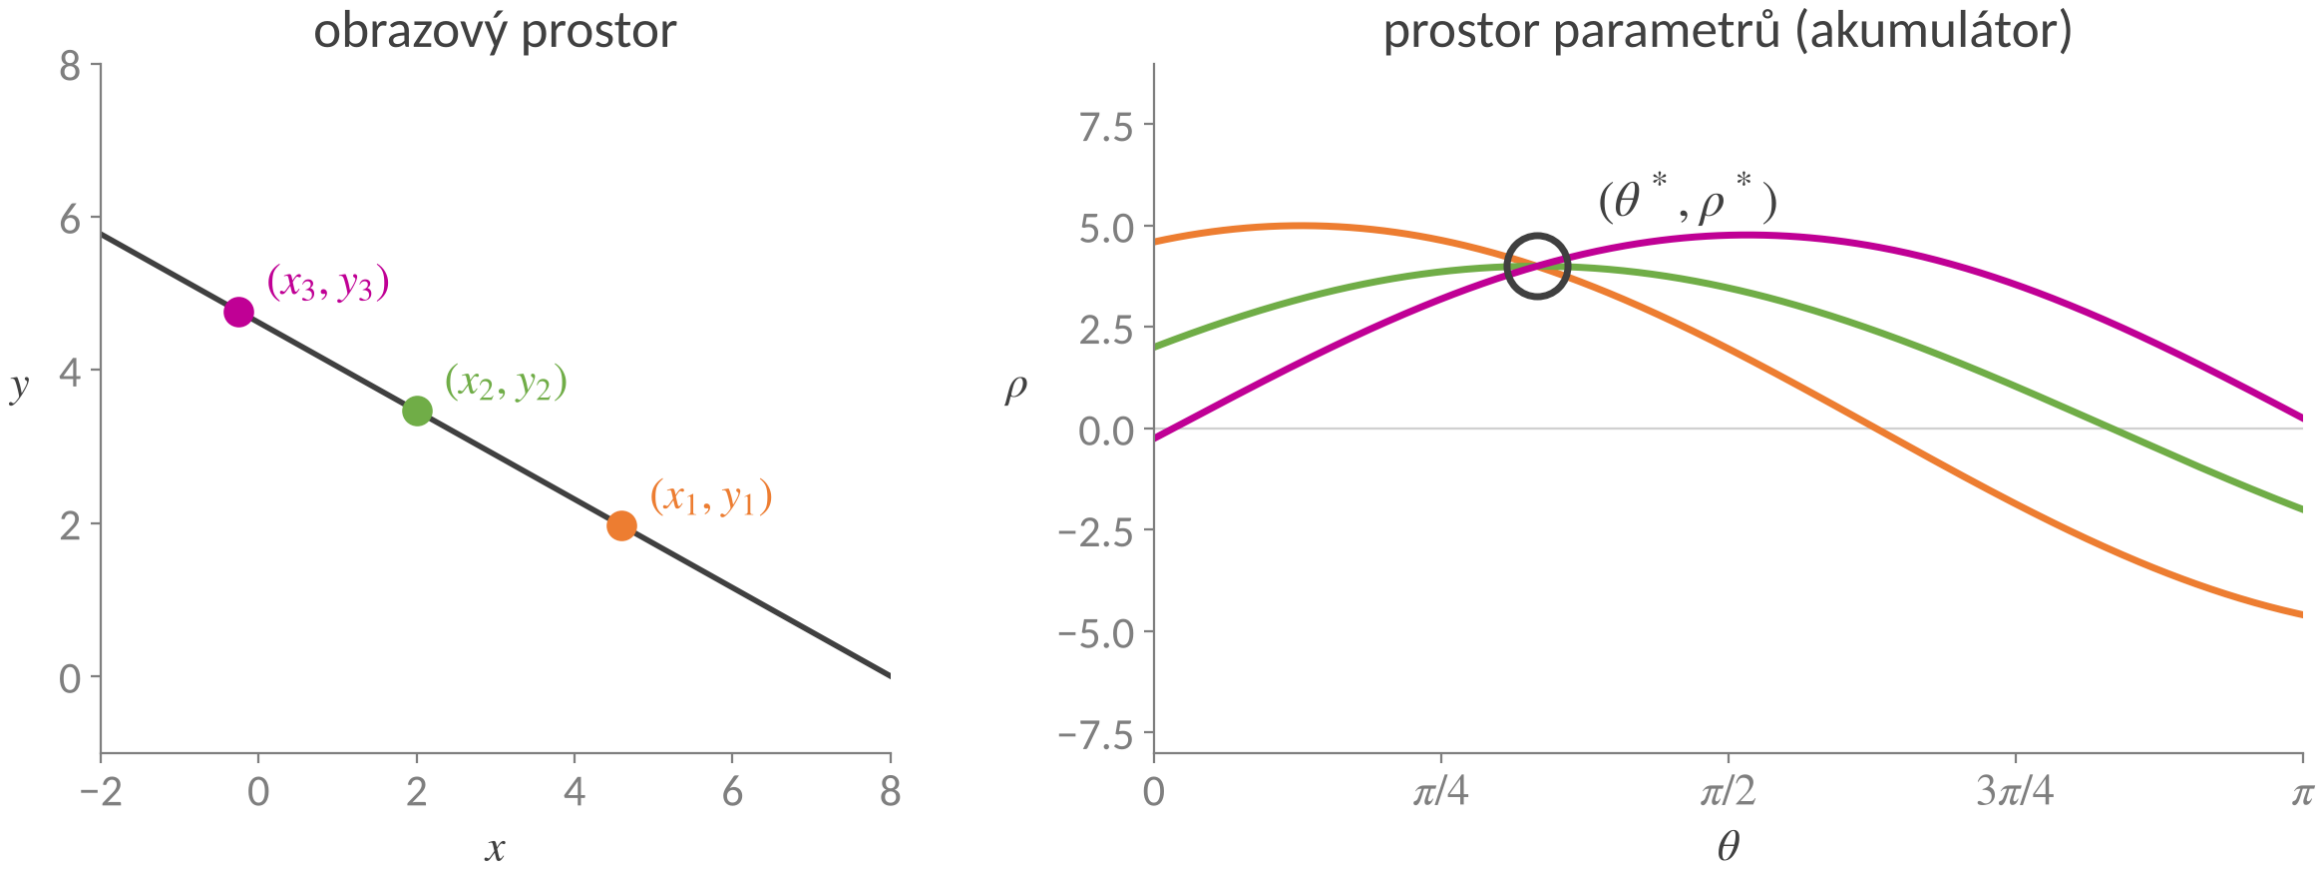
Bod v obraze ↔ sinusoida v prostoru parametrů (všechny přímky procházející bodem)

Houghova transformace: prostor parametrů



Body ležící na jedné přímce → jejich sinusoidy se protínají v jednom bodě

Houghova transformace: prostor parametrů



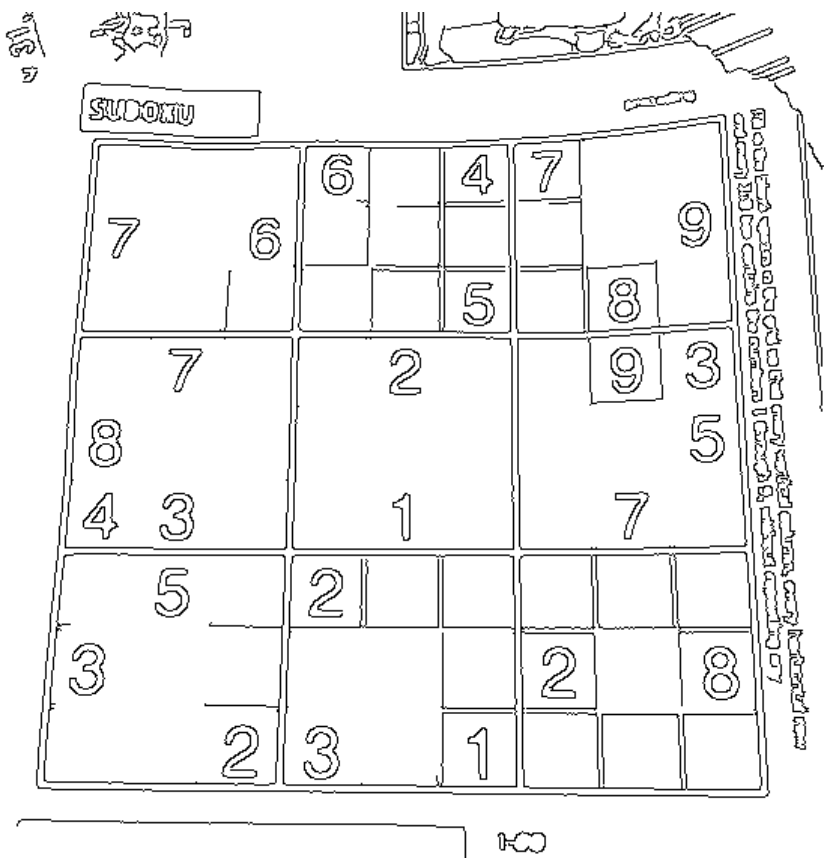
Průsečík (θ*, ρ*) = parametry hledané přímky → hledáme maxima akumulátoru

Houghova transformace: algoritmus

1. Detekujeme hrany (např. Canny)
2. Diskretizujeme prostor parametrů → akumulátor $A[\theta,\rho]=0$
3. Pro každý hranový bod (x,y) a každé θ:

   $\rho=x\cdot cos(\theta)+y\cdot sin(\theta),\ \ A[\theta,\rho]\ +=1$

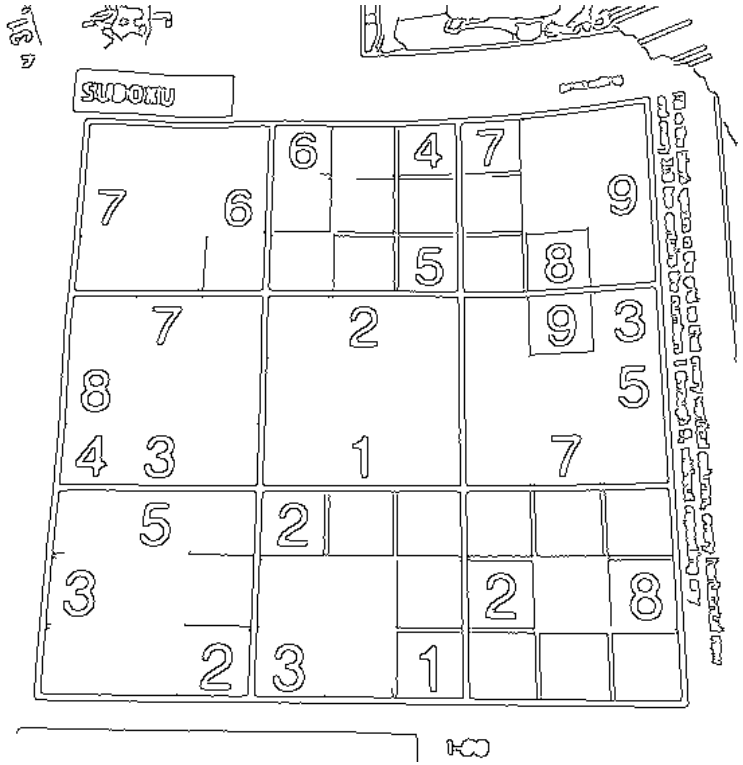
1. Najdeme lokální maxima akumulátoru nad prahem (potlačení nemaxim)
2. Každé maximum = jedna detekovaná přímka



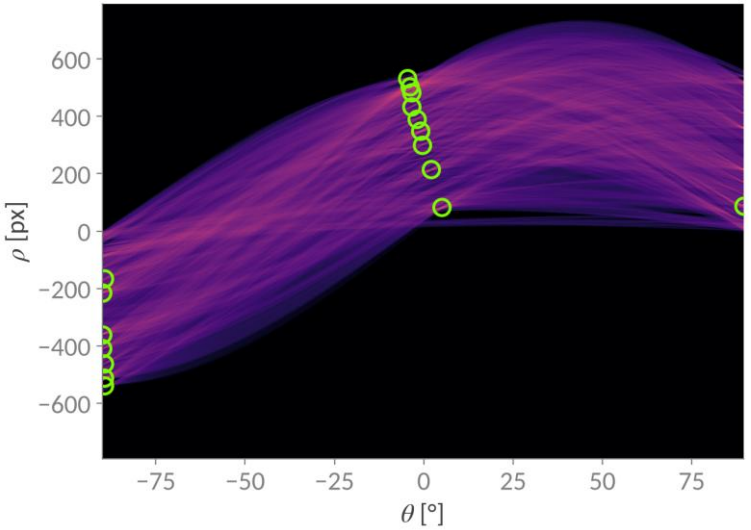
zrychlení: bod hlasuje jen pro θ blízké směru gradientu

obrázek: OpenCV (samples/data/sudoku.png)

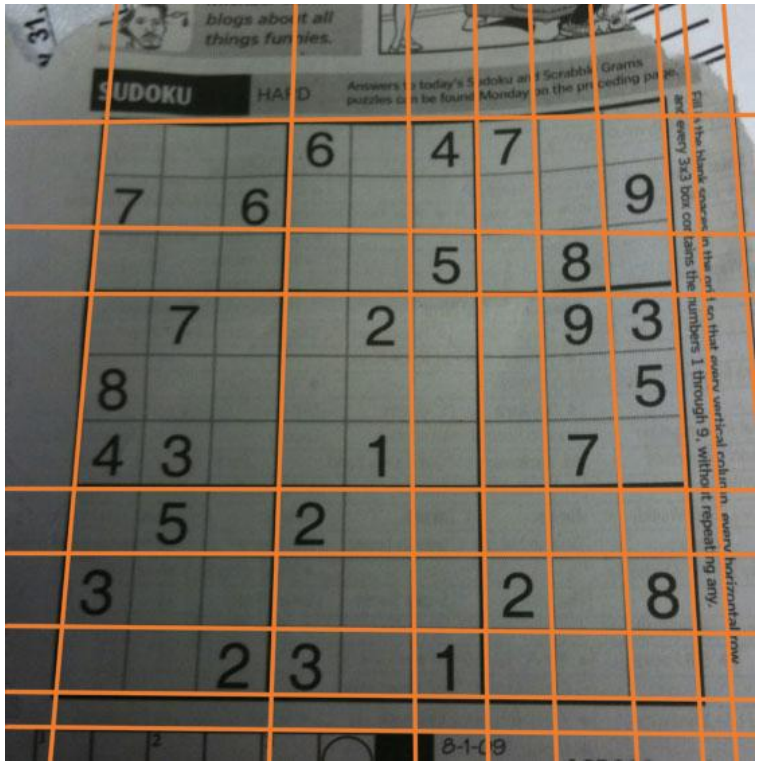
Houghova transformace: příklad



hranový obraz (Canny)



akumulátor a nalezená maxima



detekované přímky

obrázek: OpenCV (samples/data/sudoku.png)

Houghova transformace: rozšíření a srovnání s RANSAC

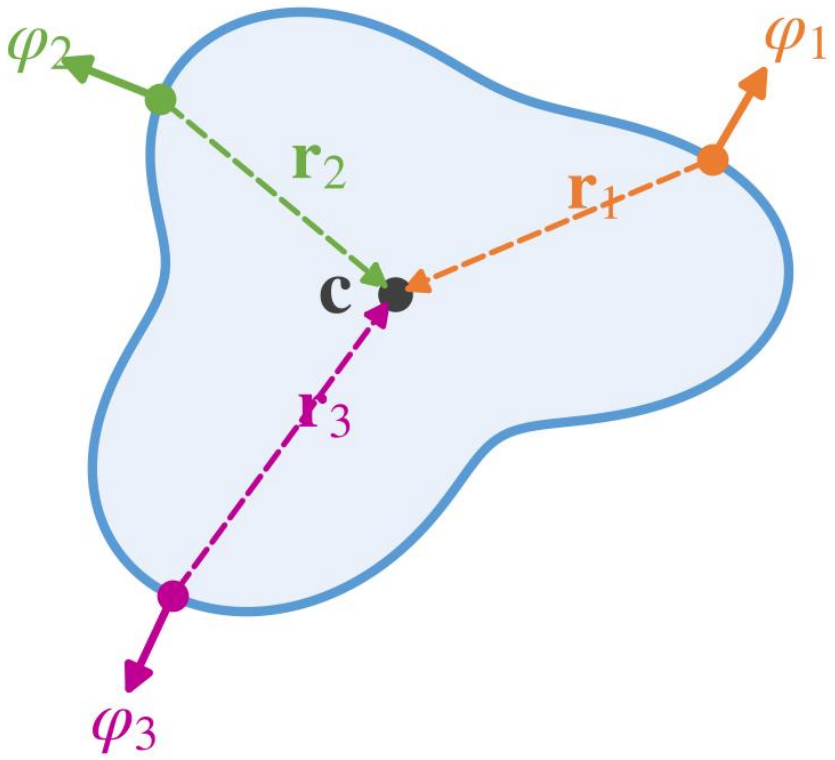
- **Kružnice:** 3D akumulátor (a,b,r)
  - se směrem gradientu stačí hlasovat podél jedné polopřímky
- **Libovolný tvar:** zobecněná Houghova transformace
- **Pravděpodobnostní HT:** hlasuje jen náhodná podmnožina bodů, vrací úsečky

$$(x - x_c)^2 + (y - y_c)^2 = r^2$$

```
cv2.HoughLines(edges, ...)
cv2.HoughLinesP(edges, ...)
cv2.HoughCircles(gray, ...)
```

	Houghova transformace	**RANSAC**
Robustní vůči outlierům	ano	ano
Více instancí modelu	ano, najednou (více maxim)	sekvenčně (odebereme inliery a opakujeme)
Počet parametrů	malý (2–3), paměť roste exponenciálně	i větší (homografie: 8)
Klíčová volba	diskretizace akumulátoru	práh e, počet iterací

Zobecněná Houghova transformace



- Ballard (1981): detekce tvaru **bez analytického popisu**
- Model: zvolíme referenční bod $\boldsymbol{c}$
- Pro každý hranový bod $\boldsymbol{p}_i$ modelu uložíme vektor do **R-tabulky**, indexované orientací gradientu φ_i

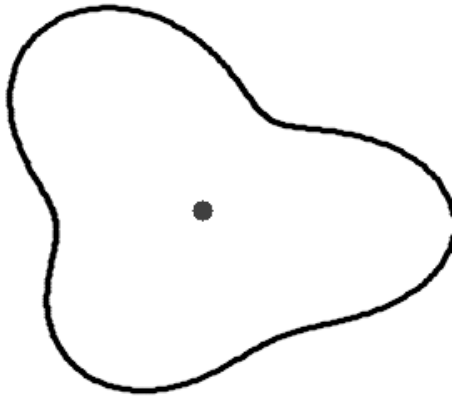
$$\boldsymbol{r}_i = \boldsymbol{c} - \boldsymbol{p}_i$$

orientace φ	vektory r = c – p
φ_1	$\boldsymbol{r}_1, \boldsymbol{r}_5, \ldots$
φ_2	$\boldsymbol{r}_2, \ldots$
φ_3	$\boldsymbol{r}_3, \boldsymbol{r}_7, \ldots$
⋮	⋮

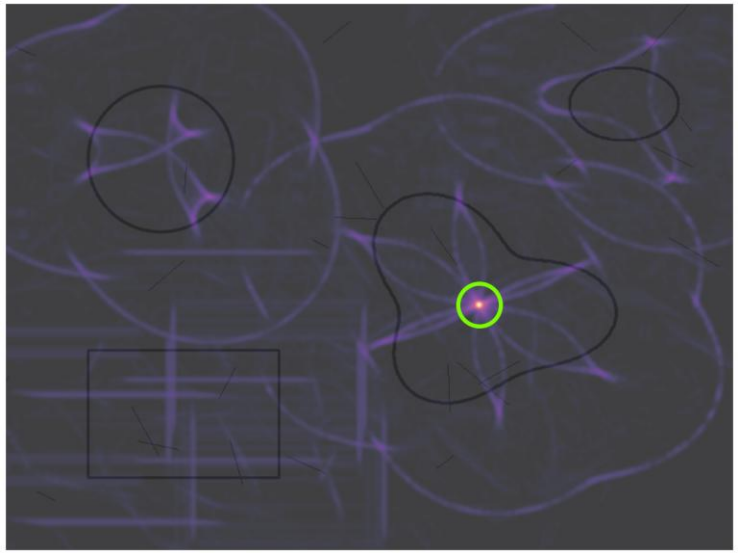
Zobecněná Houghova transformace: detekce

1. Pro každý hranový bod $\boldsymbol{p}$ v obraze určíme orientaci gradientu φ
2. Každý vektor z $R(\varphi)$ hlasuje pro polohu referenčního bodu
3. Maximum akumulátoru = poloha objektu

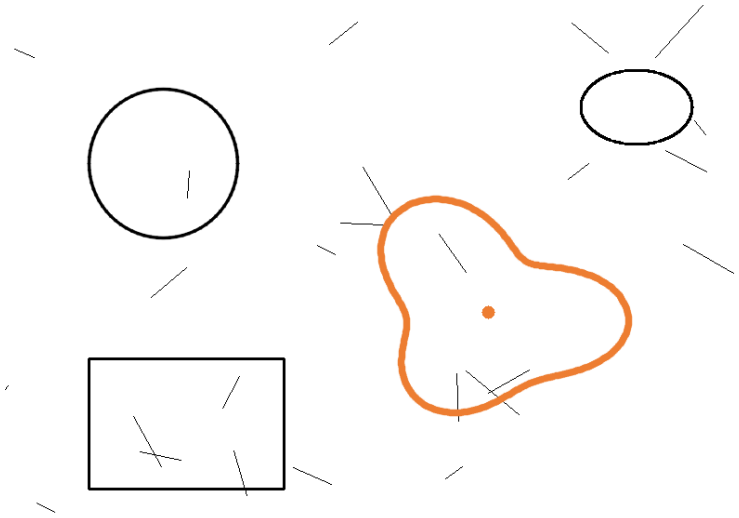
$$\boldsymbol{c} = \boldsymbol{p} + \boldsymbol{r}, \qquad \boldsymbol{r} \in (\varphi)$$



model



akumulátor



detekce

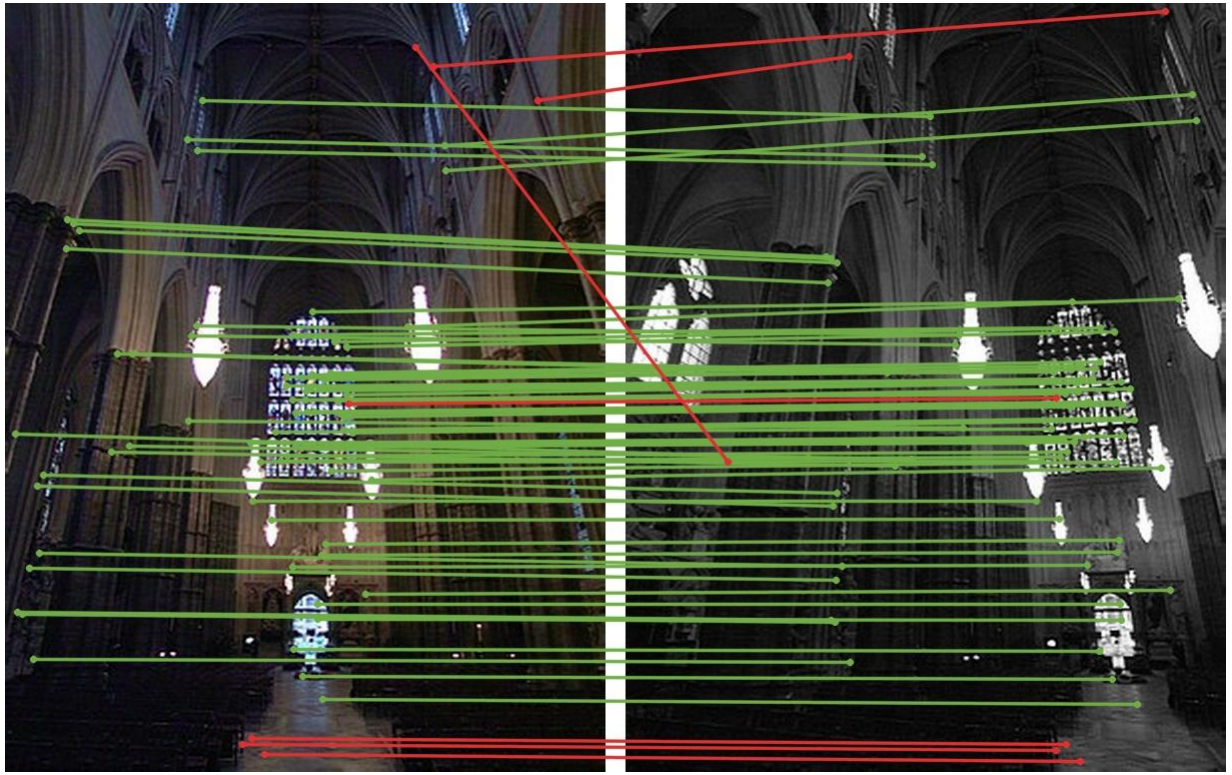
rotace + měřítko → 4D akumulátor (x, y, s, α)

Registrace obrazů a slepování panoramat

Aplikace odhadu homografie

Slepování panoramat: postup

Detekce klíčových bodů → Výpočet deskriptorů → Párování + poměrový test → Odhad homografie (RANSAC) → Transformace obrazu → Prolínání (blending)



- Prostřední snímek zvolíme jako referenční, ostatní transformujeme do jeho souřadnic
- Zde 1 001 z 1 079 korespondencí jsou inliery (RANSAC, e = 4 px)

inliery / **outliery**

obrázky: OpenCV (opencv_extra/testdata/stitching)

Slepování panoramat: transformace a prolínání



přímé překrytí: viditelný šev (jiná expozice)



prolínání vahami dle vzdálenosti od okraje (feathering)

obrázky: OpenCV (opencv_extra/testdata/stitching)

Slepování panoramat z více snímků



- Homografie platí jen pro rotaci kamery kolem optického středu nebo rovinnou scénu – jinak paralaxa („duchové“)
- Řetězení homografií → kumulace chyb → společná optimalizace (bundle adjustment)

- Široký záběr → projekce na válec nebo kouli
- Kompenzace expozice, hledání švů, vícepásmové prolínání
- OpenCV: `cv2.Stitcher_create().stitch(images)`

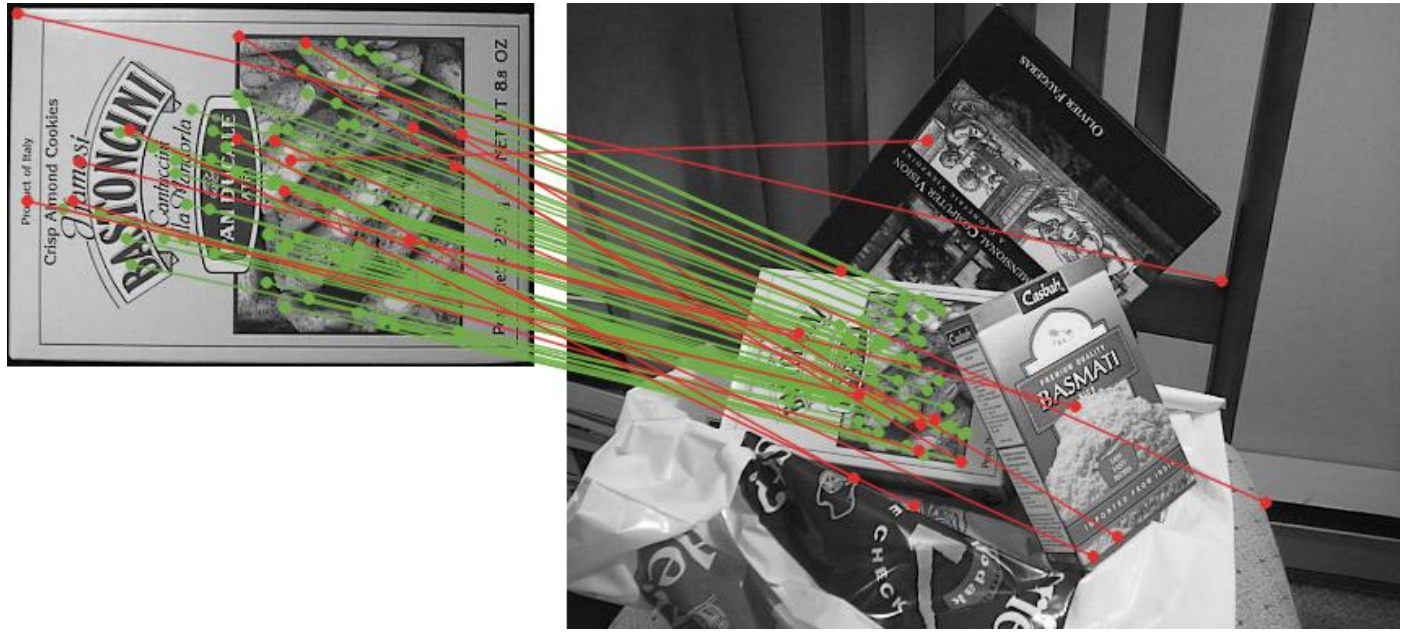
obrázky: OpenCV (opencv_extra/testdata/stitching), výsledek cv2.Stitcher

Detekce objektů pomocí lokálních korespondencí

Rovinné objekty: obaly, karty, doklady, obrazy, …

Detekce objektu: princip

1. **Model:** referenční snímek objektu → klíčové body + deskriptory (předpočítáme)
2. **Scéna:** klíčové body + deskriptory
3. Párování + poměrový test
4. RANSAC → homografie $\boldsymbol{A}$ a inliery
5. Rozhodnutí: objekt je nalezen, pokud je dost inlierů
6. Lokalizace: rohy modelu promítneme pomocí $\boldsymbol{A}$



94 korespondencí: **79 inlierů**, **15 outlierů**

obrázky: OpenCV (samples/data/box.png, box_in_scene.png)

Detekce objektu: lokalizace a zarovnání



model



lokalizace: obrys modelu ve scéně



zarovnání: scéna v souřadnicích modelu

$$\bar{\boldsymbol{x}}_i' = \boldsymbol{A} \cdot \bar{\boldsymbol{x}}_i, \qquad i = 1, \ldots, 4$$

$$I_{\text{rect}}(x,) = I\big(\pi(\boldsymbol{A} \cdot \bar{\boldsymbol{x}})\big)$$

funguje i při částečném zakrytí objektu

```
cv2.warpPerspective(scene, np.linalg.inv(A), (w, h))
```

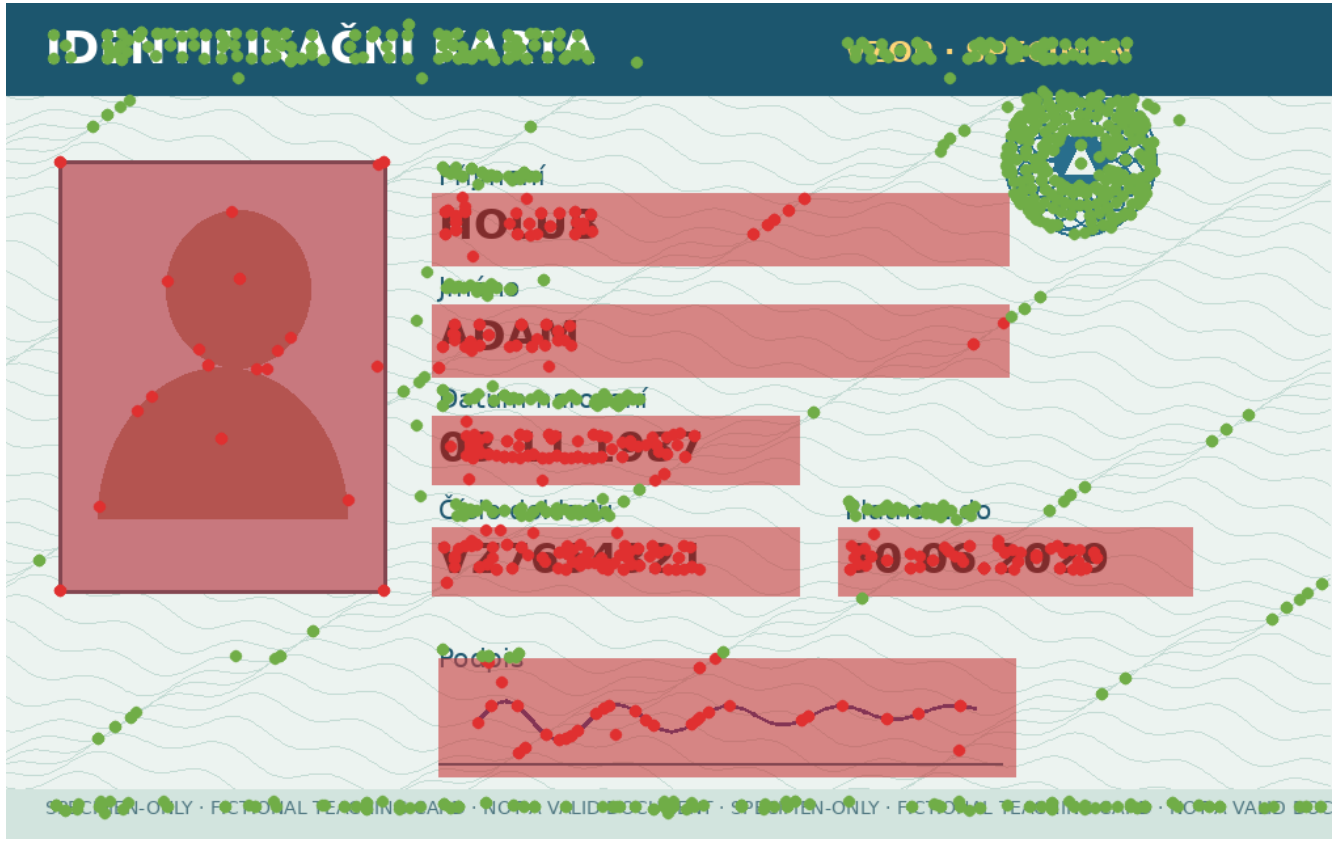
obrázky: OpenCV (samples/data/box.png, box_in_scene.png)

Kdy je objekt opravdu nalezen?

- Dostatečný počet inlierů (např. ≥ 10–15) a jejich poměr ke všem korespondencím
- Věrohodnost homografie
  - promítnutý obrys je konvexní čtyřúhelník
  - det levé horní 2×2 podmatice $\boldsymbol{A} > 0$ (bez zrcadlení)
  - rozumné měřítko a poměr stran, ne extrémní perspektiva (malé $a_{3,1}$, $a_{3,2}$)
- Více instancí: odebereme inliery a RANSAC zopakujeme, nebo hlasování (další slide)
- Mnoho modelů (databáze): rychlé párování – FLANN, kd-strom, vizuální slova



Příklad: čtení údajů z dokladu – šablona



● použité klíčové body ● maskované (proměnné) oblasti

- Šablona = referenční snímek dokladu v normované velikosti
  - např. 1012 × 638 px (formát ID-1: 85,60 × 53,98 mm, ≈ 300 DPI)
- Klíčové body bereme jen ze **statických částí**
  - osobní údaje, fotografie a podpis se liší → maska
- Pozice polí (ROI) definujeme jednou v souřadnicích šablony

```
sift.detectAndCompute(tpl, mask)
```

Příklad: čtení údajů z dokladu – detekce



330 korespondencí po poměrovém testu → **257 inlierů** (MAGSAC++), **73 outlierů**

fiktivní vzorový doklad vytvořený pro výuku; pozadí: scikit-image (data.coffee)

Příklad: čtení údajů z dokladu – zarovnání a OCR



detekce v obraze



zarovnaný doklad + oblasti polí

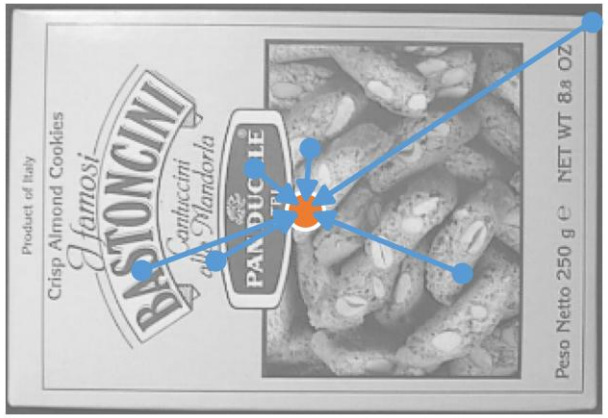
Pole	OCR výstup
Příjmení	BERAN
Jméno	MARTIN
Datum narození	12.05.1999
Číslo dokladu	VZ1234567
Platnost do	31.12.2031

- Po zarovnání leží každé pole vždy na stejném místě → výřez ROI → binarizace → OCR (Tesseract, EasyOCR, …)
- Kontrola výsledku: formát data, kontrolní číslice, slovník jmen

fiktivní vzorový doklad vytvořený pro výuku; OCR: Tesseract 5

Více instancí: hlasování lokálních příznaků

- Klíčový bod nese polohu, měřítko σ a orientaci α
- Jediná korespondence tak určí podobnostní transformaci → hlasuje pro polohu středu objektu





- **shluk hlasů** = objekt
- hlasujeme do hrubých binů (x, y, σ, α) → každé maximum = jedna instance
- poté ověření afinní transformací / homografií

D. Lowe: Distinctive image features from scale-invariant keypoints, IJCV 2004

Závěr

- Hierarchie transformací: euklidovská (3) ⊂ podobnostní (4) ⊂ afinní (6) ⊂ projektivní (8 stupňů volnosti)
- Homogenní souřadnice → transformace = násobení maticí, snadné řetězení a inverze
- Transformace obrazu: zpětné mapování + interpolace
- Odhad z korespondencí: lineární soustava a nejmenší čtverce, pro homografii DLT s normalizací
- Chybné korespondence → robustní odhad: RANSAC a jeho varianty, LMedS, Houghova transformace
- Aplikace: registrace a slepování panoramat, detekce a zarovnání rovinných objektů

